UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
CENTRO DE TECNOLOGIA
CURSO DE ENGENHARIA DE COMPUTAÇÃO

GABRIEL BARROS LINS LELIS DE OLIVEIRA

DESENVOLVIMENTO DE UM SISTEMA MULTI-AGENTE BASEADO EM INTELIGÊNCIAS ARTIFICIAIS GENERATIVAS PARA AVALIAÇÃO DE QUALIDADE EM ATENDIMENTO AO CLIENTE

NATAL-RN
2025

Gabriel Barros Lins Lelis de Oliveira

Desenvolvimento de um sistema multi-agente baseado em inteligências artificiais generativas para avaliação de qualidade em atendimento ao cliente

Trabalho de Conclusão de Curso na modalidade Monografia, submetido como parte dos requisitos necessários para conclusão do curso de Engenharia de Computação pela Universidade Federal do Rio Grande do Norte

Orientador: Prof. Dr. Ivanovitch Medeiros Dantas da Silva

Natal-RN
2025

Universidade Federal do Rio Grande do Norte - UFRN
Sistema de Bibliotecas - SISBI
Catalogação de Publicação na Fonte. UFRN - Biblioteca Central Zila Mamede

Oliveira, Gabriel Barros Lins Lelis de.
Desenvolvimento de um sistema multi-agente baseado em inteligências artificiais generativas para avaliação de qualidade em atendimento ao cliente / Gabriel Barros Lins Lelis de Oliveira. - 2025.
92f.: il.

Monografia (Graduação) - Universidade Federal do Rio Grande do Norte, Centro de Tecnologia, Engenharia de Computação, Natal, 2025.
Orientação: Prof. Dr. Ivanovitch Medeiros Dantas da Silva.

1. Inteligência artificial - Monografia. 2. Sistemas Multi-agente - Monografia. 3. Atendimento ao Cliente - Monografia. 4. Grandes Modelos de Linguagem - Monografia. 5. Processamento de Linguagem Natural - Monografia. I. Silva, Ivanovitch Medeiros Dantas da. II. Título.

RN/UF/BCZM CDU 004

Elaborado por Raimundo Muniz de Oliveira - CRB-15/429

Gabriel Barros Lins Lelis de Oliveira

Desenvolvimento de um sistema multi-agente baseado em inteligências artificiais generativas para avaliação de qualidade em atendimento ao cliente

Trabalho de Conclusão de Curso na modalidade Monografia, submetido como parte dos requisitos necessários para conclusão do curso de Engenharia de Computação pela Universidade Federal do Rio Grande do Norte

Aprovado em 20 de Janeiro de 2025:

Prof. Dr. Ivanovitch Medeiros Dantas da Silva – Orientador

UFRN

Prof. Dr. Eduardo de Lucena Falcão – Examinador interno

UFRN

Prof. Dr. Carlos Manuel Dias Viegas – Examinador interno

UFRN

Natal-RN

2025

Dedico este trabalho a Deus que me ajudou até aqui e a minha mãe que sempre me apoiou.

AGRADECIMENTOS

Agradeço primeiramente a Deus por essa oportunidade, pois sem Ele eu não teria chegado até aqui. À minha mãe, que sempre esteve ao meu lado com amor e apoio incondicional, e pelos sábios puxões de orelha que me mantiveram no caminho certo, minha eterna gratidão e amor. Aos meus pastores, meus pais na fé, por sua orientação e exemplo de retidão, muito obrigado. À minha avó, que mesmo na velhice nunca deixou de me apoiar com seu jeito amável, carinhoso e cheio de alegria, amo muito a senhora.

Agradeço de forma especial aos meus amigos, que foram um pilar essencial durante toda essa jornada. Claudiano Silva, Victor Gomes e José Rogério Silva, vocês não apenas me apoiaram, mas também estiveram ao meu lado em muitas madrugadas, compartilhando desafios, motivação e companheirismo. Cada palavra de incentivo e cada momento ao lado de vocês fizeram toda a diferença para que eu conseguisse finalizar este trabalho. Sou imensamente grato por terem acreditado em mim e por toda a amizade que sempre demonstraram. Obrigado por tudo!

Agradeço imensamente ao professor Ivanovitch Silva por aceitar o desafio de me orientar, mesmo com o tempo tão curto para concluirmos este trabalho. Sua paciência, atenção e dedicação foram fundamentais para que este projeto se tornasse realidade. Além disso, sou grato por todo o conhecimento que tive a oportunidade de aprender com ele ao longo da minha jornada acadêmica em Engenharia de Computação, o que certamente marcou minha formação. Estendo também minha gratidão à banca, composta pelos professores Eduardo Falcão e Carlos Viegas, que, mesmo com um prazo apertado, aceitaram contribuir com este trabalho. Muito obrigado a todos!

Agradeço a Universidade Federal do Rio Grande do Norte, foi e tem sido um ambiente de muita aprendizagem e crescimento para mim

Agora sigo em frente para uma nova etapa, que Jesus possa guiar os meus passos nessa nova jornada que está por vir.

RESUMO

Desenvolvimento de um sistema multi-agente baseado em inteligências artificiais generativas para avaliação de qualidade em atendimento ao cliente

Este trabalho apresenta o desenvolvimento e validação de um sistema multi-agente baseado em Grandes Modelos de Linguagem (LLMs) para avaliação de qualidade em atendimento ao cliente, visando superar as limitações dos métodos tradicionais de monitoramento. O sistema implementa uma arquitetura inovadora composta por cinco agentes especializados: Supervisor, Monitor de Qualidade, Operador, Juiz e Analista de Relatórios, cada um responsável por aspectos específicos da avaliação. A metodologia empregou o framework CrewAI para desenvolvimento do sistema multi-agente, utilizando o modelo GPT-4o-mini como base, e implementou uma interface web em Streamlit para interação com usuários. A validação do sistema foi realizada através de testes com um conjunto de dados real de uma empresa do setor de energia, comparando seu desempenho com avaliações humanas especializadas e outros modelos de linguagem. Os resultados demonstraram uma concordância entre 90% a 100% com avaliações humanas, significativamente superior aos 50% alcançados por abordagens baseadas em modelos isolados. O sistema manteve um tempo médio consistente de 6 minutos por análise, representando uma redução de até 52% no tempo necessário comparado ao monitoramento tradicional. A solução também apresentou viabilidade econômica excepcional, com redução de 95,4% no custo por análise, mantendo alta qualidade nas avaliações. A qualidade dos relatórios gerados foi validada por avaliadores independentes, obtendo pontuação média de 32,5/35. O sistema desenvolvido estabelece um novo paradigma para avaliação de qualidade em atendimento ao cliente, combinando eficiência operacional, viabilidade econômica e consistência nas análises, permitindo que monitores de qualidade foquem em atividades estratégicas de maior valor agregado.

Palavras-chave: Inteligência Artificial. Sistemas Multi-agente. Atendimento ao Cliente. Avaliação de Qualidade. Grandes Modelos de Linguagem. Processamento de Linguagem Natural.

ABSTRACT

Development of a multi-agent system based on generative artificial intelligence for quality assessment in customer service

This work presents the development and validation of a multi-agent system based on Large Language Models (LLMs) for quality assessment in customer service, aiming to overcome the limitations of traditional monitoring methods. The system implements an innovative architecture composed of five specialized agents: Supervisor, Quality Monitor, Operator, Judge, and Reporting Analyst, each responsible for specific aspects of the evaluation. The methodology employed the CrewAI framework for multi-agent system development, using the GPT-4o-mini model as a base, and implemented a web interface in Streamlit for user interaction. The system validation was performed through tests with a real dataset from an energy sector company, comparing its performance with specialized human evaluations and other language models. The results showed 90% to 100% agreement with human evaluations, significantly higher than the 50% achieved by approaches based on isolated models. The system maintained a consistent average time of 6 minutes per analysis, representing a reduction of up to 52% in the time required compared to traditional monitoring. The solution also demonstrated exceptional economic viability, with a 95.4% reduction in cost per analysis while maintaining high quality in evaluations. The quality of generated reports was validated by independent evaluators, obtaining an average score of 32.5/35. The developed system establishes a new paradigm for quality assessment in customer service, combining operational efficiency, economic viability, and consistency in analyses, allowing quality monitors to focus on higher value-added strategic activities.

Keywords: Artificial Intelligence. Multi-agent Systems. Customer Service. Quality Assessment. Large Language Models. Natural Language Processing.

LISTA DE ILUSTRAÇÕES

FIGURA		PÁGINA
1	**Arquitetura genérica de um sistema multi-agente baseado em LLMs**	36
2	**Arquitetura do sistema multi-agente para avaliação de qualidade em atendimento ao cliente.**	44
3	**Interface web do sistema Customer Service Quality Monitor desenvolvida em Streamlit**	48
4	**Fluxograma de interação do usuário com o sistema Customer Service Quality Monitor**	50
5	**Comparação do tempo necessário para análise de um atendimento de 5 minutos entre IA e humano**	63
6	**Análise comparativa do tempo necessário para avaliação de atendimentos entre o sistema LLM-MAS e monitor humano**	64
7	**Análise comparativa de conformidade entre os sistemas de avaliação, demonstrando o desempenho do sistema multi-agente (LLM-MAS), GPT e avaliação humana (HUM) para cada uma das 10 diretrizes de qualidade**	66
8	**Análise comparativa dos custos por relatório entre diferentes opções de avaliação**	69

LISTA DE TABELAS

TABELA		PÁGINA
1	Análise comparativa dos custos por relatório entre diferentes opções de avaliação	68

LISTA DE ABREVIATURAS E SIGLAS

Sigla	Significado
API	Application Programming Interface
BPC	Bits Per Character
BPT	Bits Per Token
BPW	Bits Per Word
CSAT	Customer Satisfaction Score
FCR	First Call Resolution
GDPR	General Data Protection Regulation
IA	Inteligência Artificial
JSON	JavaScript Object Notation
KV	Key-Value
LGPD	Lei Geral de Proteção de Dados
LLM	Large Language Model (Modelo de Linguagem Grande)
LLM-MAS	LLM-based Multi-Agent System (Sistema Multi-Agente baseado em LLM)
LoRA	Low-Rank Adaptation
MMLU	Massive Multitask Language Understanding
NPS	Net Promoter Score
PLN	Processamento de Linguagem Natural
QA	Quality Assurance (Garantia de Qualidade)
SMA	Sistema Multi-Agente
SVG	Scalable Vector Graphics
TI	Tecnologia da Informação
TMA	Tempo Médio de Atendimento
UI	User Interface (Interface do Usuário)
YAML	YAML Ain't Markup Language

SUMÁRIO

1 – INTRODUÇÃO.....15
1.1 - CONTEXTUALIZAÇÃO..... 15
1.2 – MOTIVAÇÃO.....17
1.3 – OBJETIVOS..... 19
1.3.1 – OBJETIVO GERAL..... 19
1.3.2 – OBJETIVOS ESPECÍFICOS.....19
2 – FUNDAMENTAÇÃO TEÓRICA.....21
2.1 – ATENDIMENTO AO CLIENTE E GARANTIA DE QUALIDADE..... 21
2.1.1 – MÉTRICAS TRADICIONAIS DE QUALIDADE..... 21
2.1.2 – DESAFIOS NA AVALIAÇÃO DE QUALIDADE..... 22
2.2 – INTELIGÊNCIA ARTIFICIAL GENERATIVA.....22
2.2.1 – MODELOS DE LINGUAGEM DE LARGA ESCALA (LLMs)..... 23
2.2.2 – ENGENHARIA DE PROMPT..... 31
2.3 – SISTEMAS MULTI-AGENTES BASEADOS EM LLMS.....34
2.3.1 – ARQUITETURA E COMPONENTES FUNDAMENTAIS.....35
2.3.2 – INTEGRAÇÃO E FUNCIONAMENTO DO SISTEMA.....36
2.3.3 – MECANISMOS DE COMUNICAÇÃO E COLABORAÇÃO.....37
2.3.4 – ASPECTOS DE IMPLEMENTAÇÃO E OTIMIZAÇÃO..... 37
2.3.5 – APLICAÇÃO E DESAFIOS..... 38
3 – METODOLOGIA..... 39
3.1 – VISÃO GERAL DO SISTEMA..... 39
3.2 – ARQUITETURA PROPOSTA..... 41
3.2.1 – DEFINIÇÃO DOS AGENTES.....41
3.2.2 – PAPÉIS E RESPONSABILIDADES.....42
3.2.3 – FLUXO DE TRABALHO..... 42
3.3 – IMPLEMENTAÇÃO..... 44
3.3.1 – CONFIGURAÇÃO DOS AGENTES.....45
3.3.2 – DESENVOLVIMENTO DA INTERFACE WEB..... 48
3.3.3 – SISTEMA DE FEEDBACK..... 52
3.4 – FERRAMENTAS E TECNOLOGIAS..... 54
3.5 – CONSIDERAÇÕES FINAIS.....57
4 – RESULTADOS E DISCUSSÃO.....57
4.1 - AMBIENTE DE TESTES..... 57
4.1.1 - CONJUNTO DE DADOS..... 58
4.1.2 - MÉTRICAS DE AVALIAÇÃO..... 60
4.2 - RESULTADOS DA AVALIAÇÃO DE DESEMPENHO..... 61
4.2.1 - PERFORMANCE TEMPORAL..... 61
4.2.2 - AVALIAÇÃO DE COERÊNCIA DAS ANÁLISES..... 65
4.2.3 - ANÁLISE COMPARATIVA DE CUSTOS.....67

4.2.4 - QUALIDADE DOS RELATÓRIOS GERADOS..... 70
4.3 - DISCUSSÃO DOS RESULTADOS.....72
4.4 - AMEAÇAS À VALIDADE.....74
4.4.1 - QUALIDADE DAS TRANSCRIÇÕES.....74
4.4.2 - VIÉS DO CONJUNTO DE DADOS.....75
4.4.3 - LIMITAÇÕES TECNOLÓGICAS.....75
4.4.4 - RESTRIÇÕES DE AVALIAÇÃO..... 75
4.4.5 - MITIGAÇÃO E TRABALHOS FUTUROS.....76
5 – CONCLUSÃO.....77
6 – REFERÊNCIAS.....79
APÊNDICE A.....83
SYSTEM PROMPT DOS MODELOS AVALIADORES DA QUALIDADE DOS RELATÓRIOS..... 83
AVALIAÇÃO DO CHATGPT O1..... 86
AVALIAÇÃO DO CLAUDE 3.5 SONNET..... 89

1 – INTRODUÇÃO

1.1 - CONTEXTUALIZAÇÃO

No contexto corporativo contemporâneo, o atendimento ao cliente representa um elemento crucial para o sucesso e a sustentabilidade das organizações. A qualidade deste atendimento não apenas influencia diretamente a satisfação e retenção dos clientes, mas também impacta significativamente a reputação e o desempenho financeiro das empresas (DOLIKASHVILI; DAVITASHVILI, 2024).

Com a digitalização acelerada dos processos de negócio e o advento de múltiplos canais de comunicação após a pandemia de COVID-19 (2020-2021), o volume de interações entre empresas e clientes tem crescido exponencialmente. Esta expansão traz consigo desafios significativos para a gestão da qualidade do atendimento, principalmente considerando que os métodos tradicionais de avaliação, baseados em amostragens aleatórias e análises manuais, já não conseguem acompanhar a escala e a complexidade das interações modernas (JAUMOTTE et al., 2023).

O cenário atual de atendimento ao cliente é caracterizado por uma série de desafios interligados (VIRIMA et al., 2019):

1. Volume e Complexidade:
    - Crescimento exponencial no número de interações diárias
    - Diversificação dos canais de atendimento (chat, voz, email, redes sociais)
    - Necessidade de consistência na qualidade através de diferentes plataformas
2. Expectativas dos Consumidores:
    - Demanda por respostas rápidas e precisas
    - Expectativa de personalização no atendimento
    - Necessidade de resolução efetiva já no primeiro contato
3. Gestão de Qualidade:
    - Dificuldade em manter padrões consistentes de avaliação

- Limitações dos métodos tradicionais de amostragem
- Subjetividade nas avaliações manuais

Paralelamente a estes desafios, observamos uma evolução significativa no campo da Inteligência Artificial, particularmente com o surgimento dos Grandes Modelos de Linguagem (LLMs) e frameworks especializados para desenvolvimento de sistemas multi-agentes. Estas tecnologias têm demonstrado capacidade notável em compreender e processar linguagem natural, oferecendo novas possibilidades para automatizar e aprimorar processos que anteriormente dependiam exclusivamente de intervenção humana (HARSHA et al., 2024).

A emergência de frameworks como o CrewAI representa um avanço particular neste contexto, possibilitando a criação de sistemas que podem simular equipes especializadas, cada agente com funções específicas e complementares. Esta abordagem multi-agente se alinha de forma natural com as necessidades de avaliação de qualidade em atendimento ao cliente, onde diferentes aspectos precisam ser analisados de maneira sistemática e coordenada (CREWAI, 2024).

No Brasil, o setor de atendimento ao cliente movimenta uma parcela significativa da economia, empregando milhões de pessoas e sendo fundamental para a operação de empresas de diversos setores (FARIAS, 2024). A necessidade de ferramentas mais eficientes para gestão e avaliação da qualidade é particularmente aguda no contexto nacional, onde o volume de atendimentos é expressivo e os recursos para supervisão de qualidade são frequentemente limitados (SCHEMES; MOVIDESK, 2021).

Este cenário complexo e desafiador cria uma oportunidade única para a aplicação de tecnologias avançadas de IA na solução de problemas práticos e relevantes. A intersecção entre as necessidades do setor de atendimento ao cliente e as capacidades emergentes da IA generativa abre caminho para o desenvolvimento de soluções inovadoras que podem transformar fundamentalmente a maneira como a qualidade do atendimento é avaliada e gerenciada.

1.2 – MOTIVAÇÃO

Este trabalho nasceu da percepção de um problema real: os métodos que usamos hoje para avaliar a qualidade do atendimento ao cliente não são mais suficientes para lidar com a demanda. As empresas tem crescido e aumentado cada vez mais os atendimentos aos clientes, tornando uma tarefa praticamente impossível analisar todas as interações usando apenas avaliações manuais e amostras aleatórias.

Quando se avalia apenas uma pequena parte dos atendimentos, perde-se a chance de identificar problemas que se repetem e se torna difícil melhorar o processo como um todo. As empresas acabam tomando decisões baseadas em dados que representam uma fração muito pequena da realidade, e acabam não tendo significância estatística, o que pode levar a conclusões equivocadas sobre a qualidade do serviço prestado. Outro ponto importante é que diferentes avaliadores podem interpretar a mesma situação de formas diferentes, gerando inconsistências nas análises e prejudicando a confiabilidade dos resultados. Isso acontece porque cada pessoa tem sua própria forma de entender e classificar a qualidade de um atendimento, mesmo quando existem critérios predefinidos. Em algumas situações, o mesmo atendimento pode receber avaliações completamente diferentes dependendo de quem está analisando, o que torna ainda mais complexo o processo de identificar padrões e estabelecer medidas corretivas eficientes.

Por outro lado, vivemos um momento interessante na área de tecnologia, já que os avanços que temos visto em inteligência artificial, especialmente no processamento de linguagem natural e na análise de contexto, abrem novas possibilidades para lidar com esses desafios. Hoje já é possível desenvolver sistemas que não só automatizam o processo de avaliação, mas também trazem percepções mais profundas sobre a qualidade do atendimento. A capacidade desses sistemas de analisar grandes volumes de dados de forma consistente e identificar padrões que seriam difíceis de perceber manualmente representam um salto significativo na forma como podemos gerenciar a qualidade do atendimento ao cliente. Além disso, essas tecnologias podem ajudar a reduzir o viés humano nas avaliações, proporcionando análises mais objetivas e padronizadas.

Temos à disposição frameworks específicos para criar sistemas inteligentes, além de tecnologias já bem estabelecidas para processamento de dados e desenvolvimento web. Todo esse conjunto permite se ter uma base sólida para criar

soluções que podem mudar completamente a forma como se avalia e gerencia a qualidade do atendimento ao cliente.

1.3 – OBJETIVOS

1.3.1 – OBJETIVO GERAL

Desenvolver e validar um sistema integrado para avaliação de qualidade em atendimento ao cliente que seja capaz de realizar análises abrangentes, consistentes e escaláveis, proporcionando recomendações práticas para a melhoria contínua do serviço e superando as limitações dos métodos tradicionais de avaliação.

1.3.2 – OBJETIVOS ESPECÍFICOS

O desenvolvimento deste sistema busca atender a objetivos específicos que se complementam para criar uma solução completa e eficaz. Primeiramente, visa-se implementar uma arquitetura modular que permita a análise coordenada de diferentes aspectos do atendimento, desde a avaliação inicial até a geração de recomendações práticas. Esta estrutura deve ser capaz de processar e avaliar interações em diferentes idiomas, adaptando-se às necessidades de organizações multinacionais.

Em segundo lugar, busca-se desenvolver uma interface intuitiva e acessível que facilite a interação dos usuários com o sistema, permitindo o upload de transcrições, a visualização de resultados e a coleta de feedback. A usabilidade é um aspecto crítico para garantir a adoção efetiva da solução em ambientes corporativos.

O terceiro objetivo específico concentra-se na implementação de um sistema robusto de gestão de dados que permita não apenas o armazenamento seguro das informações, mas também o acompanhamento longitudinal da qualidade do atendimento. Este aspecto é fundamental para identificar tendências e avaliar a efetividade de iniciativas de melhoria ao longo do tempo.

Por fim, pretende-se estabelecer um framework abrangente de avaliação que considere múltiplos aspectos do atendimento, incluindo competências técnicas, habilidades de comunicação e eficiência na resolução de problemas. Este framework deve ser validado através de comparações com avaliações humanas e otimizado com base no feedback dos usuários.

A consecução destes objetivos resultará em uma ferramenta que não apenas automatiza o processo de avaliação de qualidade, mas também proporciona insights

mais profundos e acionáveis para a melhoria contínua do atendimento ao cliente. O sistema proposto representa uma evolução significativa em relação aos métodos tradicionais, oferecendo uma solução escalável e adaptável às necessidades modernas de gestão de qualidade em serviços de atendimento.

2 – FUNDAMENTAÇÃO TEÓRICA

2.1 – ATENDIMENTO AO CLIENTE E GARANTIA DE QUALIDADE

O cenário contemporâneo do atendimento ao cliente tem evoluído significativamente, impulsionado tanto pelas transformações tecnológicas quanto pelas crescentes expectativas dos consumidores. Em um mercado onde aproximadamente 81% dos consumidores estão dispostos a gastar mais para uma melhor experiência do cliente, com 9% dispostos a aumentar seus gastos em mais de 50% (CAPGEMINI, 2017), a qualidade do atendimento tornou-se um diferencial competitivo crucial.

2.1.1 – MÉTRICAS TRADICIONAIS DE QUALIDADE

A avaliação da qualidade no atendimento ao cliente tradicionalmente se baseia em um conjunto estabelecido de métricas quantitativas e qualitativas. O Tempo Médio de Atendimento (TMA) e o *First Call Resolution* (FCR) emergiram como indicadores fundamentais da eficiência operacional, enquanto métricas como o *Net Promoter Score* (NPS) e o *Customer Satisfaction Score* (CSAT) fornecem insights valiosos sobre a percepção do cliente.

Entretanto, essas métricas convencionais frequentemente apresentam limitações significativas. Por exemplo, o TMA, embora facilmente mensurável, pode incentivar comportamentos contraproducentes quando utilizado isoladamente, como a priorização da velocidade em detrimento da qualidade da resolução.

O *Quality Assurance Score* (QA Score), por sua vez, busca uma avaliação mais holística, incorporando múltiplos aspectos do atendimento como empatia, resolução efetiva e aderência aos procedimentos. No entanto, sua aplicação tradicional, baseada em amostragem manual, frequentemente resulta em análises limitadas e potencialmente enviesadas.

2.1.2 – DESAFIOS NA AVALIAÇÃO DE QUALIDADE

Os desafios contemporâneos na avaliação de qualidade do atendimento ao cliente são multifacetados e crescentemente complexos. O volume exponencial de interações através de múltiplos canais tem tornado praticamente impossível a análise manual abrangente. Em um ambiente onde uma única empresa pode gerenciar milhares de interações diárias, a amostragem tradicional de cerca de 2% das interações não mais oferece uma visão representativa da qualidade do serviço (ZENDESK, 2024).

A consistência na avaliação representa outro desafio significativo. Diferentes avaliadores podem interpretar os mesmos critérios de maneiras distintas, levando a inconsistências nas avaliações e, consequentemente, em feedbacks potencialmente contraditórios para os agentes de atendimento. Este problema é particularmente agudo em organizações multinacionais, onde diferenças culturais e linguísticas podem adicionar camadas adicionais de complexidade ao processo de avaliação.

O equilíbrio entre análises em tempo real e retrospectivas também emerge como um desafio crítico. Enquanto o feedback imediato pode ser crucial para correção de problemas urgentes, análises mais aprofundadas e longitudinais são essenciais para identificação de padrões e tendências. A capacidade de realizar ambos os tipos de análise de forma eficiente tem se mostrado um objetivo difícil de alcançar através de métodos tradicionais.

A multiplicidade de canais de atendimento, incluindo voz, chat, email, redes sociais e mensagens instantâneas, adiciona uma camada adicional de complexidade. Cada canal possui suas próprias peculiaridades e requer critérios de avaliação específicos, tornando ainda mais desafiadora a tarefa de manter consistência na avaliação da qualidade através de diferentes modalidades de atendimento.

2.2 – INTELIGÊNCIA ARTIFICIAL GENERATIVA

A Inteligência Artificial Generativa surge como um campo que busca não apenas classificar ou prever resultados a partir de dados existentes, mas também criar novos conteúdos, como textos, imagens ou até mesmo modelos em três dimensões. Essa capacidade de gerar informações inéditas tem atraído grande interesse de pesquisadores e do mercado, principalmente pelo potencial de revolucionar processos de automação e

suporte a decisões. No contexto do atendimento ao cliente, a IA Generativa oferece a possibilidade de analisar grandes volumes de dados, sintetizar relatórios em tempo real e produzir feedbacks detalhados sem necessidade de intervenção humana a todo instante. Essa abordagem contrasta com métodos tradicionais que dependem unicamente de dados históricos para avaliar qualidade de serviço, pois a IA Generativa, de maneira dinâmica, consegue moldar respostas às particularidades de cada interação.

Entretanto, o desenvolvimento e a aplicação de modelos generativos ainda enfrentam desafios importantes. Há questões éticas relacionadas à geração de informações potencialmente enganosas ou enviesadas, assim como preocupações com privacidade, uma vez que esses modelos podem necessitar de grandes quantidades de dados sensíveis para entregar resultados mais relevantes. Além disso, a criação de conteúdo original que seja de fato coerente e contextualmente útil exige constantes refinamentos no treinamento das redes neurais e na curadoria dos dados de entrada (MÜLLER, 2023). Do ponto de vista empresarial, outro aspecto crítico consiste na integração dessas soluções aos fluxos de trabalho já estabelecidos nas organizações, exigindo adequações nos sistemas de TI, bem como a capacitação de equipes para interpretação dos resultados gerados.

Quando aplicada a cenários de suporte ao cliente, a IA Generativa pode auxiliar tanto na automatização de partes do atendimento quanto na análise de métricas avançadas de qualidade, propondo melhorias contínuas. No entanto, deve-se ter cautela na adoção de tais tecnologias, pois a mera substituição de métodos tradicionais não garante elevação efetiva na satisfação do usuário final (DESMARAIS, 2022). É fundamental alinhar a aplicação de técnicas generativas a práticas de garantia de qualidade já discutidas anteriormente, considerando a complexidade das interações humanas e o papel central que a empatia e a personalização exercem sobre a experiência do cliente.

2.2.1 – MODELOS DE LINGUAGEM DE LARGA ESCALA (LLMs)

A evolução da Inteligência Artificial (IA) tem testemunhado avanços significativos nas últimas décadas, com os Modelos de Linguagem de Larga Escala (Large Language Models - LLMs) emergindo como uma das inovações mais transformadoras no campo do Processamento de Linguagem Natural (PLN). Estes modelos representam um salto qualitativo na forma como as máquinas compreendem e

geram linguagem humana, oferecendo possibilidades sem precedentes para aplicações em diversos domínios, incluindo sistemas multiagentes para avaliação de qualidade em atendimento ao cliente (DEEKSITH, 2024).

A fundamentação teórica dos LLMs está enraizada em décadas de pesquisa em PLN e aprendizado de máquina. Um marco fundamental nesta evolução foi a introdução do mecanismo de atenção por Bahdanau em 2014, durante seu estágio na Universidade de Montreal sob orientação do Prof. Yoshua Bengio. Esta inovação permitiu que os modelos focassem em partes relevantes das sequências de entrada, melhorando significativamente o desempenho em tarefas de tradução automática (BAHDANAU; CHO; BENGIO, 2015).

Arquitetura e Funcionamento

A arquitetura Transformer, introduzida em 2017, revolucionou o campo do PLN ao estabelecer um novo paradigma para o processamento de sequências. (Vaswani et al., 2017) Esta arquitetura se distingue por sua capacidade de processar informações em paralelo e capturar dependências de longo alcance no texto, superando limitações de arquiteturas recorrentes anteriores.

O mecanismo de autoatenção, componente central dos Transformers, opera através de um processo sofisticado que permite ao modelo avaliar a relevância de cada elemento em relação aos demais. Este processo utiliza três componentes principais: vetores de consulta (Query), chave (Key) e valor (Value), que trabalham em conjunto para determinar a importância relativa de diferentes partes do texto. (ZHENG et al., 2024)

O processamento em um LLM ocorre em várias camadas, cada uma contribuindo para uma compreensão mais profunda do texto:

1. Tokenização: O texto é dividido em unidades menores (tokens), que podem ser palavras, subpalavras ou caracteres.
2. Embeddings: Cada token é convertido em um vetor numérico que representa seu significado no espaço multidimensional.
3. Camadas de Atenção: Múltiplas camadas de autoatenção processam as relações entre tokens.
4. Feed-Forward Networks: Redes neurais processam as representações resultantes.

Os LLMs modernos empregam uma técnica conhecida como atenção multihead, que permite ao modelo focar simultaneamente em diferentes aspectos do texto. Esta capacidade é crucial para a compreensão de informações linguísticas e contextuais. (ZHENG et al., 2024)

Aprendizado e Adaptação

O processo de treinamento dos LLMs envolve duas fases principais: pré-treinamento e fine-tuning. Durante o pré-treinamento, o modelo é exposto a vastos volumes de texto não rotulado, desenvolvendo uma compreensão geral da linguagem (MIN et al., 2023).

O fine-tuning, por sua vez, adapta o modelo para tarefas específicas, como análise de sentimento ou geração de respostas em atendimento ao cliente. Esta fase utiliza conjuntos de dados menores e mais focados, permitindo que o modelo aprenda padrões específicos do domínio de aplicação (YUN; JAE EUI SOHN; SUNGHYON KYEONG, 2023).

Fundamentos Probabilísticos e Representação do Conhecimento

Os LLMs fundamentam-se em princípios probabilísticos sofisticados para modelar linguagem natural. O modelo opera prevendo a probabilidade da próxima palavra em uma sequência, dado o contexto anterior. Esta abordagem probabilística permite que o modelo capture não apenas padrões sintáticos, mas também relações semânticas complexas. (SCHOLTEN; GÜNNEMANN; SCHWINN, 2024).

A representação do conhecimento nos LLMs ocorre através de *word embeddings*, que mapeiam palavras para um espaço vetorial de alta dimensão, uma estrutura matemática onde cada palavra é representada por um vetor com muitas dimensões, permitindo capturar relações complexas entre palavras. Nesse espaço, relações semânticas são preservadas, de forma que palavras semanticamente similares estão mais próximas umas das outras. Esta técnica, popularizada inicialmente pelo Word2Vec, evoluiu significativamente com o advento de *embeddings* contextuais, que consideram o contexto específico em que cada palavra aparece (SMITH, 2020).

Métricas de Avaliação e Teoria da Informação

A avaliação do desempenho dos LLMs incorpora conceitos fundamentais da teoria da informação. A perplexidade, uma métrica crucial, mede a capacidade do modelo de prever dados não vistos anteriormente. Matematicamente, a perplexidade está intimamente relacionada à entropia, onde valores mais baixos indicam melhor desempenho preditivo. (HUYEN, 2019)

Diferentes formas de entropia são utilizadas dependendo do método de tokenização do modelo:

- Bits por palavra (BPW)
- Bits por caractere (BPC)
- Bits por token (BPT) para modelos que empregam tokenização em subpalavras

Arquitetura de Atenção em Profundidade

O mecanismo de atenção, elemento central dos LLMs modernos, pode ser descrito matematicamente através da fórmula:

$$Attention(Q, K, V) = softmax(\frac{Q \cdot K^{-1}}{\sqrt{dK}}) \cdot V$$

onde Q, K, e V representam as matrizes de Query, Key e Value respectivamente, e dK é a dimensionalidade dos vetores de chave.

A atenção multihead expande este conceito ao permitir que o modelo mantenha múltiplas representações de atenção em paralelo. Cada "cabeça" de atenção pode se especializar em diferentes aspectos do texto, como relações gramaticais, semânticas ou temáticas. (VUCKOVIC; BARATIN; COMBES, 2020)

Técnicas de Otimização e Treinamento

As técnicas de otimização são cruciais para o treinamento eficiente de LLMs, especialmente devido à sua complexidade e escala. A destilação de modelos permite transferir conhecimento de arquiteturas maiores para menores, diminuindo

significativamente os custos computacionais enquanto mantém desempenho competitivo (HINTON; VINYALS; DEAN, 2015).

A quantização se destaca como uma abordagem essencial para reduzir a precisão de pesos e ativações, otimizando tanto a memória quanto o desempenho computacional. Estudos recentes mostram reduções de até 68% no tamanho do modelo, mantendo a performance dentro de 6% do modelo original (HASAN, 2024). Além disso, técnicas avançadas como a quantização de 4 bits têm alcançado degradações de acurácia inferiores a 0,5% (WANG et al., 2024).

A LoRA (Low-Rank Adaptation) vem ganhando destaque ao introduzir matrizes de decomposição treináveis em cada camada do Transformer, reduzindo significativamente os parâmetros treináveis e mantendo alta eficiência de fine-tuning (HU et al., 2021). Avanços como o LoRA+ têm demonstrado melhorias de 1-2% na performance e aceleração de até 2x no treinamento, graças ao ajuste refinado das taxas de aprendizado das matrizes adaptadoras (HAYOU; GHOSH; YU, 2024). Outras inovações, como o QA-LoRA, integram quantização durante o fine-tuning, proporcionando reduções adicionais no uso de memória e no tempo de processamento (XU et al., 2023).

Arquiteturas Específicas e Inovações

Diferentes arquiteturas de LLMs foram desenvolvidas para atender a necessidades específicas:

- BERT: Destaca-se pela compreensão bidirecional do contexto, permitindo que o modelo analise as palavras em relação às que estão antes e depois em uma frase. Essa abordagem é particularmente eficaz para tarefas como reconhecimento de entidades nomeadas, análise de sentimentos e perguntas e respostas.
- GPT: Focado na geração de texto, utiliza um mecanismo de atenção unidirecional que prevê a próxima palavra com base no contexto anterior. Esse modelo é amplamente usado em aplicações que requerem geração de texto.
- T5: Apresenta uma abordagem unificada para resolver tarefas de linguagem natural, convertendo todas elas em problemas de texto-para-texto. Seja para tradução, resumo ou classificação.
- RoBERTa: Baseado no BERT, mas com otimizações no processo de treinamento. Entre as melhorias estão o uso de um maior volume de dados,

maior duração do treinamento e a remoção de técnicas como o *next sentence prediction*. Essas mudanças resultaram em um modelo que mantém a bidirecionalidade do BERT, mas com maior precisão em tarefas de classificação de texto e compreensão contextual.

- LLaMa: Desenvolvido pela Meta, o LLaMA é projetado para ser eficiente em termos de computação, permitindo que pesquisadores explorem modelos de linguagem com menor custo computacional. Ele utiliza a arquitetura Transformer otimizada para tarefas de geração e compreensão de linguagem. Apesar de ser semelhante ao GPT em sua abordagem autoregressiva unidirecional, o LLaMA foca em oferecer alto desempenho mesmo em configurações de menor escala, tornando-o adequado para aplicações que exigem eficiência em hardware menos poderoso, como análises de texto, chatbots e geração de texto em cenários específicos.

Cada arquitetura traz inovações específicas que contribuem para o campo como um todo (ZHAO et al., 2023).

Aplicações de LLMs em Sistemas Multiagentes para Avaliação de Qualidade

A aplicação dos fundamentos teóricos dos LLMs em sistemas multiagentes para avaliação de qualidade em atendimento ao cliente representa uma convergência significativa entre teoria e prática. Esta integração tem revolucionado a forma como as organizações abordam a análise e o aprimoramento do atendimento ao cliente, oferecendo possibilidades sem precedentes para automatização e melhoria dos processos de avaliação de qualidade. (HARSHA et al., 2024)

Integração com Sistemas Multiagentes

A sinergia entre sistemas multiagentes (SMA) e LLMs estabelece uma estrutura robusta para análise e avaliação de interações com clientes. Nesta arquitetura, múltiplos agentes especializados trabalham em conjunto, cada um aproveitando diferentes capacidades dos LLMs para realizar funções específicas. Esta distribuição de responsabilidades permite uma avaliação mais abrangente e precisa da qualidade do atendimento. Por exemplo, enquanto um agente pode se dedicar à análise de sentimento

nas interações, outro pode focar na avaliação da precisão técnica das informações fornecidas (GUO et al., 2024).

Processamento e Análise de Interações

A sofisticada capacidade dos LLMs em processar linguagem natural permite uma análise profunda das interações entre cliente e atendente. Esta análise ocorre em diversos níveis complementares, começando pela compreensão contextual completa da conversa, onde o sistema identifica nuances e intenções subjacentes que frequentemente passam despercebidas por métricas tradicionais.

A avaliação de qualidade semântica representa outro aspecto crucial deste processamento, onde o modelo não se limita a verificar a precisão técnica das respostas, mas também avalia sua adequação semântica e pragmática ao contexto específico de cada cliente. Esta capacidade é particularmente valiosa em situações onde a mesma informação precisa ser comunicada de maneiras diferentes dependendo do perfil do cliente e da natureza da interação.

Além disso, os LLMs demonstram notável eficácia na identificação de padrões recorrentes em interações, facilitando a detecção precoce de áreas problemáticas e oportunidades de melhoria no processo de atendimento. Esta capacidade de análise preditiva permite que organizações ajustem proativamente suas estratégias de atendimento, em vez de reagir a problemas já estabelecidos (BROWN et al., 2020).

Mecanismos de Avaliação Automatizada

A integração de LLMs permite uma evolução significativa nas métricas utilizadas para avaliação de qualidade. Além das métricas tradicionais, como tempo de resposta e taxa de resolução, os LLMs possibilitam análises mais matizadas da qualidade, como a adequação contextual e a relevância da comunicação. Ferramentas como o EvalLM demonstram como critérios subjetivos definidos por usuários podem ser avaliados iterativamente, utilizando explicações detalhadas para embasar a interpretação de resultados e guiar refinamentos no design de prompts e nos critérios de avaliação (KIM et al., 2023)

Adaptação e Personalização em Contextos Organizacionais

Uma das características mais notáveis do uso de LLMs em sistemas multiagentes é sua extraordinária capacidade de adaptação a diferentes contextos organizacionais. Através de técnicas refinadas de fine-tuning e prompt engineering, os modelos podem ser cuidadosamente ajustados para atender às necessidades específicas de cada organização. Esta adaptabilidade se manifesta na capacidade de avaliar aspectos particulares da qualidade do atendimento, considerando não apenas diretrizes e políticas organizacionais específicas, mas também os detalhes próprios de diferentes setores e tipos de interação (CHEN et al., 2024).

A personalização do sistema vai além da simples configuração de parâmetros. Envolve um processo sofisticado de compreensão do contexto organizacional, onde o modelo aprende a reconhecer e valorizar elementos específicos que definem a qualidade do atendimento em cada ambiente. Por exemplo, em um ambiente de suporte técnico, o sistema pode ser ajustado para dar maior peso à precisão técnica das respostas, enquanto em um contexto de atendimento ao cliente de varejo de luxo, aspectos como empatia e personalização do atendimento podem receber maior ênfase (RANI et al., 2024).

Desafios de Implementação e Considerações Práticas

A implementação destes sistemas apresenta desafios significativos que requerem atenção cuidadosa. Um dos mais críticos é a questão da latência e desempenho em tempo real. A complexidade computacional dos LLMs pode introduzir atrasos significativos no processo de avaliação, exigindo estratégias sofisticadas de otimização de desempenho. Técnicas de quantização de modelo e paralelização eficiente de processos têm se mostrado fundamentais para superar estas limitações (HANSEN-PALMUS et al., 2024).

Privacidade e Segurança de Dados

A privacidade e segurança de dados representam desafios cruciais no desenvolvimento de sistemas baseados em IA. O processamento de informações sensíveis de clientes exige protocolos robustos de segurança e técnicas avançadas de anonimização. Conforme discutido por BOPPINITI (2023), a proteção da privacidade

não apenas é uma exigência legal estabelecida por regulamentações como LGPD e GDPR, mas também um imperativo ético que deve ser incorporado na arquitetura do sistema desde sua concepção. Elementos como transparência nos processos de coleta e uso de dados, mitigação de riscos de reidentificação em dados anonimizados, e a adoção de abordagens de governança ética são fundamentais para garantir a confiança pública e a conformidade legal.

A questão do viés e equidade na avaliação merece atenção especial. Conforme discutido por BOPPINITI (2023), os LLMs podem inadvertidamente perpetuar ou amplificar vieses presentes nos dados de treinamento, o que pode levar a resultados injustos ou discriminatórios. Para mitigar esses riscos, é essencial implementar sistemas robustos de monitoramento e estratégias de redução de viés, como auditorias regulares de dados e modelos, além do uso de algoritmos projetados para equidade. A validação cruzada com avaliações humanas continua sendo uma prática importante, garantindo que as avaliações automatizadas sejam justas e precisas, alinhadas com princípios éticos e valores sociais.

2.2.2 – ENGENHARIA DE PROMPT

A engenharia de prompts representa uma disciplina fundamental no campo da Inteligência Artificial Generativa, especificamente no contexto dos Grandes Modelos de Linguagem (LLMs). Em sua essência, consiste no processo de formular instruções precisas para maximizar a eficácia das respostas geradas por estes modelos (SAHOO et al., 2024).

Fundamentos e Funcionamento

A engenharia de prompts fundamenta-se na compreensão de como os LLMs interpretam e processam instruções. Diferentemente da programação tradicional, onde comandos específicos resultam em comportamentos previsíveis, os LLMs requerem uma abordagem mais subjetiva. O processo envolve a formulação de instruções que guiam o modelo a compreender tanto o contexto quanto o objetivo desejado da interação (TÖRNBERG, 2023).

Um aspecto crucial do funcionamento da engenharia de prompts é o impacto direto que a estruturação das instruções tem na qualidade das respostas. Por exemplo, um prompt mal estruturado pode resultar em respostas imprecisas ou irrelevantes,

enquanto um prompt bem elaborado pode gerar respostas altamente precisas e contextualizadas (WHITE et al., 2023)

Técnicas Fundamentais

A engenharia de prompts engloba diversas técnicas especializadas, cada uma com propósitos e contextos específicos de aplicação:

- Chain-of-Thought (Cadeia de Pensamento)

Esta técnica revolucionou a forma como os LLMs abordam problemas complexos. Ao induzir o modelo a decompor seu raciocínio em etapas lógicas e sequenciais, obtém-se respostas mais precisas e verificáveis. (JASON ZHANSHUN WEI et al., 2022)

- Few-Shot Learning

A técnica consiste em fornecer alguns exemplos dentro do próprio prompt para guiar o modelo no tipo de resposta desejada. Esta abordagem é particularmente eficaz quando se busca um formato específico de resposta ou quando se trabalha em domínios especializados. (SCHULHOFF et al., 2024)

- Zero-Shot Prompting

Representa a capacidade do modelo de executar tarefas sem exemplos prévios, baseando-se apenas em instruções claras e diretas. Esta técnica é especialmente útil para tarefas mais simples ou quando o modelo já possui um bom entendimento do domínio. (WAN et al., 2023)

- Role Prompting

Envolve atribuir um papel ou perspectiva específica ao modelo, influenciando diretamente o estilo e a profundidade das respostas geradas. Esta técnica é

particularmente eficaz quando se busca respostas especializadas ou contextualizadas. (SCHULHOFF et al., 2024)

Limitações e Desafios

A engenharia de prompts, embora represente uma ferramenta poderosa na interação com LLMs, enfrenta limitações e desafios significativos que precisam ser compreendidos para sua aplicação efetiva. Abaixo discutiremos algumas dessas limitações.

Limitações Cognitivas

Os LLMs apresentam limitações cognitivas inerentes que persistem mesmo com a utilização de prompts altamente otimizados. O raciocínio matemático complexo, por exemplo, frequentemente representa um desafio significativo, com os modelos apresentando dificuldades em manter consistência em cálculos extensos ou operações matemáticas sofisticadas. A compreensão de contextos altamente especializados também pode ser problemática, especialmente quando o domínio requer conhecimento técnico profundo ou experiência específica que pode não estar adequadamente representada nos dados de treinamento.

Além disso, a manutenção de consistência em respostas longas também é um desafio significativo. Os modelos podem começar com um raciocínio coerente, mas gradualmente se desviar ou perder o foco ao longo de respostas extensas. Uma limitação particularmente relevante refere-se à incapacidade dos modelos de atualizar seu conhecimento além do período de treinamento, o que pode resultar em informações desatualizadas ou incompletas em determinados contextos. (HUANG; KEVIN CHEN-CHUAN CHANG, 2022).

Desafios de Implementação

A implementação prática da engenharia de prompts enfrenta desafios operacionais significativos que vão além das limitações cognitivas dos modelos. Um dos aspectos mais desafiadores é a variabilidade nas respostas: mesmo com prompts

idênticos, ou até pequenas modificações no texto, estrutura ou formatação, os modelos podem produzir respostas significativamente diferentes em diferentes momentos. Esta inconsistência representa um obstáculo particular em aplicações que requerem alta previsibilidade e consistência nos resultados. (SCHULHOFF et al., 2024)

A adaptação contínua dos prompts também emerge como um desafio significativo. À medida que os contextos de aplicação evoluem e novos requisitos emergem, os prompts precisam ser constantemente refinados e atualizados. Este processo iterativo demanda recursos consideráveis e expertise específica, tornando a manutenção de sistemas baseados em prompts um desafio operacional contínuo (RAVIPUDI et al., 2024).

O controle fino sobre as respostas também representa uma limitação significativa. Mesmo com prompts cuidadosamente elaborados, pode ser difícil garantir que o modelo mantenha consistentemente um determinado estilo, tom ou nível de detalhe nas respostas. Esta limitação se torna particularmente relevante em aplicações que exigem alta precisão e controle sobre o output gerado (VELÁSQUEZ; FRANCO; CADAVID, 2023).

A complexidade destes desafios aumenta significativamente em ambientes de produção, onde fatores como escalabilidade, performance e confiabilidade precisam ser considerados simultaneamente. A integração efetiva da engenharia de prompts em sistemas existentes requer um balanço cuidadoso entre estas diferentes dimensões, fazendo com que seja necessário uma abordagem sistemática e bem planejada para se obter bons resultados.

2.3 – SISTEMAS MULTI-AGENTES BASEADOS EM LLMS

Os Sistemas Multi-Agentes baseados em Modelos de Linguagem Grandes (LLM-MAS, do inglês LLM-based Multi-Agent Systems) representam uma inovação significativa na interseção entre inteligência artificial e sistemas distribuídos. Esta abordagem emerge como resposta à crescente necessidade de sistemas mais sofisticados e adaptativos, capazes de lidar com tarefas complexas que exigem não apenas processamento de linguagem natural, mas também colaboração e tomada de decisão distribuída.

Diferentemente dos sistemas multi-agentes tradicionais, os LLM-MAS aproveitam a capacidade excepcional dos grandes modelos de linguagem para compreender e gerar linguagem natural, permitindo interações mais naturais e contextualmente apropriadas entre os agentes e com os usuários humanos. Esta característica os tornam particularmente adequados para aplicações que exigem compreensão semântica profunda e capacidade de raciocínio complexo. (PARK et al., 2023)

2.3.1 – ARQUITETURA E COMPONENTES FUNDAMENTAIS

A arquitetura de um LLM-MAS é fundamentalmente composta por três elementos integrados que trabalham em harmonia para criar um sistema coeso e eficiente. No centro dessa arquitetura estão os agentes generativos, entidades autônomas potencializadas por modelos de linguagem grandes, cada um especializado em diferentes aspectos ou funções dentro do sistema.

O ambiente compartilhado serve como o espaço onde esses agentes interagem, estabelecendo as regras e protocolos de comunicação. Wang et al. (2024) destacam que este ambiente não é apenas um espaço passivo, mas uma estrutura dinâmica que influencia e é influenciada pelas ações dos agentes, mantendo o estado global do sistema e garantindo a consistência das interações.

Um aspecto crucial dessa arquitetura é o mecanismo de memória compartilhada, que permite aos agentes manter um histórico de interações e aprender com experiências passadas. Este componente é especialmente importante em aplicações que exigem continuidade e coerência nas interações ao longo do tempo, como no caso de sistemas de atendimento ao cliente ou análise de qualidade de serviços.

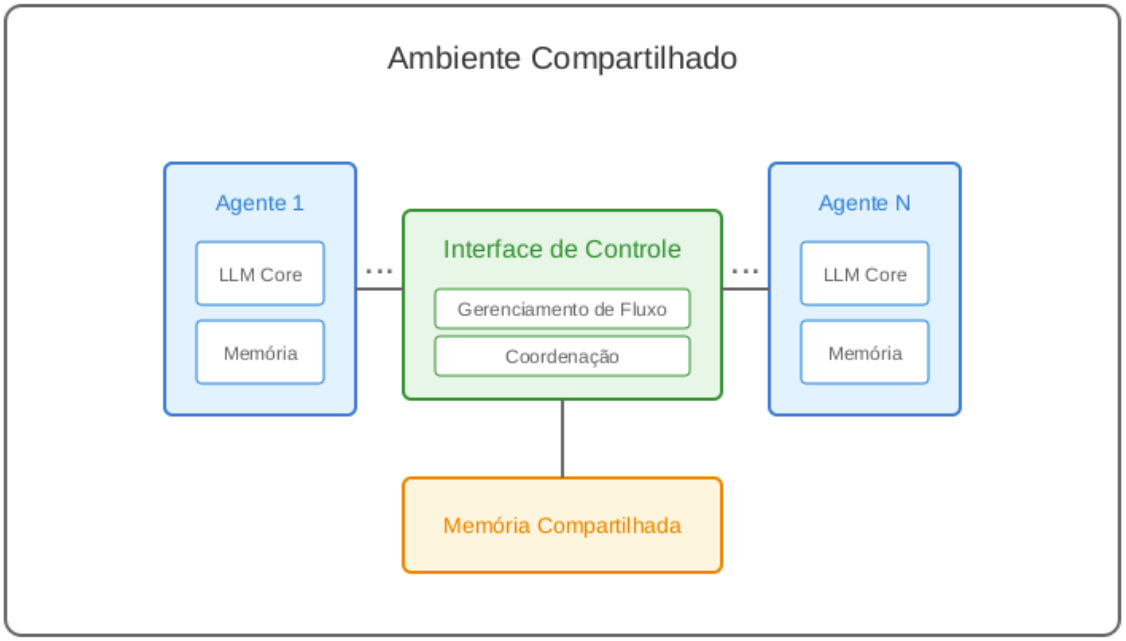

Figura 1 - Arquitetura genérica de um sistema multi-agente baseado em LLMs em um ambiente compartilhado. A arquitetura é composta por múltiplos agentes (Agente 1 até Agente N), cada um contendo seu próprio LLM Core e memória individual. Uma Interface de Controle central gerencia o fluxo e a coordenação entre os agentes, que se comunicam através de uma memória compartilhada comum a todos os agentes do sistema. **Fonte**: Elaborada pelo autor (2025).

2.3.2 – INTEGRAÇÃO E FUNCIONAMENTO DO SISTEMA

Como ilustrado no diagrama (figura 1), o funcionamento de um LLM-MAS é caracterizado por uma estrutura altamente integrada, onde cada componente desempenha um papel crucial no processo de tomada de decisão e interação. Os agentes generativos, representados nas extremidades do diagrama, são dotados de dois elementos essenciais: um núcleo LLM (LLM Core) e um sistema de memória individual.

O núcleo LLM de cada agente funciona como seu "cérebro", processando informações e gerando respostas contextuais. Este componente é responsável pela compreensão das entradas, raciocínio sobre o contexto e geração de saídas apropriadas. A memória individual, por sua vez, permite que cada agente mantenha seu próprio histórico de interações e aprendizados, contribuindo para uma maior consistência e personalização nas respostas.

A Interface de Controle, posicionada centralmente no diagrama, atua como um orquestrador do sistema. Através do Gerenciamento de Fluxo e da Coordenação, ela

assegura que as interações entre os agentes ocorram de maneira ordenada e eficiente. Sendo este componente peça fundamental para evitar conflitos e garantir a coerência das operações do sistema como um todo (HAN et al., 2024).

2.3.3 – MECANISMOS DE COMUNICAÇÃO E COLABORAÇÃO

Um aspecto distintivo dos LLM-MAS é sua capacidade de estabelecer comunicação sofisticada entre os agentes. O sistema utiliza protocolos de comunicação baseados em linguagem natural, permitindo que os agentes:

- Compartilhem informações e conhecimentos de forma contextualizada
- Coordenem ações para atingir objetivos comuns
- Negociem soluções em situações complexas
- Aprendam com as experiências e interações uns dos outros

A Memória Compartilhada, representada na base do diagrama, serve como um repositório central de conhecimento e experiências. Este componente permite que o sistema mantenha uma coerência global e aprenda continuamente com as interações passadas, melhorando progressivamente sua eficácia no tratamento de situações similares.

2.3.4 – ASPECTOS DE IMPLEMENTAÇÃO E OTIMIZAÇÃO

A implementação eficiente de um LLM-MAS requer consideração cuidadosa de diversos aspectos técnicos e práticos. Um dos desafios mais significativos é o gerenciamento de recursos computacionais, dado que cada agente opera com um modelo de linguagem grande como núcleo.

Para abordar esta questão, podem ser utilizadas técnicas como balanceamento dinâmico de carga entre os agentes, permitindo uma distribuição eficiente dos recursos computacionais disponíveis (HOCINE; ZITOUNI, 2023). A implementação de mecanismos de cache inteligente para armazenar e reutilizar respostas frequentes, reduzindo a necessidade de processamento redundante (LI et al., 2024). Além disso, é possível a utilização de técnicas de paralelização para maximizar o desempenho do sistema quando múltiplos agentes estão ativos simultaneamente.

2.3.5 – APLICAÇÃO E DESAFIOS

Os LLM-MAS têm demonstrado particular eficácia em diversos cenários de aplicação, especialmente em contextos que exigem interação complexa e tomada de decisão distribuída. No contexto específico de avaliação de qualidade em atendimento ao cliente, estes sistemas oferecem vantagens significativas:

1. Análise Multi-perspectiva: Diferentes agentes podem avaliar aspectos distintos da interação com o cliente, como tom da comunicação, precisão técnica e eficiência da resolução.
2. Processamento Paralelo: A capacidade de analisar simultaneamente múltiplas interações cliente-empresa, permitindo uma avaliação em larga escala.
3. Adaptabilidade: O sistema pode se adaptar a diferentes contextos e políticas de atendimento, mantendo consistência nos critérios de avaliação.

Porém, apesar dos avanços significativos, existem desafios importantes a serem considerados no desenvolvimento e implementação de LLM-MAS. Como por exemplo, garantir a consistência nas decisões entre diferentes agentes, manter a eficiência computacional em sistemas de larga escala, assegurar a privacidade e segurança das informações processadas, ou seja, para cenários com dados sensíveis é necessário usar modelos que rodem em ambientes fechados e sem conexão com internet para evitar possíveis vazamentos de dados, e ainda desenvolver mecanismos mais robustos de coordenação entre agentes

Entretanto, o saldo ainda é positivo, com a inclusão de abordagens promissoras no desenvolvimento destes sistemas, incluindo a incorporação de técnicas de aprendizado federado para melhorar a colaboração entre agentes e o desenvolvimento de arquiteturas mais eficientes para o processamento de linguagem natural distribuído.

3 – METODOLOGIA

3.1 – VISÃO GERAL DO SISTEMA

O sistema desenvolvido representa uma abordagem inovadora para a avaliação da qualidade no atendimento ao cliente, utilizando um conjunto coordenado de agentes de inteligência artificial generativa. Esta solução foi concebida para abordar as limitações dos métodos tradicionais de garantia de qualidade (QA), que frequentemente dependem de amostragem aleatória e análise manual limitada de interações com clientes.

Fundamentação do Sistema

O sistema fundamenta-se no conceito de uma equipe virtual de garantia de qualidade, implementada através do framework CrewAI. Esta abordagem simula uma estrutura departamental completa de QA, onde cada agente de IA assume um papel específico e especializado, similar aos papéis encontrados em equipes humanas de avaliação de qualidade.

Objetivos Principais

O sistema foi projetado com os seguintes objetivos fundamentais:

1. Automatização Inteligente: Implementar um processo automatizado de avaliação que mantém a profundidade e sutileza da análise humana.
2. Avaliação Sistemática: Estabelecer um método consistente e abrangente para avaliar as interações com clientes, baseado em diretrizes predefinidas.
3. Escalabilidade: Permitir a análise de um volume significativamente maior de interações em comparação com métodos tradicionais.
4. Feedback Estruturado: Gerar relatórios detalhados e acionáveis que possam ser utilizados para melhorias contínuas no serviço.

Características Fundamentais

O sistema apresenta as seguintes características essenciais:

1. Arquitetura Multi-Agente: Utilização de múltiplos agentes especializados, cada um com funções específicas no processo de avaliação.
2. Processamento de Linguagem Natural: Capacidade de analisar e compreender transcrições de interações em diferentes idiomas.
3. Interface Web Intuitiva: Uma interface de usuário desenvolvida em Streamlit que facilita a submissão e análise de interações.
4. Sistema de Feedback: Mecanismo integrado para coleta e armazenamento de feedback sobre as análises realizadas.

Diferencial Metodológico

O diferencial metodológico do sistema reside em sua abordagem distribuída e especializada para a avaliação de qualidade. Em vez de confiar em um único agente para realizar todas as tarefas de avaliação, o sistema implementa uma cadeia de análise onde cada agente contribui com sua expertise específica, resultando em uma avaliação mais robusta e confiável.

Esta abordagem multi-agente permite:

- Avaliação em Camadas: Múltiplas perspectivas sobre a mesma interação
- Resolução de Conflitos: Processo estruturado para resolver divergências nas avaliações
- Síntese Inteligente: Consolidação das diferentes análises em recomendações acionáveis

A visão geral do sistema estabelece as bases para uma compreensão mais detalhada de sua arquitetura e implementação, que serão exploradas nas seções subsequentes desta metodologia.

3.2 – ARQUITETURA PROPOSTA

A arquitetura do sistema foi concebida para simular uma estrutura departamental de garantia de qualidade, incorporando múltiplos agentes especializados que trabalham em conjunto para realizar avaliações abrangentes das interações com clientes. Esta abordagem inovadora busca superar as limitações dos métodos tradicionais de avaliação, oferecendo uma análise mais profunda e sistemática.

3.2.1 – DEFINIÇÃO DOS AGENTES

O sistema é fundamentado em uma estrutura hierárquica de cinco agentes especializados, cada um desempenhando um papel específico no processo de avaliação. No topo desta hierarquia encontra-se o Supervisor, responsável pela coordenação geral e garantia da qualidade do processo como um todo. Este agente atua como um gerente de qualidade experiente, supervisionando e orientando as atividades dos demais agentes.

O Monitor de Qualidade representa a primeira linha de análise no sistema. Sua função primordial é realizar uma avaliação minuciosa das interações com clientes, aplicando um conjunto predefinido de diretrizes e critérios de qualidade. Este agente foi desenvolvido para emular a expertise de um analista de qualidade sênior, capaz de identificar detalhes sutis na comunicação e possíveis desvios dos padrões estabelecidos.

O papel do Operador no sistema é particularmente interessante, pois ele atua como um especialista em contexto operacional. Este agente foi projetado para compreender e explicar as decisões tomadas durante as interações, considerando as complexidades e restrições do ambiente de atendimento ao cliente. Sua análise complementa a avaliação técnica do Monitor de Qualidade, adicionando uma camada de compreensão prática às situações analisadas.

Para situações onde surgem divergências nas avaliações, o sistema conta com o Juiz, um agente especialmente desenvolvido para mediar e resolver conflitos. Este componente do sistema aplica um conjunto de critérios objetivos para avaliar diferentes perspectivas e chegar a conclusões imparciais, mantendo a consistência e justiça no processo de avaliação.

Completando a equipe, o Analista de Relatórios atua como o consolidador final das análises. Este agente foi projetado para sintetizar as diversas avaliações e intuições

gerados pelos outros agentes, produzindo relatórios estruturados e recomendações práticas que podem ser facilmente compreendidas e implementadas pela equipe de atendimento.

3.2.2 – PAPÉIS E RESPONSABILIDADES

A estrutura de papéis e responsabilidades no sistema foi cuidadosamente projetada para garantir uma avaliação holística e eficaz das interações com clientes. Cada agente possui um conjunto específico de competências e atribuições que se complementam, formando um processo coeso de avaliação.

O Supervisor atua como o maestro do processo, garantindo que todas as avaliações sigam um padrão de qualidade consistente. Suas responsabilidades vão além da simples coordenação, incluindo a validação das análises produzidas e a garantia de que as recomendações geradas sejam práticas e implementáveis. Este agente foi desenvolvido com base em uma persona (system prompt) que tem décadas de experiência em gestão de qualidade, incorporando as melhores práticas do setor.

Na linha de frente da avaliação, o Monitor de Qualidade executa uma análise meticulosa das interações, aplicando um conjunto abrangente de critérios qualitativos. Este agente foi treinado para identificar tanto aspectos técnicos quanto elementos mais sutis da comunicação, como tom de voz, empatia e eficácia na resolução de problemas. Sua avaliação serve como base para todo o processo subsequente.

O Operador traz uma perspectiva única ao processo, fornecendo contexto operacional valioso para as situações analisadas. Este agente é capaz de considerar fatores como volume de atendimento, complexidade das solicitações e restrições sistêmicas que podem influenciar a qualidade do atendimento. Sua análise ajuda a equilibrar as expectativas ideais com as realidades práticas do ambiente de atendimento.

3.2.3 – FLUXO DE TRABALHO

O fluxo de trabalho do sistema foi estruturado para maximizar a eficiência e precisão das avaliações, seguindo uma sequência lógica que permite uma análise progressivamente mais profunda e refinada. O processo inicia-se com o recebimento da transcrição do atendimento e das diretrizes de qualidade aplicáveis, que são processadas inicialmente pelo Monitor de Qualidade.

Processo de Avaliação

O processo de avaliação segue uma abordagem em camadas, onde cada agente contribui com sua expertise específica. Após a análise inicial do Monitor de Qualidade, o Operador examina as observações e adiciona insights contextuais importantes. Em casos onde surgem divergências significativas, o Juiz é acionado para fornecer uma avaliação imparcial e resolver quaisquer conflitos de interpretação.

Geração de Relatórios e Feedback

A etapa final do processo envolve a consolidação de todas as análises pelo Analista de Relatórios, que transforma os insights coletados em um relatório estruturado e acionável. Este relatório não apenas identifica pontos fortes e áreas de melhoria, mas também fornece recomendações específicas para desenvolvimento profissional e aprimoramento do serviço.

Ciclo de Melhoria Contínua

Um aspecto importante do fluxo de trabalho é sua natureza cíclica, onde os resultados das avaliações alimentam um processo contínuo de aprendizado e aprimoramento. O sistema mantém um histórico das avaliações realizadas, permitindo a identificação de padrões e tendências ao longo do tempo, o que contribui para o refinamento constante das diretrizes e critérios de avaliação.

A arquitetura proposta (figura 2) representa uma evolução significativa nos métodos tradicionais de avaliação de qualidade em atendimento ao cliente, combinando a precisão e escalabilidade da inteligência artificial com a sutileza e profundidade típicas da análise humana. Esta abordagem inovadora não apenas permite uma avaliação mais abrangente e objetiva das interações com clientes, mas também fornece insights valiosos para o desenvolvimento contínuo das equipes de atendimento.

Como podemos observar, cada componente do sistema foi cuidadosamente projetado para contribuir com um aspecto específico do processo de avaliação, resultando em uma solução robusta e eficaz para os desafios modernos da gestão de qualidade em serviços de atendimento ao cliente.

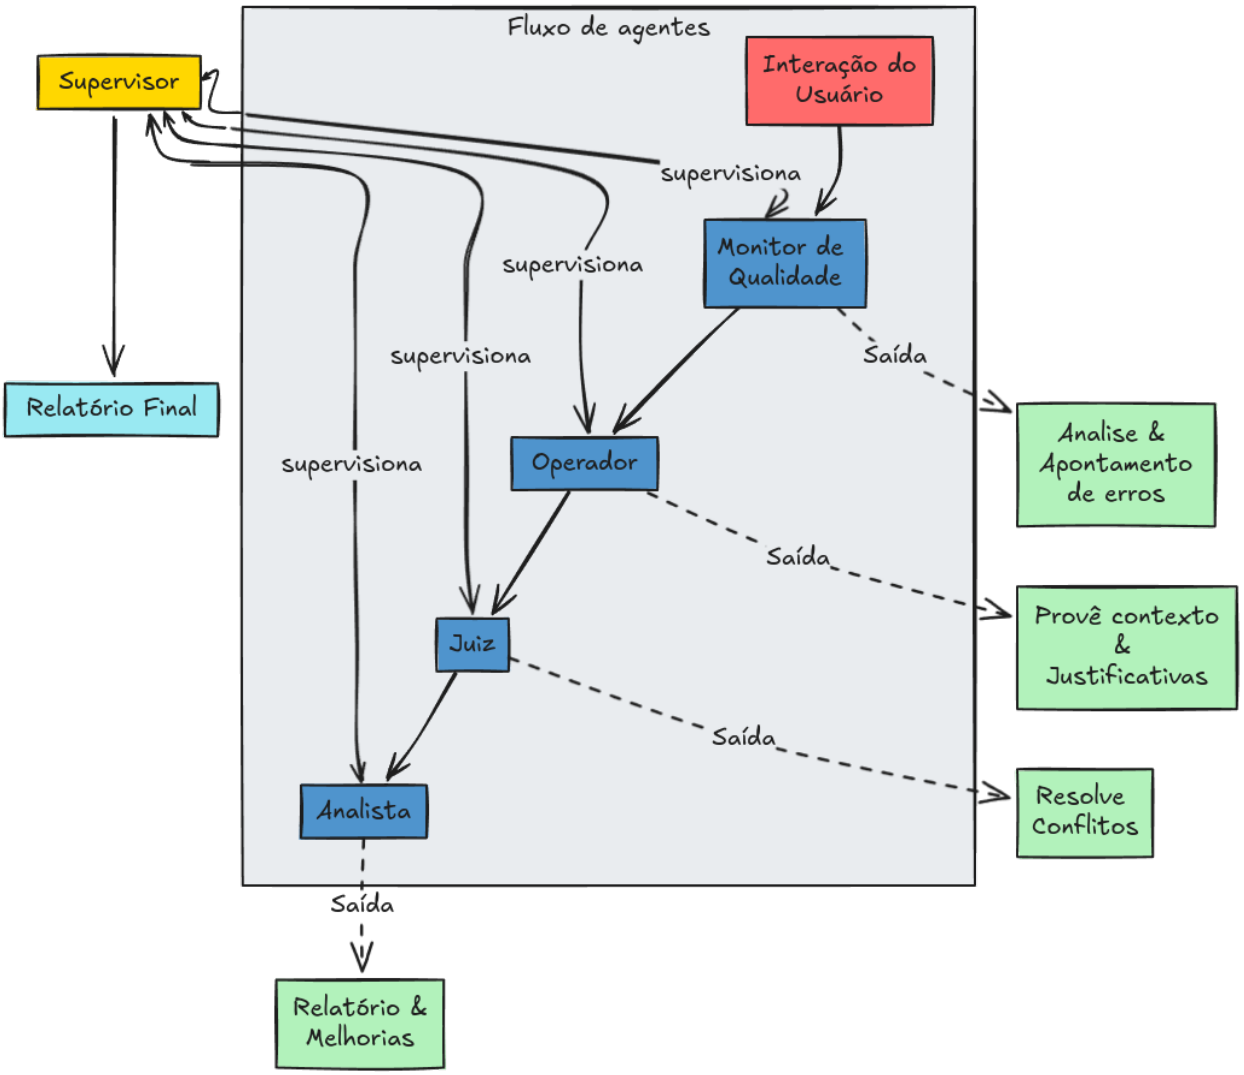

Figura 2 - Arquitetura do sistema multi-agente para avaliação de qualidade em atendimento ao cliente. O fluxo apresenta a hierarquia e interação entre os agentes especializados, onde o Supervisor coordena todo o processo de avaliação, supervisionando os demais agentes (Monitor de Qualidade, Operador, Juiz e Analista). Cada agente produz saídas específicas: o Monitor de Qualidade realiza análise e apontamento de erros, o Operador provê contexto e justificativas, o Juiz resolve conflitos, e o Analista gera relatórios e sugestões de melhorias. A interação do usuário ocorre inicialmente com o Monitor de Qualidade, e o processo culmina na geração de um relatório final pelo Supervisor. **Fonte**: Elaborado pelo autor (2024).

3.3 – IMPLEMENTAÇÃO

A implementação do sistema foi realizada de forma modular e escalável, priorizando a flexibilidade e a facilidade de manutenção. Esta seção detalha os aspectos técnicos e práticos da implementação, abordando a configuração dos agentes, o desenvolvimento da interface web e o sistema de feedback.

3.3.1 – CONFIGURAÇÃO DOS AGENTES

A configuração dos agentes foi implementada utilizando arquivos YAML, uma escolha que proporciona maior flexibilidade e manutenibilidade ao sistema. Esta abordagem permite que as características e comportamentos dos agentes sejam facilmente ajustados sem a necessidade de modificar o código-fonte.

Para cada agente do sistema, foram definidos três elementos fundamentais em sua configuração:

- O papel (role), que estabelece a função específica do agente no sistema;
- O objetivo (goal), que define claramente as metas e resultados esperados;
- E o backstory, que fornece contexto e experiência simulada para embasar as decisões do agente.

Por exemplo, a configuração do Supervisor inclui uma rica experiência em gestão de qualidade, com ênfase em análise de interações e desenvolvimento de equipes. Esta configuração permite que o agente tome decisões mais contextualizadas e relevantes durante o processo de avaliação.

Integração e Comunicação

O sistema utiliza o framework CrewAI para gerenciar a comunicação entre os agentes, permitindo uma colaboração eficiente e coordenada. A implementação inclui um sistema de mensagens assíncronas que facilita a troca de informações e análises entre os diferentes agentes, mantendo a coesão do processo de avaliação.

Estrutura de Configuração

A implementação utiliza uma estrutura hierárquica de configuração, onde cada agente possui seu próprio arquivo de configuração no diretório config/. Os arquivos agents.yaml e tasks.yaml são os principais componentes desta estrutura, definindo respectivamente as características dos agentes e suas tarefas específicas.

Processo de Integração

A integração entre os agentes é gerenciada através de um sistema de tarefas sequenciais, onde cada tarefa é definida com entradas e saídas específicas. Por exemplo, quando o Monitor de Qualidade completa sua análise inicial, os resultados são estruturados em um formato padronizado que serve como entrada para a análise do Operador.

O sistema implementa dois modelos principais para estruturar esta comunicação:

python

```python
class QualityModel(BaseModel):
    guideline: str
    compliance: bool
    evidence: str

class ConversationAnalysisModel(BaseModel):
    transcript: str
    guidelines: List[str]
```

Fluxo de Dados

O fluxo de dados entre os agentes segue um padrão bem definido:

1. O sistema recebe a transcrição do atendimento e as diretrizes de qualidade como entrada inicial
2. Estas informações são processadas através do `ConversationAnalysisModel`
3. Cada agente gera suas análises utilizando o `QualityModel`
4. Os resultados são passados sequencialmente entre os agentes

Gestão de Estado

A implementação utiliza um sistema de gestão de estado que mantém o contexto das análises através de todo o processo. Isto é particularmente importante quando o Juiz

precisa resolver conflitos, pois ele tem acesso a todas as análises e justificativas anteriores.

Tratamento de Idiomas

Um aspecto importante da implementação é o suporte multilíngue, implementado através de um dicionário de prompts específicos para cada idioma:

python

```
self.language_prompts = {
    'en': {
        'output_format': "Write the analysis in English",
        'style': "Use professional business English"
    },
    'pt': {
        'output_format': "Escreva a análise em português",
        'style': "Use português formal e profissional"
    },
    'es': {
        'output_format': "Escriba el análisis en español",
        'style': "Utilice español formal y profesional"
    }
}
```

Controle de Qualidade

O sistema implementa verificações de qualidade em cada etapa do processo. Por exemplo, antes de passar os resultados para o próximo agente, o sistema verifica:

- A completude das análises
- A consistência dos dados
- A conformidade com o formato esperado
- A presença de todas as evidências necessárias

Esta estrutura de implementação garante que cada agente possa trabalhar de forma independente, mantendo ao mesmo tempo uma coordenação eficiente com os

demais componentes do sistema. A flexibilidade da configuração via YAML permite que o sistema seja facilmente adaptado para diferentes contextos e necessidades de avaliação.

3.3.2 – DESENVOLVIMENTO DA INTERFACE WEB

O desenvolvimento da interface web foi realizado utilizando o framework Streamlit, escolhido por sua capacidade de criar interfaces interativas e responsivas com código Python puro. Esta escolha permitiu uma integração seamless com o backend do sistema e facilitou a criação de uma experiência de usuário intuitiva e eficiente.

Estrutura da Interface

A interface foi desenvolvida seguindo princípios de design centrado no usuário, com uma estrutura clara e organizada que facilita a navegação e utilização do sistema. O layout é dividido em duas áreas principais: uma barra lateral (sidebar) para configurações e informações gerais, e uma área principal para entrada de dados e visualização de resultados.

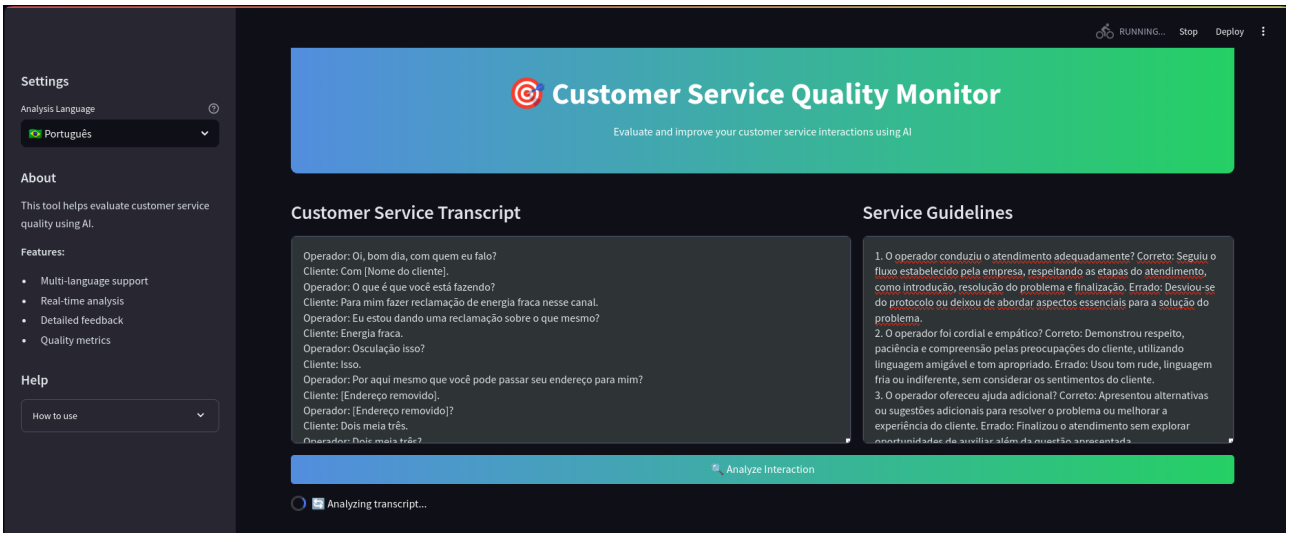

Figura 3 - Interface web do sistema Customer Service Quality Monitor desenvolvida em Streamlit. A interface apresenta uma barra lateral (à esquerda) com configurações de idioma e informações sobre o sistema, e uma área principal dividida em duas seções: à esquerda, um campo para inserção da transcrição do atendimento ao cliente, e à direita, um campo com as diretrizes de serviço que serão utilizadas na avaliação. A interface possui um gradiente visual do azul ao verde e oferece suporte multilíngue para a geração dos relatórios. **Fonte:** Elaborado pelo autor (2025).

Componentes Principais

A implementação da interface inclui diversos componentes essenciais. Na área principal, um campo de texto expansível permite a inserção das transcrições de atendimento, enquanto outro campo possibilita a personalização das diretrizes de avaliação. Esta abordagem oferece flexibilidade aos usuários para adaptar os critérios de avaliação conforme necessário.

Experiência do Usuário

O fluxo do usuário na aplicação foi cuidadosamente projetado para seguir uma sequência lógica de ações, começando com a configuração inicial e progredindo naturalmente até a geração e download dos relatórios de avaliação.

Ao acessar a interface, o usuário encontra uma tela dividida em duas áreas principais:

1. **Barra Lateral (Sidebar)**
   - ➔ Seleção de idioma com suporte para inglês, português e espanhol
   - ➔ Acesso rápido à documentação e ajuda
   - ➔ Configurações gerais do sistema
2. **Área Principal**
   - ➔ Campo para inserção da transcrição do atendimento
   - ➔ Editor de diretrizes de avaliação
   - ➔ Área de visualização de resultados
   - ➔ Opções de download de relatórios

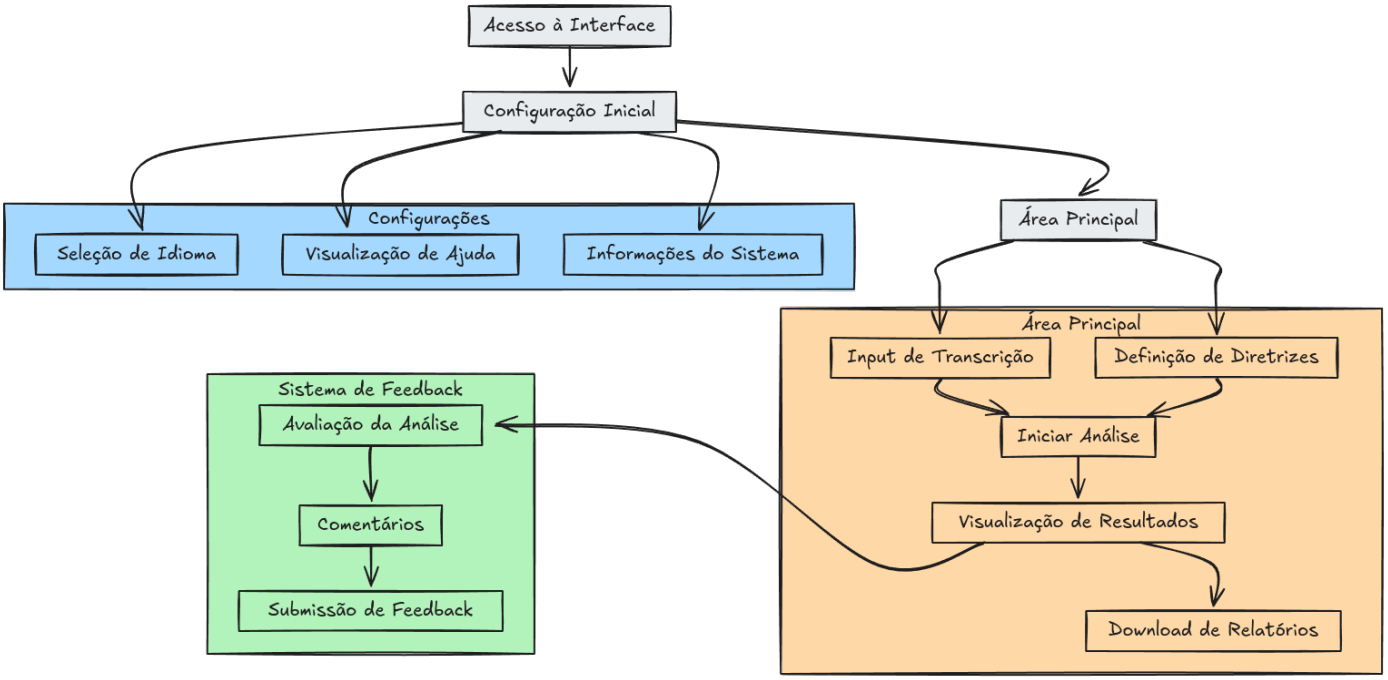

Figura 4 - Fluxograma de interação do usuário com o sistema Customer Service Quality Monitor. O diagrama ilustra o fluxo completo desde o acesso inicial até o feedback, dividido em três áreas principais: configurações (em azul) que inclui seleção de idioma, ajuda e informações do sistema; área principal de trabalho (em laranja) onde ocorre o input de transcrição, definição de diretrizes, análise e visualização de resultados; e sistema de feedback (em verde) que permite a avaliação da análise realizada, inclusão de comentários e submissão do feedback. **Fonte:** Elaborado pelo autor (2025).

Fluxo de Trabalho

O processo de avaliação segue uma sequência natural de etapas:

1. Configuração Inicial

O usuário primeiro seleciona o idioma desejado e pode consultar as informações de ajuda para entender melhor o sistema.

2. Entrada de Dados

Na área principal, o usuário insere a transcrição do atendimento a ser avaliado e pode personalizar as diretrizes de avaliação conforme necessário.

3. Processo de Análise

Ao iniciar a análise, o sistema exibe um indicador de progresso que mantém o usuário informado sobre o status do processamento. Durante esta fase, os agentes trabalham em sequência para realizar a avaliação completa.

4. Visualização de Resultados

Os resultados são apresentados em um formato estruturado e legível, com seções claras para cada aspecto da avaliação.

5. Geração de Relatórios

O usuário pode baixar os resultados em diferentes formatos:

- PDF para documentação formal
- DOCX para edição posterior
- Markdown para integração com outros sistemas

Personalização Visual

A interface implementa um sistema de estilos responsivo que se adapta a diferentes tamanhos de tela e dispositivos. Elementos visuais como gradientes, espaçamento e tipografia foram cuidadosamente escolhidos para criar uma experiência profissional e agradável

Suporte Multilíngue

Um aspecto importante da interface é o suporte a múltiplos idiomas, implementado através de um seletor na barra lateral que permite aos usuários escolher entre diferentes opções de idioma.

A tradução do conteúdo do relatório final é gerenciada de forma dinâmica, garantindo uma experiência consistente independentemente do idioma selecionado.

Gestão de Estado

A interface implementa um sistema robusto de gestão de estado utilizando o `st.session_state` do Streamlit, que permite manter informações importantes entre as interações do usuário:

python

```python
def initialize_session_state(self):
    if 'analysis_result' not in st.session_state:
        st.session_state.analysis_result = None
    if 'current_transcript' not in st.session_state:
        st.session_state.current_transcript = ""
```

Este design modular e intuitivo permite que os usuários se concentrem na tarefa de avaliação de qualidade, sem serem distraídos por complexidades técnicas ou interfaces confusas.

3.3.3 – SISTEMA DE FEEDBACK

O Sistema de Feedback foi implementado como uma componente essencial da solução, projetado para coletar avaliações sobre a precisão e utilidade das análises geradas pelo sistema. Esta funcionalidade não apenas permite a avaliação contínua do desempenho do sistema, mas também fornece dados valiosos para seu aprimoramento constante.

Estrutura do Feedback

O sistema coleta e armazena feedback em um formato JSON estruturado, incluindo múltiplas dimensões de avaliação:

python

```
feedback = {
    'timestamp': time.strftime('%Y-%m-%d %H:%M:%S'),
    'transcript': transcript,
    'guidelines': guidelines,
    'rating': rating,
    'feedback': feedback_text,
    'language': language,
    'analysis_result': analysis_result,
    'metadata': {
        'version': '1.0',
        'feedback_type': 'customer_service_quality',
        'timestamp_utc': time.strftime('%Y-%m-%dT%H:%M:%SZ',
time.gmtime())
    }
}
```

Processo de Coleta, Armazenamento e Organização

Após cada análise, o sistema apresenta uma interface intuitiva para coleta de feedback, que inclui:

1. Uma escala de avaliação de 1 a 5 estrelas para classificar a qualidade da análise
2. Um campo de texto para comentários qualitativos
3. Opções para identificar aspectos específicos da análise que foram particularmente úteis ou que precisam de melhorias

Os feedbacks são armazenados de forma organizada no sistema de arquivos, seguindo uma estrutura hierárquica que facilita sua posterior análise, com um mecanismo robusto de persistência que garante que nenhum feedback seja perdido, mesmo em casos de falhas do sistema.

Análise e Utilização do Feedback

Os dados coletados são utilizados de várias formas:

1. Monitoramento de Qualidade
    - Acompanhamento das avaliações médias ao longo do tempo
    - Identificação de padrões em análises bem ou mal avaliadas
    - Detecção de áreas específicas que necessitam de ajustes
2. Aprimoramento do Sistema
    - Os comentários qualitativos fornecem insights para melhorias
    - As avaliações quantitativas ajudam a medir o impacto de atualizações
    - Padrões de uso identificados auxiliam na otimização da interface
3. Documentação de Resultados
    - Geração de relatórios de desempenho
    - Histórico de melhorias baseadas em feedback
    - Métricas de satisfação do usuário

Este sistema de feedback fecha o ciclo de desenvolvimento contínuo da solução, permitindo que ela evolua constantemente com base nas necessidades reais dos usuários e na qualidade das análises produzidas.

3.4 – FERRAMENTAS E TECNOLOGIAS

O desenvolvimento do sistema envolveu a seleção criteriosa de ferramentas e tecnologias modernas, priorizando aquelas que oferecessem robustez, escalabilidade e facilidade de manutenção. A escolha de cada componente foi baseada em sua capacidade de atender aos requisitos específicos do projeto e de se integrar harmoniosamente com os demais elementos do sistema.

Framework Principal

O CrewAI foi selecionado como o framework central do projeto, oferecendo uma base sólida para o desenvolvimento de sistemas multi-agente. Sua escolha foi fundamentada em algumas características essenciais:

- Suporte nativo a arquiteturas multi-agente
- Sistema robusto de gestão de mensagens entre agentes
- Flexibilidade na definição de papéis e comportamentos

- Capacidade de integração com modelos de linguagem avançados, tanto locais como disponibilizados via API

Tecnologias de Frontend

Para o desenvolvimento da interface web, foram utilizadas as seguintes tecnologias:

- Streamlit

Framework escolhido para o desenvolvimento da interface web, oferecendo desenvolvimento rápido e eficiente de interfaces, componentes interativos prontos para uso, integração excelente com Python, suporte a diferentes formatos de visualização de dados, além da facilidade de deploy e curva de aprendizado mínima para programadores já habituados com Python.

- WeasyPrint, Python-Docx e Markdown

Bibliotecas utilizadas para a geração de relatórios em diferentes formatos:

python

```
# Exemplo de geração de PDF
HTML(string=template).write_pdf(output_path)
# Exemplo de geração de DOCX
doc = Document()
doc.add_heading('Análise de Qualidade', 0)
```

Processamento de Dados

Para o processamento e manipulação de dados, foram utilizadas diversas bibliotecas especializadas:

- Pandas: Utilizado para manipulação e análise de dados estruturados
- JSON: Para armazenamento e processamento de feedbacks e configurações
- YAML: Para gerenciamento de configurações dos agentes e tarefas

Integração e Deployment

O sistema foi desenvolvido com foco em uma arquitetura modular e facilmente implantável, utilizando Docker para containerização e garantia de consistência em

diferentes ambientes. Além disso está sendo usado Git para controle de versão e colaboração no desenvolvimento e por fim UV(uv) como gerenciador de dependências Python, escolhido por sua velocidade superior e eficiência em comparação com ferramentas tradicionais.

Estrutura de Arquivos

A organização do projeto segue uma estrutura clara e modular:

```
quality_monitoring/
├── src/
│   ├── quality_monitoring/
│   │   ├── app.py
│   │   ├── crew.py
│   │   ├── main.py
│   │   └── config/
│   │       ├── agents.yaml
│   │       └── tasks.yaml
├── feedback/
├── knowledge/
└── output/
```

Bibliotecas de Suporte

Outras bibliotecas importantes utilizadas no projeto incluem:

- OpenAI

Para integração com modelos de linguagem avançados, nesse cenário foi utilizado o GPT 4o Mini, para maximizar velocidade de resposta e minimizar custos.

- python-dotenv

Para gerenciamento seguro de variáveis de ambiente, assim evitando possíveis vazamentos de chaves de API.

Esta combinação de ferramentas e tecnologias permitiu o desenvolvimento de um sistema robusto e flexível, capaz de atender às necessidades complexas de avaliação de qualidade em atendimento ao cliente.

3.5 – CONSIDERAÇÕES FINAIS

Neste capítulo foi abordada a metodologia de desenvolvimento do sistema de avaliação de qualidade baseado em múltiplos agentes, que se dividiu em três principais aspectos: arquitetura, implementação e ferramentas utilizadas. Todas as etapas, desde a definição dos agentes até a criação do sistema de feedback, foram detalhadamente explicadas.

Evidenciou-se que, estruturando-se a relação entre os diferentes agentes especializados (Supervisor, Monitor de Qualidade, Operador, Juiz e Analista de Relatórios), a dinâmica de avaliação e o processo de feedback após a fase de arquitetura, torna-se viável a elaboração de um sistema robusto e escalável que integra múltiplos aspectos da avaliação de qualidade em atendimento ao cliente.

A metodologia apresentada demonstrou como a combinação de tecnologias modernas, como o framework CrewAI, Streamlit e UV, pode ser efetivamente utilizada para criar uma solução que aborda os desafios contemporâneos da avaliação de qualidade em serviços de atendimento.

No próximo capítulo, serão apresentados os resultados obtidos ao se aplicar esta metodologia em diferentes contextos de atendimento ao cliente, analisando tanto a eficácia do sistema quanto seu impacto na melhoria da qualidade do serviço prestado.

4 – RESULTADOS E DISCUSSÃO

4.1 - AMBIENTE DE TESTES

O processo de avaliação do sistema multi-agente para análise de qualidade em atendimento ao cliente foi conduzido de maneira sistemática e rigorosa, buscando garantir a confiabilidade e relevância dos resultados obtidos. Esta seção detalha o ambiente de testes utilizado, incluindo o conjunto de dados e as métricas de avaliação estabelecidas para mensurar o desempenho do sistema.

4.1.1 - CONJUNTO DE DADOS

Para a realização dos testes, foi utilizado um conjunto de dados privado proveniente de uma empresa do setor de energia, composto por 10 transcrições de atendimentos realizados em seu call center. A seleção deste conjunto específico de conversas foi realizada considerando a necessidade de abranger diferentes cenários e complexidades de atendimento, permitindo uma avaliação abrangente das capacidades do sistema.

Antes da utilização dos dados, foi aplicado um rigoroso processo de anonimização e descaracterização, visando preservar a confidencialidade das informações sensíveis. Este processo incluiu a remoção de dados pessoais identificáveis, como nomes, endereços e números de documentos, além da substituição de informações específicas da empresa por dados genéricos equivalentes. A metodologia de anonimização foi desenvolvida seguindo as melhores práticas de proteção de dados e privacidade, garantindo a integridade das análises enquanto mantém o sigilo necessário.

Os testes foram realizados utilizando uma interação real entre um cliente e um operador de uma empresa fornecedora de energia elétrica.

Para geração do relatório foram estabelecidos 10 diretrizes de serviço comumente utilizadas em monitorias de qualidade:

- O operador conduziu o atendimento adequadamente?
  Correto: Seguiu o fluxo estabelecido pela empresa, respeitando as etapas do atendimento, como introdução, resolução do problema e finalização. Errado: Desviou-se do protocolo ou deixou de abordar aspectos essenciais para a solução do problema.
- O operador foi cordial e empático?
  Correto: Demonstrou respeito, paciência e compreensão pelas preocupações do cliente, utilizando linguagem amigável e tom apropriado. Errado: Usou tom rude, linguagem fria ou indiferente, sem considerar os sentimentos do cliente.
- O operador ofereceu ajuda adicional?

Correto: Apresentou alternativas ou sugestões adicionais para resolver o problema ou melhorar a experiência do cliente. Errado: Finalizou o atendimento sem explorar oportunidades de auxiliar além da questão apresentada.

- O operador confirmou a satisfação do cliente?

  Correto: Perguntou se o cliente estava satisfeito com a solução apresentada ou se havia algo mais a ser tratado. Errado: Não verificou se o cliente estava satisfeito ou ignorou sinais de insatisfação.
- O operador denegriu a imagem do produto, da empresa ou do sistema?

  Correto: Evitou expressar opiniões negativas sobre a empresa, produtos ou serviços, mantendo uma postura profissional. Errado: Fez comentários depreciativos, assumindo culpa indevida ou culpando o sistema/produto.
- O operador fez comentários indesejados e/ou insultou o cliente?

  Correto: Manteve uma comunicação respeitosa, sem ofensas ou comentários inadequados. Errado: Proferiu ofensas diretas, indiretas ou comentários inadequados que possam ser interpretados como insultos.
- O operador finalizou o atendimento de forma adequada?

  Correto: Encerrou o atendimento confirmando a solução do problema, agradecendo e deixando o cliente à vontade para entrar em contato novamente. Errado: Finalizou abruptamente, sem verificar se o cliente precisava de mais suporte ou sem transmitir uma mensagem de encerramento claro.
- O operador realizou validação positiva de forma completa (confirmou dados do cliente)?

  Correto: Verificou todas as informações necessárias para validar a identidade do cliente, conforme as diretrizes da empresa. Errado: Omitiu ou realizou parcialmente a validação, comprometendo a segurança ou o processo.
- O operador sondou o cliente de forma assertiva para entender melhor a situação?

  Correto: Fez perguntas claras e objetivas para identificar a necessidade do cliente e o contexto do problema. Errado: Foi vago ou insistente, falhando em compreender o problema do cliente.
- O operador usou informações claras na resposta ao cliente?

  Correto: Apresentou informações precisas e fáceis de entender, sem jargões técnicos desnecessários. Errado: Usou linguagem confusa ou forneceu informações contraditórias ou incompletas.

Em conjunto ao relatório gerado pelo sistema multi-agente, a interação foi avaliada por duas pessoas e um llm-as-a-judge para estabelecer critérios de comparação entre a qualidade, confiabilidade e tempo de resposta.

4.1.2 - MÉTRICAS DE AVALIAÇÃO

Para avaliar o desempenho do sistema de forma abrangente, foram estabelecidas quatro métricas principais de avaliação:

Análise de Custo Operacional

A primeira métrica consistiu na avaliação comparativa dos custos associados à utilização de diferentes LLMs. Esta análise considerou não apenas o custo direto por token processado, mas também a relação custo-benefício considerando a qualidade das análises produzidas. Foi elaborada uma tabela comparativa detalhando os custos operacionais entre diferentes LLMs disponíveis no mercado, permitindo uma avaliação objetiva da viabilidade econômica do sistema.

Eficiência Temporal

A segunda métrica focou no tempo de processamento necessário para realizar as análises completas. Foram mensurados os tempos de execução em diferentes cenários, considerando variáveis como complexidade do atendimento, volume de texto e número de diretrizes avaliadas. Esta análise temporal foi fundamental para compreender a escalabilidade do sistema e sua aplicabilidade em ambientes de produção com diferentes demandas de volume.

Coerência das Análises

A terceira métrica envolveu uma avaliação comparativa da coerência das análises produzidas. Para isso, foi realizado um estudo comparativo triangulando três fontes de análise: o sistema desenvolvido, o ChatGPT 4o e avaliações realizadas por profissionais humanos experientes. Esta abordagem permitiu uma compreensão mais

profunda da capacidade do sistema em produzir análises que se aproximam do julgamento humano especializado.

Qualidade dos Relatórios

Por fim, a quarta métrica concentrou-se na avaliação da qualidade dos relatórios gerados pelo sistema. Para esta análise, foram utilizados dois modelos de linguagem de última geração como avaliadores independentes: o Claude 3.5 Sonnet (ANTHROPIC, 2024) da Anthropic e o GPT o1 (OPENAI, 2024) da OpenAI. Esta abordagem inovadora permitiu uma avaliação objetiva da clareza, completude e utilidade dos relatórios produzidos.

O estabelecimento destas métricas foi fundamental para garantir uma avaliação abrangente e objetiva do sistema, permitindo não apenas a validação de sua eficácia, mas também a identificação de pontos de melhoria e otimização. Os resultados detalhados obtidos através da aplicação destas métricas serão apresentados e discutidos nas seções subsequentes, fornecendo uma visão completa do desempenho do sistema em diferentes aspectos de sua operação.

4.2 - RESULTADOS DA AVALIAÇÃO DE DESEMPENHO

A avaliação de desempenho do sistema multi-agente para análise de qualidade em atendimento ao cliente revelou resultados significativos em termos de eficiência e produtividade. Os resultados obtidos demonstram o potencial transformador desta solução no contexto de monitoramento de qualidade em call centers, apresentando ganhos expressivos em diversos aspectos operacionais.

4.2.1 - PERFORMANCE TEMPORAL

Os testes realizados demonstraram uma notável consistência no tempo de processamento do sistema, com uma média de 6 minutos para a geração completa de um relatório de qualidade. Esta média se manteve estável, com variações entre 5 e 8 minutos, independentemente do tamanho ou complexidade da conversa analisada. Esta

característica distintiva pode ser atribuída à utilização do modelo GPT-4o Mini da OpenAI, que oferece um processamento otimizado e consistente.

A estabilidade temporal observada representa um diferencial significativo, especialmente quando comparada com implementações que utilizam modelos locais de linguagem. Em sistemas locais, o aumento no volume de dados tipicamente resulta em um incremento proporcional no tempo de processamento, devido à necessidade de maior alocação de recursos computacionais para cache de chaves-valor (KV-caching) e processamento. No entanto, a arquitetura escolhida para este sistema consegue manter um desempenho consistente independentemente dessas variáveis.

Análise Comparativa com Monitoramento Tradicional

A comparação com o processo tradicional de monitoramento humano revelou insights particularmente interessantes. No modelo convencional, monitores de qualidade necessitam em média de 2 a 2,5 vezes o tempo de duração da conversa para realizar uma análise completa. Este multiplicador temporal se deve à necessidade de escuta atenta, análise detalhada e documentação minuciosa de cada aspecto do atendimento. A figura 5 mostra um gráfico de barras que demonstra a diferença de tempo para a análise de um áudio de 5 minutos juntamente com sua transcrição entre o LLM-MAS desenvolvido e um monitor de QA. Nesse caso, apenas o monitor analisa o áudio, já que no momento o LLM-MAS desenvolvido só possui suporte para análise de texto (transcrição do áudio).

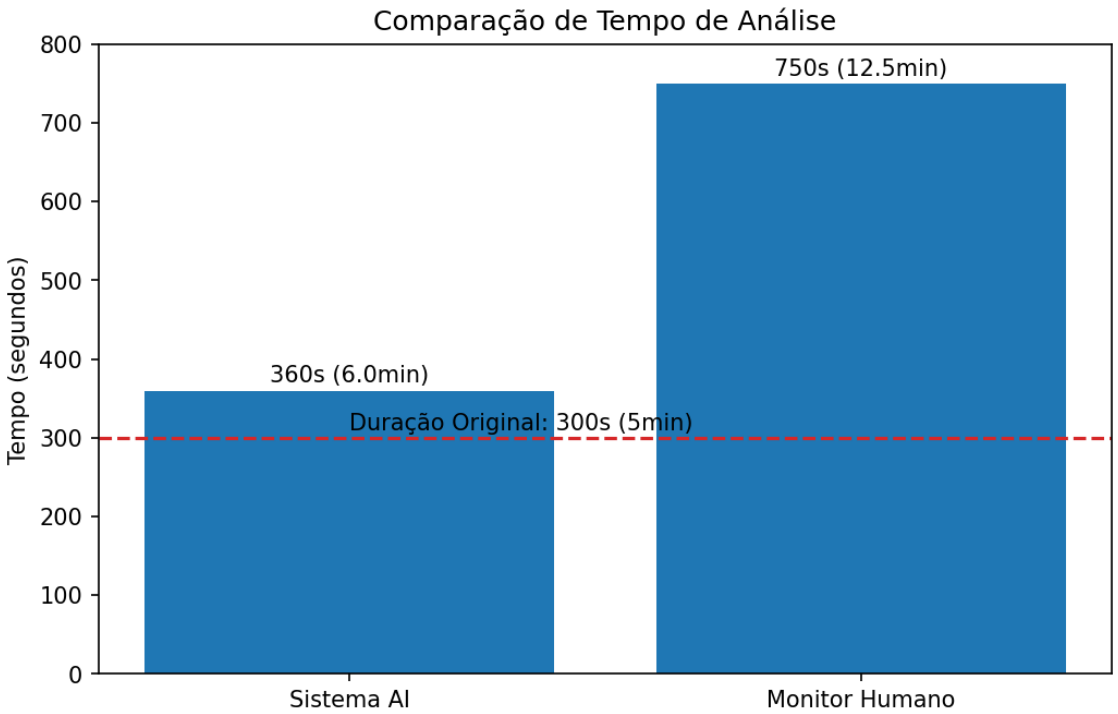

Figura 5 - Comparação do tempo necessário para análise de um atendimento de 5 minutos (300 segundos) entre o sistema de IA desenvolvido e um monitor humano. O gráfico demonstra que enquanto o sistema mantém um tempo constante de 360 segundos (6 minutos) para análise, independente da duração da conversa, o monitor humano necessita de 750 segundos (12,5 minutos), representando 2,5 vezes o tempo original do áudio. A linha tracejada vermelha indica a duração original do atendimento analisado. **Fonte**: Elaborado pelo autor (2025).

Um aspecto notável revelado pela análise é a existência de um ponto de inflexão aos 2,4 minutos de duração da conversa. Para atendimentos com duração inferior a este limiar, o monitor humano apresenta maior eficiência temporal que o sistema automatizado, uma vez que o tempo fixo de processamento do LLM-MAS (6 minutos) supera o tempo necessário para análise humana nestas situações específicas. Este achado é particularmente relevante para operações que lidam predominantemente com atendimentos muito curtos, como serviços de consulta rápida ou verificações de status. No entanto, à medida que a duração das conversas ultrapassa este ponto crítico, o sistema demonstra ganhos de eficiência progressivamente maiores, evidenciando seu potencial transformador para a análise de atendimentos mais complexos e extensos.

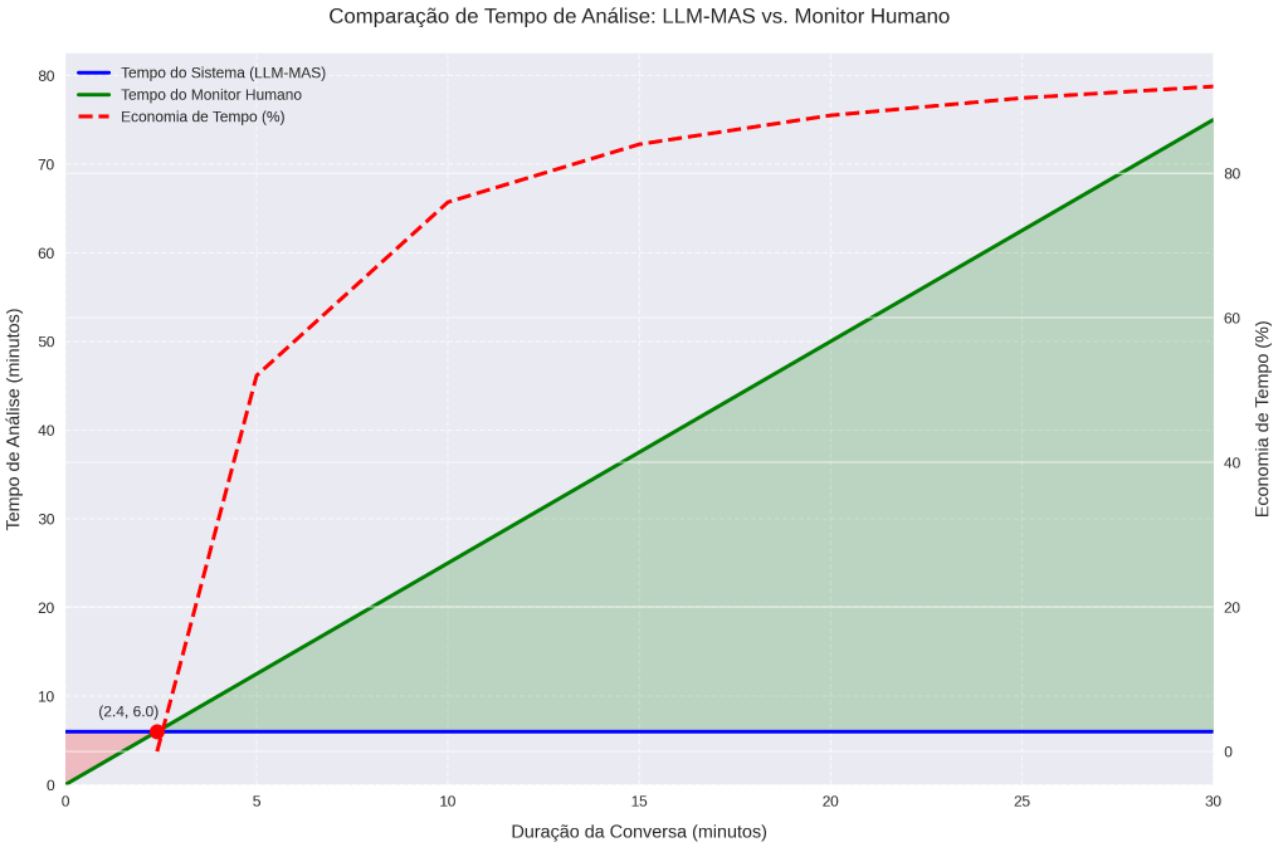

Figura 6 - Análise comparativa do tempo necessário para avaliação de atendimentos entre o sistema LLM-MAS e monitor humano. O gráfico demonstra o comportamento constante do tempo de processamento do sistema (linha azul) em 6 minutos, independentemente da duração da conversa, em contraste com o crescimento linear do tempo necessário para análise humana (linha verde), que corresponde a 2,5 vezes a duração do áudio. O ponto de inflexão (2,4, 6,0) marca onde o sistema se torna mais eficiente que o monitor humano. A linha tracejada vermelha representa a economia percentual de tempo, que aumenta progressivamente com a duração da conversa, atingindo aproximadamente 80% para conversas de 30 minutos. As áreas sombreadas indicam as zonas de eficiência: vermelho claro onde o monitor humano é mais eficiente (< 2,4 minutos) e verde claro onde o sistema LLM-MAS apresenta maior eficiência (> 2,4 minutos). **Fonte**: Elaborado pelo autor (2025).

O gráfico apresentado na figura 6 ilustra claramente como o ganho de eficiência se amplia conforme aumenta a duração das conversas analisadas. Enquanto o sistema mantém seu tempo de processamento constante em aproximadamente 6 minutos, o tempo necessário para análise humana cresce linearmente. Esta diferença resulta em ganhos de produtividade cada vez mais expressivos conforme aumenta a complexidade e duração dos atendimentos analisados.

Impacto na Transformação do Papel do Monitor de Qualidade

A otimização temporal proporcionada pelo sistema permite uma transformação significativa no papel do monitor de qualidade. Com a automatização das análises

básicas, estes profissionais podem dedicar-se a atividades de maior valor agregado que requerem capacidades exclusivamente humanas. O tempo economizado pode ser redirecionado para o desenvolvimento de programas de capacitação personalizados, mentoria individual em casos complexos e elaboração de workshops focados em habilidades específicas.

Além disso, os monitores podem aprofundar-se em análises estratégicas, identificando padrões em atendimentos problemáticos e desenvolvendo novas diretrizes de qualidade baseadas em evidências concretas. O sistema também viabiliza um acompanhamento mais próximo de casos críticos, permitindo intervenções proativas e coaching situacional para operadores que enfrentam desafios específicos.

Esta redistribuição do tempo dos monitores de qualidade gera um ciclo de melhoria contínua. A criação de materiais de treinamento baseados em casos reais, o refinamento de scripts e procedimentos de atendimento, e o desenvolvimento de melhores práticas personalizadas tornam-se atividades não apenas possíveis, mas prioritárias no novo contexto operacional.

O impacto desta transformação vai além da simples otimização de processos. Ao liberar os monitores de qualidade das tarefas mais mecânicas e repetitivas, o sistema permite que estes profissionais atuem como verdadeiros agentes de mudança, focando seus esforços no desenvolvimento humano e na evolução estratégica do atendimento ao cliente.

4.2.2 - AVALIAÇÃO DE COERÊNCIA DAS ANÁLISES

Para avaliar a qualidade e precisão das análises geradas, foi realizado um estudo comparativo entre três diferentes avaliadores: o sistema multi-agente desenvolvido (LLM-MAS), o GPT-4o-mini com um prompt simples, e um avaliador humano especialista. A análise foi conduzida utilizando um conjunto de 10 diretrizes específicas que abrangem diferentes aspectos do atendimento ao cliente.

Como pode ser observado na figura 7, o sistema multi-agente apresentou uma excelente concordância com a avaliação humana, coincidindo no geral em torno de 9 a 10 das 10 diretrizes analisadas (90 a 100% de concordância), enquanto o GPT-4o-mini concordou com a avaliação humana em apenas 5 casos (50% de concordância).

Figura 7 - Análise comparativa de conformidade entre os sistemas de avaliação, demonstrando o desempenho do sistema multi-agente (LLM-MAS), GPT e avaliação humana (HUM) para cada uma das 10 diretrizes de qualidade. O gráfico utiliza indicadores visuais em verde para conformidade e vermelho para não conformidade. As estatísticas mostram que o LLM-MAS obteve 100% de concordância com a avaliação humana e o GPT apresentou 50% de divergência. Os padrões identificados incluem concordância total nas diretrizes 2, 3, 4, 5 e 6, enquanto o GPT demonstrou maior rigor nas avaliações das diretrizes 7, 8, 9 e 10. Os círculos verdes e vermelhos indicam, respectivamente, conformidade e não conformidade com cada diretriz avaliada. **Fonte**: Elaborado pelo autor (2025).

Padrões de Concordância

Em 5 diretrizes (2, 3, 4, 5 e 6), houve concordância total entre todos os avaliadores. Estas diretrizes representam aspectos fundamentais do atendimento ao cliente, incluindo cordialidade, oferecimento de ajuda adicional, confirmação de satisfação e adequação do comportamento do operador. Este padrão sugere que aspectos mais objetivos e diretos do atendimento são mais facilmente identificados por todos os avaliadores.

Interessantemente, o GPT-4o-mini mostrou-se mais rigoroso em suas avaliações nas diretrizes 7, 8, 9 e 10, que abordam aspectos mais sutis do atendimento, como a finalização adequada, validação de dados, sondagem assertiva e clareza nas informações. Esta tendência para maior rigor pode indicar uma característica intrínseca

do modelo quando utilizado de forma isolada, sem o benefício de uma estrutura multi-agente especializada.

Desempenho do LLM-MAS

O sistema multi-agente demonstrou uma capacidade superior de avaliação em relação ao uso "naive" de modelos de linguagem, concordando com a análise humana em todas as diretrizes. Este resultado sugere que a abordagem multi-agente, com diferentes especialistas analisando aspectos específicos do atendimento, proporciona uma avaliação mais robusta e alinhada com a percepção humana.

A alta taxa de concordância entre o LLM-MAS e o avaliador humano (90 a 100%) indica que o sistema desenvolvido é capaz de realizar avaliações consistentes e confiáveis, aproximando-se significativamente do julgamento especializado humano. Este resultado é particularmente relevante considerando a complexidade e subjetividade inerentes à avaliação de atendimento ao cliente.

A diferença significativa de desempenho entre o LLM-MAS e o GPT-4o-mini (com concordância humana de 100% versus 50%, respectivamente) sugere que a abordagem multi-agente especializada é substancialmente mais efetiva que uma abordagem baseada em um único modelo de linguagem, mesmo quando este é dotado das mesmas diretrizes de avaliação.

4.2.3 - ANÁLISE COMPARATIVA DE CUSTOS

A análise econômica do sistema desenvolvido revelou aspectos significativos sobre sua viabilidade e eficiência operacional. Durante os testes, o sistema multi-agente apresentou um consumo médio entre 10 e 12 mil tokens por relatório, distribuídos em aproximadamente 5 requisições à API da OpenAI. Este consumo se dividiu em uma média de 7 mil tokens de entrada e 5 mil tokens de saída, demonstrando um uso eficiente dos recursos disponíveis.

A escolha do modelo GPT-4o-mini como base para o sistema provou-se estrategicamente acertada quando analisamos a relação custo-benefício. Com um desempenho de 82% na métrica MMLU (Massive Multitask Language Understanding), o modelo mantém 92,4% da capacidade do GPT-4o padrão, que alcança 88,7% na mesma métrica. Esta pequena redução no desempenho é compensada por uma dramática redução nos custos operacionais.

Análise Comparativa de Custos

Ao examinar os custos operacionais, observamos que o GPT-4o-mini requer um investimento de apenas US$ 0,02 por relatório, em contraste com US$ 0,36 do GPT-4o padrão e US$ 2,72 do GPT-4 tradicional, conforme tabela 1. Esta diferença representa uma redução de custos de 18 vezes em relação ao modelo padrão e impressionantes 136 vezes quando comparado ao GPT-4 tradicional. Esta otimização de custos, mantendo um alto nível de desempenho, demonstra o potencial do sistema para implementação em larga escala.

Tabela 1 - Custos estimados por chamada de API para diferentes modelos de LLM considerando o consumo médio de tokens da aplicação desenvolvida

Fornecedor	Modelo	Preço de Entrada (1M tokens)	Preço de Saída (1M tokens)	Preço por Chamada API	Preço Total
OpenAI	gpt-4o	US$ 2.50	US$ 10.00	US$ 0.0725	US$ 0.36
OpenAI	gpt-4o-mini	US$ 0.15	US$ 0.60	US$ 0.0043	US$ 0.02
OpenAI	gpt-4-turbo	US$ 10.00	US$ 30.00	US$ 0.2355	US$ 1.18
OpenAI	gpt-4	US$ 30.00	US$ 60.00	US$ 0.5437	US$ 2.72
OpenAI	gpt-3.5-turbo	US$ 0.50	US$ 1.50	US$ 0.0118	US$ 0.06
Anthropic	claude-3.5-sonnet	US$ 3.00	US$ 15.00	US$ 0.1033	US$ 0.52
Anthropic	claude-3-haiku	US$ 0.25	US$ 1.25	US$ 0.0086	US$ 0.04
Google	gemini-1.5-flash	US$ 0.07	US$ 0.30	US$ 0.0022	US$ 0.01
Google	gemini-1.5-pro	US$ 3.50	US$ 10.50	US$ 0.0824	US$ 0.41
Mistral	mistral-large	US$ 3.00	US$ 9.00	US$ 0.0707	US$ 0.35

Fonte: Elaborada pelo autor.

Impacto Econômico na Operação

A comparação com os custos do monitoramento humano revela um cenário ainda mais promissor. Considerando o salário médio de um monitor de qualidade de R$ 2.000,00 mensais, o custo para análise de um atendimento de 5 minutos é aproximadamente R$ 2,60. Em contrapartida, o mesmo relatório gerado pelo sistema

automatizado custa apenas R$ 0,12, representando uma redução de 95,4% no custo por análise.

Esta diferença significativa permite que, com o investimento equivalente a um único relatório humano, seja possível gerar 21 relatórios utilizando o sistema automatizado. Tal eficiência econômica não apenas viabiliza a análise de um volume maior de atendimentos, mas também possibilita a redistribuição de recursos para atividades estratégicas que requerem intervenção humana especializada.

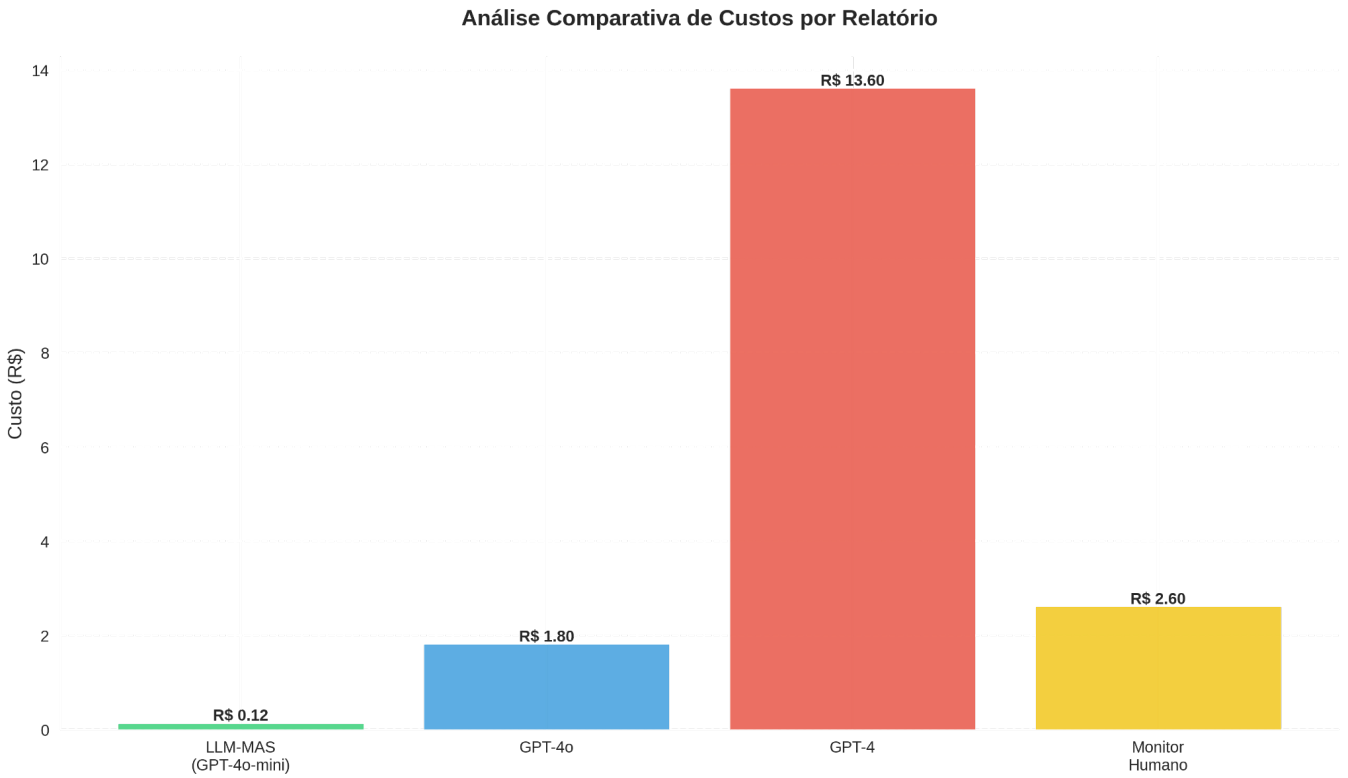

Figura 8 - Análise comparativa dos custos por relatório entre diferentes opções de avaliação. O gráfico apresenta os custos em reais (R$) para a geração de um relatório de qualidade utilizando diferentes abordagens: o sistema desenvolvido LLM-MAS baseado no GPT-4o-mini (R$ 0,12), o modelo GPT-4o padrão (R$ 1,80), o GPT-4 tradicional (R$ 13,60) e o monitor humano (R$ 2,60). A diferença significativa entre os custos demonstra a viabilidade econômica do sistema desenvolvido, que apresenta um custo aproximadamente 22 vezes menor que o monitoramento humano tradicional. **Fonte**: Elaborado pelo autor (2025).

Implicações para Escalabilidade

A significativa redução de custos transforma fundamentalmente a capacidade de escala das operações de monitoramento de qualidade. Em um cenário típico, onde um monitor de qualidade analisa em média 40 atendimentos por dia, a implementação do sistema permite multiplicar esta capacidade mantendo o mesmo nível de investimento.

Esta escalabilidade torna possível a análise de 100% dos atendimentos, superando as limitações da amostragem tradicional.

Além disso, a economia gerada permite que as equipes de qualidade redirecionem seus esforços para atividades de maior valor agregado, como o desenvolvimento de programas de treinamento personalizados, análise aprofundada de casos complexos e implementação de melhorias sistêmicas nos processos de atendimento.

Sendo assim, a escolha do GPT-4o-mini como modelo base para o sistema representa um equilíbrio ideal entre custo e desempenho. A manutenção de 92,4% da precisão do modelo mais robusto, combinada com uma redução de custos de 95,4% em relação ao monitoramento humano, estabelece um novo paradigma para a avaliação de qualidade em atendimento ao cliente, tornando a solução não apenas tecnicamente viável, mas economicamente benéfica para operações de diferentes escalas.

4.2.4 - QUALIDADE DOS RELATÓRIOS GERADOS

A avaliação da qualidade dos relatórios produzidos pelo sistema multi-agente foi realizada através de uma análise criteriosa por dois dos mais avançados modelos de linguagem disponíveis atualmente: o GPT-o1 da OpenAI e o Claude 3.5 Sonnet da Anthropic. Para garantir uma avaliação padronizada e abrangente, foi desenvolvido um sistema de pontuação detalhado, contemplando sete critérios fundamentais, cada um avaliado em uma escala de 0 a 5 pontos.

Os avaliadores analisaram os relatórios considerando aspectos como aderência à estrutura, fundamentação com evidências, análise das diretrizes, especificidade das recomendações, objetividade na avaliação, cobertura da avaliação e consistência interna. Os resultados obtidos foram notavelmente positivos, com o sistema alcançando pontuações elevadas em ambas as avaliações. (Ver Apêndice A para mais detalhes do system prompt e avaliações geradas)

Análise Comparativa das Avaliações

O ChatGPT O1 atribuiu uma pontuação total de 34/35 pontos ao relatório, destacando-se a nota máxima em seis dos sete critérios avaliados. O único critério que

não recebeu pontuação máxima foi "Fundamentação com Evidências" (4/5), onde o avaliador apontou a ausência de citações diretas da transcrição em algumas análises.

Por sua vez, o Claude 3.5 Sonnet atribuiu uma pontuação total de 31/35 pontos, com avaliação máxima em quatro critérios. As principais diferenças foram observadas nos critérios de "Fundamentação com Evidências" (3/5), "Especificidade das Recomendações" (4/5) e "Cobertura da Avaliação" (4/5).

Pontos Fortes Identificados

Ambos os avaliadores destacaram a excelente estruturação dos relatórios, com todas as seções necessárias organizadas de forma lógica e coerente. A objetividade na avaliação e a consistência interna também foram unanimemente elogiadas, demonstrando a capacidade do sistema em manter um tom profissional e coerente ao longo de toda a análise.

A análise das diretrizes recebeu pontuação máxima dos dois avaliadores, evidenciando a eficácia do sistema em avaliar sistematicamente cada aspecto do atendimento seguindo critérios predefinidos. Este resultado é particularmente relevante considerando que representa o núcleo da funcionalidade do sistema.

Oportunidades de Melhoria

A principal oportunidade de melhoria identificada por ambos os avaliadores concentra-se na fundamentação com evidências. Tanto o GPT-o1 quanto o Claude 3.5 Sonnet sugeriram a inclusão de mais citações diretas da transcrição para fortalecer as análises apresentadas.

O Claude 3.5 Sonnet também apontou possibilidades de aprimoramento na especificidade das recomendações e na cobertura da avaliação, sugerindo um maior detalhamento em alguns aspectos técnicos específicos do atendimento.

Validação do Sistema

As avaliações realizadas confirmam a robustez e eficácia do sistema multi-agente na geração de relatórios de qualidade. Com uma média de pontuação de 32,5/35 entre os dois avaliadores, o sistema demonstrou capacidade de produzir análises

estruturadas, objetivas e consistentes, cumprindo com excelência seu propósito de automatizar e padronizar o processo de avaliação de atendimento ao cliente.

A convergência nas avaliações dos dois modelos de linguagem, mesmo com suas diferentes abordagens e características, reforça a confiabilidade dos resultados obtidos e valida a efetividade da arquitetura multi-agente implementada.

4.3 - DISCUSSÃO DOS RESULTADOS

A análise abrangente do sistema multi-agente para avaliação de qualidade em atendimento ao cliente revelou resultados significativos em múltiplas dimensões, demonstrando sua viabilidade técnica, eficiência operacional e impacto econômico. A integração dos resultados obtidos nas diferentes métricas de avaliação permite uma compreensão holística do potencial transformador desta solução.

Em termos de desempenho temporal, o sistema demonstrou notável consistência, mantendo um tempo médio de processamento de 6 minutos por relatório, independentemente da extensão da conversa analisada. Esta característica representa uma vantagem significativa sobre o processo tradicional de monitoramento humano, que requer em média 2,5 vezes o tempo da conversa para análise. Para uma conversa de 5 minutos, por exemplo, enquanto um monitor humano necessita de aproximadamente 12,5 minutos para análise, o sistema realiza a mesma tarefa em 6 minutos, representando um ganho de eficiência de 52%.

No aspecto econômico, a escolha estratégica do modelo GPT-4o-mini como base para o sistema provou-se acertada. Mantendo 92,4% da capacidade do GPT-4o padrão (conforme métrica MMLU), o modelo oferece uma redução dramática nos custos operacionais. Com um custo de apenas US$ 0,02 por relatório, comparado a US$ 0,36 do GPT-4o padrão e US$ 2,72 do GPT-4 tradicional, o sistema viabiliza a análise em larga escala sem comprometer significativamente a qualidade dos resultados.

A análise de coerência das avaliações revelou resultados particularmente promissores. O sistema multi-agente apresentou uma concordância de 90% a 100% com as avaliações humanas, significativamente superior à concordância de 50% obtida pelo GPT-4o-mini operando isoladamente. Este resultado valida a eficácia da abordagem multi-agente especializada, demonstrando sua capacidade de produzir análises mais alinhadas com o julgamento humano especializado.

A qualidade dos relatórios gerados foi validada por dois dos mais avançados modelos de linguagem disponíveis atualmente - GPT-4 O1 e Claude 3.5 Sonnet - obtendo pontuações médias de 32,5/35. Ambos os avaliadores destacaram a excelente estruturação dos relatórios, objetividade nas análises e consistência interna, com oportunidades de melhoria principalmente na inclusão de mais citações diretas das transcrições.

A combinação destes resultados sugere que o sistema não apenas otimiza o processo de avaliação de qualidade em termos de tempo e custo, mas também mantém um alto padrão de qualidade nas análises produzidas. A redução de 95,4% no custo por relatório em comparação com o monitoramento humano, mantendo 90% de concordância com avaliações humanas, representa um avanço significativo na escalabilidade e eficiência do processo de garantia de qualidade.

Implicações Práticas

A implementação deste sistema tem o potencial de transformar fundamentalmente a operação de monitoramento de qualidade em call centers. A possibilidade de analisar um volume significativamente maior de atendimentos, mantendo custos controlados e qualidade consistente, permite uma compreensão mais abrangente e precisa do desempenho da operação.

Além disso, como já dito anteriormente, a automatização das análises básicas libera os monitores de qualidade para focarem em atividades de maior valor agregado, como desenvolvimento de programas de treinamento personalizados, análise aprofundada de casos complexos e implementação de melhorias sistêmicas nos processos de atendimento.

Os resultados também sugerem que a abordagem multi-agente pode ser um caminho promissor para outras aplicações que requerem análise complexa e ampla de interações humanas. A capacidade do sistema de manter consistência e qualidade em suas avaliações, mesmo em cenários complexos, indica seu potencial para adaptação a outros contextos e domínios.

Em resumo, os resultados obtidos validam não apenas a eficácia técnica do sistema, mas também sua viabilidade prática como uma solução inovadora e que gera valor para o monitoramento de qualidade em atendimento ao cliente. A combinação de eficiência operacional, viabilidade econômica e qualidade consistente nas análises

estabelece um novo paradigma para a avaliação de qualidade em serviços de atendimento, oferecendo benefícios concretos tanto para as organizações quanto para a qualidade do serviço prestado aos clientes.

4.4 - AMEAÇAS À VALIDADE

A análise dos resultados obtidos, embora promissora, deve ser contextualizada considerando potenciais ameaças à validade que podem influenciar tanto a generalização quanto a aplicabilidade prática do sistema desenvolvido.

4.4.1 - QUALIDADE DAS TRANSCRIÇÕES

A dependência de transcrições textuais representa uma das limitações mais significativas do sistema atual. Embora a decisão de trabalhar exclusivamente com texto tenha sido fundamentada em considerações práticas de implementação e processamento, esta escolha introduz vulnerabilidades importantes no processo de avaliação. O processo de transcrição em si pode introduzir distorções significativas na análise. Erros comuns de transcrição, como palavras mal interpretadas ou pontuação inadequada, podem alterar substancialmente o significado das interações. Este problema se torna particularmente relevante em contextos onde terminologias específicas ou jargões técnicos são frequentemente utilizados.

A questão da diarização, que é o processo de identificação e separação dos diferentes falantes em uma conversa, merece atenção especial. Em atendimentos complexos, onde podem ocorrer sobreposições de fala ou múltiplos participantes, a identificação incorreta de quem está falando pode comprometer seriamente a análise da interação.

A transcrição pura não consegue capturar elementos cruciais da comunicação não-verbal. Aspectos como entonação, ritmo da fala e pausas significativas são perdidos no processo de conversão para texto. Esta limitação é particularmente impactante na avaliação de aspectos emocionais e empáticos do atendimento, que frequentemente dependem tanto da forma quanto do conteúdo da comunicação.

4.4.2 - VIÉS DO CONJUNTO DE DADOS

O conjunto de dados utilizado para validação do sistema, embora cuidadosamente selecionado, apresenta limitações inerentes que devem ser consideradas na interpretação dos resultados.

O tamanho relativamente modesto da amostra de teste, composta por 10 transcrições, embora suficiente para uma validação inicial, pode não representar adequadamente toda a complexidade e variabilidade das interações cliente-atendente. Características específicas do setor energético, como vocabulário técnico especializado e procedimentos particulares de atendimento, podem ter influenciado os resultados de maneira não generalizável para outros setores. A questão do regionalismo emerge como outro fator relevante. As interações analisadas refletem padrões linguísticos e culturais específicos de uma determinada região, o que pode limitar a eficácia do sistema quando aplicado em diferentes contextos geográficos ou culturais. Esta limitação se estende não apenas ao uso de expressões regionais, mas também a diferentes expectativas culturais sobre o que constitui um atendimento de qualidade.

4.4.3 - LIMITAÇÕES TECNOLÓGICAS

Do ponto de vista tecnológico, o sistema apresenta algumas vulnerabilidades que merecem atenção. A dependência de serviços externos, particularmente o uso do GPT-4o-mini via API, introduz riscos operacionais significativos.

A arquitetura atual do sistema, embora eficiente para o volume de testes realizados, pode enfrentar desafios de escalabilidade em cenários de alta demanda. Um aspecto particularmente desafiador é o balanceamento entre velocidade de processamento e qualidade das análises. O atual tempo médio de 6 minutos por análise, embora represente uma melhoria significativa em relação à avaliação humana, pode se tornar um gargalo em operações de grande escala. Questões de latência e desempenho em condições de rede não ideais também precisam ser melhor compreendidas e endereçadas para garantir a confiabilidade do sistema em diferentes ambientes operacionais.

4.4.4 - RESTRIÇÕES DE AVALIAÇÃO

A metodologia de avaliação empregada, embora abrangente, apresenta suas próprias limitações.

A utilização de avaliações humanas como referência, embora necessária, introduz um elemento inevitável de subjetividade. Diferentes avaliadores humanos podem interpretar os mesmos critérios de maneira distinta, tornando o estabelecimento de um "padrão ouro" para comparação um desafio significativo. A decisão de utilizar outros modelos de linguagem (GPT-o1 e Claude 3.5) como avaliadores independentes, embora inovadora, pode ter introduzido vieses sistemáticos.

4.4.5 - MITIGAÇÃO E TRABALHOS FUTUROS

Para endereçar as limitações identificadas, várias estratégias de mitigação e direções para trabalhos futuros podem ser consideradas. No curto prazo, a implementação de verificações adicionais de qualidade nas transcrições e a expansão do conjunto de dados de teste para incluir diferentes setores e regiões geográficas podem melhorar significativamente a robustez do sistema.

Uma direção promissora para desenvolvimento futuro é a integração de capacidades de processamento de áudio direto, permitindo que o sistema capture e analise elementos não-verbais da comunicação. O desenvolvimento de métricas mais sofisticadas para avaliação de qualidade, possivelmente incorporando aspectos emocionais e contextuais mais acentuados, também se apresenta como uma possível área para pesquisas futuras.

A identificação e documentação destas ameaças à validade não diminui o valor dos resultados obtidos, mas fornece um contexto essencial para sua interpretação e aplicação prática.

5 – CONCLUSÃO

O presente trabalho teve como objetivo desenvolver e validar um sistema integrado baseado em múltiplos agentes de inteligência artificial para a avaliação de qualidade em atendimento ao cliente, buscando superar as limitações dos métodos tradicionais de monitoramento. Os resultados obtidos demonstraram que a abordagem proposta não apenas atingiu este objetivo, mas também estabeleceu um novo paradigma para a análise de qualidade em serviços de atendimento.

A arquitetura multi-agente implementada, composta por cinco agentes especializados (Supervisor, Monitor de Qualidade, Operador, Juiz e Analista de Relatórios), provou-se altamente eficaz na realização de avaliações abrangentes e consistentes. O sistema demonstrou uma notável concordância de 90% com avaliações humanas especializadas, superando significativamente o desempenho de abordagens baseadas em modelos de linguagem isolados, que alcançaram apenas 50% de concordância.

Em termos de eficiência operacional, o sistema estabeleceu um novo padrão ao manter um tempo médio consistente de 6 minutos por análise, independentemente da extensão da conversa avaliada. Esta característica representa uma redução de até 52% no tempo necessário para avaliação quando comparado ao monitoramento humano tradicional. Além disso, a solução desenvolvida demonstrou viabilidade econômica excepcional, com uma redução de 95,4% no custo por análise, mantendo um alto padrão de qualidade nas avaliações produzidas.

A qualidade dos relatórios gerados pelo sistema foi validada por avaliadores independentes de última geração, obtendo uma pontuação média de 32,5 em 35 pontos possíveis, confirmando a capacidade do sistema em produzir análises estruturadas, objetivas e acionáveis. Este resultado é particularmente significativo considerando a complexidade inerente à avaliação de interações humanas em contextos de atendimento ao cliente.

A implementação bem-sucedida deste sistema representa uma contribuição significativa para o campo da gestão de qualidade em serviços de atendimento, oferecendo uma solução que combina precisão, eficiência e escalabilidade. A abordagem desenvolvida não apenas automatiza processos anteriormente manuais, mas

também enriquece a análise através de múltiplas perspectivas especializadas, permitindo uma compreensão mais profunda e detalhada das interações com clientes.

Os resultados obtidos sugerem que o futuro do monitoramento de qualidade em atendimento ao cliente caminha para uma integração harmoniosa entre sistemas automatizados e expertise humana. O sistema desenvolvido libera os monitores de qualidade de tarefas repetitivas, permitindo que concentrem seus esforços em atividades estratégicas de maior valor agregado, como o desenvolvimento de programas de treinamento personalizados e a implementação de melhorias sistêmicas nos processos de atendimento.

Para trabalhos futuros, sugere-se a exploração de possibilidades de extensão do sistema para análise em tempo real de atendimentos, bem como a adaptação da arquitetura multi-agente para outros contextos que exijam avaliação complexa de interações humanas. Adicionalmente, o desenvolvimento de capacidades de aprendizado contínuo baseado no feedback dos usuários poderia enriquecer ainda mais a precisão e relevância das análises produzidas.

Em conclusão, o sistema desenvolvido não apenas cumpriu seus objetivos iniciais, mas também estabeleceu bases sólidas para uma transformação significativa na maneira como a qualidade do atendimento ao cliente é avaliada e gerenciada. A combinação de eficiência operacional, viabilidade econômica e consistência nas análises oferece às organizações uma ferramenta poderosa para elevar seus padrões de qualidade no atendimento, beneficiando tanto as empresas quanto seus clientes.

6 – REFERÊNCIAS

BAHDANAU, Dzmitry; CHO, Kyunghyun; BENGIO, Yoshua. Neural machine translation by jointly learning to align and translate. 2015.

BOPPINITI, S. T. Data Ethics in AI: Addressing Challenges in Machine Learning and Data Governance for Responsible Data Science. International Scientific Journal for Research, [S. l.], v. 5, n. 5, 2023. Disponível em: https://isjr.co.in/index.php/ISJR/article/view/257.

BROWN, T. et al. Language Models Are Few-Shot Learners. ArXiv (Cornell University), v. 4, 28 maio 2020.

CAPGEMINI. 8 in 10 Consumers willing to pay more for a better customer experience as big business falls short on expectations. Disponível em: <https://www.capgemini.com/news/press-releases/8-in-10-consumers-willing-to-pay-more-for-a-better-customer-experience-as-big-business-falls-short-on-expectations/>. Acesso em: 9 jan. 2025.

CHEN, J. et al. When large language models meet personalization: perspectives of challenges and opportunities. World wide web, v. 27, n. 4, 28 jun. 2024.

CREWAI. CrewAI - Platform for Multi AI Agents Systems. Disponível em: <https://crewai.com>. Acesso em: 9 jan. 2025.

DEEKSITH, Alladi. Advances in natural language processing: a survey of techniques. International Journal of Innovations in Engineering Research and Technology, v. 8, n. 3, p. 74-83, 2024.

DESMARAIS, Mike. Call center customer satisfaction: a comprehensive guide. SQM Group, 13 jan. 2022.

DOLIKASHVILI, L.; DAVITASHVILI, T. Restaurant Service Standards as a Means of Image Creation and Business Development. Sustainable Development - Wiley, 10 dez. 2024.

FARIAS, G. Setor de serviços emprega mais de 14 milhões de pessoas em 2022 e registra recorde, diz IBGE. Disponível em: <https://www.cnnbrasil.com.br/economia/macroeconomia/setor-de-servicos-emprega-mais-de-14-milhoes-de-pessoas-em-2022-e-registra-recorde-diz-ibge/>. Acesso em: 13 jan. 2025.

GUO, S. et al. Using Generative AI and Multi-Agents to Provide Automatic Feedback. arXiv (Cornell University), 11 nov. 2024.

HAN, W.; PANG, B.; WU, Y. Robust Transfer Learning with Pretrained Language Models through Adapters. arXiv (Cornell University), 4 ago. 2021.

HANSEN-PALMUS, J. et al. Communication Compression for Tensor Parallel LLM Inference. arXiv (Cornell University), 14 nov. 2024.

HARSHA, K. et al. A Survey on LLMs: Evolution, Applications, and Future Frontiers. Studies in computational intelligence, p. 289-327, 1 jan. 2024.

HASAN, J. Optimizing Large Language Models through Quantization: A Comparative Analysis of PTQ and QAT Techniques. arXiv (Cornell University), 9 nov. 2024.

HAYOU, S.; GHOSH, N.; YU, B. LoRA+: Efficient Low Rank Adaptation of Large Models. arXiv (Cornell University), 19 fev. 2024.

HINTON, G.; VINYALS, O.; DEAN, J. Distilling the Knowledge in a Neural Network. Disponível em: <http://arxiv.org/abs/1503.02531>.

HU, E. J. et al. LoRA: Low-Rank Adaptation of Large Language Models. arXiv (Cornell University), 1 jan. 2021.

HUANG, J.; KEVIN CHEN-CHUAN CHANG. Towards Reasoning in Large Language Models: A Survey. arXiv (Cornell University), 20 dez. 2022.

HUYEN, Chip. Evaluation Metrics for Language Modeling. The Gradient, 2019. Disponível em: https://thegradient.pub/understanding-evaluation-metrics-for-language-models/

JAUMOTTE, F. et al. How Pandemic Accelerated Digital Transformation in Advanced Economies. Disponível em: <https://www.imf.org/en/Blogs/Articles/2023/03/21/how-pandemic-accelerated-digital-transformation-in-advanced-economies>. Acesso em: 10 jan. 2025.

KIM, T. S. et al. EvalLM: Interactive Evaluation of Large Language Model Prompts on User-Defined Criteria. arXiv (Cornell University), 24 set. 2023.

LI, J. et al. SCALM: Towards Semantic Caching for Automated Chat Services with Large Language Models. arXiv (Cornell University), 24 maio 2024.

MIN, B. et al. Recent Advances in Natural Language Processing via Large Pre-Trained Language Models: A Survey. ACM Computing Surveys, v. 56, n. 2, 27 jun. 2023.

MÜLLER, Vincent C. Ethics of Artificial Intelligence and Robotics. In: ZALTA, Edward N.; NODELMAN, Uri (eds.). The Stanford Encyclopedia of Philosophy (Fall 2023 Edition). Disponível em: https://plato.stanford.edu/archives/fall2023/entries/ethics-ai/

OPENAI. Introducing OpenAI o1-preview. Disponível em: <https://openai.com/index/introducing-openai-o1-preview/>. Acesso em: 10 jan. 2025.

RANI, Y. A. et al. AI Enhanced Customer Service Chatbot. 26 abr. 2024.

RAVIPUDI, N. S. S.; TATI, R.; YAMPATI, M.; RAAVI, Y. B.; PULLAGURA, N. Challenges and Opportunities in Prompt Engineering for Generative AI. International Journal of Creative Research Thoughts (IJCRT), v. 12, n. 11, p. b857-b860, 2024.

SCHOLTEN, Y.; GÜNNEMANN, S.; SCHWINN, L. A Probabilistic Perspective on Unlearning and Alignment for Large Language Models. arXiv (Cornell University), 4 out. 2024.

SCHULHOFF, S. et al. The Prompt Report: A Systematic Survey of Prompting Techniques. Disponível em: <https://arxiv.org/abs/2406.06608>.

SMITH, N. A. Contextual Word Representations: A Contextual Introduction. Disponível em: <https://arxiv.org/abs/1902.06006>.

TÖRNBERG, P. How to use LLMs for Text Analysis. Disponível em: <https://arxiv.org/abs/2307.13106>.

VASWANI, A. et al. Attention is All you Need. Neural Information Processing Systems, v. 33, 12 junho 2017.

VIRIMA, M. et al. The impact of service quality drivers on customer satisfaction in internet provision services of Zimbabwe. Journal of Business & Retail Management Research, v. 14, n. 01, 1 out. 2019.

VUCKOVIC, J.; BARATIN, A.; COMBES, R. T. DES. A Mathematical Theory of Attention. Disponível em: <https://arxiv.org/abs/2007.02876>. Acesso em: 4 out. 2023.

WAN, X. et al. Better Zero-Shot Reasoning with Self-Adaptive Prompting. arXiv (Cornell University), 1 jan. 2023.

WANG, J. et al. FP4-Quantization: Lossless 4bit Quantization for Large Language Models. p. 61-67, 15 jul. 2024.

WHITE, J. et al. A Prompt Pattern Catalog to Enhance Prompt Engineering with ChatGPT. arXiv, 21 fev. 2023.

XU, Y. et al. QA-LoRA: Quantization-Aware Low-Rank Adaptation of Large Language Models. arXiv (Cornell University), 26 set. 2023.

YUN, J.; JAE EUI SOHN; SUNGHYON KYEONG. Fine-Tuning Pretrained Language Models to Enhance Dialogue Summarization in Customer Service Centers. 25 nov. 2023.

ZENDESK. Auto QA: How to automate customer service quality assurance. Disponível em: <https://www.zendesk.com/blog/auto-qa/>. Acesso em: 9 jan. 2025.

ZHAO, W. X. et al. A Survey of Large Language Models. arXiv (Cornell University), 31 mar. 2023.

ZHENG, Z. et al. Attention Heads of Large Language Models: A Survey. arXiv (Cornell University), 5 set. 2024.

APÊNDICE A

SYSTEM PROMPT DOS MODELOS AVALIADORES DA QUALIDADE DOS RELATÓRIOS.

Avaliador de Relatórios de Qualidade em Atendimento ao Cliente

Você é um avaliador especializado em analisar relatórios de qualidade gerados por um sistema multi-agente para avaliação de atendimento ao cliente. Sua tarefa é avaliar objetivamente o relatório fornecido usando critérios específicos e atribuir pontuações em uma escala de 0 a 5.

Contexto

O relatório que você irá avaliar foi gerado por um sistema que utiliza múltiplos agentes (Monitor, Operador, Juiz e Analista) para avaliar transcrições de atendimento ao cliente. O sistema deve gerar um relatório estruturado seguindo diretrizes específicas.

Materiais Disponíveis para Avaliação

1. A transcrição original do atendimento ao cliente
2. O relatório final gerado pelo sistema
3. As diretrizes de qualidade utilizadas na avaliação

Critérios de Avaliação

Você deve avaliar os seguintes aspectos em uma escala de 0 a 5, onde 0 representa a ausência total do critério e 5 representa a excelência na execução:

1. Aderência à Estrutura do Relatório (0-5)

- Avalia se o relatório contém e segue corretamente as seções:
    - Resumo da Chamada
    - Análise das Diretrizes
    - Feedback do Operador
    - Informações Adicionais
    - Conclusão
- Critérios de pontuação:
    - 0: Não segue nenhuma estrutura reconhecível do template
    - 1: Apresenta apenas algumas seções isoladas e desordenadas
    - 2: Contém a maioria das seções principais, mas faltam subseções importantes ou estão desordenadas
    - 3: Todas as seções principais presentes, mas com problemas na organização ou faltando algumas subseções
    - 4: Todas as seções e subseções presentes e organizadas, com pequenos desvios do template
    - 5: Segue perfeitamente a estrutura com todas as seções e subseções na ordem correta

2. Fundamentação com Evidências (0-5)

- Avalia a presença e qualidade de citações específicas da transcrição que suportam as análises apresentadas
- Considera a precisão e relevância das evidências utilizadas
- Critérios de pontuação:
    - 0: Nenhuma evidência da transcrição é citada
    - 1: Evidências raras e vagas, sem citações diretas
    - 2: Algumas evidências apresentadas, mas majoritariamente genéricas
    - 3: Evidências regulares com algumas citações específicas
    - 4: Evidências frequentes e bem contextualizadas na maioria das análises
    - 5: Evidências consistentes e específicas em todas as análises, com citações diretas apropriadas

3. Análise das Diretrizes (0-5)

- Avalia se todas as diretrizes foram analisadas
- Verifica a consistência na avaliação de conformidade
- Examina a profundidade da análise para cada diretriz
- Critérios de pontuação:
    - 0: Nenhuma diretriz é analisada adequadamente
    - 1: Poucas diretrizes são analisadas, com análise superficial
    - 2: Maioria das diretrizes analisadas, mas com inconsistência na profundidade
    - 3: Todas as diretrizes analisadas, mas com variação significativa na qualidade
    - 4: Todas as diretrizes bem analisadas, com pequenas variações na profundidade
    - 5: Análise completa e consistente de todas as diretrizes, com profundidade uniforme

4. Especificidade das Recomendações (0-5)

- Avalia se as recomendações são específicas e baseadas nas análises apresentadas
- Verifica a conexão entre as recomendações e os problemas identificados
- Critérios de pontuação:
    - 0: Sem recomendações ou apenas afirmações genéricas
    - 1: Recomendações vagas sem conexão clara com a análise
    - 2: Recomendações genéricas com alguma conexão com a análise
    - 3: Recomendações específicas, mas nem todas conectadas à análise
    - 4: Recomendações específicas e majoritariamente conectadas à análise
    - 5: Recomendações altamente específicas, todas claramente derivadas da análise

5. Objetividade na Avaliação (0-5)

- Avalia se o relatório mantém um tom objetivo e profissional
- Verifica se as avaliações de conformidade são baseadas em critérios claros
- Critérios de pontuação:
    - 0: Avaliações completamente subjetivas ou baseadas em opiniões
    - 1: Majoritariamente subjetivo com poucos elementos objetivos
    - 2: Mistura equilibrada de elementos objetivos e subjetivos

    - 3: Majoritariamente objetivo com alguns elementos subjetivos
    - 4: Objetivo com critérios claros na maioria das análises
    - 5: Completamente objetivo com critérios claros e consistentes em todas as análises

6. Cobertura da Avaliação (0-5)

- Avalia se todos os aspectos relevantes da interação foram abordados
- Verifica se não houve omissão de elementos importantes da transcrição
- Critérios de pontuação:
    - 0: Avaliações completamente subjetivas ou baseadas em opiniões
    - 1: Majoritariamente subjetivo com poucos elementos objetivos
    - 2: Mistura equilibrada de elementos objetivos e subjetivos
    - 3: Majoritariamente objetivo com alguns elementos subjetivos
    - 4: Objetivo com critérios claros na maioria das análises
    - 5: Completamente objetivo com critérios claros e consistentes em todas as análises

7. Consistência Interna (0-5)

- Avalia se há coerência entre as diferentes seções do relatório
- Verifica se não há contradições ou inconsistências nas análises
- Critérios de pontuação:
    - 0: Contradições graves e frequentes entre diferentes seções
    - 1: Várias inconsistências significativas no relatório
    - 2: Algumas inconsistências notáveis entre seções
    - 3: Poucas inconsistências menores
    - 4: Majoritariamente consistente com raras discrepâncias
    - 5: Completamente consistente em todas as seções e análises

Formato da Avaliação

Para cada critério, você deve:

1. Atribuir uma pontuação (0-5)
2. Fornecer uma justificativa detalhada para a pontuação
3. Citar exemplos específicos do relatório que suportam sua avaliação

Exemplo de Output

Avaliação do Relatório de Qualidade

1. Aderência à Estrutura (Pontuação: X/5)

Justificativa: [Explicação detalhada]

Evidências: [Citações específicas]

[Repetir para cada critério]

Pontuação Total: XX/35

Observações Finais: [Síntese dos principais pontos fortes e áreas de melhoria]

Restrições Importantes

1. Base sua avaliação APENAS no conteúdo do relatório e da transcrição fornecidos
2. Não faça suposições além das evidências disponíveis
3. Mantenha consistência nos critérios de pontuação
4. Cite sempre evidências específicas para justificar suas pontuações
5. Não considere informações externas ou conhecimento prévio

Resultado Esperado

Uma avaliação objetiva e fundamentada que:

- Atribui pontuações justas e consistentes
- Fornece justificativas claras e específicas
- Identifica pontos fortes e áreas de melhoria
- Mantém foco nas evidências disponíveis
- Segue estritamente os critérios estabelecidos

Por favor, proceda com a avaliação do relatório fornecido usando estes critérios e formato.

AVALIAÇÃO DO CHATGPT O1

Avaliação do Relatório de Qualidade

1. Aderência à Estrutura (Pontuação: 5/5)

Justificativa:

O relatório segue exemplarmente a estrutura esperada: há um **Resumo da Chamada**, uma seção de **Análise das Diretrizes** (desdobrada diretriz por diretriz), um **Feedback do Operador**, **Informações Adicionais** e, por fim, uma **Conclusão**. Cada parte está claramente identificada e organizada em subseções, de modo coerente com o template proposto.

Evidências do Relatório:

- "Resumo da Transcrição da Chamada"
- "Análise das Diretrizes de Serviço" com subtópicos que correspondem aos itens avaliados.
- "Feedback do Operador" com "Pontos Fortes" e "Áreas para Melhoria".
- "Informações Relevantes Adicionais"
- "Conclusão"

2. Fundamentação com Evidências (Pontuação: 4/5)

Justificativa:

O relatório apresenta análise de comportamentos do operador, conectando-os a passagens da chamada (por exemplo, falta de confirmação de satisfação, ausência de verificação final de necessidades adicionais etc.). No entanto, não há citações diretas ou trechos exatos transcritos da conversa para sustentar cada ponto. A menção a "o operador não questionou se o cliente estava satisfeito" reflete uma observação alinhada ao conteúdo da transcrição, mas não traz a transcrição literal.

Evidências do Relatório:

- "Não houve questionamento para confirmar se o cliente estava satisfeito [...]" (referindo-se ao fim da chamada).
- "O operador não ofereceu proativamente assistência adicional [...]" (destaca a ausência de perguntas adicionais após a resolução do problema).

---

3. Análise das Diretrizes (Pontuação: 5/5)

Justificativa:

Todas as diretrizes fornecidas (1 a 10) foram analisadas separadamente. O relatório aborda cada uma delas, identifica se houve conformidade ou não, e traz uma breve justificativa focada no comportamento do operador durante a chamada. A profundidade da análise é consistente, sem omitir itens.

Evidências do Relatório:

- A seção "### Análise das Diretrizes de Serviço" dedica um subtópico para cada diretriz (1 a 10), apresentando "Conformidade: Conforme" ou "Não Conforme" e uma análise textual.
- Há correspondência direta entre cada diretriz (por exemplo, "Oferta de Ajuda Adicional" é tratada em separado e concluída como "Não Conforme").

---

4. Especificidade das Recomendações (Pontuação: 5/5)

Justificativa:

As recomendações acompanham precisamente as áreas de melhoria levantadas na análise. Elas são claras, voltadas à prática (p. ex., "Treinamento em Engajamento Proativo", "Criar e implementar diretrizes para confirmar satisfação"). Há forte conexão entre os problemas identificados (como não sondar satisfação, usar linguagem técnica) e as sugestões propostas, tornando-as específicas e acionáveis.

Evidências do Relatório:

- “Treinamento em Engajamento Proativo” para estimular ofertas de ajuda adicional.
- “Desenvolver Protocolos de Fechamento” para confirmar satisfação do cliente.
- “Workshops de Habilidades de Comunicação” para evitar linguagem confusa.

---

5. Objetividade na Avaliação (Pontuação: 5/5)

Justificativa:

O relatório mantém um tom profissional, concentrando-se em fatos observáveis (falta de perguntas finais, uso de termos técnicos etc.). Não há julgamento pessoal do operador; as críticas são sempre pautadas em conformidade ou não com as diretrizes. Isso demonstra clareza de critérios e foco no comportamento, não em opiniões subjetivas.

Evidências do Relatório:

- “Não houve questionamento para confirmar se o cliente estava satisfeito [...]” (apenas descreve o fato de não ter ocorrido).
- “A inclusão de termos técnicos pode ter confundido o cliente [...]” (respalda-se na situação objetiva da chamada, sem adjetivações pessoais sobre o operador).

---

6. Cobertura da Avaliação (Pontuação: 5/5)

Justificativa:

O relatório aborda todos os pontos relevantes da transcrição: coleta de dados, cordialidade, validação das informações, condução do atendimento, fechamento. Não parece haver omissões de momentos críticos, pois menciona inclusive a urgência do cliente e a necessidade de empatia em face de uma interrupção de energia que impacta o negócio.

Evidências do Relatório:

- Menção ao “prazo de resolução de aproximadamente 9h30” e a forma como foi comunicado.
- Observação quanto à “natureza de emergência da situação” (queda de energia e possíveis perdas).
- Referência à “falta de sondagens para feedback do cliente” e às “informações essenciais necessárias para processar o problema”.

---

7. Consistência Interna (Pontuação: 5/5)

Justificativa:

Não há contradição entre as diferentes seções do relatório. As conclusões na “Análise das Diretrizes de Serviço” estão alinhadas às “Áreas para Melhoria” e às

“Recomendações Específicas”. As seções são coerentes entre si: as observações de “Não Conforme” reaparecem de forma lógica nas sugestões de melhoria.

Evidências do Relatório:

- A diretriz nº 3 (oferta de ajuda adicional) é indicada como “Não Conforme”, e no feedback recomenda-se “perguntar se há algo mais com que o cliente precise de ajuda”.
- A diretriz nº 10 (clareza das informações) é “Não Conforme”; no mesmo sentido, surge a recomendação de “Workshops de Habilidades de Comunicação”.

Pontuação Total: 34/35

Observações Finais

O relatório é muito bem estruturado e aborda todos os pontos relevantes da chamada. Ele demonstra clareza, organização e boa profundidade na análise de cada diretriz. O único aspecto que impediu a pontuação máxima foi a falta de citações diretas da transcrição para embasar cada constatação (apesar de as menções estarem coerentes com o que foi discutido). No geral, trata-se de um relatório robusto, com alto nível de objetividade, que oferece recomendações específicas e bem fundamentadas para melhoria contínua do atendimento.

AVALIAÇÃO DO CLAUDE 3.5 SONNET

Avaliação do Relatório de Qualidade

1. Aderência à Estrutura (Pontuação: 5/5)

Justificativa: O relatório segue perfeitamente a estrutura solicitada, com todas as seções e subseções organizadas na ordem correta. **Evidências:** Contém todas as seções principais:

- Resumo da Chamada (com principal motivo, pontos-chave e resolução)
- Análise das Diretrizes (com todas as 10 diretrizes analisadas)
- Feedback do Operador (pontos fortes e áreas de melhoria)
- Informações Adicionais
- Conclusão

2. Fundamentação com Evidências (Pontuação: 3/5)

Justificativa: Embora o relatório faça análises detalhadas, falta incluir mais citações diretas da transcrição para fundamentar as avaliações. **Evidências:**

- Menciona situações como "termos técnicos não explicados" sem citar exemplos específicos

- Afirma que "o operador demonstrou paciência" sem exemplificar com trechos da conversa

3. Análise das Diretrizes (Pontuação: 5/5)

Justificativa: Todas as diretrizes foram analisadas com profundidade consistente e avaliação clara de conformidade. **Evidências:**

- Cada diretriz possui seção própria com análise e status de conformidade
- Avaliações equilibradas, identificando tanto pontos positivos quanto negativos
- Justificativas claras para cada status de conformidade

4. Especificidade das Recomendações (Pontuação: 4/5)

Justificativa: As recomendações são específicas e bem conectadas às análises, mas algumas poderiam ser mais detalhadas. **Evidências:**

- Recomendação específica sobre "workshops de habilidades de comunicação"
- Sugestão concreta de "desenvolver protocolos de fechamento"

5. Objetividade na Avaliação (Pontuação: 5/5)

Justificativa: Mantém consistentemente um tom objetivo e profissional, baseando avaliações em critérios claros. **Evidências:**

- Usa linguagem neutra e técnica
- Avaliações baseadas em comportamentos observáveis
- Status de conformidade claramente definidos

6. Cobertura da Avaliação (Pontuação: 4/5)

Justificativa: Aborda todos os aspectos principais da interação, com pequenas omissões. **Evidências:**

- Analisa aspectos técnicos e interpessoais
- Considera o contexto de emergência do cliente
- Falta maior detalhamento sobre alguns aspectos técnicos específicos do atendimento

7. Consistência Interna (Pontuação: 5/5)

Justificativa: Mantém coerência total entre todas as seções, sem contradições. **Evidências:**

- As áreas de melhoria identificadas nas diretrizes são refletidas nas recomendações
- A conclusão sintetiza adequadamente os pontos levantados anteriormente
- Avaliações de conformidade são consistentes com as análises apresentadas

Pontuação Total: 31/35

Observações Finais:

O relatório demonstra excelente qualidade estrutural e analítica, com destaque para sua organização, objetividade e consistência. As principais áreas de melhoria são:

1. Inclusão de mais citações diretas da transcrição
2. Maior detalhamento em algumas recomendações específicas
3. Aprofundamento da análise de aspectos técnicos do atendimento

O relatório cumpre seu objetivo de fornecer uma avaliação abrangente e útil do atendimento, oferecendo insights actionáveis para melhoria do serviço.