Matheus Gomes Diniz Andrade

Metodologia Orientada a Grandes Modelos de Linguagens para Extração de Conhecimento em Textos Acadêmicos

Natal – RN

Janeiro de 2025

Matheus Gomes Diniz Andrade

Metodologia Orientada a Grandes Modelos de Linguagens para Extração de Conhecimento em Textos Acadêmicos

Trabalho de Conclusão de Curso de Engenharia de Computação da Universidade Federal do Rio Grande do Norte, apresentado como requisito parcial para a obtenção do grau de Bacharel em Engenharia de Computação.

Orientador: Prof. Dr. Ivanovitch Medeiros Dantas da Silva

Universidade Federal do Rio Grande do Norte – UFRN

Departamento de Engenharia de Computação e Automação – DCA

Curso de Engenharia de Computação

Natal – RN

Janeiro de 2025

Universidade Federal do Rio Grande do Norte - UFRN
Sistema de Bibliotecas - SISBI
Catalogação de Publicação na Fonte. UFRN - Biblioteca Central Zila Mamede

Andrade, Matheus Gomes Diniz.
Metodologia Orientada a Grandes Modelos de Linguagens para Extração de Conhecimento em Textos Acadêmicos / Matheus Gomes Diniz Andrade. - 2025.
63f.: il.

Monografia (Graduação) - Universidade Federal do Rio Grande do Norte, Centro de Tecnologia, Engenharia de Computação, Natal, 2025.
Orientação: Prof. Dr. Ivanovitch Medeiros Dantas da Silva.

1. Recuperação de Informações - Monografia. 2. Grandes Modelos de Linguagem - Monografia. 3. Bancos de Dados Vetoriais - Monografia. 4. Objetivos de Desenvolvimento Sustentável - Monografia. 5. Processamento de Linguagem Natural - Monografia. I. Silva, Ivanovitch Medeiros Dantas da. II. Título.

RN/UF/BCZM CDU 004

Elaborado por Raimundo Muniz de Oliveira - CRB-15/429

Matheus Gomes Diniz Andrade

Metodologia Orientada a Grandes Modelos de Linguagens para Extração de Conhecimento em Textos Acadêmicos

Trabalho de Conclusão de Curso de Engenharia de Computação da Universidade Federal do Rio Grande do Norte, apresentado como requisito parcial para a obtenção do grau de Bacharel em Engenharia de Computação.

Orientador: Prof. Dr. Ivanovitch Medeiros Dantas da Silva

Trabalho aprovado. Natal – RN, 16 de Janeiro de 2025:

Prof. Dr. Ivanovitch Medeiros Dantas da Silva - Orientador
UFRN

Dr. Breno Santana Santos - Convidado
UFS

Prof. Dr. Elias Jacob de Menezes Neto - Convidado
UFRN

Prof. Dr. Marcos Cesar Madruga Alves Pinheiro - Convidado
UFRN

Natal – RN

Janeiro de 2025

Dedico este trabalho a minha família, em especial a meus pais, por todo apoio durante a minha trajetória acadêmica.

AGRADECIMENTOS

Primeiramente, agradeço a Deus pelo dom da vida e por ter me dado a oportunidade de chegar onde jamais imaginei, e a Nossa Senhora por me acompanhar em toda minha trajetória.

Aos meus pais, Maria Rozelia Gomes Andrade e Paulo Salviano Diniz Andrade, pelo amor, pelos valores que me transmitiram e pelo apoio constante aos meus estudos, que foram fundamentais para que eu pudesse chegar até aqui.

À minha namorada, companheira e confidente, Sabrinne Sampaio, pela paciência, compreensão e encorajamento ao longo dessa caminhada. Sua presença tornou os desafios mais leves e as vitórias ainda mais especiais.

À minha prima Débora Darciane, por seu companheirismo nos primeiros anos de Graduação, que foram essenciais para meu crescimento pessoal e para que eu me adaptasse a essa nova fase da vida.

Ao meu orientador, professor Ivanovitch Medeiros Dantas da Silva, por todas as oportunidades proporcionadas ao longo desta jornada. Pela dedicação em guiar meus passos e pelo incentivo constante que me motivou a superar desafios e alcançar meus objetivos acadêmicos.

A Marianne Diniz e Breno Santos, pelas orientações, trocas de conhecimento e experiência. Por serem fontes de inspiração e motivação para o meu crescimento acadêmico e pessoal.

Aos professores Luiz Affonso Henderson Guedes de Oliveira, Carlos Manuel Dias Viegas, Adrião Duarte Dória Neto e Ignacio Sánchez Gendriz, por todos os ensinamentos compartilhados.

Aos meus amigos do grupo de pesquisa Conect2ai, em especial Miguel Euripedes, Thaís Medeiros, Morsinaldo Medeiros, Gisliany Alves, Hilton Thallyson e Fellipe Milomem, pelo apoio, trocas de ideias e ajuda ao longo dessa caminhada acadêmica.

À todos que, direta ou indiretamente, contribuíram para a minha formação.

"Atrás das dificuldades é que a gente acaba encontrando mais força, mais certeza daquilo que a gente realmente quer."

(Ayrton Senna)

RESUMO

O crescimento exponencial da produção científica nas últimas décadas, impulsionado pela ampla disponibilidade de periódicos online e pela necessidade de progressão acadêmica, tem gerado um grande volume de publicações acadêmicas. Devido a esse crescimento, o acesso eficiente a informações acadêmicas tornou-se um desafio significativo. Os sistemas tradicionais de recuperação de informações acadêmicas dependem fortemente de palavras-chave fornecidas pelos autores, o que pode introduzir vieses e limitar a diversidade e a relevância dos resultados. Nesse contexto, o presente trabalho propõe uma metodologia baseada em Grandes Modelos de Linguagem (LLMs, do inglês, *Large Language Models*) para otimizar a recuperação de informações em bases de dados acadêmicas. A metodologia desenvolvida integra técnicas de Geração Aumentada por Recuperação (RAG, do inglês, *Retrieval-Augmented Generation*) e análise semântica para consultas em linguagem natural. Com o uso de ferramentas como LangChain e ChromaDB, a metodologia foi projetada para incluir filtros baseados em metadados e alinhar as buscas aos Objetivos de Desenvolvimento Sustentável (ODS). O processo também emprega técnicas de pré-processamento e armazenamento vetorial, garantindo eficiência na indexação e recuperação de dados. Os resultados do estudo de caso indicam que a metodologia aplicada permite consultas personalizadas e respostas precisas. O sistema foi capaz de realizar buscas complexas, combinando múltiplos critérios como categoria, ano de publicação, autor, orientador e ODS. Além disso, a abordagem mostrou-se eficiente em termos de custos, havendo um custo máximo de $0.001385 nas consultas utilizadas como testes.

Palavras-chaves: Recuperação de Informações; Grandes Modelos de Linguagem ; Bancos de Dados Vetoriais; Objetivos de Desenvolvimento Sustentável; Processamento de Linguagem Natural.

ABSTRACT

The exponential growth of scientific production in recent decades, driven by the widespread availability of online journals and the need for academic progression, has generated a large volume of academic publications. Due to this growth, efficient access to academic information has become a significant challenge. Traditional academic information retrieval systems heavily rely on keywords provided by authors, which can introduce biases and limit the diversity and relevance of the results. In this context, this work proposes a methodology based on Large Language Models (LLMs) to optimize information retrieval in academic databases. The developed methodology integrates Retrieval-Augmented Generation (RAG) techniques and semantic analysis for natural language queries. Using tools such as LangChain and ChromaDB, the methodology was designed to include metadata-based filters and align searches with the Sustainable Development Goals (SDGs). The process also employs preprocessing and vector storage techniques, ensuring efficiency in data indexing and retrieval. The results of the case study indicate that the applied methodology enables personalized queries and precise responses. The system was able to perform complex searches, combining multiple criteria such as category, publication year, author, advisor, and SDGs. Additionally, the approach proved to be cost-efficient, with a maximum cost of $0.001385 in the test queries.

Keywords: Information Retrieval; Large Language Models (LLMs); Vector Databases; Sustainable Development Goals (SDGs); Natural Language Processing (NLP).

LISTA DE ILUSTRAÇÕES

Figura 1 – Indexação no banco de dados vetorial 23
Figura 2 – Estrutura clássica de um sistema com uso de RAG. 26
Figura 3 – Exemplo de funcionamento do *Self-querying Retriever*. 27
Figura 4 – Indexação no banco de dados vetorial 31
Figura 5 – Exemplo de documento armazenado. 33

LISTA DE TABELAS

Tabela 1 – Metadados utilizados no sistema de consulta 28
Tabela 2 – *Prompt* para o Sistema 35
Tabela 3 – Custos máximos de consultas baseados no número de requisições . . . 59

LISTA DE ABREVIATURAS E SIGLAS

API	*Application Program Interface*
CSV	*Comma-separated Values*
HTML	*HyperText Markup Language*
IA	Inteligência Artificial
LCEL	*LangChain Expression Language*
LLM	*Large Language Model*
ODS	Objetivos de Desenvolvimento Sustentável
QA	*Question-Answering*
RAG	*Retrieval-Augmented Generation*
UFRN	Universidade Federal do Rio Grande do Norte
URL	*Uniform Resource Locator*

SUMÁRIO

1 INTRODUÇÃO . . . 14
1.1 Contextualização . . . 14
1.2 Problemática . . . 15
1.3 Objetivos . . . 16
1.4 Justificativa . . . 16
1.5 Classificação da Pesquisa . . . 17
1.6 Organização do Texto . . . 17

2 FUNDAMENTAÇÃO TEÓRICA . . . 18
2.1 Recuperação de Informações . . . 18
2.2 Processamento de Linguagem Natural . . . 19
2.2.1 Modelos de Linguagem de Grande Escala . . . 19
2.2.2 *Transformer* . . . 20
2.2.3 *Embeddings* . . . 20
2.3 Banco de Dados Vetoriais . . . 20
2.4 *Retrieval-Augmented Generation* . . . 21
2.5 Trabalhos Relacionados . . . 21

3 ABORDAGEM PROPOSTA . . . 23
3.1 Aquisição dos Dados . . . 24
3.1.1 Coleta dos Dados Brutos . . . 24
3.1.2 Pré-processamento dos Dados . . . 25
3.1.3 Armazenamento em Base Vetorial . . . 25
3.2 Desenvolvimento do Sistema de Consultas . . . 26
3.2.1 *Self-Querying Retriever* . . . 27
3.2.2 Integração com a OpenAI . . . 28
3.2.3 Definição do *Prompt* . . . 29

4 PROVA DE CONCEITO . . . 30
4.0.1 Coleta dos Dados Brutos . . . 30
4.0.2 Pré-processamento dos Dados . . . 32
4.0.3 Armazenamento em Base Vetorial . . . 33
4.0.4 Integração com a OpenAI . . . 34
4.0.5 Definição do *Prompt* . . . 34

5 RESULTADOS E DISCUSSÕES . . . 37

5.1 Preparação **37**
5.2 Consultas relacionadas a um metadado **37**
5.2.1 Consultas relacionadas à categoria 37
5.2.2 Consultas relacionadas ao título 41
5.2.3 Consultas relacionadas ao autor 42
5.2.4 Consultas relacionadas ao orientador 43
5.2.5 Consultas relacionadas ao ano de defesa 46
5.2.6 Consultas relacionadas ao ODS 49
5.3 Consultas relacionadas a múltiplos metadados **51**
5.4 Consultas relacionadas ao conteúdo armazenado **55**
5.5 Custos **58**

6 CONCLUSÃO **60**

REFERÊNCIAS **61**

1 INTRODUÇÃO

Neste capítulo, busca-se apresentar o contexto geral da pesquisa, destacando a importância da recuperação eficiente de informações acadêmicas em um cenário marcado pelo crescimento exponencial de dados disponíveis. Em particular, são discutidas as abordagens baseadas em Inteligência Artificial (IA) para consultas avançadas, combinando múltiplos critérios, como metadados e análise semântica de conteúdo. Além disso, introduz-se a problemática enfrentada neste trabalho, os objetivos definidos, a justificativa para a pesquisa, fornecendo uma base sólida para as discussões subsequentes.

1.1 Contextualização

As publicações científicas constituem a base das realizações acadêmicas e do avanço do conhecimento. O crescimento exponencial de publicações nas últimas décadas é um reflexo de múltiplos fatores, como os requisitos para progressão acadêmica e a ampla disponibilidade de periódicos *online* (DEBNATH; DEBNATH; PATRIKAR, 2023). Esse aumento na produção científica tem gerado a necessidade de ferramentas mais eficientes para acessar e organizar informações relevantes em um volume crescente de dados.

Nesse cenário, a integração de tecnologias de IA tem desempenhado um papel fundamental na transformação dos sistemas acadêmicos de recuperação de informações (KINI et al., 2024). Estudos recentes destacam que técnicas como aprendizado de máquina, processamento de linguagem natural e aprendizado profundo têm proporcionado avanços significativos em acessibilidade, personalização e experiência do usuário (KINI et al., 2024).

Além disso, a IA tem impactado os processos de educação e formação (KALLOGIANNAKIS et al., 2023). Seu uso oferece novas possibilidades para o ensino e a pesquisa, ao mesmo tempo em que levanta preocupações éticas e pedagógicas sobre sua aplicação (KALLOGIANNAKIS et al., 2023). Essas questões ressaltam a necessidade de um uso responsável e bem fundamentado dessas tecnologias no ambiente acadêmico.

Entre as inovações mais recentes, ferramentas de IA generativa, como o ChatGPT, destacam-se pelo potencial impacto nos serviços acadêmicos (KHAN et al., 2023). Com funcionalidades avançadas, como interação conversacional, classificação de conteúdo e suporte a pesquisas, essas ferramentas estão redefinindo os limites da busca e organização de informações científicas (KHAN et al., 2023). Tal evolução pode auxiliar as bibliotecas acadêmicas a se adaptarem ao cenário da tecnologia em constante mudança (KHAN et al., 2023).

Um exemplo promissor de inovação na área de recuperação de informações é a técnica conhecida como *Retrieval-Augmented Generation* (RAG), que combina o uso de modelos de linguagem de grande escala com bases externas de conhecimento, permitindo que as respostas geradas pelos modelos sejam enriquecidas com informações relevantes e confiáveis provenientes de fontes externas (NASSIRI; AKHLOUFI, 2024).

1.2 Problemática

Os sistemas acadêmicos de recuperação de informações dependem fortemente das palavras-chave fornecidas pelos autores (CHAMORRO-PADIAL; RODRíGUEZ-SáNCHEZ, 2023). Embora amplamente utilizados, esses critérios podem introduzir diversos vieses, limitando a diversidade e a relevância das informações recuperadas (CHAMORRO-PADIAL; RODRíGUEZ-SáNCHEZ, 2023).

Apesar dos avanços na área, obstáculos significantes ainda persistem (AI et al., 2023). Entre eles, estão os altos custos computacionais, preocupações relacionadas à credibilidade dos resultados, limitações no desempenho em domínios específicos e questões éticas que precisam ser abordadas de forma abrangente (AI et al., 2023).

Além disso, organizações enfrentam dificuldades ao integrar os Objetivos de Desenvolvimento Sustentável (ODS) em suas agendas estratégicas (BERRONE et al., 2023). Apesar da existência de diretrizes e *frameworks* criados para orientar essas iniciativas, muitas vezes essas orientações carecem do suporte científico mais aprofundado, o que pode comprometer a qualidade e a relevância das ações implementadas (BERRONE et al., 2023).

Diante dessa perspectiva, propõe-se uma abordagem fundamentada no uso de Modelos de Linguagem de Grande Escala para aprimorar a recuperação de informações em sistemas acadêmicos. Essa solução busca superar as limitações dos métodos tradicionais ao integrar consultas em linguagem natural, permitindo uma interação mais intuitiva e contextualizada. Espera-se que essa abordagem otimize o processo de busca, tornando a obtenção de informações relevantes mais eficiente e acessível aos usuários. Adicionalmente, inclui-se como aspecto relevante a integração dos Objetivos de Desenvolvimento Sustentável como um critério de busca na abordagem proposta.

Portanto, este trabalho concentra-se na abordagem de recuperação de informações acadêmicas baseada em Inteligência Artificial, com foco na integração de consultas complexas que combinem filtros de metadados, análise semântica e alinhamento com os Objetivos de Desenvolvimento Sustentável. O objetivo é não apenas superar as limitações dos sistemas tradicionais, mas também oferecer uma abordagem que equilibre eficiência e precisão, atendendo às demandas de um ambiente acadêmico em constante evolução.

1.3 Objetivos

O objetivo geral deste trabalho é propor e avaliar uma metodologia para a recuperação de informações acadêmicas baseada em Inteligência Artificial, que integre consultas por metadados e análise semântica, visando auxiliar na melhoria dos sistemas de recuperação de informação, por meio de uma análise de viabilidade de incorporação de RAG e LLMs em tais sistemas. Para isso, foi desenvolvido e avaliado um sistema de recuperação de informação acadêmica, baseado em IA, que combina consultas por metadados e análise semântica, a fim de melhorar eficiência e precisão na busca. Para alcançar esse propósito, este estudo se orienta nos seguintes objetivos específicos:

- Desenvolver uma abordagem que integre consultas personalizadas, aplicando filtros como categoria, ano de publicação e palavras-chave, além de incorporar análise semântica.
- Incorporar os Objetivos de Desenvolvimento Sustentável como um critério nas consultas, permitindo a recuperação de informações alinhadas a temas e metas relacionadas aos ODS.
- Conduzir uma prova de conceito que analise a precisão dos resultados, os custos computacionais das consultas e a capacidade do sistema em atender a cenários complexos e personalizáveis de busca acadêmica.

1.4 Justificativa

As tecnologias de IA generativa, como o ChatGPT, estão transformando o ambiente acadêmico ao oferecer suporte personalizado para estudantes e pesquisadores (CHAN; HU, 2023). Sua capacidade de fornecer suporte individualizado ao aprendizado tem promovido maior eficiência e acessibilidade na execução de tarefas acadêmicas tem sido notória (CHAN; HU, 2023).

Esse impacto reflete a tendência mais ampla da aplicação de IA em ambientes de informação, como bibliotecas, onde sistemas baseados em IA têm demonstrado potencial para revolucionar a forma como os usuários acessam o conhecimento (BARSHA; MUNSHI, 2024). Com funcionalidades como recomendações inteligentes e navegação personalizada, a IA não apenas facilita o acesso a informações, mas também aprimora a experiência do usuário, tanto para estudantes quanto para profissionais (BARSHA; MUNSHI, 2024).

Desse modo, surge uma oportunidade para o desenvolvimento de uma abordagem que vise a recuperação de informações específicas para o meio acadêmico, utilizando modelos de linguagem de grande escala. Em um contexto em que o volume de publicações cresce exponencialmente (DEBNATH; DEBNATH; PATRIKAR, 2023), essa abordagem

podem desempenhar um papel essencial na organização e acessibilidade do conhecimento, facilitando o avanço acadêmico e científico.

1.5 Classificação da Pesquisa

Para alcançar os objetivos deste estudo, foi essencial adotar uma classificação metodológica que integrasse abordagens qualitativas e quantitativas, garantindo uma análise abrangente e bem fundamentada. A análise qualitativa centrou-se na avaliação da relevância e adequação dos resultados retornados pelo sistema em diferentes cenários de consulta. Por outro lado, a análise quantitativa utilizou o custo monetário associado ao processamento de consultas.

A natureza desta pesquisa é aplicada, uma vez que busca resolver problemas práticos relacionados à recuperação de informações em ambientes acadêmicos. O desenvolvimento da metodologia proposta visa superar as limitações dos métodos tradicionais, introduzindo uma solução que integre filtros por metadados e análise semântica, oferecendo uma alternativa prática e efetiva para pesquisadores e usuários de bases de dados.

Os objetivos deste trabalho também são exploratórios, com foco na investigação das potencialidades de ferramentas de Inteligência Artificial para lidar com consultas complexas. Essa abordagem permite analisar detalhadamente como a metodologia desenvolvida se adequa a diferentes cenários de consulta, destacando oportunidades de aprimoramento e pontos críticos a serem abordados.

Além disso, o método escolhido para avaliação foi uma prova de conceito, envolvendo a simulação de consultas em ambientes controlados. Esse método possibilitou a análise prática, avaliando a capacidade de atender às demandas específicas de recuperação de informações acadêmicas.

1.6 Organização do Texto

Este capítulo apresentou uma introdução sobre o tema, mostrando os fatores que motivam a implantação da ideia, além dos objetivos, justificativa, classificação da pesquisa. Em sequência, o Capítulo 2 aborda a fundamentação teórica. O Capítulo 3, por sua vez, explica a abordagem proposta para o desenvolvimento do trabalho. Posteriormente, o Capítulo 4 apresenta a prova de conceito utilizada. Em sequência, no Capítulo 5 estão presentes os resultados obtidos. Por fim, o Capítulo 6 traz as principais conclusões e contribuições deste trabalho.

2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo, são apresentados os conceitos fundamentais para a compreensão e desenvolvimento do sistema de recuperação de informações proposto. Inicialmente, explora-se a Recuperação de Informações, abordando suas características e limitações no contexto acadêmico. Em seguida, discute-se o Processamento de Linguagem Natural, com destaque para os avanços proporcionados pelos Modelos de Linguagem de Grande Escala e pela arquitetura *Transformer*, fundamentais para o entendimento semântico e geração de respostas. A importância dos *embeddings* como representações vetoriais para busca por similaridade é também analisada. Adicionalmente, são apresentados os bancos de dados vetoriais, essenciais para o armazenamento e recuperação eficiente de informações em sistemas baseados em RAG. O capítulo ainda aborda frameworks como o LangChain, utilizados para integrar fluxos de trabalho com LLMs, e técnicas de *Web Scraping*, que possibilitam a coleta de dados para alimentar o sistema. Por fim, os conceitos apresentados são conectados à solução proposta, destacando como cada elemento contribui para sua implementação e eficácia.

2.1 Recuperação de Informações

A recuperação de informações refere-se ao processo de localizar, dentro de um grande conjunto de dados, um subconjunto de documentos que atendam às necessidades específicas do usuário, conforme descritas em uma consulta textual (MOSBAH, 2023). Essa tarefa é geralmente desempenhada por sistemas automatizados, amplamente conhecidos como sistemas de recuperação de informações (MOSBAH, 2023).

Esses documentos são classificados de acordo com sua relevância, formando um *ranking* que reflete o quão bem cada documento atende aos tópicos fornecidos (JOSEPH; RAVANA, 2024). Como vários registros podem ser relevantes, os resultados são frequentemente classificados de acordo com sua pontuação de similaridade com a consulta do usuário (HAMBARDE; PROENçA, 2023).

Com os avanços no campo do Processamento de Linguagem Natural, impulsionados pelo crescente acesso a grandes volumes de dados e pelo desenvolvimento de algoritmos mais sofisticados, os sistemas de recuperação de informações têm apresentado melhorias significativas em seu desempenho (HAMBARDE; PROENçA, 2023).

2.2 Processamento de Linguagem Natural

O Processamento de Linguagem Natural (PLN) é um campo interdisciplinar que une linguística e ciência da computação, sendo também um subcampo da inteligência artificial (NAGARHALLI; VAZE; RANA, 2021). Seu objetivo principal é capacitar os computadores a compreenderem a linguagem humana, seja ela falada ou escrita (NAGARHALLI; VAZE; RANA, 2021). Ele surgiu para facilitar o trabalho dos usuários e satisfazer o desejo de se comunicar com o computador em linguagem natural, podendo ser classificado em duas partes: Compreensão da Linguagem Natural ou Linguística e Geração de Linguagem Natural, que envolve a tarefa de entender e gerar texto (KHURANA et al., 2023).

Para isso, o PLN utiliza várias etapas de análise, como a análise morfológica, que trata da formação de palavras, sintática, que estuda a estrutura das frases, semântica, que explora o significado das sentenças, e pragmática, que está relacionada à compreensão contextual, cada uma contribuindo para o entendimento preciso da linguagem em diferentes níveis (NAGARHALLI; VAZE; RANA, 2021; KHURANA et al., 2023).

Mecanismos de atenção, que permitem a uma rede aprender onde focar sua atenção de acordo com o estado oculto atual e as anotações, juntamente com o uso de Transformers, também trouxeram avanços significativos no Processamento de Linguagem Natural (KHURANA et al., 2023).

Grandes modelos de linguagem, como BERT (*Bidirectional Encoder Representations from Transformers*) e GPT (*Generative Pre-trained Transformer*), têm desempenhado um papel central na evolução do PLN (MIN et al., 2023). Esses modelos utilizam vastas quantidades de texto para aprender representações genéricas e latentes da linguagem, que podem ser adaptadas a diferentes tarefas de PLN por meio de técnicas como *fine-tuning* e *prompting* (MIN et al., 2023).

2.2.1 Modelos de Linguagem de Grande Escala

Os Modelos de Linguagem de Grande Escala, como o GPT, têm alcançado avanços expressivos no campo do PLN (KASNECI et al., 2023). Esses modelos, treinados em enormes volumes de dados textuais, são capazes de gerar textos com qualidade próxima à humana, responder perguntas e realizar outras tarefas relacionadas à linguagem com alta precisão (KASNECI et al., 2023). Um exemplo notável é o GPT-3, desenvolvido pela OpenAI, que foi treinado em cerca de 45 terabytes de dados textuais, representando um custo estimado de milhões de dólares (BARRETO et al., 2023).

Um desenvolvimento-chave no progresso dos LLMs é o uso de arquiteturas de *transformers* e do mecanismo de atenção (KASNECI et al., 2023). A arquitetura *transformer* utiliza o mecanismo de autoatenção (*self-attention*), que permite ao modelo identificar as

partes mais relevantes de uma entrada ao fazer previsões (KASNECI et al., 2023).

2.2.2 *Transformer*

Inicialmente introduzida por Vaswani et al. (2023), a arquitetura conhecida como *transformer* revolucionou o campo do PLN ao substituir as camadas recorrentes e convolucionais, tradicionalmente usadas, por um mecanismo de autoatenção (*self-attention*). Essa abordagem permite que os modelos processem sequências de maneira mais eficiente, conectando todas as posições de entrada e saída com um número constante de operações sequenciais (VASWANI et al., 2023).

Um dos principais diferenciais do *transformer* está na sua capacidade de lidar com dependências de longo alcance (VASWANI et al., 2023). Isso é possível graças ao mecanismo de autoatenção, que reduz o "caminho"entre posições de entrada e saída, facilitando o aprendizado de relações contextuais complexas.

2.2.3 *Embeddings*

Os *word embeddings*, também chamados de representações distribuídas ou vetores de palavras, são formas compactas e densas de representar palavras em um espaço dimensional (MARS, 2022). Eles são construídos por algoritmos não supervisionados que analisam grandes volumes de texto para capturar características essenciais das palavras. Essas representações permitem que palavras sejam mapeadas para vetores numéricos, refletindo relações semânticas e sintáticas no espaço vetorial (MARS, 2022).

Segundo Mars (2022), duas abordagens principais se destacam: os *context-free embeddings* e as representações contextuais. Os primeiros, como Word2Vec ou GloVe, geram um vetor fixo para cada palavra, independentemente de como ela é usada em diferentes contextos. Já os *embeddings* contextuais, utilizados em modelos de linguagem pré-treinados como BERT, adaptam a representação da palavra ao seu contexto, permitindo que uma mesma palavra tenha diferentes vetores dependendo da frase em que aparece.

2.3 Banco de Dados Vetoriais

Os bancos de dados vetoriais são sistemas projetados especificamente para armazenar e recuperar informações no formato de vetores, que representam dados de forma numérica (KUKREJA et al., 2023). Elementos como texto, imagens, vídeos e áudios, considerados dados não estruturados, podem ser transformados em vetores de alta dimensionalidade por meio de técnicas de *embedding* (KUKREJA et al., 2023).

A principal funcionalidade dos bancos de dados vetoriais é permitir a busca eficiente de similaridades, comparando vetores de consulta com os vetores armazenados (KUKREJA

et al., 2023). Um exemplo de aplicação é em sistemas de recomendação e recuperação de informações, onde os bancos de dados vetoriais ajudam a identificar itens relevantes com base em relações semânticas em vez de simples correspondências de palavras-chave.

2.4 *Retrieval-Augmented Generation*

A ideia do RAG foi originalmente introduzida por Lewis et al. (2021), e sua popularidade cresceu significativamente com o advento de chatbots de alto desempenho como o ChatGPT. O sucesso desses sistemas demonstrou a eficácia do RAG ao integrar recuperação de informações e geração contextual. Desde então, pesquisas têm se concentrado na otimização de seus componentes funcionais, aprimorando tanto o desempenho quanto a escalabilidade de sistemas RAG.

O RAG foi desenvolvido como uma abordagem para mitigar problemas comuns enfrentados por LLMs, como alucinações factuais e recuperação de informações imprecisas (LEWIS et al., 2021; POSEDARU et al., 2024). A técnica utiliza LLMs para criar representações vetoriais (*embeddings*) do texto contido em uma base de dados confiável. Essas representações permitem buscar e localizar rapidamente trechos relevantes em resposta a uma consulta, retornando informações de maneira útil e direcionada ao usuário (KAMATH et al., 2024).

Em sua essência, um sistema baseado em RAG funciona como um *chatbot* de perguntas e respostas (*QA chatbot*), que obtém informações de uma base de dados fixa em vez de depender exclusivamente de conhecimentos memorizados durante o treinamento (KAMATH et al., 2024). Isso torna o sistema mais confiável ao fornecer informações atualizadas e possibilita sua extensão para incluir documentos que não estavam disponíveis durante o treinamento do modelo.

Tal característica o diferencia de abordagens tradicionais baseadas exclusivamente em LLMs pré-treinados (KAMATH et al., 2024). Ao integrar informações de fontes externas, o RAG expande os limites dos modelos de linguagem, permitindo que eles acessem dados atualizados e específicos (POSEDARU et al., 2024).

2.5 Trabalhos Relacionados

Nesta seção, são apresentados e analisados trabalhos da literatura que possuem relação com este estudo. Foram explorados trabalhos relevantes sobre recuperação de informações e sistemas que utilizam RAG, destacando as contribuições.

Um método interessante de recuperação de informações foi apresentado por Lechtenberg et al. (2022), que propôs uma abordagem *query-by-document* baseada na amostragem

de palavras-chave utilizando TF-IDF e Monte Carlo. Essa técnica automatizava a construção de consultas a partir de documentos de entrada, eliminando a necessidade de intervenção humana e reduzindo os vieses inerentes ao processo de formulação de consultas. Contudo, essa abordagem poderia enfrentar dificuldades ao lidar com dados de entrada que não possuam representações claras ou consistentes, o que pode comprometer a precisão dos resultados em cenários mais complexos. Ainda assim, os autores destacam a importância de desenvolver métodos que minimizassem esses vieses, evidenciando a relevância de técnicas automáticas e eficientes para melhorar a recuperação de informações em bases de dados acadêmicas.

Seguindo em direção a soluções mais avançadas, no trabalho de Li et al. (2023), foi desenvolvido o ChatDoctor, um modelo especializado na área médica. Nesse estudo, foi realizado o *fine-tuning* do modelo LLaMA utilizando um extenso conjunto de dados de diálogos médico-paciente, além de incorporar um mecanismo de recuperação de informações autônomo que acessa fontes confiáveis *online* e *offline*. Os resultados demonstraram melhorias significativas na precisão das respostas e na capacidade de atender às necessidades dos usuários, destacando a relevância de adaptar modelos de linguagem para atender às demandas específicas de diferentes domínios, promovendo maior eficácia e confiabilidade no uso de soluções baseadas em Inteligência Artificial. Apesar dos avanços apresentados, uma limitação significativa dessa abordagem é a necessidade de realizar o treinamento para incorporar novos dados ou lidar com mudanças no domínio de aplicação.

Na mesma linha de desenvolvimento de sistemas de recuperação de informação, avanços significativos puderam ser vistos em trabalhos como o apresentado por Giglou et al. (2024), que propôs um sistema de *Question-Answering* (QA) baseado em *Retrieval-Augmented Generation* integrado ao NFDI4DataScience *Gateway*. Esse sistema utiliza um LLM para oferecer interações dinâmicas com os resultados de busca. A aplicação do RAG no contexto acadêmico, combinada com o uso de um framework unificado para busca federada em bases científicas, destacou melhorias significativas na experiência do usuário e na recuperação de informações relevantes. Os autores reforçam a importância de integrar técnicas avançadas para melhorar a eficácia e acessibilidade em sistemas acadêmicos.

No entanto, abordagens comuns de RAG utilizam a similaridade direta entre a consulta fornecida pelo usuário e os documentos presentes na base de conhecimento, o que pode limitar a precisão quando a consulta é ambígua ou pouco específica. O presente trabalho busca superar essas limitações ao integrar a técnica de *self-querying retrieval*, que reformula automaticamente a consulta inicial para gerar uma representação mais precisa e contextualizada da necessidade do usuário.

3 ABORDAGEM PROPOSTA

Neste capítulo, será detalhada a abordagem proposta baseada em um sistema RAG, permitindo que consultas sejam realizadas em linguagem natural e que as respostas sejam geradas de forma contextualizada, com base em documentos acadêmicos recuperados de fontes relevantes.

Dessa forma, a metodologia visa integrar técnicas de recuperação de informações com LLM's, permitindo que seja possível de interpretar consultas em linguagem natural, recuperar dados relevantes e gerar respostas fundamentadas nos documentos acadêmicos disponíveis.

Figura 1 – Visão Geral da Abordagem Proposta.

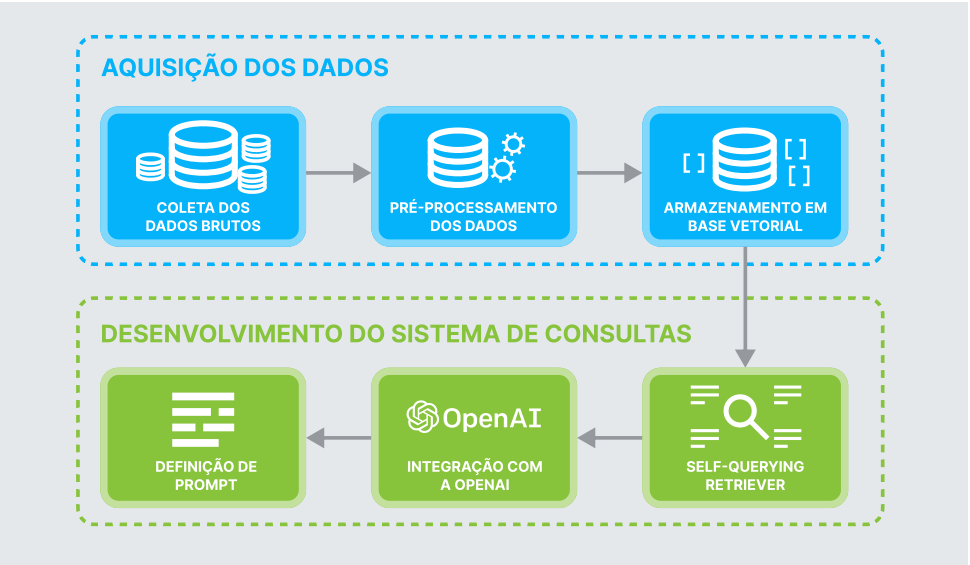

Fonte: Elaborada pelo autor (2024).

Conforme é ilustrado na Figura 1, a abordagem proposta consiste nos seguintes módulos:

- **Coleta dos Dados Brutos:** Local onde ocorre a coleta dos dados acadêmicos.
- **Pré-Processamento dos Dados:** Possibilita a realização de operações como renomeação de colunas, limpeza de valores ausentes e formatação de texto. Além disso, é o local onde os Objetivos de Desenvolvimento Sustentável são atribuídos aos trabalhos.
- **Armazenamento em Base Vetorial:** Local onde ocorre o armazenamento em uma base vetorial, permitindo indexação e geração de *embeddings*. Esse armazenamento facilita consultas baseadas em similaridade semântica.

- ***Self-Querying Retriever*:** Sistema de recuperação de informação que reformula consultas em linguagem natural para estruturas mais precisas.
- **Integração com a OpenAI:** A API da OpenAI possibilita o uso de modelos para três funções principais: a transformação de texto em embeddings, que converte textos em representações vetoriais para buscas semânticas; a construção de consultas, que traduz consultas em linguagem natural em estruturas de busca estruturadas; e a geração de respostas, que combina o conhecimento do modelo com os dados retornados pela consulta para produzir respostas contextualizadas.
- **Definição de *Prompt*:** Utilização de um *prompt* para orientar como devem ser geradas as respostas, garantindo consistência e relevância no contexto acadêmico, limitando a criação de informações fictícias.

3.1 Aquisição dos Dados

Nesta etapa, são adotadas técnicas de coleta automatizada de dados para obter informações de fontes acadêmicas relevantes. Esse processo possibilita a extração de um volume significativo de dados, que servirão como base para alimentar o sistema de recuperação de informações. A seguir, detalha-se o passo a passo da extração dos dados, bem como os critérios adotados para a seleção das fontes utilizadas.

3.1.1 Coleta dos Dados Brutos

A aquisição dos dados foi realizada por meio de técnicas de coleta automatizada de informações a partir de fontes acadêmicas disponíveis *online*. Para isso, foi utilizada uma abordagem que permite a extração estruturada de dados diretamente de páginas *web*, garantindo a obtenção de um volume significativo de informações de maneira eficiente e organizada, conforme as necessidades do projeto.

O processo de coleta foi organizado em etapas bem definidas:

- **Inicialização**: O sistema inicia acessando as URLs base e configura as funções de retorno para processar as respostas.
- **Identificação de categorias**: Em seguida, o sistema identifica e extrai as categorias de trabalhos disponíveis, como teses e dissertações, gerando novas requisições para acessar os detalhes de cada categoria.
- **Coleta de *links***: O sistema coleta os *links* para os trabalhos acadêmicos dentro de cada categoria, verificando a existência de páginas adicionais e realizando requisições subsequentes, se necessário.

- **Extração de detalhes**: Por fim, o sistema extrai os dados específicos de cada trabalho, como título, autores, data de defesa e links para download, armazenando-os de forma organizada para posterior utilização.

3.1.2 Pré-processamento dos Dados

O pré-processamento dos dados coletados é uma etapa essencial para garantir a consistência e a qualidade das informações. Em seguida, são realizadas operações de limpeza, como a identificação e substituição de valores ausentes por um padrão definido, garantindo uniformidade e compatibilidade para as etapas subsequentes.

O processo de pré-processamento inclui:

- **Renomeação de colunas**: Os nomes das colunas são ajustados para refletir melhor o conteúdo e atender às necessidades da aplicação. Por exemplo, campos como "autores" e "palavras-chave" são renomeados para facilitar a manipulação dos dados.
- **Remoção de colunas irrelevantes**: Colunas que não são úteis para a análise, como informações redundantes ou desnecessárias, são removidas para simplificar a estrutura dos dados.
- **Padronização de campos textuais**: Os dados textuais, como nomes de autores, títulos e resumos, são formatados e limpos para remover caracteres indesejados, espaços em excesso e inconsistências.
- **Atribuição de categorias temáticas**: Com base no conteúdo dos textos, são atribuídas categorias temáticas a cada trabalho acadêmico. No caso deste trabalho, foram utilizados os Objetivos de Desenvolvimento Sustentável (ODS) como critério de classificação. Cada trabalho foi associado ao ODS mais alinhado com o tema tratado, com base em uma análise do conteúdo dos resumos e títulos.

3.1.3 Armazenamento em Base Vetorial

Para o armazenamento eficiente dos dados coletados, foi utilizada uma base de dados vetorial, uma estrutura especialmente projetada para aplicações que envolvem técnicas de aprendizado de máquina e processamento de linguagem natural. Esse tipo de banco de dados permite a indexação de documentos e a geração de *embeddings*, que são representações vetoriais de textos, facilitando a recuperação de informações baseadas em similaridade semântica.

No contexto deste trabalho, os dados coletados são processados em formato de documentos, incluindo informações textuais como títulos, resumos (em português e inglês)

e palavras-chave dos trabalhos acadêmicos. Além disso, são armazenados metadados associados a cada documento:

- **Categoria**: Indica se o trabalho é de mestrado ou doutorado.
- **Título**: O título do trabalho acadêmico.
- **Autor**: Nome completo do autor do trabalho.
- **Orientador**: Nome completo do orientador do trabalho.
- **Ano de defesa**: Ano em que o trabalho foi defendido.
- **ODS**: Objetivo de Desenvolvimento Sustentável associado ao trabalho.

3.2 Desenvolvimento do Sistema de Consultas

Com os dados armazenados em formato vetorial na base de dados, foi possível implementar um sistema de recuperação de informação, que utiliza técnicas baseadas em similaridade semântica. O sistema foi projetado para permitir que os usuários realizem buscas nos documentos indexados, explorando tanto o conteúdo textual dos trabalhos acadêmicos quanto os metadados associados, como autor, orientador e ano de defesa.

A abordagem adotada no desenvolvimento deste trabalho é baseada na técnica RAG, que combina a capacidade de modelos de linguagem de grande escala em gerar respostas com a recuperação de documentos relevantes. Essa combinação garante que as respostas fornecidas pelo sistema sejam não apenas baseadas na similaridade semântica, mas também enriquecidas com o conteúdo mais apropriado disponível na base de dados.

Figura 2 – Estrutura clássica de um sistema com uso de RAG.

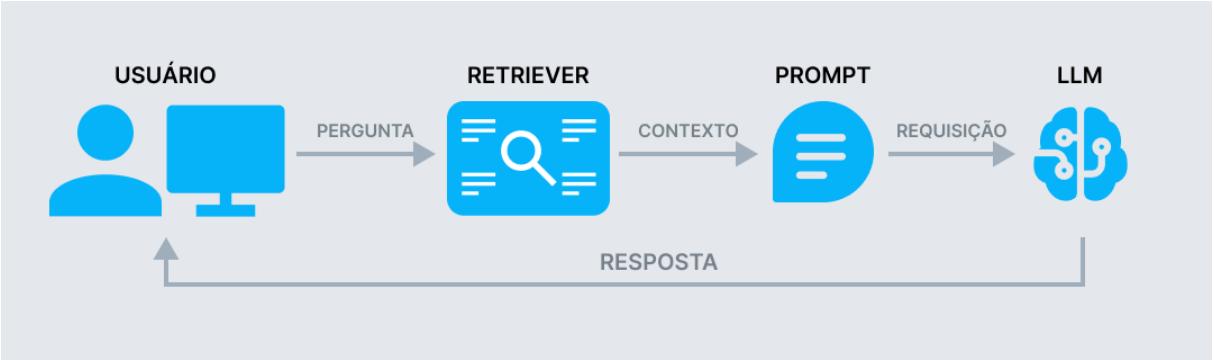

Fonte: Elaborada pelo autor (2025).

Na Figura 2 está ilustrada a estrutura básica de um sistema RAG, que combina a recuperação de informações com a geração de respostas contextualizadas. Os principais módulos envolvidos no processo são:

- **Usuário**: Inicia o processo ao fazer uma pergunta em linguagem natural.
- ***Retriever***: Responsável por recuperar os documentos mais relevantes da base de dados com base na similaridade semântica da pergunta.
- ***Prompt***: Define as diretrizes para a geração da resposta, garantindo que o modelo de linguagem siga um formato específico e evite a criação de informações inexistentes.
- **LLM**: Utiliza o contexto fornecido pelo *Retriever* e as diretrizes do *Prompt* para gerar uma resposta contextualizada e precisa.

O uso do RAG possibilita que o sistema não dependa exclusivamente da base de conhecimento estática dos LLMs, mas também busque informações atualizadas e específicas armazenadas no vetor de documentos. Essa abordagem é particularmente útil em sistemas acadêmicos, nos quais a precisão e a relevância da informação são essenciais.

3.2.1 *Self-Querying Retriever*

Neste trabalho, a abordagem proposta adota um sistema de *retriever* mais avançado, conhecido como *self-querying retriever*. Esse sistema, ao receber uma consulta em linguagem natural, utiliza uma cadeia de construção de consultas, gerada por um modelo de linguagem, para formular uma consulta estruturada.

Figura 3 – Exemplo de funcionamento do *Self-querying Retriever*

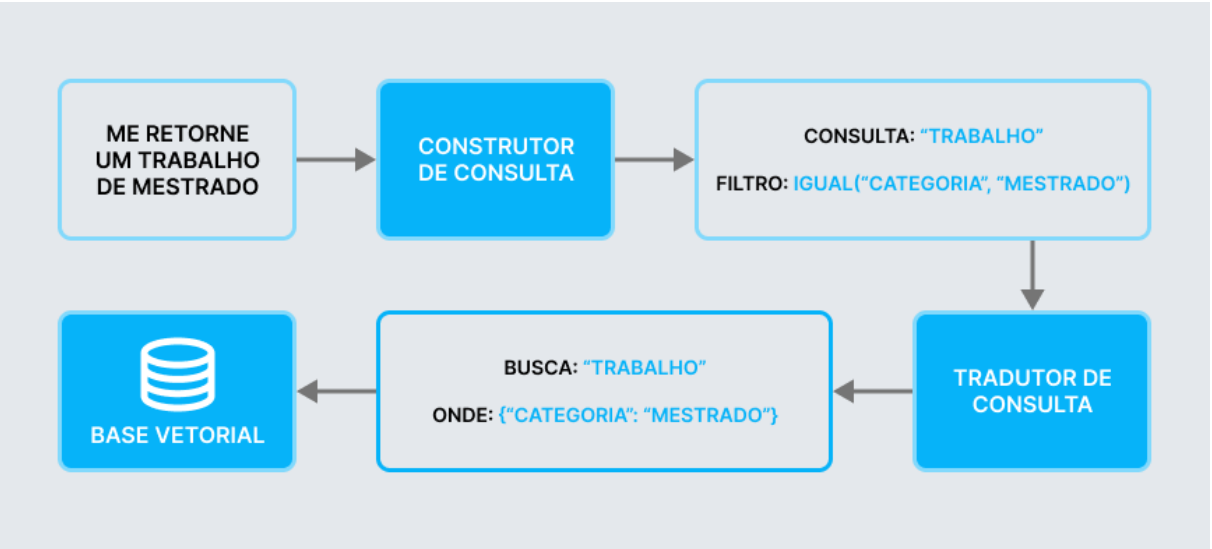

Fonte: Elaborada pelo autor (2025).

A Figura 3 exemplifica o funcionamento do *self-querying retriever*. Esse *retriever* possibilita a criação de consultas mais precisas e refinadas, uma vez que permite ao sistema gerar automaticamente a própria consulta com base nos metadados dos documentos, além de considerar o conteúdo textual propriamente dito. Por intermédio dessa abordagem,

o modelo é capaz de interpretar a intenção contida na consulta do usuário e ajustar a busca, priorizando campos específicos ou atributos relevantes conforme os parâmetros predefinidos.

Os principais diferenciais em relação a um sistema de RAG tradicional residem na presença de dois elementos-chave, um construtor de consulta e um tradutor de consulta (LANGCHAIN, 2024). O construtor de consulta permite a formação de perguntas mais elaboradas, enquanto o tradutor de consulta converte a intenção do usuário em comandos que o sistema pode entender e processar adequadamente. Essa sinergia entre metadados e processamento de linguagem natural resulta em um sistema de recuperação de informações mais robusto e eficiente.

3.2.2 Integração com a OpenAI

Para a criação do construtor de consulta, foi utilizado um modelo de linguagem da `OpenAI`, configurado para gerar respostas determinísticas e consistentes. A configuração do modelo foi ajustada para reduzir a variabilidade das respostas, garantindo que elas fossem precisas e alinhadas às necessidades do sistema. Essa abordagem permite que as consultas sejam processadas de forma eficiente, com foco em resultados confiáveis e relevantes.

Já para o tradutor de consulta, utiliza-se a classe para permitir a tradução de elementos de linguagem de consulta do banco vetorial escolhido para filtros válidos. Adicionalmente, para um melhor funcionamento do *retriever*, é recomendada a passagem de informações para o *retreiver* acerca dos metadados presentes na base. Isso é possível com o uso de uma classe específica que permita criar informações sobre os metadados a partir do nome, descrição e tipo da variável, como pode ser observado na Tabela 1.

Tabela 1 – Metadados utilizados no sistema de consulta

Nome	**Tipo**	**Descrição**
`category`	`string`	A categoria do trabalho se refere ao nível que pode ser doutorado ou mestrado. Deve ser buscado como um valor entre [PhD, MSc].
`title`	`string`	O título do trabalho.
`author`	`string`	O nome do autor do trabalho.
`advisor`	`string`	O nome do orientador do trabalho.
`defense_date_year`	`integer`	O ano da defesa do trabalho.
`ods`	`integer`	Número do ODS relacionado ao trabalho. Pode ser um valor entre 1 e 17.

Fonte: Elaborada pelo autor (2025).

A definição rigorosa dos tipos de dados e atributos permite a aplicação de filtros complexos nas consultas, como operadores de comparação (por exemplo, “maior que” ou

"menor que") para campos numéricos. Isso contribui para um sistema de consulta mais robusto e confiável, capaz de lidar com buscas personalizadas e específicas.

3.2.3 Definição do *Prompt*

No desenvolvimento do sistema, foi criada uma cadeia de operações, que permite encadear chamadas de diferentes componentes do sistema de forma modular. Essa cadeia é essencial para a execução de tarefas complexas, como a transformação de consultas, a recuperação de documentos e a geração de respostas.

Para otimizar o desempenho do sistema, foi incorporado à cadeia um *prompt* que orienta a formatação das respostas. O *prompt* atua como uma diretriz clara, definindo as expectativas do modelo em relação ao formato e ao conteúdo das respostas. Isso é fundamental para garantir que as respostas sejam consistentes, relevantes e precisas, evitando que o modelo gere informações inexistentes ou fora do contexto.

O *prompt* foi principalmente desenvolvido para para limitar o escopo das respostas a perguntas relacionadas a trabalhos acadêmicos, evitando desvios do tema, evitar criação de respostas sem contexto, garantindo que o modelo nunca crie informações, e formatar as respostas em um padrão específico, incluindo título, autor, orientador, resumo, palavras-chave e Objetivo de Desenvolvimento Sustentável associado ao trabalho.

4 PROVA DE CONCEITO

A prova de conceito realizada neste trabalho é detalhada nas seções a seguir, abordando os procedimentos de preparação necessários para a condução da metodologia proposta. Para o desenvolvimento da metodologia proposta, foi essencial dispor de uma base de dados acadêmicos relevante. Assim, a estrutura experimental do estudo foi elaborada com foco na coleta e análise de documentos acadêmicos provenientes do Programa de Pós-Graduação em Engenharia Elétrica e de Computação da UFRN. Para a aquisição dos dados a técnicas escolhida foi a de *web scraping*.

4.0.1 Coleta dos Dados Brutos

O *web scraping* é uma técnica utilizada para extrair dados e armazená-los em sistemas de arquivos ou bancos de dados, permitindo análises ou consultas posteriores (ZHAO, 2022). Essa técnica pode ser realizada manualmente ou por meio de *bots* e *web crawlers* automatizados, utilizando protocolos como o HTTP ou navegadores *web*. Dado o volume crescente de dados heterogêneos disponíveis na internet, o *web scraping* tem se destacado como uma abordagem eficiente para a coleta de grandes volumes de informações (ZHAO, 2022).

Além disso, as tecnologias de *web scraping* evoluíram significativamente, passando de processos pequenos e assistidos por humanos para sistemas automatizados capazes de transformar websites inteiros em conjuntos de dados estruturados e organizados, atendendo a diferentes cenários e necessidades de coleta (ZHAO, 2022).

Nesse sentido, fora utilizado o framework `Scrapy`, uma ferramenta que possibilita a captura automatizada de dados diretamente de páginas *web*, baseada no framework de rede assíncrona Twisted, que permite o processamento simultâneo de tarefas (GAO; MENG, 2023). Essa abordagem elimina o tempo de espera excessivo durante as requisições, evitando desperdício de recursos. Uma de suas principais vantagens é o suporte a operações assíncronas, permitindo que requisições sejam agendadas e processadas simultaneamente. Isso significa que o Scrapy pode continuar enviando e processando outras requisições enquanto aguarda o retorno de respostas, otimizando o desempenho geral (GAO; MENG, 2023). Esse processo permite a obtenção de um volume significativo de informações de maneira eficiente, assegurando que as entradas fossem coletadas de forma organizada, conforme as necessidades do trabalho.

Os dados foram adquiridos por meio do site do Repositório Institucional da UFRN, que centraliza a produção acadêmica da comunidade universitária, incluindo docentes, técnicos e alunos. A Figura 4 ilustra o processo de aquisição dos dados, que incluiu a

utilização de técnicas de *web scraping* para capturar informações relevantes.

Figura 4 – Indexação no banco de dados vetorial.

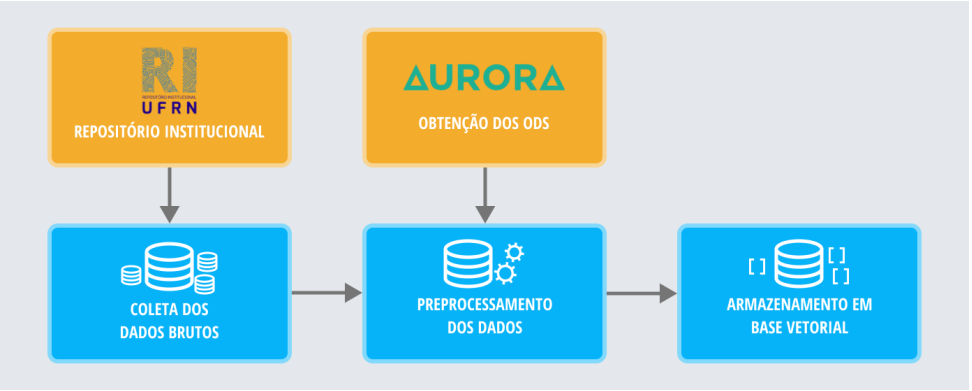

Fonte: Elaborada pelo autor (2025).

A biblioteca `scrapy` segue uma arquitetura baseada em *spiders*, que são classes responsáveis por navegar pelas páginas web e coletar dados. No código implementado, a classe `SpiderRIUFRN` herda da classe base `Spider` fornecida pela biblioteca. Essa herança permite que a classe se beneficie de vários métodos predefinidos que facilitam o processo de *scraping*.

O funcionamento da classe `SpiderRIUFRN` depende da definição de métodos personalizados pelo desenvolvedor, que são associados aos *callbacks* no processo de *scraping*. Embora a biblioteca `scrapy` forneça uma estrutura básica e alguns métodos predefinidos, como o `start_requests()`, a criação de métodos específicos como `parse_categories()`, `parse_thesis_links()` e `parse_data()` permite a implementação de um fluxo flexível e a extração dos dados desejados conforme a necessidade do projeto.

A seguir, descrevem-se os métodos implementados na classe `SpiderRIUFRN`, detalhando sua função no fluxo de coleta de dados:

- `start_requests()`: inicia o processo de *scraping*. O `scrapy` o chama automaticamente, e ele deve retornar um ou mais objetos `scrapy.Request` que especificam as URLs iniciais a serem acessadas. Nesse caso, ele faz uma requisição à URL base e define o método de *callback* como `parse_categories`.

- `parse_categories()`: responsável por analisar a página de categorias. Utiliza a biblioteca `BeautifulSoup` para selecionar os elementos HTML contendo as categorias de trabalhos acadêmicos e extrai o nome e a URL de cada uma. Para cada categoria encontrada, uma nova requisição é feita, em que o método de *callback* será `parse_thesis_links`. A categoria também é armazenada como metadado para as requisições subsequentes.

- `parse_thesis_links()`: extrai os *links* dos trabalhos encontrados, Para cada trabalho, uma requisição é feita para obter detalhes, chamando o método `parse_data`.
- `parse_data()`: coleta os metadados (título, autor, orientador, data da defesa, etc) de cada tese ou dissertação.

No total, foram coletados 904 trabalhos acadêmicos. Antes de serem armazenados na base vetorial, os dados foram organizados e salvos em formato CSV. Essa etapa possibilita a revisão e a reutilização das informações para outros fins, assegurando a consistência e a qualidade dos dados utilizados no estudo.

4.0.2 Pré-processamento dos Dados

Inicialmente, os dados capturados ao longo da etapa de coleta dos dados brutos foram convertidos em um *DataFrame* utilizando a biblioteca `pandas`. Essa transformação possibilita a estruturação e manipulação adequada das informações. Em seguida, valores ausentes foram identificados e substituídos por `None`, assegurando uniformidade e compatibilidade dos dados para etapas subsequentes.

Para realizar essas operações, tem-se o método `closed`, que é, por padrão, chamado automaticamente pelo `scrapy` ao término da execução da *spider*. Nesse contexto, o método desempenha um papel importante ao automatizar o pré-processamento dos dados coletados, preparando-os para análises posteriores de forma organizada e eficiente.

O método também inclui a renomeação de colunas para adequar os nomes às necessidades da aplicação. O campo "`authors`" é renomeado para "`author`", "`keywords`" é renomeado para "`auth_keywords`", "`portuguese abstract`" é renomeado para "`pt_abstract`", "`abstract`" é renomeado para "`en_abstract`", e "`issue date`" passa a ser "`defense_date`". Colunas irrelevantes, como "`other titles`" e "`embargoed until`", são removidas.

Adicionalmente, o método realiza transformações nos dados, como ajustar o formato dos nomes de autores e orientadores para "`Nome Sobrenome`" e padronizar as palavras-chave em uma estrutura de tupla. Outros campos textuais, como título e resumo, são processados por funções de limpeza para garantir que não contenham caracteres indesejados ou inconsistências.

Por fim, o método utiliza a SDG (Objetivos de Desenvolvimento Sustentável, do inglês, *Sustainable Development Goals*) API para predizer os Objetivos de Desenvolvimento Sustentável (ODS) com base nos resumos e títulos das dissertações e teses. A API em questão é disponibilizada pela Aurora, que é resultado de uma parceria entre universidades europeias. Essa API possibilita o uso de diferentes modelos para classificação de ODS. O selecionado para o presente trabalho foi o `aurora-sdg-multi`, que é um modelo `mBERT` *multi-label* rápido e disponível para 104 idiomas.

Ao submeter um texto como entrada para o modelo da API, a resposta inclui, entre outros elementos, uma lista de dicionários no formato chave-valor, que mapeia a porcentagem de cada ODS associado ao conteúdo do texto. Dessa forma, o ODS com a maior porcentagem é atribuído a cada trabalho acadêmico, representando aquele mais alinhado com o tema tratado.

4.0.3 Armazenamento em Base Vetorial

Para o armazenamento eficiente dos dados coletados, foi utilizada uma base vetorial Chroma. O ChromaDB é um banco de dados de código aberto projetado para armazenar e utilizar *embeddings* vetoriais em conjunto com seus metadados relevantes (ALBAYRAK et al., 2025). Ele é empregado em atividades de *Retrieval-Augmented Generation* (RAG), destacando-se por sua capacidade de gerenciar vetores necessários para enriquecer consultas e gerar respostas mais relevantes (CHIN et al., 2024).

Isso facilita a recuperação de informações baseadas em similaridade semântica. No contexto deste trabalho, os dados coletados são processados em formato de documentos que incluem informações textuais, como títulos, resumos em português e inglês, e palavras-chave dos trabalhos acadêmicos.

Figura 5 – Exemplo de documento armazenado.

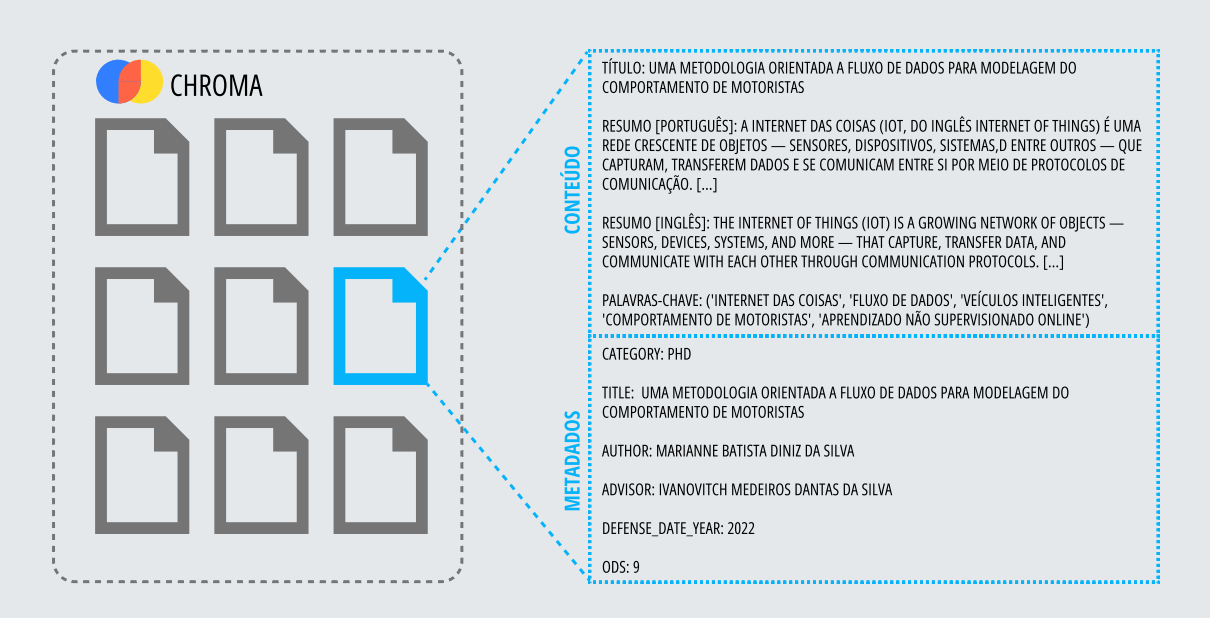

Fonte: Elaborada pelo autor (2025).

Adicionalmente, como pode ser visto na Figura 5, foram armazenados os metadados "`category`", que se refere a classificação do trabalho quanto a ser de mestrado ou doutorado, "`author`", que representa o nome completo do autor do trabalho, "`advisor`", que representa o nome completo do orientador do trabalho, "`defense_date_year`", que é o ano defesa

do trabalho extraído a parte de "`defense_date`", e "`ods`", que se refere a classificação do ODS do trabalho.

A arquitetura da base de dados Chroma é projetada para facilitar a integração com modelos de linguagem, possibilitando armazenar documentos e a geração de *embeddings* a partir dos textos armazenados. Para transformar esses documentos em vetores, utilizou-se o modelo de *embeddings* `text-embedding-3-small` da OpenAI, cujo custo é de $0.02 a cada 1 milhão de tokens, tornando esse modelo a solução de *embeddings* mais barata da OpenAI (OPENAI, 2024). Para o armazenamento de todos os 904 registros foi gasto um total de $0,07.

4.0.4 Integração com a OpenAI

Para a criação do contrutor de consulta, utilizou-se a classe `ChatOpenAI`, com o modelo `gpt-4o-mini` e o parâmetro `temperature` definido como 0. O `gpt-4o-mini` é um modelo de menor custo e mais eficiente em comparação ao `GPT-3.5 Turbo`, além de possuir um contexto de 128K tokens (OPENAI, 2024). A definição do parâmetro `temperature` em 0 visa reduzir a variabilidade das respostas, tornando-as mais determinísticas e menos criativas. Isso garante maior consistência nas consultas realizadas.

Já para o tradutor de consulta, utilizou-se a classe `ChromaTranslator`, para permitir a tradução de elementos de linguagem de consulta do Chroma para filtros válidos. Adicionalmente, para um melhor funcionamento do *retriever*, é recomendada a passagem de informações para o *retreiver* acerca dos metadados presentes na base. Isso foi possível com o uso da classe `AttributeInfo` que permite criar informações sobre os metadados a partir do nome, descrição e tipo da variável, como pode ser observado na Tabela 1.

O uso dessa descrição de atributos é útil para simplificar a construção dos filtros aplicados nas consultas, garantindo uma abordagem padronizada para a interação com os metadados. Especificar que `defense_date_year` é um valor inteiro, por exemplo, abre-se a possibilidade de utilizar operadores de comparação, como "menor ou igual", por exemplo. Assim, a definição rigorosa dos tipos de dados contribui para um sistema de consulta mais robusto e confiável.

4.0.5 Definição do *Prompt*

Adicionalmente, foi criada uma cadeia de operações (ou *chain*) utilizando o framework `LangChain`, meio do uso da LCEL. Esse framework é projetado para facilitar o desenvolvimento de aplicações baseadas em modelos de linguagem de grande escala (TOPSAKAL; AKINCI, 2023). Seu principal objetivo é capacitar os desenvolvedores a integrar esses modelos com outras fontes de dados e aplicações de forma prática e eficiente (TOPSAKAL; AKINCI, 2023).

Para alcançar essa funcionalidade, o LangChain fornece componentes modulares, que abstraem operações comuns, e cadeias, que permitem a construção de pipelines personalizados adaptados a casos de uso específicos. Essa flexibilidade torna o LangChain uma ferramenta poderosa para criar soluções que vão além da interação direta com LLMs, viabilizando sistemas robustos em áreas como atendimento ao cliente, pesquisa e automação de processos (TOPSAKAL; AKINCI, 2023).

Para otimizar o desempenho do sistema, foi incorporado à *chain* um *prompt* que orienta a formatação da resposta. Essa inclusão é fundamental, pois o *prompt* atua como uma diretriz que define especificamente as expectativas do modelo em relação à saída que deve ser gerada.

Ao especificar o formato da resposta, como ilustrado na Tabela 2, o *prompt* ajuda adicionando consistência nas respostas. Com um *prompt* bem estruturado, o modelo é capaz de interpretar de forma mais eficaz a intenção do usuário e adaptar suas respostas, auxiliando a evitar que o modelo crie informações inexistentes.

Tabela 2 – *Prompt* para o Sistema

Prompt
Sua função é ajudar os usuários de um programa de pós-graduação a encontrar informações sobre trabalhos acadêmicos. O programa em questão é o de pós-graduação em engenharia elétrica e de computação da UFRN. 1. VOCÊ NÃO DEVE RESPONDER PERGUNTAS FORA DO CONTEXTO DE TRABALHOS ACADÊMICOS. 2. VOCÊ NUNCA NUNCA NUNCA DEVE INVENTAR INFORMAÇÕES. 3. SE NÃO ENCONTROU A INFORMAÇÃO, DIGA QUE NÃO ENCONTROU. Retorne os trabalhos no formato: Título: Título do trabalho (Ano de defesa) Autor: Nome do autor (Mestrado ou Doutorado) Orientador: Nome do orientador Resumo: Resumo do trabalho Palavras-chave: Palavras-chave ODS: Objetivo de Desenvolvimento Sustentável Contexto: context Pergunta: question

Fonte: Elaborada pelo autor (2025).

Por fim, o modelo que recebe o *prompt* da Tabela 2 é o `gpt-4o-mini`. Dessa forma, quando a consulta é realizada na base vetorial, o contexto obtido é integrado ao *prompt*,

resultando em uma resposta formatada conforme solicitado. Dessa forma, o sistema é capaz de aplicar filtros com base nos dados e realizar buscas por similaridade, garantindo que as respostas sejam relevantes e adequadas às necessidades dos usuários.

5 RESULTADOS E DISCUSSÕES

Neste capítulo, são apresentados os resultados obtidos a partir da prova de conceito realizada para implementar e avaliar a abordagem proposta. O foco é analisar as respostas geradas pela abordagem proposta, validando assim a eficácia da solução proposta.

5.1 Preparação

Para facilitar a avaliação da abordagem proposta, foram implementadas duas funções principais, que desempenham papéis fundamentais na análise do desempenho e na eficiência do sistema:

- `get_query_constructor()`: função responsável por retornar a saída do construtor de consultas, apresentando a maneira como a consulta foi construída principalmente para os termos que foram usados na busca semântica e os filtros que foram aplicados na base vetorial ao buscar as informações.
- `get_cost()`: função responsável por imprimir em tela o custo do processamento da entrada do usuário e o custo da resposta gerada.

Em seguida, foi necessário configurar a chave de API da OpenAI no ambiente de execução, atribuindo a variável de ambiente `OPENAI_API_KEY`.

5.2 Consultas relacionadas a um metadado

Nesta seção, serão abordadas algumas perguntas que se referem a um único metadado. O objetivo é avaliar inicialmente a capacidade do sistema em realizar buscas e filtragens simples, utilizando apenas um critério de busca.

5.2.1 Consultas relacionadas à categoria

Foram feitas três consultas para avaliar a capacidade do sistema de filtrar os trabalhos acadêmicos com base na categoria (mestrado ou doutorado). O objetivo dessas perguntas foi testar a precisão do sistema ao diferenciar entre esses níveis de pós-graduação e sua capacidade de retornar uma quantidade específica de trabalhos solicitada.

Os resultados obtidos a partir dessas consultas demonstram a eficácia do sistema em processar consultas relacionadas à categoria dos trabalhos acadêmicos, aplicando

corretamente os filtros de mestrado e doutorado. A seguir, estão os resultados para cada consulta:

1. **Consulta:** Me retorne 2 trabalhos acadêmicos.

   Resposta:

   ```
   Título: Moduladores Sigma-Delta passa-banda programáveis usando
   filtro N-Path (2023)
   Autor: Evelyn Cristina de Oliveira Lima (Mestrado)
   Orientador: Diomadson Rodrigues Belfort
   Resumo: No Rádio Definido por Software (SDR) a maioria das
   funções analógicas, como a conversão descendente e a seleção de
   canal são movidas para o domínio digital. [...]
   Palavras-chave: (‘Conversor analógico-digital’, ‘Modulador
   Sigma-Delta’, ‘Filtro N-Path’)
   ODS: 7

   Título: Conversor CC/CA de alta freqüência baseado em inversores
   ressonantes com comutação seqüencial para excitação de uma tocha
   indutiva a plasma térmico (2010)
   Autor: Jean Paul Dubut (Doutorado)
   Orientador: Andrés Ortiz Salazar
   Resumo: Este trabalho descreve o estudo, a análise, a
   metodologia de projeto e os detalhes de construção de um
   conversor ressonante CC/CA de alta freqüência usando [...]
   Palavras-chave: (‘Conversor CC/CA’, ‘Inversor ressonante’,
   ‘Comutação sequencial’, ‘Rádiofreqüência’, ‘Series resonant
   inverter’, ‘IGBT’, ‘Sequential pulse gating’, ‘Soft switching
   ZVS’, ‘Thermal plasma’)
   ODS: 7
   ```

   Retorno da função `get_query_constructor`:

   ```
   query=" "
   filter=None
   limit=None
   ```

   Retorno da função `get_cost`:

   ```
   Custo da Entrada: $0.000001
   Custo da Saída: $0.000591
   ```

2. Consulta: Me retorne 2 trabalhos acadêmicos de mestrado.

   Resposta:

   ```
   Título: Dispositivos internos para coleta automática de dados de
   material particulado no ar com aplicação na prevenção e
   mitigação de Covid-19 e outras endemias de síndrome respiratória
   aguda grave (2022)
   Autor: Arthur Andrade Bezerra (Mestrado)
   Orientador: Luiz Marcos Garcia Gonçalves
   Resumo: Este trabalho propõe o desenvolvimento, calibração e
   validação de um dispositivo capaz de capturar ativamente dados
   relacionados à aferição de qualidade do ar para uma [...]
   Palavras-chave: (‘Covid-19’, ‘Índice de qualidade do ar’,
   ‘Sistema embarcado’, ‘Matéria particulada’)
   ODS: 3

   Título: Nova proposta de representação de genoma viral aplicada
   na classificação do Sars-Cov-2 com aprendizagem profunda (2022)
   Autor: Luisa Christina de Souza (Mestrado)
   Orientador: Marcelo Augusto Costa Fernandes
   Resumo: Em dezembro de 2019, o primeiro caso de COVID-19 foi
   observado, e em julho de 2022, já haviam 540 milhões de casos
   confirmados. Devido a rápida propagação do vírus, [...]
   Palavras-chave: (‘Covid-19’, ‘Sars-Cov-2’, ‘Representação
   genômica’, ‘Processamento de sinais genômicos’, ‘Aprendizagem
   profunda’)
   ODS: 17
   ```

   Retorno da função `get_query_constructor`:

   ```
   query=" "
   filter=Comparison(
       comparator=<Comparator.EQ: "eq">,
       attribute="category",
       value="MSc"
   )
   limit=None
   ```

   Retorno da função `get_cost`:

```
Custo da Entrada: $0.000002
Custo da Saída: $0.000408
```

3. Consulta: Me retorne 2 trabalhos acadêmicos de doutorado.

   Resposta:

```
Título: Stacked Sparse Autoencoder applied to SARS-CoV-2 virus
classification based on image representations of genome
sequences (2023)
Autor: Maria Gracielly Fernandes Coutinho (Doutorado)
Orientador: Marcelo Augusto Costa Fernandes
Resumo: Desde dezembro de 2019, o mundo foi severamente afetado
pela pandemia de COVID19, ocasionada pelo vírus SARS-CoV-2. Em
casos como este de nova identificação viral, a [...]
Palavras-chave: (‘Deep learning’, ‘SARS-CoV-2’, ‘Covid-19’,
‘Viral classification’, ‘Image representations’)
ODS: 3

Título: A set of independent variables for time series
regression tasks of pandemic scenarios based on Covid-19 (2024)
Autor: Dunfrey Pires Aragão (Doutorado)
Orientador: Luiz Marcos Garcia Gonçalves
Resumo: Elaboramos investigações sobre uma ampla gama de
variáveis que abrangem fatores, intervenções governamentais e
eventos, com potenciais implicações na dinâmica de [...]
Palavras-chave: (‘Covid-19’, ‘Machine learning’, ‘Feature
survey’, ‘Data selection’, ‘Time series regression models’)
ODS: 3
```

Retorno da função `get_query_constructor`:

```
query=" "
filter=Comparison(
    comparator=<Comparator.EQ: "eq">,
    attribute="category",
    value="PhD"
)
limit=None
```

Retorno da função `get_cost`:

```
Custo da Entrada: $0.000002
Custo da Saída: $0.000644
```

O resultado da primeira consulta demonstra que o sistema conseguiu retornar dois trabalhos acadêmicos conforme solicitado. A análise da função `get_query_constructor` confirma que nenhum filtro foi aplicado, uma vez que não houve especificação de restrições adicionais na consulta.

De forma similar, os resultados da segunda e terceira consultas retornaram dois trabalhos cada, conforme solicitado. Diferentemente da primeira consulta, a análise da função `get_query_constructor` mostra que foram aplicados filtros específicos relativos às categorias dos trabalhos, ajustando a busca de acordo com os critérios estabelecidos.

5.2.2 Consultas relacionadas ao título

Em seguida, foi realizada uma consulta específica baseada no título de um trabalho acadêmico. O objetivo dessa consulta foi avaliar a capacidade do sistema de localizar e retornar um trabalho com base na entrada do título completo.

1. Consulta: Me retorne o trabalho entitulado 'Análise de desempenho de sistemas de comunicação sem-fio para monitoramento de unidade de produção de poços petrolíferos terrestres'

   Resposta:

   ```
   Título: Análise de desempenho de sistemas de comunicação sem-fio
   para monitoramento de unidade de produção de poços petrolíferos
   terrestres (2008)
   Autor: Ivanovitch Medeiros Dantas da Silva (Mestrado)
   Orientador: Luiz Affonso Henderson Guedes de Oliveira
   Resumo: Grande parte do monitoramento de poços petrolíferos
   terrestres realizados atualmente está baseado em soluções sem
   fio (wireless). Todavia, essas soluções apresentam [...]
   Palavras-chave: ('Redes de sensores sem fio', 'Simulação',
   'Monitoramento de poços petrolíferos', 'Técnicas de roteamento',
   'Wireless sensor network', 'Simulation', 'Oil and gas
   application', 'Routing techniques')
   ODS: 7
   ```

   Retorno da função `get_query_constructor`:

```
query="Análise de desempenho de sistemas de comunicação sem-fio
para monitoramento de unidade de produção de poços petrolíferos
terrestres"
filter=None
limit=None
```

Retorno da função `get_cost`:

```
Custo da Entrada: $0.000006
Custo da Saída: $0.000180
```

Apesar de o sistema ter retornado corretamente o trabalho solicitado, observa-se que a consulta foi realizada sem o uso de filtros adicionais. Isso indica que o retorno para a consulta baseou-se na similaridade do título completo com relação aos documentos presentes na base vetorial.

5.2.3 Consultas relacionadas ao autor

Dando sequência, foi realizada uma consulta utilizando o nome completo de um autor como critério de busca. O objetivo dessa consulta foi verificar a capacidade do sistema em identificar e retornar trabalhos acadêmicos de forma precisa com base na autoria.

1. Consulta: Me retorne trabalhos acadêmicos cujo autor seja Ivanovitch Medeiros Dantas da Silva

   Resposta:

```
Título: Análise de desempenho de sistemas de comunicação sem-fio
para monitoramento de unidade de produção de poços petrolíferos
terrestres (2008)
Autor: Ivanovitch Medeiros Dantas da Silva (Mestrado)
Orientador: Luiz Affonso Henderson Guedes de Oliveira
Resumo: Grande parte do monitoramento de poços petrolíferos
terrestres realizados atualmente está baseado em soluções sem
fio (wireless). Todavia, essas soluções apresentam [...]
Palavras-chave: (‘Redes de sensores sem fio’, ‘Simulação’,
‘Monitoramento de poços petrolíferos’, ‘Técnicas de roteamento’,
‘Wireless sensor network’, ‘Simulation’, ‘Oil and gas
application’, ‘Routing techniques’)
ODS: 7
```

```
Título: Uma metodologia para modelagem e avaliação da
dependabilidade de redes industriais sem fio (2013)
Autor: Ivanovitch Medeiros Dantas da Silva (Doutorado)
Orientador: Luiz Affonso Henderson Guedes de Oliveira
Resumo: Garantir os requisitos de dependabilidade é fundamental
para as aplicações industriais, onde falhas podem conduzir a
defeitos cujas consequências impactam em prejuízos [...]
Palavras-chave: (‘Redes industriais sem fio. WirelessHART.
ISA100.11a. WIA-PA. Árvores de falhas. Análise de
dependabilidade. Confiabilidade. Disponibilidade’, ‘Wireless
industrial networks. WirelessHART. ISA100.11a. WIA-PA. Fault
tree. Dependability evaluation. Reliability and availability’)
ODS: 12
```

Retorno da função `get_query_constructor`:

```
query=" "
filter=Comparison(
    comparator=<Comparator.EQ: "eq">,
    attribute="author",
    value="Ivanovitch Medeiros Dantas da Silva"
)
limit=None
```

Retorno da função `get_cost`:

```
Custo da Entrada: $0.000003
Custo da Saída: $0.000497
```

Como resultado da consulta por trabalhos acadêmicos específicos do autor indicado, foram retornadas as duas publicações associadas ao nome solicitado. A análise da função `get_query_constructor` mostra que o filtro foi corretamente aplicado aos metadados com base no nome completo do autor, garantindo que os trabalhos recuperados estivessem de fato alinhados ao critério especificado.

5.2.4 Consultas relacionadas ao orientador

De forma análoga às consultas baseadas no autor, foi realizada uma consulta utilizando o nome completo do orientador como critério de busca. O intuito dessa consulta

foi avaliar a habilidade do sistema em recuperar trabalhos acadêmicos orientados por um pesquisador específico.

1. Consulta: Me retorne trabalhos acadêmicos cujo orientador seja Ivanovitch Medeiros Dantas da Silva

   Resposta:

   ```
   Título: Um algoritmo online e evolutivo para compressão
   automática de dados em cenários de IoT (2021)
   Autor: Gabriel Lucas Albuquerque Maia Signoretti (Mestrado)
   Orientador: Ivanovitch Medeiros Dantas da Silva
   Resumo: Com o avanço e adoção em massa de soluções no campo de
   Internet das Coisas (IoT) e cidades conectadas, o número de
   dispositivos e sensores conectados à rede tende a [...]
   Palavras-chave: (‘Compressão de dados online’, ‘IoT’, ‘Veículos
   inteligentes’, ‘TinyML’, ‘Aprendizado de máquina’,
   ‘Excentricidade de dados’)
   ODS: 9

   Título: A deep learning model for identifying academic
   publications aligned with the sustainable development goals
   (2023)
   Autor: Alexandre Henrique Soares Dias (Mestrado)
   Orientador: Ivanovitch Medeiros Dantas da Silva
   Resumo: Em 2015, as Nações Unidas estabeleceram os 17 Objetivos
   de Desenvolvimento Sustentável (ODS) para promover a
   responsabilidade ambiental, o avanço econômico e a [...]
   Palavras-chave: (‘Sustainable development’, ‘Multilabel
   classification’, ‘Deep learning’, ‘Natural language’,
   ‘Scientometrics’)
   ODS: 17

   Título: Uma proposta para detecção de buracos com aprendizagem
   de máquina na borda (2024)
   Autor: Jordão Paulino Cassiano da Silva (Mestrado)
   Orientador: Ivanovitch Medeiros Dantas da Silva
   Resumo: Buracos em vias urbanas representam um problema
   significativo, afetando tanto a segurança dos usuários quanto a
   durabilidade dos veículos. Este estudo surge da [...]
   ```

```
Palavras-chave: ('Aprendizado de máquina na borda',
'Infraestrutura urbana', 'Detecção de buracos', 'Otimização de
modelos', 'TinyML')
ODS: 11

Título: Learning analytics e avaliações online: uma metodologia
orientada a ciência de dados em grafos (2023)
Autor: Elvis Medeiros de Melo (Doutorado)
Orientador: Ivanovitch Medeiros Dantas da Silva
Resumo: A avaliação é um instrumento importante para corrigir
falhas e promover acertos em processos de aprendizagem. É um dos
pilares da educação, junto com o currículo e o processo [...]
Palavras-chave: ('Learning analytics', 'Ciência de dados em
grafos', 'Grafos', 'Avaliação online', 'Machine learning',
'eXplainable artificial intelligence')
ODS: 4

Título: Um algoritmo anticolisão para RFID de larga escala em
ambientes ruidosos (2020)
Autor: Israel Eduardo de Barros Filho (Doutorado)
Orientador: Ivanovitch Medeiros Dantas da Silva
Resumo: A Internet das Coisas Industrial (IIoT) é frequentemente
apresentada como um conceito que está mudando significativamente
o cenário tecnológico das indústrias, através de [...]
Palavras-chave: ('IoT industrial', 'GSPN', 'RFID', 'Desempenho',
'Confiabilidade', 'Modelagem de erro')
ODS: 9
```

Retorno da função `get_query_constructor`:

```
query=" "
filter=Comparison(
    comparator=<Comparator.EQ: "eq">,
    attribute="advisor",
    value="Ivanovitch Medeiros Dantas da Silva"
)
limit=None
```

Retorno da função `get_cost`:

```
Custo da Entrada: $0.000003
Custo da Saída: $0.001385
```

Para essa consulta, foi possível retornar corretamente os trabalhos acadêmicos do orientador solicitado. O retorno da função `get_query_constructor` implica que o filtro foi aplicado corretamente nos metadados, garantindo que todos os resultados fossem trabalhos supervisionados pelo orientador especificado.

5.2.5 Consultas relacionadas ao ano de defesa

Como citado no capítulo 3, o uso de um atributo com valor inteiro nos metadados possibilita consultas utilizando operadores de comparação. Desse modo, as consultas realizadas tiveram o intuito de demonstrar a capacidade do sistema em lidar com essas operações, permitindo a filtragem de trabalhos acadêmicos com base em valores numéricos.

1. Consulta: Me retorne trabalhos acadêmicos defendidos em 2021

   Resposta:

```
Título: Um algoritmo online e evolutivo para compressão
automática de dados em cenários de IoT (2021)
Autor: Gabriel Lucas Albuquerque Maia Signoretti (Mestrado)
Orientador: Ivanovitch Medeiros Dantas da Silva
Resumo: Com o avanço e adoção em massa de soluções no campo de
Internet das Coisas (IoT) e cidades conectadas, o número de
dispositivos e sensores conectados à rede tende a [...]
Palavras-chave: (‘Compressão de dados online’, ‘IoT’, ‘Veículos
inteligentes’, ‘TinyML’, ‘Aprendizado de máquina’,
‘Excentricidade de dados’)
ODS: 9

Título: Analytical speedup modeling for parallel applications
with variable memory access delay in symmetric architectures
(2021)
Autor: Alex Fabiano de Araújo Furtunato (Doutorado)
Orientador: Samuel Xavier de Souza
Resumo: Vários modelos analíticos criados desde o trabalho
pioneiro de Amdahl exploraram aspectos tais como variação no
tamanho do problema, tamanho da memória, sobrecarga [...]
Palavras-chave: (‘Analytical modeling’, ‘Speedup modeling’,
‘Parallel systems’, ‘Data access delay’, ‘Speedup’, ‘Memory
```

```
wall')
ODS: 9

Título: Holographic projection with deep learning for
microparticles detection from water samples (2021)
Autor: Andouglas Gonçalves da Silva Júnior (Doutorado)
Orientador: Luiz Marcos Garcia Gonçalves
Resumo: Esta tese propõe um sistema holográfico completo para
ser aplicado em pesquisa científica e em monitoramento, que é
capaz de detectar micropartículas a partir da [...]
Palavras-chave: ('Holografia', 'Aprendizado profundo',
'Diatomáceas', 'Microplásticos')
ODS: 6

Título: A parallel software-defined ultra-low-power receiver for
a satellite message forwarding system (2021)
Autor: Raffael Sadite Cordoville Gomes de Lima (Mestrado)
Orientador: Samuel Xavier de Souza
Resumo: Os nanossatélites se tornaram a solução padrão para a
maioria dos sistemas espaciais que operam em órbita terrestre
baixa (LEO). No entanto, esta categoria de satélite impõe [...]
Palavras-chave: ('Multi-user receiver', 'Message storage and
forwarding system', 'Ultra-low power', 'Multi-core
architecture', 'Parallel processing')
ODS: 7
```

Retorno da função `get_query_constructor`:

```
query=" "
filter=Comparison(
    comparator=<Comparator.EQ: "eq">,
    attribute="defense_date_year",
    value=2021
)
limit=None
```

Retorno da função `get_cost`:

```
Custo da Entrada: $0.000002
```

```
Custo da Saída: $0.001034
```

2. Consulta: Me retorne 2 trabalhos acadêmicos defendidos entre 2020 e 2023

   Resposta:

```
Título: Dispositivos internos para coleta automática de dados de
material particulado no ar com aplicação na prevenção e
mitigação de Covid-19 e outras endemias de síndrome respiratória
aguda grave (2022)
Autor: Arthur Andrade Bezerra (Mestrado)
Orientador: Luiz Marcos Garcia Gonçalves
Resumo: Este trabalho propõe o desenvolvimento, calibração e
validação de um dispositivo capaz de capturar ativamente dados
relacionados à aferição de qualidade do ar para uma [...]
Palavras-chave: ('Covid-19', 'Índice de qualidade do ar',
'Sistema embarcado', 'Matéria particulada')
ODS: 3

Título: Nova proposta de representação de genoma viral aplicada
na classificação do Sars-Cov-2 com aprendizagem profunda (2022)
Autor: Luisa Christina de Souza (Mestrado)
Orientador: Marcelo Augusto Costa Fernandes
Resumo: Em dezembro de 2019, o primeiro caso de COVID-19 foi
observado, e em julho de 2022, já haviam 540 milhões de casos
confirmados. Devido a rápida propagação do vírus, esforços [...]
Palavras-chave: ('Covid-19', 'Sars-Cov-2', 'Representação
genômica', 'Processamento de sinais genômicos', 'Aprendizagem
profunda')
ODS: 17
```

Retorno da função `get_query_constructor`:

```
query=" "
filter=Operation(
    operator=<Operator.AND: "and">,
    arguments=[
        Comparison(
            comparator=<Comparator.GTE: "gte">,
            attribute="defense_date_year",
```

```
                value=2020
            ),
            Comparison(
                comparator=<Comparator.LTE: "lte">,
                attribute="defense_date_year",
                value=2023
            )
        ]
    )
    limit=None
```

Retorno da função `get_cost`:

```
Custo da Entrada: $0.000003
Custo da Saída: $0.000408
```

Os resultados das consultas relacionadas ao ano de defesa demonstraram a capacidade de realizar buscas precisas utilizando operadores de comparação aplicados a valores inteiros. Na primeira consulta, onde o ano de defesa foi restrito a 2021, o sistema retornou corretamente quatro trabalhos defendidos nesse ano. A função `get_query_constructor` evidencia a aplicação de um filtro específico para o ano.

Na segunda consulta, onde foram solicitados dois trabalhos defendidos entre 2020 e 2023, o sistema também retornou resultados dentro do intervalo desejado. A função `get_query_constructor` mostra a utilização de operadores $\geq$ e *leq*, confirmando a aplicação correta de uma faixa de valores para o metadado referente ao atributo `defense_date_year`. Esse uso de comparação múltipla demonstra a flexibilidade em lidar com consultas baseadas em intervalos, adaptando-se às necessidades de busca com critérios de data mais amplos.

5.2.6 Consultas relacionadas ao ODS

O sistema também foi avaliado quanto à sua capacidade de realizar consultas relacionadas aos Objetivos de Desenvolvimento Sustentável (ODS), presentes como um metadado nos trabalhos acadêmicos. Essa consulta tem como objetivo verificar a precisão do sistema ao identificar e filtrar trabalhos acadêmicos classificados de acordo com um ODS específico.

1. Consulta: Me retorne trabalhos que foram classificados como ODS 2

   Resposta:

Título: Identificação de nematóides através de técnicas de processamento inteligentes de imagens (2002)
Autor: Carlos Alberto da Silva (Mestrado)
Orientador: Adrião Duarte Dória Neto
Resumo: O desenvolvimento de técnicas automáticas para a identificação da presença de namatóides em imagens capturadas através de câmeras acopladas em microscópios para [...]
Palavras-chave: ('Engenharia elétrica', 'Nematóides', 'Transformada KLT', 'Processamento digital de imagens', 'Auto-contraste', 'Redes neurais artificiais')
ODS: Objetivo de Desenvolvimento Sustentável 2

Título: Análise da determinação da constante elétrica de materiais sólidos e líquidos usando parâmetros de transmissão na faixa de microondas (2018)
Autor: André Soffiatti (Doutorado)
Orientador: Laercio Martins de Mendonça
Resumo: Com o rápido crescimento da tecnologia, tornou-se necessário o desenvolvimento de dispositivos sensoriais para o controle e a automação de vários processos agrícolas, [...]
Palavras-chave: ('Permissividade complexa', 'Caracterização de materiais', 'Método do espaço livre', 'Antenas de microfita', 'Sensor metamaterial')
ODS: Objetivo de Desenvolvimento Sustentável 2

Título: Tomada de decisão em grupo e multi-atributos baseada na Lógica fuzzy intuicionista de Atanassov intervalarmente valorada (2016)
Autor: Ivanosca Andrade da Silva (Doutorado)
Orientador: Benjamin Rene Callejas Bedregal
Resumo: Lógica fuzzy surge em 1965 com o trabalho de Lotfi Zadeh que tem por objetivo tratar de forma rigorosa a incerteza inerente na definição de noções e propriedades imprecisas [...]
Palavras-chave: ('Lógica fuzzy', 'Tomada de decisão', 'Lógica fuzzy intuicionista de Atanassov intervalarmente valorada', 'Ordens admissíveis', 'Médias ponderadas ordenadas', 'Representação intervalar', 'Fusão de ranking')
ODS: Objetivo de Desenvolvimento Sustentável 2

Retorno da função `get_query_constructor`:

```
query=" "
filter=Comparison(
    comparator=<Comparator.EQ: "eq">,
    attribute="ods",
    value=2
)
limit=None
```

Retorno da função `get_cost`:

```
Custo da Entrada: $0.000002
Custo da Saída: $0.000989
```

O retorno para a consulta relacionada ao ODS mostra que possível filtrar trabalhos acadêmicos quando classificados por ODS específico. Nessa consulta, onde foi solicitado que apenas trabalhos classificados como ODS 2 fossem retornados, foram identificados os 3 trabalhos presentes na base classificados com essa ODS.

A função `get_query_constructor` confirma a aplicação do filtro de maneira correta. Isso destaca a eficácia do sistema em lidar com consultas baseadas no ODS, o que é útil para pesquisas focadas em áreas específicas de impacto social e ambiental.

5.3 Consultas relacionadas a múltiplos metadados

Nesta seção, serão discutidas as perguntas que envolvem mais de um metadado, permitindo avaliar o sistema para os casos em que se necessita de mais de um filtro.

1. Consulta: Me retorne 3 trabalhos de mestrado que foram classificados como ODS 2

   Resposta:

   ```
   Título: Identificação de nematóides através de técnicas de
   processamento inteligentes de imagens (2002)
   Autor: Carlos Alberto da Silva (Mestrado)
   Orientador: Adrião Duarte Dória Neto
   Resumo: O desenvolvimento de técnicas automáticas para a
   identificação da presença de namatóides em imagens capturadas
   através de câmeras acopladas em microscópios para [...]
   Palavras-chave: Engenharia elétrica, Nematóides, Transformada
   ```

```
KLT, Processamento digital de imagens, Auto-contraste, Redes
neurais artificiais
ODS: 2

Infelizmente, não encontrei mais dois trabalhos de mestrado
classificados como ODS 2.
```

Retorno da função `get_query_constructor`:

```
query=" "
filter=Operation(
    operator=<Operator.AND: "and">,
    arguments=[
        Comparison(
            comparator=<Comparator.EQ: "eq">,
            attribute="category",
            value="MSc"
        ),
        Comparison(
            comparator=<Comparator.EQ: "eq">,
            attribute="ods",
            value=2
        )
    ]
)
limit=None
```

Retorno da função `get_cost`:

```
Custo da Entrada: $0.000003
Custo da Saída: $0.000778
```

2. Consulta: Me retorne 2 trabalhos de mestrado entre 2020 e 2023 foram classificados como ODS 7

   Resposta:

```
Título: Moduladores Sigma-Delta passa-banda programáveis usando
filtro N-Path (2023)
Autor: Evelyn Cristina de Oliveira Lima (Mestrado)
```

```
Orientador: Diomadson Rodrigues Belfort
Resumo: No Rádio Definido por Software (SDR) a maioria das
funções analógicas, como a conversão descendente e a seleção de
canal são movidas para o domínio digital. Com esses [...]
Palavras-chave: (‘Conversor analógico-digital’, ‘Modulador
Sigma-Delta’, ‘Filtro N-Path’)
ODS: 7

Título: A parallel software-defined ultra-low-power receiver for
a satellite message forwarding system (2021)
Autor: Raffael Sadite Cordoville Gomes de Lima (Mestrado)
Orientador: Samuel Xavier de Souza
Resumo: Os nanossatélites se tornaram a solução padrão para a
maioria dos sistemas espaciais que operam em órbita terrestre
baixa (LEO). No entanto, esta categoria de satélite impõe [...]
Palavras-chave: (‘Multi-user receiver’, ‘Message storage and
forwarding system’, ‘Ultra-low power’, ‘Multi-core
architecture’, ‘Parallel processing’)
ODS: 7
```

Retorno da função `get_query_constructor`:

```
query=" "
filter=Operation(
    operator=<Operator.AND: "and">,
    arguments=[
        Comparison(
            comparator=<Comparator.EQ: "eq">,
            attribute="category",
            value="MSc"
        ),
        Comparison(
            comparator=<Comparator.GTE: "gte">,
            attribute="defense_date_year",
            value=2020
        ),
        Comparison(
            comparator=<Comparator.LTE: "lte">,
            attribute="defense_date_year",
```

```
                value=2023
            ),
            Comparison(
                comparator=<Comparator.EQ: "eq">,
                attribute="ods",
                value=7
            )
        ]
    )
    limit=None
```

Retorno da função `get_cost`:

```
Custo da Entrada: $0.000004
Custo da Saída: $0.000541
```

As consultas relacionadas a múltiplos metadados demonstraram a capacidade do sistema de combinar filtros diversos para refinar ainda mais os resultados, permitindo buscas específicas e direcionadas.

Na primeira consulta, o sistema foi solicitado a retornar três trabalhos de mestrado classificados como ODS 2. O sistema recuperou um trabalho compatível, mas não encontrou outros resultados que atendessem a todos os critérios simultaneamente. Esse resultado evidencia uma limitação nos dados disponíveis, uma vez que só há um dado na base que corresponde aos critérios dessa busca, mas confirma que o filtro múltiplo foi aplicado corretamente ao restringir a consulta a categoria "Mestrado"e ODS 2. A função `get_query_constructor` mostra a combinação dos filtros `category="MSc"` e `ods=2` com o operador `AND`, garantindo que ambos os critérios fossem exigidos para cada trabalho retornado.

Na segunda consulta, a complexidade dos filtros aumentou, com critérios de categoria, ano de defesa (entre 2020 e 2023) e ODS 7. O sistema foi bem-sucedido em retornar dois trabalhos que atendiam a todos os requisitos, o que demonstra sua flexibilidade em aplicar uma cadeia de filtros composta. A função `get_query_constructor` evidencia o uso dos operadores `GTE` e `LTE` para definir o intervalo de anos e o operador `AND` para combinar todos os critérios. Esse resultado reforça a robustez do sistema ao lidar com consultas complexas, proporcionando respostas precisas mesmo com múltiplos metadados.

5.4 Consultas relacionadas ao conteúdo armazenado

Por último, foram examinadas as perguntas que se referem ao conteúdo dos trabalhos armazenados (título, resumo em português, resumo em inglês e as palavras-chave). Essas perguntas tem como intuito avaliar o sistema em um cenário mais amplo em que não se busca somente pelos metadados mas também pelo conteúdo armazenado.

1. Consulta: Gostaria de desenvolver um projeto na área de Inteligência Artificial, quais trabalhos de mestrado você me recomenda?

   Resposta:

   ```
   Título: Implementação e aplicação de algoritmos de aprendizado
   em um sistema neuro-simbólico (2017)
   Autor: André Quintiliano Bezerra Silva (Mestrado)
   Orientador: André Laurindo Maitelli
   Resumo: Um dos principais objetivos da inteligência artificial é
   a criação de agentes inspirados na inteligência humana. Isso vem
   sendo pesquisado utilizando várias abordagens, e entre as [...]
   Palavras-chave: (‘Neuro-simbólico’, ‘Sistemas híbrido’, ‘Rede
   neural’)
   ODS: 17

   Título: Controle inteligente de um robô móvel omnidirecional com
   tomada de decisão utilizando aprendizagem por reforço (2021)
   Autor: Victor Ramon Firmo Moreira (Mestrado)
   Orientador: Wallace Moreira Bessa
   Resumo: Este trabalho propõe o desenvolvimento de um agente
   autônomo, combinando estratégias de controle inteligente com
   algoritmos de tomada de decisão. Para a implementação [...]
   Palavras-chave: (‘Controle não linear’, ‘Linearização por
   realimentação’, ‘Redes neurais artificiais’, ‘e-greedy’,
   ‘Robotino®’)
   ODS: 16

   Título: Sistema não-Intrusivo para Estimação da Direção do olhar
   utilizando redes neurais artificiais (2010)
   Autor: Helton Maia Peixoto (Mestrado)
   Orientador: Ana Maria Guimarães Guerreiro
   Resumo: Este trabalho consiste em apresentar um sistema
   ```

```
não-intrusivo que utiliza um computador pessoal e uma webcam de
baixo custo para a estimação da direção do olhar. Os [...]
Palavras-chave: ('Estimação da direção do olhar', 'Processamento
digital de imagens', 'Redes neurais artificiais')
ODS: 8

Título: Análise de tradução homem-máquina utilizando mecanismos
de atenção para sistemas baseados em SQL para indústria 4.0
(2020)
Autor: Silvan Ferreira da Silva Júnior (Mestrado)
Orientador: Allan de Medeiros Martins
Resumo: Neste trabalho, propomos uma aplicação de modelos
recentes de Deep Learning em processamento de linguagem natural
que utiliza mecanismos de atenção para tradução da [...]
Palavras-chave: ('NLP', 'Indústria', 'IoT', 'SQL', 'Deep
Learning')
ODS: 9
```

Retorno da função `get_query_constructor`:

```
query="Inteligência Artificial"
filter=Comparison(
    comparator=<Comparator.EQ: "eq">,
    attribute="category",
    value="MSc"
)
limit=None
```

Retorno da função `get_cost`:

```
Custo da Entrada: $0.000003
Custo da Saída: $0.000898
```

2. Consulta: Existe algum trabalho na base de dados que envolva *blockchain*?

   Resposta:

```
Não encontrei informações sobre trabalhos acadêmicos que
envolvam blockchain na base de dados fornecida.
```

Retorno da função `get_query_constructor`:

```
query="blockchain"
filter=None
limit=None
```

Retorno da função `get_cost`:

```
Custo da Entrada: $0.000002
Custo da Saída: $0.000011
```

3. Consulta: Existe algum trabalho na base de dados que envolva *blockchain* na perspectiva de promover a segurança no compartilhamento dos dados dos pacientes?

   Resposta:

```
Título: Plataforma RevELA: uma solução de saúde digital para a
gestão do cuidado e vigilância dos pacientes com Esclerose
Lateral Amiotrófica no Brasil (2023)
Autor: Ingridy Marina Pierre Barbalho (Doutorado)
Orientador: Ricardo Alexsandro de Medeiros Valentim
Resumo: A Esclerose Lateral Amiotrófica (ELA) é uma doença
neurodegenerativa rara considerada complexa em virtude da sua
heterogeneidade. Apesar de ser conhecida há muitos anos, [...]
Palavras-chave: ('Esclerose Lateral Amiotrófica', 'Registro
eletrônico em saúde', 'Solução de saúde digital', 'Saúde
pública', 'Políticas públicas')
ODS: 3
```

Retorno da função `get_query_constructor`:

```
query="blockchain segurança compartilhamento dados pacientes"
filter=None
limit=None
```

Retorno da função `get_cost`:

```
Custo da Entrada: $0.000004
Custo da Saída: $0.000368
```

As consultas realizadas com foco no conteúdo dos trabalhos acadêmicos evidenciaram a capacidade do sistema em lidar com critérios de busca que extrapolam os metadados básicos.

Na primeira consulta, que solicitou recomendações de trabalhos de mestrado na área de Inteligência Artificial, o sistema retornou uma seleção relevante de quatro trabalhos. O resultado obtido com a função `get_query_constructor` mostra que se restringiu os resultados à categoria "Mestrado", enquanto a busca pelo termo "Inteligência Artificial" garantiu a relevância temática dos resultados.

Na segunda consulta, onde o termo "*blockchain*" foi utilizado, o sistema não encontrou registros correspondentes na base de dados. No entanto, existe um trabalho que cita o uso de *blockchain*. O erro em não conseguir retornar se dá pelo fato que o *blockchain* só é citado uma vez no texto do trabalho que afirma utilizá-lo. Sendo assim, provavelmente o cálculo de similaridade resultou em um valor baixo.

A terceira consulta apresentou uma questão mais ampla, envolvendo "*blockchain*" e segurança no compartilhamento de dados de pacientes. Embora na consulta anterior o sistema não tenha identificado um trabalho relevante, a adição de termos mais específicos e contextualmente relacionados permitiu aumentar a similaridade entre a consulta e o conteúdo do documento na base de dados, o que resultou na recuperação bem-sucedida do trabalho que menciona o uso de *blockchain*.

Esse resultado sugere que a presença de termos adicionais, como "segurança" e "compartilhamento de dados de pacientes", ajudou a alinhar a consulta ao contexto semântico do trabalho, compensando a menção esparsa de "*blockchain*" e superando a limitação observada na consulta anterior. Isso indica que o sistema pode se beneficiar de consultas compostas e contextualmente ricas, que aumentam a precisão na recuperação de documentos quando os termos alvo estão distribuídos de forma dispersa no texto.

5.5 Custos

A análise dos custos das consultas revelou que o sistema demonstrou uma eficiência em termos de custos. Para as entradas, o custo máximo registrado foi de $0.000004, enquanto para as respostas o custo mais elevado foi de $0.001385. Esses valores indicam que o sistema é capaz de realizar consultas complexas e retornar informações detalhadas com um custo monetário relativamente baixo.

Isso torna a abordagem adequada para aplicações em larga escala, mostrando uma boa relação custo-benefício. Para exemplificar, a Tabela 3 apresenta uma projeção dos custos máximos com base no número de requisições, calculados multiplicando os custos unitários pelo volume de consultas.

Tabela 3 – Custos máximos de consultas baseados no número de requisições

Número de Consultas	**Entrada ($)**	**Resposta ($)**
100	0.0004	0.1385
1.000	0.004	1.385
10.000	0.04	13.85
100.000	0.4	138.50
1.000.000	4	1.385

Fonte: Elaborada pelo autor (2025).

6 CONCLUSÃO

O presente trabalho apresentou uma abordagem para a recuperação de informações acadêmicas por meio de consultas específicas, utilizando um sistema de filtragem robusto baseado em múltiplos metadados e conteúdos textuais. A metodologia proposta demonstrou eficácia em diversas consultas, desde aquelas que envolvem metadados simples, como categoria e ano de defesa, até consultas mais complexas que combinam múltiplos filtros e analisam o conteúdo semântico dos textos armazenados.

Os resultados mostraram que o sistema é capaz de responder de forma precisa às consultas por metadados, como autor, orientador e ODS. Quando combinados, esses filtros permitiram a recuperação de informações altamente específicas, adaptando a busca para atender necessidades de pesquisas orientadas a temas ou a períodos temporais específicos. Essa capacidade de filtragem e combinação de critérios confirma a flexibilidade e a precisão da metodologia proposta.

No entanto, a análise também destacou algumas limitações em consultas baseadas em termos de conteúdo com baixa frequência de ocorrência. A consulta pelo termo "*blockchain*" , por exemplo, revelou uma limitação do sistema em identificar documentos com menções esparsas do termo. Esse problema foi parcialmente superado ao adicionar mais termos a consulta, o que aumentou a similaridade semântica e possibilitou a recuperação do documento relevante.

Diante desses resultados, conclui-se que a abordagem para recuperação é eficaz para consultas complexas em bases de dados acadêmicos, proporcionando uma ferramenta útil e eficiente para pesquisadores. No entanto, há oportunidades para aprimoramento, especialmente no que diz respeito à identificação de termos menos frequentes. Implementar essas melhorias pode tornar o sistema ainda mais robusto e preciso, ampliando sua aplicabilidade em diferentes áreas do conhecimento e facilitando o acesso escalável e confiável a informações relevantes.

Como uma etapa futura, pode-se considerar a inclusão de uma funcionalidade adicional que permita, após a recuperação de um ou mais trabalhos relevantes, a realização de consultas diretamente sobre o conteúdo dos arquivos PDF disponíveis. Essa funcionalidade aumentaria ainda mais a utilidade e versatilidade da abordagem, atendendo a demandas mais específicas e detalhadas dos usuários.

REFERÊNCIAS

AI, Q. et al. Information retrieval meets large language models: A strategic report from chinese ir community. *AI Open*, v. 4, p. 80–90, 2023. ISSN 2666-6510. Disponível em: <https://www.sciencedirect.com/science/article/pii-/S2666651023000049>https://www.sciencedirect.com/science/article/pii/S2666651023000049.

ALBAYRAK, A. et al. Enhancing human phenotype ontology term extraction through synthetic case reports and embedding-based retrieval: A novel approach for improved biomedical data annotation. *Journal of Pathology Informatics*, v. 16, p. 100409, 2025. ISSN 2153-3539. Disponível em: <https://www.sciencedirect.com/science/article/pii-/S2153353924000488>https://www.sciencedirect.com/science/article/pii/S2153353924000488.

BARRETO, F. et al. Generative artificial intelligence: Opportunities and challenges of large language models. In: BALAS, V. E.; SEMWAL, V. B.; KHANDARE, A. (Ed.). *Intelligent Computing and Networking*. Singapore: Springer Nature Singapore, 2023. p. 545–553. ISBN 978-981-99-3177-4.

BARSHA, S.; MUNSHI, S. A. Implementing artificial intelligence in library services: a review of current prospects and challenges of developing countries. *Library Hi Tech News*, v. 41, n. 1, p. 7–10, 2024. Disponível em: <https://doi.org/10.1108/LHTN-07-2023-0126>https://doi.org/10.1108/LHTN-07-2023-0126.

BERRONE, P. et al. How can research contribute to the implementation of sustainable development goals? an interpretive review of sdg literature in management. *International Journal of Management Reviews*, v. 25, n. 2, p. 318–339, 2023. Disponível em: <https://onlinelibrary.wiley.com/doi/abs/10.1111/ijmr-.12331>https://onlinelibrary.wiley.com/doi/abs/10.1111/ijmr.12331.

CHAMORRO-PADIAL, J.; RODRíGUEZ-SáNCHEZ, R. Attention–survival score: A metric to choose better keywords and improve visibility of information. *Algorithms*, v. 16, n. 4, 2023. ISSN 1999-4893. Disponível em: <https://www.mdpi.com/1999-4893/16/4-/196>https://www.mdpi.com/1999-4893/16/4/196.

CHAN, C. K. Y.; HU, W. Students' voices on generative ai: perceptions, benefits, and challenges in higher education. *International Journal of Educational Technology in Higher Education*, v. 20, n. 43, 2023. Disponível em: <https://doi.org/10.1186/s41239-023-00411-8>https://doi.org/10.1186/s41239-023-00411-8.

CHIN, O. et al. Oyen: A user-centric llm-based bilingual healthcare chatbot. In: *2024 5th International Conference on Artificial Intelligence and Data Sciences (AiDAS)*. [S.l.: s.n.], 2024. p. 435–440.

DEBNATH, J.; DEBNATH, D.; PATRIKAR, S. Vexatious and euphemistic affairs in retractions of scientific publications: A pilot study. *Medical Journal Armed Forces India*,

2023. ISSN 0377-1237. Disponível em: <https://www.sciencedirect.com/science/article/pii-/S0377123723001107>https://www.sciencedirect.com/science/article/pii/S0377123723001107.

GAO, L.; MENG, Q. Design of crawler and visual interactive interface based on scrapy framework. In: *2023 IEEE 3rd International Conference on Electronic Technology, Communication and Information (ICETCI)*. [S.l.: s.n.], 2023. p. 1840–1844.

GIGLOU, H. B. et al. Scholarly question answering using large language models in the nfdi4datascience gateway. In: REHM, G. et al. (Ed.). *Natural Scientific Language Processing and Research Knowledge Graphs*. Cham: Springer Nature Switzerland, 2024. p. 3–18. ISBN 978-3-031-65794-8.

HAMBARDE, K. A.; PROENçA, H. Information retrieval: Recent advances and beyond. *IEEE Access*, v. 11, p. 76581–76604, 2023.

JOSEPH, M. H.; RAVANA, S. D. Reliable information retrieval systems performance evaluation: A review. *IEEE Access*, v. 12, p. 51740–51751, 2024.

KALLOGIANNAKIS, M. et al. Educational applications of the chatgpt ai system: A systematic review research. *Educational Process: International Journal (EDUPIJ)*, v. 12, n. 3, p. 26–55, 2023. Accessed: 2024-11-03. Disponível em: <https://www.edupij.com-/index/arsiv/59/305/educational-applications-of-the-chatgpt-ai-system-a-systematic-review-research>https://www.edupij.com/index/arsiv/59/305/educational-applications-of-the-chatgpt-ai-system-a-systematic-review-research.

KAMATH, U. et al. Retrieval-augmented generation. In: _____. *Large Language Models: A Deep Dive: Bridging Theory and Practice*. Cham: Springer Nature Switzerland, 2024. p. 275–313. ISBN 978-3-031-65647-7. Disponível em: <https://doi.org/10.1007/978-3-031-65647-7_7>https://doi.org/10.1007/978-3-031-65647-7_7.

KASNECI, E. et al. Chatgpt for good? on opportunities and challenges of large language models for education. *Learning and Individual Differences*, v. 103, p. 102274, 2023. ISSN 1041-6080. Disponível em: <https://www.sciencedirect.com/science/article/pii-/S1041608023000195>https://www.sciencedirect.com/science/article/pii/S1041608023000195.

KHAN, R. et al. Impact of conversational and generative ai systems on libraries: A use case large language model (llm). *Science & Technology Libraries*, Routledge, v. 0, n. 0, p. 1–15, 2023. Disponível em: <https://doi.org/10.1080/0194262X.2023-.2254814>https://doi.org/10.1080/0194262X.2023.2254814.

KHURANA, D. et al. Natural language processing: state of the art, current trends and challenges. *Multimedia Tools and Applications*, v. 82, n. 3, p. 3713–3744, 2023. ISSN 1573-7721. Disponível em: <https://doi.org/10.1007/s11042-022-13428-4>https://doi.org/10.1007/s11042-022-13428-4.

KINI, S. et al. The role of artificial intelligence in enhancing information retrieval systems in academic libraries. *Library Progress International*, v. 44, n. 3, p. 22526–22541, 2024. ISSN 0970-1052. Available online: Jul-Dec 2024. Disponível em: <https://bpasjournals.com/library-science/index.php/journal/article/view-/2875>https://bpasjournals.com/library-science/index.php/journal/article/view/2875.

KUKREJA, S. et al. Vector databases and vector embeddings-review. In: *2023 International Workshop on Artificial Intelligence and Image Processing (IWAIIP)*. [S.l.: s.n.], 2023. p. 231–236.

LANGCHAIN. *Self-query retrieval*. 2024. Accessed: 2024-12-23. Disponível em: <https://python.langchain.com/docs/how_to/self_query-/>https://python.langchain.com/docs/how_to/self_query/.

LECHTENBERG, F. et al. Information retrieval from scientific abstract and citation databases: A query-by-documents approach based on monte-carlo sampling. *Expert Systems with Applications*, v. 199, p. 116967, 2022. ISSN 0957-4174. Disponível em: <https://www.sciencedirect.com/science/article/pii-/S0957417422003931>https://www.sciencedirect.com/science/article/pii/S0957417422003931.

LEWIS, P. et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. 2021. Disponível em: <https://arxiv.org/abs/2005-.11401>https://arxiv.org/abs/2005.11401.

LI, Y. et al. Chatdoctor: A medical chat model fine-tuned on a large language model meta-ai (llama) using medical domain knowledge. *Cureus*, v. 15, n. 6, p. e40895, June 24 2023.

MARS, M. From word embeddings to pre-trained language models: A state-of-the-art walkthrough. *Applied Sciences*, v. 12, n. 17, 2022. ISSN 2076-3417. Disponível em: <https://www.mdpi.com/2076-3417/12/17/8805>https://www.mdpi.com/2076-3417/12/17/8805.

MIN, B. et al. Recent advances in natural language processing via large pre-trained language models: A survey. *ACM Comput. Surv.*, Association for Computing Machinery, New York, NY, USA, v. 56, n. 2, set. 2023. ISSN 0360-0300. Disponível em: <https://doi.org/10.1145/3605943>https://doi.org/10.1145/3605943.

MOSBAH, M. Query refinement into information retrieval systems: An overview. *Journal of Information and Organizational Sciences*, v. 47, n. 1, p. 133–151, 2023. Disponível em: <https://hrcak.srce.hr/305397>https://hrcak.srce.hr/305397.

NAGARHALLI, T. P.; VAZE, V.; RANA, N. K. Impact of machine learning in natural language processing: A review. In: *2021 Third International Conference on Intelligent Communication Technologies and Virtual Mobile Networks (ICICV)*. [S.l.: s.n.], 2021. p. 1529–1534.

NASSIRI, K.; AKHLOUFI, M. A. Recent advances in large language models for healthcare. *BioMedInformatics*, v. 4, n. 2, p. 1097–1143, 2024. ISSN 2673-7426. Disponível em: <https:-//www.mdpi.com/2673-7426/4/2/62>https://www.mdpi.com/2673-7426/4/2/62.

OPENAI. *API Pricing*. 2024. Accessed: 2024-12-23. Disponível em: <https://openai.com-/api/pricing/>https://openai.com/api/pricing/.

POSEDARU, B.-S. et al. Artificial intelligence text processing using retrieval-augmented generation: Applications in business and education fields. *Proceedings of the International Conference on Business Excellence*, v. 18, n. 1, p. 209–222, 2024. Disponível em: <https://doi.org/10.2478/picbe-2024-0018>https://doi.org/10.2478/picbe-2024-0018.

TOPSAKAL, O.; AKINCI, T. C. Creating large language model applications utilizing langchain: A primer on developing llm apps fast. In: *International Conference on Applied Engineering and Natural Sciences*. [S.l.: s.n.], 2023. v. 1, n. 1, p. 1050–1056.

VASWANI, A. et al. *Attention Is All You Need*. 2023. Disponível em: <https://arxiv.org-/abs/1706.03762>https://arxiv.org/abs/1706.03762.

ZHAO, B. Web scraping. In: _____. *Encyclopedia of Big Data*. Cham: Springer International Publishing, 2022. p. 951–953. ISBN 978-3-319-32010-6. Disponível em: <https://doi.org/10.1007/978-3-319-32010-6_483>https://doi.org/10.1007/978-3-319-32010-6_483.