Gabriel Ribeiro de Freitas

Predição de risco de mortalidade infantil em neonatos prematuros baseado em aprendizagem de máquina

Natal - RN

Janeiro de 2025

Gabriel Ribeiro de Freitas

Predição de risco de mortalidade infantil em neonatos prematuros baseado em aprendizagem de máquina

Trabalho de Conclusão de Curso de Engenharia de Computação da Universidade Federal do Rio Grande do Norte, apresentado como requisito parcial para a obtenção do grau de Bacharel em Engenharia de Computação

Orientador: Dr. Marcelo Augusto Costa Fernandes

Universidade Federal do Rio Grande do Norte - UFRN

Departamento de Engenharia de Computação e Automação - DCA

Curso de Engenharia de Computação

Natal - RN

Janeiro de 2025

Gabriel Ribeiro de Freitas

Predição de risco de mortalidade infantil em neonatos prematuros baseado em aprendizagem de máquina

Trabalho de Conclusão de Curso de Engenharia de Computação da Universidade Federal do Rio Grande do Norte, apresentado como requisito parcial para a obtenção do grau de Bacharel em Engenharia de Computação

Orientador: Dr. Marcelo Augusto Costa Fernandes

Trabalho aprovado. Natal - RN, 17 de Janeiro de 2025:

Prof. Dr. Marcelo Augusto Costa Fernandes
UFRN

Profª. Drª. Lucileide Medeiros Dantas da Silva
IFRN

MS. Matheus Gibeke Siqueira Dalmolin
(PPGEEC) UFRN

Natal - RN
Janeiro de 2025

Universidade Federal do Rio Grande do Norte - UFRN
Sistema de Bibliotecas - SISBI
Catalogação de Publicação na Fonte. UFRN - Biblioteca Central Zila Mamede

Freitas, Gabriel Ribeiro de.
Predição de risco de mortalidade infantil em neonatos prematuros baseado em aprendizagem de máquina / Gabriel Ribeiro de Freitas. - 2025.
65f.: il.

Monografia (Graduação) - Universidade Federal do Rio Grande do Norte, Centro de Tecnologia, Engenharia de Computação, Natal, 2025.
Orientação: Prof. Dr. Marcelo Augusto Costa Fernandes.

1. Machine Learning - Monografia. 2. Modelos preditivos - Monografia. 3. Ética em saúde - Monografia. I. Fernandes, Marcelo Augusto Costa. II. Título.

RN/UF/BCZM CDU 004

Elaborado por Raimundo Muniz de Oliveira - CRB-15/429

AGRADECIMENTOS

Agradeço primeiramente a Deus, por iluminar meu caminho e dar-me força nos momentos de dificuldade.

A minha esposa Michely, por todo incentivo durante o curso, por todo apoio, amor e companheirismo e por acreditar em mim e no meu potencial, e por não me deixar desistir deste sonho.

A todos os meus familiares que sempre me deram o suporte e não me desampararam em momento algum, em especial aos meus pais, irmãos, e minha amada sobrinha. Ao meu primo e irmão de vida Gustavo. Aos meus tios, Francisco, Ivonaide, Maria de Fátima, Helena e Betânia.

À minha falecida avó e segunda mãe, Cícera. Queria muito que pudesse estar presente nesse momento celebrando essa conquista comigo.

Agradeço também aos meus amigos e colegas de curso, pelo ambiente colaborativo e por todas as discussões enriquecedoras, em especial a Ítalo, Ana Rute, Jadson, Dorgival, Inaldo, Lucas e Lara. À universidade e a todos os professores do departamento, pelo ambiente acadêmico estimulante e pelos recursos disponibilizados.

Um agradecimento ao meu orientador, Dr. Marcelo Augusto Costa Fernandes, pela paciência, dedicação e ensinamentos valiosos. Sem a orientação e o conhecimento dele, este trabalho não teria sido possível.

Por fim, a todos que, direta ou indiretamente, contribuíram para a realização deste trabalho, meu sincero obrigado.

“Feliz o homem que encontrou a sabedoria e alcançou o entendimento,
porque a sabedoria vale mais do que a prata,
e dá mais lucro que o ouro."
(Bíblia Sagrada, Provérbios 3, 13-14)

RESUMO

O estudo investiga a aplicação de modelos de Machine Learning (ML) na predição do risco de mortalidade em neonatos prematuros, um dos desafios mais significativos da medicina neonatal contemporânea. A pesquisa explora como técnicas avançadas de ML, como Gradient Boosting, Redes Neurais, Regressão Logística e Naive Bayes, podem desenvolver sistemas preditivos precisos e confiáveis para identificar neonatos em maior risco, visando melhorar intervenções e reduzir a mortalidade infantil. A hipótese central sugere que cada modelo possui diferentes potenciais na predição desses riscos, sendo avaliado com base em desempenho, integração clínica e contribuição para políticas de saúde pública. A metodologia incluiu uma revisão sistemática da literatura e o desenvolvimento de um dataset próprio, construído a partir de dados públicos do SIM e SINASC. Esses dados foram refinados e ajustados para eliminar inconsistências e garantir sua aplicabilidade em técnicas de ML, criando uma base direcionada e consistente. A análise dos modelos indicou que, embora todos apresentem aplicabilidade, aspectos como viés nos dados, interpretabilidade e integração clínica variam entre eles. Concluiu-se que a escolha do modelo ideal deve equilibrar precisão, transparência e aplicabilidade clínica, considerando ainda questões éticas relacionadas à privacidade e ao consentimento informado.

Palavras-chaves: Machine Learning. Mortalidade neonatal. Modelos preditivos. Ética em saúde.

ABSTRACT

This study investigates the application of Machine Learning (ML) models to predict mortality risk in preterm neonates, one of the most significant challenges in contemporary neonatal medicine. The research explores how advanced ML techniques, such as Gradient Boosting, Neural Networks, Logistic Regression, and Naive Bayes, can develop accurate and reliable predictive systems to identify neonates at higher risk, aiming to improve interventions and reduce infant mortality. The central hypothesis suggests that each model has distinct potential in predicting these risks, evaluated based on performance, clinical integration, and contributions to public health policies. The methodology included a systematic literature review and the development of a custom dataset built from public data sources, SIM and SINASC. These data were refined and adjusted to eliminate inconsistencies and ensure their applicability in ML techniques, resulting in a targeted and consistent database. The analysis of the models indicated that, while all showed applicability, aspects such as data bias, interpretability, and clinical integration varied among them. It was concluded that the choice of the ideal model must balance accuracy, transparency, and clinical applicability, while also carefully considering ethical issues related to data privacy and informed consent.

Keywords: Machine Learning. Neonatal mortality. Predictive models. Health ethics.

LISTA DE ILUSTRAÇÕES

Figura 1 – Fluxograma da unificação dos Datasets SIM e SINASC 39
Figura 2 – Fluxograma da limpeza do Dataset recém unificado 40
Figura 3 – Fluxograma da limpeza do dataset unificado para formação do dataset de entradas 41
Figura 4 – Fluxograma da categorização e agrupamento dos dados do dataset para se obter melhores resultados nos algorítmos 42
Figura 5 – Resultados do modelo Gradient Boosting 53
Figura 6 – Resultados do modelo Neural Network 54
Figura 7 – Resultados do modelo Logistic Regression 56
Figura 8 – Resultados do modelo Naive Bayes 57

LISTA DE TABELAS

Tabela 1 – Distribuição relativa de dados demográficos, socioeconômicos, obstétricos e cuidados prévios relacionados aos recém-nascidos no Brasil, 2015-2017 . . 46
Tabela 2 – Comparação dos resultados de todos os mudelos utilizados 52

LISTA DE ABREVIATURAS E SIGLAS

UFRN	*Universidade Federal do Rio Grande do Norte*
UNICEF	*Fundo das Nações Unidas para a Infância (United Nations Children's Fund)*
OMS	*Organização Mundial da Saúde*
ML	*Machine Learning*
GDPR	*Regulamento Geral de Proteção de Dados (General Data Protection Regulation)*
API	*Interfaces de Programação de Aplicativos (Application Programming Interface)*
EDA	*Análise Exploratória de Dados (Exploratory Data Analysis)*
PCA	*Análise de Componentes Principais (Principal Component Analysis)*
AUC	*Área Sob a Curva ROC (Area Under the Curve)*
ROC	*Característica de Operação do Receptor (Receiver Operating Characteristic)*
CIDACS	*Centro de Integração de Dados e Conhecimentos para Saúde*
CADU	*Cadastro Único*
SINASC	*Sistema de Informação sobre Nascidos Vivos*
SIM	*Sistema de Informação sobre Mortalidade*
PCDaS/Icic	*Plataforma de Ciência de Dados aplicada à Saúde*
DN	*Declaração de Nascido Vivo*
SINAN	*Sistema de Informação de Agravos de Notificação*
ReLU	*Unidade Linear Retificada (Rectified Linear Unit)*
UTIN	*Unidade de Terapia Intensiva Neonatal*
XAI	*Apendizado de Máquina Explicável (eXplainable AI)*

SUMÁRIO

1 INTRODUÇÃO . . . 13
1.1 Contextualização do Problema . . . 13
1.2 Relevância e Justificativa . . . 14
1.3 Objetivos da Pesquisa . . . 14
1.3.1 Objetivo Geral . . . 14
1.3.2 Objetivos Específicos . . . 14
1.4 Estrutura do Trabalho . . . 15

2 REFERENCIAL TEÓRICO . . . 16
2.1 Mortalidade Infantil em Neonatos Prematuros . . . 16
2.1.1 Contexto Global da Mortalidade Infantil: . . . 16
2.1.2 Desafios no Cuidado Neonatal: . . . 17
2.1.3 Importância da Prevenção: . . . 19
2.2 Aprendizado de Máquina na Medicina . . . 20
2.2.1 Aplicação de ML na Saúde: . . . 20
2.2.2 Modelos Preditivos para Cuidados de Saúde: . . . 22
2.2.3 Desenvolvimento e Desafios: . . . 23
2.3 Datasets e Tratamento de Dados . . . 25
2.3.1 Coleta e Preparação de Dados: . . . 25
2.3.2 Análise Exploratória de Dados: . . . 26
2.3.3 Criação de Datasets para ML: . . . 27
2.4 Modelagem Preditiva e Avaliação de Desempenho . . . 29
2.4.1 Seleção de Modelos de ML: . . . 29
2.4.2 Métricas de Avaliação: . . . 30
2.4.3 Comparação e Seleção de Modelos: . . . 32
2.5 Implicações e Futuras Direções . . . 33
2.5.1 Implicações para a Saúde Pública: . . . 33
2.5.2 Limitações e Desafios Futuros: . . . 35
2.5.3 Avanços Tecnológicos e Ética: . . . 36

3 METODOLOGIA . . . 38
3.1 Dataset . . . 38
3.2 Algorítmos e suas arquiteturas . . . 47
3.2.1 Gradient Boosting . . . 47
3.2.2 Neural Network . . . 48

3.2.3 Regressão Logística 49
3.2.4 Naive Bayes 49
3.2.5 Validação e Avaliação dos Modelos 50

4 RESULTADOS E ANÁLISES 52
4.1 Resultados 52
4.1.1 Gradient Boosting 53
4.1.2 Neural Network 54
4.1.3 Logistic Regression 56
4.1.4 Naive Bayes 57
4.2 Análises 58

5 CONCLUSÕES 62

REFERÊNCIAS 64

1 INTRODUÇÃO

1.1 Contextualização do Problema

A mortalidade infantil é uma das maiores preocupações da saúde global, refletindo não apenas a qualidade do sistema de saúde de uma nação, mas também o bem-estar de suas famílias. Entre os desafios enfrentados no campo da saúde infantil, a mortalidade de neonatos prematuros destaca-se como uma área de especial preocupação. Os neonatos prematuros, bebês nascidos antes de 37 semanas de gestação, apresentam um risco consideravelmente maior de mortalidade e complicações de saúde do que seus pares nascidos a termo. Reduzir a mortalidade infantil, especialmente entre os neonatos prematuros, é um objetivo prioritário de políticas de saúde pública em todo o mundo.

De acordo com dados recentemente publicados pelo Fundo das Nações Unidas para a Infância (UNICEF), em 2016 a principal causa de mortalidade infantil até os 5 anos foi o nascimento prematuro, representando cerca de 17,9% da mortalidade infantil global (UNICEF, 2018). No Brasil, o cenário é semelhante, com a prematuridade contribuindo para 17,1% das mortes infantis, atrás apenas de problemas congênitos. Quando restringimos a análise ao período neonatal, os problemas relacionados à prematuridade tornam-se a principal causa de mortalidade infantil, representando 15,1% do total. Em 2017, cerca de 2,5 milhões de recém-nascidos morreram nos seus primeiros 28 dias de vida, sendo a grande maioria dessas mortes atribuíveis a causas evitáveis. Além disso, 80% dessas crianças tinham baixo peso ao nascer e 65% eram prematuras (OMS, 2018).

A medicina moderna fez avanços significativos na melhoria dos cuidados neonatais; no entanto, a capacidade de prever e mitigar o risco de mortalidade em neonatos prematuros continua sendo um desafio complexo. É neste contexto que surge a aplicação de técnicas de aprendizado de máquina (Machine Learning - ML) como uma ferramenta promissora para auxiliar na identificação precoce de neonatos prematuros em risco de mortalidade. A capacidade do aprendizado de máquina de processar grandes volumes de dados e identificar padrões sutis oferece uma oportunidade única para a medicina preditiva e preventiva.

Além disso, o sucesso de qualquer sistema preditivo baseado em aprendizado de máquina depende fundamentalmente da qualidade dos dados utilizados. Um dos desafios enfrentados nesta pesquisa foi a complexidade inerente aos datasets nacionais disponíveis, como o Sistema de Informações sobre Nascidos Vivos (SINASC) e o Sistema de Informações sobre Mortalidade (SIM). Esses datasets, embora abrangentes, possuem inconsistências e dados faltantes que podem comprometer o desempenho dos modelos preditivos. Portanto, este trabalho envolveu um extenso processo de criação, limpeza e preparação de um dataset inédito, construído a partir da unificação

de informações das bases SINASC e SIM, visando superar essas limitações. O resultado é um recurso valioso que poderá beneficiar a comunidade científica, sendo uma das maiores contribuições desta pesquisa.

1.2 Relevância e Justificativa

A relevância deste estudo reside na necessidade de desenvolver abordagens inovadoras para prevenir a mortalidade infantil, especialmente entre neonatos prematuros. A criação de um dataset unificado, otimizado para aplicações de aprendizado de máquina, constitui um avanço significativo nesse campo, permitindo não apenas a análise preditiva mais precisa, mas também o desenvolvimento de políticas públicas baseadas em evidências concretas. A aplicação do aprendizado de máquina nesse contexto oferece a promessa de melhorar significativamente a identificação de riscos e, consequentemente, a intervenção médica oportuna.

1.3 Objetivos da Pesquisa

1.3.1 Objetivo Geral

Este trabalho apresenta uma proposta de desenvolvimento de um sistema de predição automática baseado em técnicas de aprendizado de máquina para mensurar o risco de mortalidade infantil em neonatos prematuros, utilizando dados clínicos, informações demográficas e fatores de risco, de forma a contribuir para políticas públicas mais efetivas e auxiliar profissionais de saúde na identificação precoce de neonatos em maior risco, possibilitando intervenções oportunas e personalizadas.

1.3.2 Objetivos Específicos

- Identificar os principais fatores de risco associados à mortalidade infantil em neonatos prematuros, considerando variáveis clínicas, demográficas e socioeconômicas.
- Selecionar e preprocessar dados relevantes para a construção de modelos de aprendizado de máquina, garantindo a qualidade e consistência dos dados utilizados.
- Implementar e avaliar diferentes algoritmos de aprendizado de máquina para a predição do risco de mortalidade infantil em neonatos prematuros, buscando identificar o modelo mais preciso e confiável.
- Validar o sistema de predição com base em métricas estatísticas robustas e, se possível, compará-lo com abordagens tradicionais ou outros modelos existentes.

- Propor recomendações baseadas nos resultados obtidos, contribuindo para políticas públicas e estratégias de intervenção para a saúde neonatal.

1.4 Estrutura do Trabalho

O presente trabalho está organizado da seguinte forma: no Capítulo 2, revisaremos a literatura atual relacionada à mortalidade infantil em neonatos prematuros e ao uso de técnicas de aprendizado de máquina na área da saúde. No Capítulo 3, descreveremos a metodologia utilizada para coleta e processamento de dados, bem como os modelos de aprendizado de máquina selecionados. O Capítulo 4 apresentará os resultados obtidos, seguidos por uma discussão detalhada. Finalmente, no Capítulo 5, resumiremos as principais descobertas e destacaremos a relevância deste trabalho, além de sugerir direções futuras para a pesquisa.

Este desenvolvimento de um sistema de predição representa um passo crucial em direção a uma abordagem mais eficaz e personalizada para a prevenção da mortalidade infantil em neonatos prematuros, com o potencial de salvar vidas e melhorar a qualidade dos cuidados neonatais em todo o mundo.

2 REFERENCIAL TEÓRICO

2.1 Mortalidade Infantil em Neonatos Prematuros

2.1.1 Contexto Global da Mortalidade Infantil:

A mortalidade infantil permanece como um dos mais severos indicadores de saúde pública ao redor do mundo, refletindo não apenas as condições de saúde das populações, mas também o acesso a serviços de saúde materno-infantil de qualidade. A prematuridade é destacada como uma das principais causas de mortalidade infantil global, uma condição que afeta milhões de bebês anualmente e representa um desafio significativo para sistemas de saúde em diversos países. Organizações como a UNICEF e a Organização Mundial da Saúde (OMS) têm documentado e divulgado dados alarmantes, apontando a prematuridade como uma questão de saúde prioritária a ser enfrentada com estratégias globais e locais específicas (AKAZAWA; HASHIMOTO, 2022).

Estudos recentes sugerem uma relação direta entre as condições de saúde materna durante a gestação e o risco de partos prematuros. Doenças como hipertensão, diabetes gestacional e infecções urinárias são fatores conhecidos que contribuem para o aumento da incidência de nascimentos prematuros, ressaltando a importância de cuidados pré-natais eficazes e acessíveis para prevenir essas ocorrências. A identificação precoce de gestantes em risco pode mitigar a probabilidade de prematuridade, destacando a necessidade de desenvolver e implementar tecnologias preditivas avançadas neste campo (JASKARI et al., 2020).

Além das condições de saúde materna, fatores socioeconômicos e demográficos também desempenham papéis cruciais nas taxas de mortalidade infantil, especialmente em regiões com recursos limitados. A disponibilidade e a qualidade dos cuidados neonatais, o acesso a alimentação adequada e a existência de políticas públicas de saúde focadas na saúde materno-infantil são determinantes significativos para a sobrevivência de neonatos prematuros. Assim, o desenvolvimento de sistemas de predição automatizados, que utilizam técnicas de aprendizado de máquina, surge como uma estratégia promissora para antever e mitigar os riscos associados à prematuridade (GAO et al., 2019).

A implementação de modelos de predição baseados em aprendizado de máquina para avaliar o risco de mortalidade em neonatos prematuros representa um avanço significativo na medicina neonatal. Esses modelos podem processar grandes volumes de dados clínicos e demográficos, identificando padrões e correlações que não são facilmente perceptíveis por métodos tradicionais de análise. A capacidade de prever quais bebês estão em maior risco pode transformar a abordagem clínica, permitindo intervenções mais rápidas e personalizadas, o que é vital para melhorar as taxas de sobrevivência desses neonatos (HE et al., 2020).

O uso de dados de séries temporais, como sinais vitais e análises de gases no sangue, tem mostrado potencial para melhorar a precisão dos modelos de predição. A análise desses dados através de técnicas avançadas de aprendizado de máquina permite a criação de modelos preditivos que podem antecipar eventos críticos, como a mortalidade neonatal, com maior precisão. A implementação desses modelos em ambientes clínicos pode oferecer aos profissionais de saúde ferramentas valiosas para a tomada de decisões baseadas em evidências, contribuindo para intervenções mais eficazes e oportunas (MATSUSHITA; KREBS; CARVALHO, 2022).

No entanto, a adoção de tecnologias de predição no contexto da saúde neonatal enfrenta desafios, incluindo questões éticas, a necessidade de grandes conjuntos de dados anotados e a integração desses sistemas em fluxos de trabalho clínicos existentes. A colaboração entre médicos, pesquisadores e desenvolvedores de tecnologia é fundamental para superar esses obstáculos e garantir que os benefícios dessas ferramentas possam ser plenamente realizados no cuidado de neonatos prematuros (FENG et al., 2021).

Ademais, para que os sistemas de predição automática sejam efetivamente implementados e utilizados na prática clínica, é essencial que sejam desenvolvidos com uma abordagem centrada no usuário. Isso implica na participação ativa de profissionais de saúde no processo de desenvolvimento, garantindo que as soluções sejam práticas, intuitivas e facilmente integradas às rotinas de cuidados neonatais. O envolvimento dos usuários finais no design e teste dessas ferramentas pode significativamente aumentar sua aceitação e eficácia (BEEK et al., 2021).

Finalmente, a avaliação contínua da eficácia desses sistemas de predição é crucial para assegurar sua precisão e confiabilidade. A realização de estudos longitudinais e a análise de feedback dos usuários são componentes essenciais para o aprimoramento contínuo dessas tecnologias. À medida que os dados sobre sua utilização na prática clínica se acumulam, será possível refinar os modelos preditivos, aumentando sua precisão e, consequentemente, seu valor no suporte à tomada de decisão clínica para a gestão de riscos em neonatos prematuros (RAIHAN et al., 2024).

A exploração das taxas globais de mortalidade infantil, com um foco específico na prematuridade, destaca a importância de abordagens multidisciplinares para o desenvolvimento de soluções inovadoras. A interseção entre tecnologia, cuidado clínico e políticas públicas apresenta um caminho promissor para a redução da mortalidade infantil. O avanço contínuo em técnicas de aprendizado de máquina e a integração dessas tecnologias no cuidado neonatal são passos essenciais nessa direção, visando um futuro onde cada neonato tenha a melhor chance possível de sobrevivência e bem-estar (MONFARED; HASHEMI, 2023).

2.1.2 Desafios no Cuidado Neonatal:

Na busca incansável pela redução da mortalidade neonatal, particularmente entre neonatos prematuros, enfrentamos uma complexa rede de desafios que vão além dos avanços tecnológicos

e científicos na medicina neonatal. Apesar dos progressos significativos alcançados nas últimas décadas, a prematuridade continua a ser uma das principais causas de morte entre neonatos, revelando lacunas persistentes no cuidado e na intervenção precoce. O cuidado neonatal avançado, embora disponível em muitas partes do mundo, ainda é limitado ou inacessível em regiões de baixa e média renda, onde a maior parte das mortes por prematuridade ocorre (CHANDRIKA; SURENDRAN, 2022).

Um dos principais obstáculos ao melhoramento das taxas de sobrevivência de neonatos prematuros é a identificação e a gestão eficaz de complicações que frequentemente acompanham a prematuridade. Condições como a displasia broncopulmonar, a enterocolite necrosante e a hemorragia intraventricular representam desafios significativos para a equipe de cuidados neonatais, exigindo não apenas equipamentos especializados, mas também uma equipe altamente treinada e protocolos de tratamento adaptativos (FENG et al., 2021).

Além das questões médicas diretas, a interação entre fatores socioeconômicos e o acesso ao cuidado neonatal de qualidade desempenha um papel crucial nas disparidades observadas nas taxas de mortalidade infantil. A falta de acesso a cuidados pré-natais de qualidade e a serviços de saúde materno-infantil adequados são barreiras significativas que contribuem para o alto índice de prematuridade e suas consequências. Esta situação é exacerbada em comunidades carentes, onde as gestantes frequentemente carecem de informações e recursos para gerir adequadamente sua saúde e a de seus bebês (AKAZAWA; HASHIMOTO, 2022).

A adoção de tecnologias avançadas, como sistemas de predição automatizados baseados em aprendizado de máquina, oferece um potencial significativo para melhorar o prognóstico de neonatos prematuros. Contudo, a implementação dessas tecnologias enfrenta desafios, incluindo a necessidade de grandes volumes de dados clínicos de alta qualidade, a integração dessas ferramentas nos sistemas de saúde existentes, e a formação de profissionais para utilizá-las eficientemente (GAO et al., 2019).

A resistência à adoção de novas tecnologias e práticas baseadas em evidências no ambiente de cuidado neonatal pode ser um obstáculo adicional. A cultura de cuidado em muitos hospitais e unidades neonatais pode ser resistente a mudanças, mesmo diante de evidências claras que demonstram os benefícios de novas abordagens e tecnologias. A superação dessa barreira cultural exige esforços contínuos de educação e sensibilização dos profissionais de saúde (HE et al., 2020).

O desenvolvimento de diretrizes clínicas baseadas em evidências e sua implementação efetiva são essenciais para padronizar o cuidado aos neonatos prematuros, minimizando assim a variabilidade no tratamento e potencialmente melhorando os resultados. A colaboração internacional e o compartilhamento de conhecimentos e práticas podem acelerar esse processo, embora sejam necessários esforços coordenados para garantir a adoção dessas diretrizes em uma escala global (JASKARI et al., 2020).

A formação e a retenção de uma força de trabalho qualificada em neonatologia são fundamentais para garantir a qualidade do cuidado prestado aos neonatos prematuros. A falta de especialistas e de pessoal de enfermagem treinado em cuidados neonatais é uma realidade em muitos países, limitando a capacidade de oferecer cuidados de alta qualidade a esta população vulnerável. Investimentos em educação e treinamento são cruciais para endereçar este desafio (BEEK et al., 2021).

Por fim, o compromisso com a pesquisa contínua é indispensável para avançar no entendimento da prematuridade e suas complicações. Apesar dos desafios significativos, a investigação contínua pode proporcionar as inovações necessárias para melhorar os cuidados e os resultados para neonatos prematuros. A colaboração entre clínicos, pesquisadores e decisores políticos é essencial para traduzir descobertas de pesquisa em práticas clínicas efetivas e políticas de saúde pública eficazes (RAIHAN et al., 2024).

2.1.3 Importância da Prevenção:

A prevenção da mortalidade em neonatos prematuros representa um dos maiores desafios e oportunidades na medicina neonatal contemporânea. A capacidade de prever eficazmente os riscos associados à prematuridade e implementar medidas preventivas pode resultar em um impacto significativo na redução das taxas de mortalidade infantil. Isso não apenas melhora os resultados de saúde para os neonatos, mas também tem implicações positivas para as famílias e os sistemas de saúde como um todo. O desenvolvimento de métodos preditivos precisos e confiáveis, baseados em tecnologias de ponta como aprendizado de máquina, é fundamental para este esforço (GAO et al., 2019).

A importância de estratégias de prevenção eficazes é sublinhada pela prevalência de fatores de risco modificáveis associados à prematuridade, como condições de saúde materna, práticas de estilo de vida e exposição a riscos ambientais. Intervenções focadas na saúde materna durante a gestação têm o potencial de reduzir significativamente a incidência de partos prematuros, demonstrando a necessidade de programas de saúde pública direcionados e educação para a saúde (FENG et al., 2021).

A utilização de dados clínicos e demográficos em modelos de aprendizado de máquina para prever o risco de prematuridade abre novas avenidas para intervenções precoces. Estes modelos podem identificar gestantes em alto risco de parto prematuro, permitindo o acompanhamento e a intervenção personalizados para mitigar esses riscos. A implementação bem-sucedida dessas ferramentas pode transformar o paradigma de cuidado prenatal, movendo-se em direção a um modelo mais proativo e preventivo (HE et al., 2020).

No entanto, a aplicação efetiva dessas tecnologias preditivas enfrenta desafios, incluindo a necessidade de grandes conjuntos de dados anotados para treinamento e validação dos modelos. Além disso, a integração desses sistemas preditivos nos fluxos de trabalho clínicos existen-

tes requer uma mudança cultural e organizacional dentro das instituições de saúde, além do desenvolvimento de políticas claras para a gestão de dados de saúde (JASKARI et al., 2020).

A colaboração entre profissionais de saúde, pesquisadores e desenvolvedores de tecnologia é crucial para o desenvolvimento de soluções preditivas que sejam não apenas tecnicamente viáveis, mas também clinicamente relevantes e facilmente adotáveis no ambiente de cuidado neonatal. Essa abordagem multidisciplinar pode acelerar a inovação e garantir que as soluções desenvolvidas atendam às necessidades reais dos pacientes e profissionais de saúde (AKAZAWA; HASHIMOTO, 2022).

A educação e o treinamento contínuos de profissionais de saúde em tecnologias emergentes e práticas baseadas em evidências são fundamentais para a adoção e implementação eficazes de sistemas de previsão. O comprometimento com a educação médica contínua assegura que a força de trabalho esteja preparada para utilizar as ferramentas mais avançadas na prevenção da mortalidade neonatal prematura (BEEK et al., 2021).

O envolvimento dos pais e cuidadores no processo de cuidado é outro componente vital da prevenção. Programas de educação para a saúde que enfocam a importância do acompanhamento pré-natal, identificação de sinais de alerta e práticas saudáveis de gestação podem empoderar as famílias a contribuir ativamente para a prevenção da prematuridade. Essa abordagem centrada na família complementa as estratégias clínicas e tecnológicas, criando uma rede de suporte holística para a gestante e o feto (MATSUSHITA; KREBS; CARVALHO, 2022).

Além disso, políticas públicas e iniciativas de saúde pública que visam melhorar o acesso a cuidados de saúde de qualidade, nutrição adequada e ambientes saudáveis são essenciais para reduzir a incidência de partos prematuros. A implementação dessas políticas requer um esforço coordenado entre governos, organizações não governamentais e a sociedade civil para abordar os determinantes sociais e ambientais da saúde materna e infantil (RAIHAN et al., 2024).

Em conclusão, a prevenção da mortalidade em neonatos prematuros é uma área complexa que demanda uma abordagem multifacetada, incorporando avanços tecnológicos, práticas clínicas baseadas em evidências, educação, políticas públicas e envolvimento comunitário. O potencial para salvar vidas e melhorar os resultados para neonatos prematuros é significativo, exigindo um compromisso contínuo de todos os stakeholders envolvidos na saúde materno-infantil (MONFARED; HASHEMI, 2023).

2.2 Aprendizado de Máquina na Medicina

2.2.1 Aplicação de ML na Saúde:

A introdução de técnicas de Machine Learning (ML) na saúde tem marcado uma era de transformação significativa na forma como os dados são interpretados e utilizados para benefício do paciente. Com a capacidade de processar e analisar grandes volumes de dados de

forma eficiente, o ML tem o potencial de identificar padrões complexos e fornecer insights que seriam impossíveis de serem detectados por métodos tradicionais. Essa capacidade de extrair conhecimento a partir de vastas quantidades de dados é fundamental para avançar no diagnóstico, tratamento e prevenção de doenças (JASKARI et al., 2020).

A aplicabilidade do ML na saúde é vasta, abrangendo desde a análise de imagens médicas até a predição de surtos de doenças. Em particular, no contexto de cuidados neonatais, a capacidade do ML de analisar dados temporais e vitais pode desempenhar um papel crucial na identificação precoce de neonatos em risco de complicações graves. Este é um exemplo claro de como as técnicas de ML podem ser aplicadas para salvar vidas, permitindo intervenções oportunas e personalizadas (FENG et al., 2021).

Além da identificação de riscos e diagnósticos, o ML também está reformulando o campo da pesquisa clínica, oferecendo novos métodos para analisar a eficácia dos tratamentos e entender melhor as doenças. Por exemplo, os modelos preditivos podem ser usados para simular o curso de uma doença sob diferentes tratamentos, ajudando os médicos a escolherem a melhor abordagem para cada paciente. Esta personalização do tratamento é um dos principais benefícios do ML na saúde, promovendo cuidados mais eficazes e eficientes (AKAZAWA; HASHIMOTO, 2022).

Um dos desafios na implementação de ML na saúde é a necessidade de grandes conjuntos de dados, que são essenciais para treinar modelos precisos e confiáveis. A qualidade e a quantidade dos dados têm um impacto direto na eficácia dos modelos de ML. Isso levanta questões sobre privacidade, segurança de dados e consentimento do paciente, que devem ser cuidadosamente gerenciadas para aproveitar os benefícios do ML, mantendo a confiança e a segurança dos pacientes (GAO et al., 2019).

A integração de sistemas de ML nos fluxos de trabalho clínicos existentes representa outro desafio. Requer não apenas a adaptação tecnológica dos sistemas de saúde, mas também a aceitação e adaptação por parte dos profissionais de saúde. A educação e o treinamento em ML se tornam fundamentais para equipar médicos, enfermeiros e outros profissionais de saúde com o conhecimento necessário para utilizar essas ferramentas de forma eficaz (HE et al., 2020).

A colaboração interdisciplinar entre médicos, cientistas de dados, engenheiros e pesquisadores é essencial para o desenvolvimento e a implementação bem-sucedida de soluções de ML na saúde. Essa colaboração pode acelerar a inovação e garantir que as soluções de ML sejam tanto tecnicamente viáveis quanto clinicamente relevantes, abordando as necessidades reais dos pacientes e dos sistemas de saúde (BEEK et al., 2021).

Além disso, para que o ML alcance seu potencial máximo na saúde, é essencial o desenvolvimento de políticas e regulamentações que apoiem a inovação, garantindo ao mesmo tempo a proteção dos pacientes. Isso inclui diretrizes para o uso ético da IA, padrões para a interoperabilidade dos sistemas de saúde e marcos regulatórios para o uso de dados de saúde (CHANDRIKA; SURENDRAN, 2022).

Em conclusão, o ML apresenta uma oportunidade extraordinária para transformar a saúde, melhorando os resultados para os pacientes e otimizando os sistemas de saúde. Ao enfrentar os desafios relacionados à integração tecnológica, privacidade de dados e desenvolvimento de competências entre os profissionais de saúde, podemos desbloquear o potencial do ML para avançar no cuidado ao paciente e na pesquisa clínica (RAIHAN et al., 2024).

2.2.2 Modelos Preditivos para Cuidados de Saúde:

Modelos preditivos desenvolvidos com técnicas de Machine Learning (ML) estão revolucionando a área da saúde, oferecendo ferramentas poderosas para prever riscos e melhorar a qualidade dos cuidados oferecidos aos pacientes. Especificamente no contexto de cuidados neonatais, esses modelos têm o potencial de identificar prematuramente neonatos em risco de desenvolver condições graves, permitindo intervenções mais rápidas e personalizadas, o que pode significar a diferença entre a vida e a morte (JASKARI et al., 2020).

A aplicação de ML no cuidado neonatal representa um avanço significativo na previsão de riscos de saúde. Utilizando dados históricos e em tempo real, os modelos de ML podem analisar padrões e variáveis que humanos podem não ser capazes de interpretar ou que exigiriam muito tempo para análise. Isso inclui desde sinais vitais até informações genéticas e ambientais, oferecendo um panorama abrangente da saúde do neonato (FENG et al., 2021).

Os modelos de ML são particularmente adequados para lidar com a complexidade e a alta dimensionalidade dos dados em saúde. Eles podem identificar correlações e tendências ocultas em grandes conjuntos de dados, o que é crucial para desenvolver estratégias de prevenção e tratamento eficazes. No cenário dos cuidados neonatais, isso significa poder antecipar complicações como sepse neonatal, distúrbios respiratórios e problemas de desenvolvimento, entre outros (GAO et al., 2019).

A criação desses modelos envolve o treinamento com conjuntos de dados extensos e bem anotados, o que destaca a importância da coleta de dados de qualidade e do consentimento informado. O desenvolvimento responsável de modelos de ML em saúde também deve levar em consideração questões éticas, garantindo que os dados sejam utilizados de maneira que respeite a privacidade e a confidencialidade dos pacientes (HE et al., 2020).

Um dos desafios na implementação de modelos preditivos em cuidados neonatais é a integração dessas ferramentas em sistemas de saúde já estabelecidos. Isso requer não apenas infraestrutura tecnológica, mas também mudanças nos processos de trabalho e na cultura organizacional, além do treinamento de profissionais de saúde para interpretar e agir com base nas previsões dos modelos (AKAZAWA; HASHIMOTO, 2022).

Outro aspecto crítico é a necessidade de validação e teste contínuos desses modelos em ambientes clínicos reais. A eficácia de um modelo de ML deve ser comprovada através de estudos clínicos rigorosos, garantindo que as previsões sejam precisas e relevantes para a prática

clínica. Isso é essencial para conquistar a confiança dos profissionais de saúde e dos pacientes nas previsões geradas pelos modelos (BEEK et al., 2021).

Além disso, a colaboração multidisciplinar entre médicos, cientistas da computação, estatísticos e outros especialistas é fundamental para o desenvolvimento bem-sucedido de modelos preditivos em saúde. Essa colaboração pode acelerar a inovação e garantir que os modelos sejam desenvolvidos com uma compreensão profunda das necessidades clínicas e dos desafios práticos enfrentados na área de cuidados neonatais (CHANDRIKA; SURENDRAN, 2022).

A longo prazo, a implementação bem-sucedida de modelos de ML em cuidados neonatais tem o potencial de transformar a maneira como o atendimento é prestado, melhorando os resultados para os neonatos e suas famílias. Ao permitir intervenções baseadas em evidências e altamente personalizadas, os modelos preditivos podem contribuir significativamente para a redução da mortalidade e morbidade neonatais (RAIHAN et al., 2024).

Em conclusão, os modelos preditivos baseados em ML representam uma fronteira promissora na melhoria dos cuidados de saúde para neonatos prematuros. Com a combinação certa de tecnologia avançada, dados de qualidade e colaboração interdisciplinar, esses modelos têm o potencial de oferecer previsões precisas que podem salvar vidas e melhorar a qualidade do atendimento neonatal (MONFARED; HASHEMI, 2023).

2.2.3 Desenvolvimento e Desafios:

A integração de sistemas preditivos baseados em Machine Learning (ML) na prática médica abre um novo horizonte para a prevenção, diagnóstico e tratamento de doenças. No entanto, a implementação dessas tecnologias enfrenta desafios significativos, desde a coleta e processamento de dados até questões éticas e de privacidade. Um dos principais desafios é a necessidade de grandes volumes de dados de alta qualidade para treinar os modelos de forma eficaz, o que exige sistemas robustos de coleta e armazenamento de dados, bem como uma gestão cuidadosa para garantir a precisão e a relevância dos dados utilizados (GAO et al., 2019).

Além disso, a variabilidade inerente aos dados clínicos e a complexidade das condições médicas apresentam dificuldades adicionais na modelagem de sistemas preditivos precisos. A diversidade de populações de pacientes e as múltiplas variáveis que influenciam os desfechos de saúde exigem modelos altamente sofisticados, capazes de generalizar bem a partir dos dados de treinamento e adaptar-se às peculiaridades de novos dados. Isso requer uma abordagem interdisciplinar, combinando expertise em saúde, estatística e ciência da computação (FENG et al., 2021).

A adoção desses sistemas na prática clínica também levanta questões sobre a aceitação por parte dos profissionais de saúde. A resistência às mudanças, a desconfiança nas decisões geradas por algoritmos e a preocupação com a perda de autonomia profissional são barreiras que

precisam ser superadas. Isso envolve não apenas demonstrar a eficácia dos sistemas preditivos através de estudos clínicos rigorosos, mas também educar e treinar profissionais de saúde sobre como essas ferramentas podem auxiliar, e não substituir, o julgamento clínico (HE et al., 2020).

Questões éticas e de privacidade são especialmente críticas quando se trata de dados de saúde. A implementação de sistemas preditivos baseados em ML deve ser acompanhada de estritas salvaguardas para proteger a confidencialidade e a integridade dos dados dos pacientes. Isso inclui garantir a conformidade com regulamentos de proteção de dados, como o GDPR na Europa, e desenvolver políticas claras sobre o uso e compartilhamento de dados (JASKARI et al., 2020).

Outro desafio importante é a necessidade de transparência e explicabilidade dos modelos de ML. A "caixa preta"associada a muitos modelos avançados de ML pode ser uma barreira significativa à sua aceitação por profissionais de saúde e pacientes, que desejam entender as razões por trás das previsões. Desenvolver modelos que sejam tanto precisos quanto interpretáveis é um campo de pesquisa ativo e crucial para a integração bem-sucedida dessas tecnologias na medicina (AKAZAWA; HASHIMOTO, 2022).

A interoperabilidade com os sistemas de saúde existentes é outro desafio técnico. Os sistemas preditivos precisam ser capazes de integrar-se de forma eficaz com os registros eletrônicos de saúde, sistemas de gestão hospitalar e outras ferramentas tecnológicas já em uso. Isso requer padrões abertos e interfaces de programação de aplicativos (APIs) flexíveis, além de um esforço colaborativo entre desenvolvedores de tecnologia, profissionais de saúde e instituições (BEEK et al., 2021).

O desenvolvimento de políticas e diretrizes regulatórias para orientar o uso de sistemas preditivos em saúde é fundamental. As autoridades regulatórias têm o desafio de promover a inovação, garantindo ao mesmo tempo a segurança e a eficácia dessas tecnologias. Isso inclui estabelecer padrões para o desenvolvimento, validação e monitoramento contínuo dos sistemas preditivos baseados em ML, assegurando que eles atendam às necessidades dos pacientes e aos padrões de cuidados de saúde (CHANDRIKA; SURENDRAN, 2022).

Por fim, a integração bem-sucedida de sistemas preditivos na prática médica requer uma abordagem colaborativa, envolvendo uma ampla gama de stakeholders. Isso inclui não apenas cientistas de dados e profissionais de saúde, mas também pacientes, reguladores e formuladores de políticas. Juntos, esses grupos podem trabalhar para superar os desafios e maximizar o potencial dos sistemas preditivos para melhorar os cuidados de saúde (RAIHAN et al., 2024).

2.3 Datasets e Tratamento de Dados

2.3.1 Coleta e Preparação de Dados:

O processo de coleta de dados clínicos e demográficos é um passo fundamental na pesquisa médica e na aplicação de técnicas de Machine Learning (ML) na saúde. Esta coleta envolve reunir informações precisas e relevantes de diversas fontes, como prontuários eletrônicos de saúde, registros médicos, bancos de dados demográficos e questionários específicos. A integridade e a qualidade desses dados são essenciais para o desenvolvimento de modelos preditivos confiáveis e precisos (JASKARI et al., 2020).

A importância da preparação e limpeza de datasets para análise não pode ser subestimada. Esta etapa inclui a correção de erros, a remoção de duplicatas, a tratativa de valores ausentes e a normalização dos dados para garantir que os modelos de ML sejam treinados com informações consistentes e confiáveis. A preparação de dados é um processo que pode consumir um tempo significativo, mas é crucial para a eficácia da análise subsequente (FENG et al., 2021).

Uma das maiores dificuldades na coleta de dados clínicos e demográficos é garantir a representatividade e a diversidade da amostra. Dados enviesados ou não representativos podem levar a modelos de ML que não generalizam bem para a população geral, limitando sua utilidade e precisão na prática clínica. Portanto, é vital que os esforços de coleta de dados sejam meticulosamente planejados para capturar uma ampla gama de variáveis e populações (GAO et al., 2019).

A interoperabilidade dos dados também representa um desafio significativo. Dados clínicos e demográficos frequentemente vêm de sistemas distintos, cada um com seu próprio formato e padrões. A capacidade de integrar esses dados de maneira eficaz é crucial para o desenvolvimento de sistemas de ML na saúde, exigindo esforços de padronização e harmonização dos dados coletados (HE et al., 2020).

A privacidade e a segurança dos dados são considerações essenciais em todo o processo. Com a coleta e o manuseio de informações sensíveis, é imperativo aderir a rigorosas diretrizes de proteção de dados, garantindo que todas as informações sejam anonimizadas e criptografadas para proteger a privacidade dos pacientes. Isso requer um equilíbrio cuidadoso entre a acessibilidade dos dados para pesquisa e a salvaguarda da confidencialidade dos pacientes (AKAZAWA; HASHIMOTO, 2022).

A fase de limpeza de dados envolve técnicas específicas para lidar com dados ausentes ou incorretos, que são comuns em registros clínicos. Métodos de imputação, por exemplo, podem ser usados para estimar valores ausentes, enquanto a análise exploratória de dados pode ajudar a identificar e corrigir erros ou inconsistências. Este processo é vital para assegurar a confiabilidade das análises realizadas com os dados (BEEK et al., 2021).

Após a limpeza, a etapa de transformação de dados prepara o dataset para análise,

convertendo os dados para formatos adequados para modelagem e realizando normalizações ou transformações necessárias. Esta etapa também envolve a seleção de características, onde variáveis significativas são identificadas e selecionadas para inclusão no modelo de ML. A seleção eficaz de características pode significativamente melhorar a performance dos modelos preditivos (CHANDRIKA; SURENDRAN, 2022).

A validação dos dados é outro componente crítico do processo, assegurando que os datasets sejam não apenas precisos e limpos, mas também relevantes para as perguntas de pesquisa ou objetivos clínicos. Isso frequentemente envolve a revisão dos dados por especialistas na área de estudo, garantindo que as variáveis selecionadas sejam clinicamente relevantes e que os dados reflictam adequadamente as condições ou populações em análise (RAIHAN et al., 2024).

Por fim, a preparação de dados é um processo contínuo e iterativo, que requer uma avaliação constante à medida que novos dados são coletados e novas análises são realizadas. A adoção de práticas rigorosas de coleta e preparação de dados não apenas melhora a qualidade dos modelos de ML desenvolvidos, mas também aumenta a confiança dos profissionais de saúde nas previsões geradas, potencializando seu impacto na melhoria dos cuidados de saúde (MONFARED; HASHEMI, 2023).

2.3.2 Análise Exploratória de Dados:

A análise exploratória de dados (EDA) é uma etapa crucial no processo de modelagem preditiva, especialmente quando se lida com grandes datasets na área da saúde. Essa técnica permite aos pesquisadores e cientistas de dados entenderem a estrutura, os padrões e as peculiaridades dos dados, facilitando a identificação de variáveis relevantes para análises posteriores. A EDA emprega uma combinação de métodos estatísticos e visualizações gráficas para resumir as características principais do dataset, oferecendo insights valiosos sem a necessidade de fazer suposições a priori sobre os dados (JASKARI et al., 2020).

Uma técnica fundamental na EDA é a análise de distribuição das variáveis, que ajuda a identificar tendências, outliers e padrões de distribuição anormais que podem indicar erros de coleta de dados ou insights importantes sobre a população estudada. Histogramas, boxplots e gráficos de densidade são ferramentas comumente utilizadas para essa finalidade, permitindo uma visualização clara das distribuições de variáveis contínuas e facilitando a detecção de irregularidades (FENG et al., 2021).

Para variáveis categóricas, gráficos de barras e tabelas de frequência são empregados para explorar a contagem ou proporção de cada categoria, revelando possíveis desequilíbrios ou tendências significativas nas categorias analisadas. Essa análise é crucial para entender a composição da amostra e identificar variáveis que possam exigir estratificação ou ponderação durante a modelagem (GAO et al., 2019).

A análise de correlação é outra técnica importante na EDA, utilizada para investigar a relação entre variáveis. Gráficos de dispersão e mapas de calor de coeficientes de correlação, como o de Pearson ou Spearman, são ferramentas úteis para visualizar a força e a direção das relações entre variáveis. Essa análise ajuda a identificar variáveis que estão fortemente relacionadas ao desfecho de interesse ou a outras variáveis, guiando a seleção de características para modelos de ML (HE et al., 2020).

A EDA também envolve a verificação da qualidade dos dados, incluindo a identificação e o tratamento de valores ausentes. A análise de padrões de dados faltantes e a aplicação de técnicas apropriadas de imputação são essenciais para garantir a integridade do dataset e a validade das análises subsequentes. A escolha da técnica de imputação depende da natureza dos dados e do mecanismo de ausência, sendo crucial para evitar viés na modelagem final (AKAZAWA; HASHIMOTO, 2022).

Outliers ou pontos fora da curva representam outra área de foco durante a EDA. A identificação de outliers é fundamental, pois eles podem distorcer as análises e influenciar o desempenho dos modelos de ML. Métodos estatísticos e visualizações específicas, como gráficos de caixa, ajudam a detectar e avaliar a relevância desses pontos, determinando se representam erros de coleta de dados ou variações naturais dentro da população estudada (BEEK et al., 2021).

A transformação de dados é frequentemente necessária após a EDA para preparar o dataset para a modelagem. Isso pode incluir a normalização ou padronização de variáveis, a transformação de variáveis categóricas em formatos numéricos por meio de codificação, e a criação de novas variáveis por meio da combinação ou transformação de variáveis existentes. Essas manipulações visam melhorar a interpretabilidade e o desempenho dos modelos preditivos (CHANDRIKA; SURENDRAN, 2022).

Em suma, a EDA é um componente essencial no processo de modelagem preditiva, fornecendo uma base sólida para a seleção e preparação de variáveis. Ao aplicar técnicas de EDA, os pesquisadores podem garantir que os modelos de ML sejam desenvolvidos com uma compreensão profunda dos dados disponíveis, aumentando a chance de gerar previsões precisas e úteis na prática médica (RAIHAN et al., 2024).

2.3.3 Criação de Datasets para ML:

A criação de datasets otimizados para o treinamento de modelos de Machine Learning (ML) é uma etapa crítica no desenvolvimento de sistemas preditivos eficazes. Esse processo começa com a coleta cuidadosa de dados, seguida por uma série de etapas projetadas para garantir que o dataset final seja representativo, preciso e livre de vieses. A seleção criteriosa de variáveis é o primeiro passo, onde características relevantes para o problema em estudo são identificadas e escolhidas com base em conhecimento de domínio e análise exploratória de dados (JASKARI et al., 2020).

A importância de trabalhar com dados de qualidade não pode ser subestimada. Dados imprecisos ou mal coletados podem levar a modelos de ML que são ineficazes ou, pior, enganosos. Portanto, a verificação e a validação dos dados são fundamentais, incluindo a correção de erros de entrada, a verificação da consistência dos dados ao longo do tempo e a confirmação da precisão das medidas e das categorizações utilizadas (FENG et al., 2021).

Tratar dados faltantes é outro desafio importante na preparação de datasets para ML. Dependendo da natureza e da quantidade dos dados ausentes, diferentes técnicas podem ser aplicadas, como imputação, onde os valores faltantes são substituídos por estimativas baseadas no restante do dataset. A escolha da técnica de imputação depende de vários fatores, incluindo o mecanismo de ausência dos dados e a estrutura do dataset (GAO et al., 2019).

A detecção e o tratamento de outliers também são considerações importantes. Outliers podem ser indicativos de erros de medição ou de variações genuínas nos dados. A decisão de remover ou manter outliers deve ser cuidadosamente considerada, uma vez que a exclusão de dados válidos pode introduzir viés no modelo, enquanto a inclusão de erros pode prejudicar a precisão do modelo (HE et al., 2020).

A normalização ou padronização dos dados é frequentemente necessária para garantir que os modelos de ML não sejam indevidamente influenciados por variáveis em escalas significativamente diferentes. Esse processo envolve ajustar os dados para que tenham uma média de zero e um desvio padrão de um, ou que todos os valores estejam dentro de uma mesma escala pré-definida, melhorando a estabilidade e a performance do modelo (AKAZAWA; HASHIMOTO, 2022).

A divisão do dataset em conjuntos de treinamento, validação e teste é uma etapa crítica para avaliar a performance do modelo de ML de forma justa e robusta. Essa separação permite que o modelo seja treinado em um conjunto de dados, ajustado em outro e finalmente testado em um conjunto de dados completamente independente, fornecendo uma avaliação confiável de seu desempenho em dados novos e não vistos (BEEK et al., 2021).

Além disso, a seleção de características é um processo pelo qual as variáveis mais significativas para prever o desfecho de interesse são identificadas. Técnicas de redução de dimensionalidade, como análise de componentes principais (PCA) ou seleção de características baseada em importância, podem ser utilizadas para reduzir a complexidade do modelo e melhorar a interpretabilidade, sem sacrificar a precisão (CHANDRIKA; SURENDRAN, 2022).

Finalmente, a documentação completa do processo de criação do dataset é essencial para garantir a reprodutibilidade da pesquisa e permitir a validação independente dos resultados. Isso inclui registrar detalhadamente a coleta de dados, as decisões de limpeza e preparação, as técnicas de divisão dos dados e os métodos de seleção de características, fornecendo uma base sólida para o desenvolvimento futuro de modelos de ML na área da saúde (RAIHAN et al., 2024).

A criação cuidadosa de datasets otimizados representa a espinha dorsal para o desenvolvimento de modelos de ML precisos e eficazes. Através de uma combinação de seleção rigorosa de variáveis, tratamento meticuloso de dados faltantes ou incorretos, e aplicação de técnicas de preparação de dados, pesquisadores podem construir modelos robustos que têm o potencial de transformar a prática médica, melhorando os cuidados ao paciente e informando decisões clínicas (MONFARED; HASHEMI, 2023).

2.4 Modelagem Preditiva e Avaliação de Desempenho

2.4.1 Seleção de Modelos de ML:

A seleção de modelos de Machine Learning (ML) para aplicação em estudos de saúde é uma etapa crítica que pode determinar o sucesso ou falha do projeto. Diferentes modelos possuem características e suposições que os tornam mais adequados para certos tipos de dados ou problemas. Entre os modelos mais utilizados, encontram-se o Gradient Boosting, Redes Neurais, Regressão Logística e Naive Bayes, cada um com seus pontos fortes e situações preferenciais de uso (JASKARI et al., 2020).

O Gradient Boosting é uma técnica poderosa de ML que constrói modelos de forma sequencial, onde cada novo modelo corrige erros cometidos pelos modelos anteriores. Esta técnica é particularmente eficaz para lidar com dados não lineares e complexos, tornando-a ideal para muitas aplicações de saúde onde as relações entre variáveis podem ser altamente intrincadas e difíceis de modelar com métodos lineares (FENG et al., 2021)

As Redes Neurais, inspiradas no funcionamento do cérebro humano, são capazes de aprender e modelar relações complexas entre variáveis de entrada e saída através de camadas de neurônios artificiais. Esta capacidade as torna extremamente versáteis e poderosas para uma ampla gama de tarefas, incluindo classificação de imagens, análise de sequências genéticas e previsão de desfechos clínicos, especialmente em situações onde as relações entre os dados não são bem compreendidas ou são altamente não lineares (GAO et al., 2019).

A Regressão Logística, por outro lado, é um modelo estatístico que estima a probabilidade de uma variável dependente binária com base em uma ou mais variáveis independentes. Por ser um modelo mais simples e interpretável, é frequentemente utilizado para estudos clínicos onde é crucial entender o efeito de variáveis específicas sobre a probabilidade de um evento, como a ocorrência de uma doença (HE et al., 2020).

O Naive Bayes é um classificador probabilístico baseado no teorema de Bayes, com a suposição de independência entre as variáveis preditoras. Apesar de sua simplicidade e da suposição de independência muitas vezes ser uma aproximação, o Naive Bayes tem se mostrado eficaz em uma variedade de tarefas de classificação, especialmente em condições onde a dimensionalidade dos dados é alta, como na classificação de textos e análise de sentimentos

(AKAZAWA; HASHIMOTO, 2022).

Cada um desses modelos requer um processo cuidadoso de seleção e preparação de dados, onde a qualidade e a natureza dos dados influenciam diretamente a escolha do modelo. A seleção de variáveis é uma etapa crucial neste processo, garantindo que apenas as características mais relevantes sejam incluídas no modelo, o que pode melhorar a precisão e reduzir o risco de overfitting (BEEK et al., 2021).

O tratamento de dados faltantes ou incorretos é outra consideração importante na preparação de datasets para ML. Técnicas apropriadas de imputação e limpeza de dados podem impactar significativamente a qualidade do treinamento do modelo e, consequentemente, sua performance em dados de teste ou na prática clínica (CHANDRIKA; SURENDRAN, 2022).

A validação cruzada é frequentemente utilizada para avaliar a capacidade de generalização dos modelos selecionados, permitindo uma estimativa mais confiável de como o modelo irá se comportar em dados não vistos. Esse processo ajuda a evitar o overfitting, garantindo que o modelo mantenha um bom desempenho tanto nos dados de treinamento quanto em novos dados (RAIHAN et al., 2024).

Em resumo, a seleção do modelo de ML adequado é um processo multifacetado que envolve entender as características dos dados, os objetivos do estudo e as limitações de cada modelo. Através de uma combinação cuidadosa de conhecimento de domínio, técnicas estatísticas e computacionais, é possível desenvolver modelos robustos e eficazes que podem melhorar significativamente os desfechos em saúde (MONFARED; HASHEMI, 2023).

2.4.2 Métricas de Avaliação:

A avaliação do desempenho de modelos de Machine Learning (ML) é uma etapa crítica no desenvolvimento de aplicações clínicas, garantindo que os modelos sejam confiáveis, precisos e úteis na prática médica. Entre as métricas de avaliação mais comuns e informativas estão a Área sob a Curva ROC (AUC) e as Matrizes de Confusão. Essas métricas fornecem insights valiosos sobre a capacidade do modelo de distinguir entre classes de resultados e sua precisão geral (JASKARI et al., 2020).

A Curva ROC (Receiver Operating Characteristic) é uma ferramenta gráfica usada para ilustrar o desempenho de um classificador binário à medida que seu limiar de discriminação é variado. A AUC, ou Área sob a Curva ROC, é uma medida que resume a curva inteira em um único valor, com valores mais próximos de 1 indicando um desempenho melhor. Uma AUC de 1.0 representa um modelo perfeito, enquanto uma AUC de 0.5 indica um desempenho não melhor que o acaso (FENG et al., 2021).

As Matrizes de Confusão são tabelas que descrevem o desempenho de um modelo de classificação nas diferentes categorias, fornecendo detalhes sobre os verdadeiros positivos, falsos

positivos, verdadeiros negativos e falsos negativos. Esta desagregação permite uma compreensão mais profunda de como o modelo está classificando cada classe e onde podem estar ocorrendo os erros (GAO et al., 2019).

Além da AUC e das Matrizes de Confusão, outras métricas também são importantes na avaliação de modelos de ML, como precisão, recall (sensibilidade), especificidade e F1-Score. A precisão mede a proporção de identificações positivas que foram de fato corretas, enquanto o recall avalia a proporção de positivos reais que foram corretamente identificados pelo modelo (HE et al., 2020).

A especificidade, por outro lado, mede a proporção de negativos reais que são corretamente identificados, sendo especialmente importante em contextos clínicos onde a identificação correta de negativos é tão crucial quanto a de positivos. O F1-Score é a média harmônica entre precisão e recall, fornecendo um balanço entre essas duas métricas quando ambas são importantes (AKAZAWA; HASHIMOTO, 2022).

A escolha das métricas de avaliação deve ser feita com base nos objetivos específicos do modelo e na importância relativa de detectar positivos versus negativos corretamente. Em algumas aplicações médicas, por exemplo, um alto recall pode ser mais valorizado do que a precisão, especialmente em casos onde a falha em detectar uma condição pode ter consequências graves (BEEK et al., 2021).

A avaliação cruzada, ou cross-validation, é outra técnica crucial na avaliação de modelos, permitindo que os pesquisadores testem o desempenho do modelo em diferentes subconjuntos dos dados para garantir sua robustez e generalização. Esta técnica é particularmente útil para evitar o overfitting, assegurando que o modelo será eficaz em dados novos, não vistos durante o treinamento (CHANDRIKA; SURENDRAN, 2022).

A interpretabilidade do modelo também é uma consideração importante na seleção de métricas de avaliação. Modelos altamente precisos mas ininteligíveis podem ser de pouca utilidade na prática clínica, onde a compreensão das razões por trás das previsões é crucial para a tomada de decisão. Assim, as métricas de avaliação devem ser selecionadas de modo a equilibrar precisão, confiabilidade e interpretabilidade (RAIHAN et al., 2024).

A seleção cuidadosa de métricas de avaliação é fundamental para o desenvolvimento de modelos de ML em saúde. Por meio da utilização de uma combinação de métricas, incluindo AUC, Matrizes de Confusão, precisão, recall, especificidade e F1-Score, os pesquisadores podem obter uma compreensão abrangente do desempenho do modelo, facilitando a identificação de áreas para melhoria e garantindo que os modelos sejam tanto precisos quanto úteis na prática médica (MONFARED; HASHEMI, 2023).

2.4.3 Comparação e Seleção de Modelos:

A análise comparativa do desempenho de modelos de Machine Learning (ML) na predição do risco de mortalidade em neonatos prematuros é um passo crucial na identificação das técnicas mais eficazes. Dada a sensibilidade do contexto e a necessidade de alta precisão, o emprego de diferentes modelos e a avaliação de seu desempenho sob vários aspectos tornam-se essenciais. Modelos como Gradient Boosting, Redes Neurais, Regressão Logística e Naive Bayes têm sido aplicados com variados graus de sucesso, exigindo uma análise criteriosa de suas capacidades e limitações específicas (JASKARI et al., 2020).

O Gradient Boosting destaca-se por sua habilidade em modelar complexas relações não lineares entre as características dos dados e o resultado. Sua eficácia vem da construção sequencial de árvores de decisão que ajustam os erros dos modelos anteriores, refinando progressivamente as previsões. No contexto dos cuidados neonatais, essa técnica pode capturar sutilezas nos dados que outros modelos lineares podem não detectar, tornando-se uma ferramenta poderosa para a predição de riscos (FENG et al., 2021).

Redes Neurais, com sua capacidade de aprender representações profundas dos dados, oferecem outra abordagem promissora. Elas são particularmente adequadas para lidar com a alta dimensionalidade e a complexidade dos dados clínicos, adaptando-se bem à variabilidade inerente aos registros de saúde. A aplicação de Redes Neurais na predição de mortalidade neonatal tem mostrado resultados encorajadores, embora a interpretabilidade das decisões do modelo continue a ser um desafio (GAO et al., 2019).

A Regressão Logística, um modelo mais simples e interpretável, oferece vantagens em termos de compreensão clara dos fatores de risco associados à mortalidade neonatal. Sua aplicabilidade prática é reforçada pela facilidade de implementação e pela interpretação direta dos coeficientes do modelo, facilitando a comunicação dos resultados aos clínicos. No entanto, sua simplicidade pode ser uma limitação ao tratar de relações complexas e interações entre variáveis (HE et al., 2020).

O Naive Bayes, por ser baseado em probabilidade e assumir independência entre as características, proporciona um modelo rápido e eficiente, ideal para análises iniciais ou quando os recursos computacionais são limitados. Apesar de suas suposições simplificadoras, pode surpreender em termos de desempenho quando aplicado a conjuntos de dados bem preparados, embora possa não ser tão robusto quanto outras técnicas em situações mais complexas (AKAZAWA; HASHIMOTO, 2022).

A seleção do modelo adequado envolve não apenas considerar o desempenho puro, como medido pela AUC ou precisão, mas também outros fatores críticos como a interpretabilidade, a facilidade de implementação e a capacidade de generalização para dados não vistos. A validação cruzada e as matrizes de confusão desempenham papéis importantes neste processo, ajudando a garantir que a seleção do modelo seja robusta e baseada em evidências concretas (BEEK et al.,

2021).

A evolução contínua das técnicas de ML e a crescente disponibilidade de dados clínicos detalhados abrem novas possibilidades para a melhoria dos modelos preditivos. A colaboração multidisciplinar entre cientistas de dados, clínicos e pesquisadores é fundamental para explorar essas oportunidades, garantindo que os modelos selecionados sejam não apenas tecnicamente sólidos, mas também clinicamente relevantes e aplicáveis (CHANDRIKA; SURENDRAN, 2022).

Finalmente, a implementação bem-sucedida de modelos de ML na prática clínica para a predição de riscos em neonatos prematuros requer uma abordagem cuidadosa à seleção de modelos, com atenção rigorosa à validação e à avaliação do desempenho. À medida que a tecnologia avança, a expectativa é que modelos cada vez mais sofisticados e precisos sejam desenvolvidos, levando a melhorias significativas nos cuidados e nos resultados para os neonatos prematuros (RAIHAN et al., 2024).

Assim, a comparação e a seleção de modelos de ML na predição de risco de mortalidade em neonatos prematuros são tarefas complexas que exigem uma consideração cuidadosa de uma gama de fatores, incluindo desempenho, interpretabilidade e aplicabilidade clínica. A busca pelo modelo ótimo é um processo iterativo e colaborativo, essencial para avançar a prática clínica e melhorar os desfechos para os pacientes mais vulneráveis (MONFARED; HASHEMI, 2023).

2.5 Implicações e Futuras Direções

2.5.1 Implicações para a Saúde Pública:

Os avanços em Machine Learning (ML) e suas aplicações na saúde têm o potencial de transformar significativamente as práticas médicas e políticas de saúde pública, especialmente no contexto de redução da mortalidade infantil. A capacidade desses modelos de prever riscos com alta precisão abre novas possibilidades para intervenções preventivas e tratamentos personalizados para neonatos prematuros, um grupo particularmente vulnerável à mortalidade infantil (JASKARI et al., 2020).

A implementação de modelos de ML que podem precisamente prever riscos de mortalidade em neonatos prematuros permite que os profissionais de saúde intervenham mais cedo, possivelmente antes mesmo de condições críticas se manifestarem. Essa abordagem preventiva poderia reduzir significativamente a incidência de complicações graves que levam à mortalidade, transformando o paradigma de cuidado de reativo para proativo (FENG et al., 2021).

Além disso, os resultados obtidos a partir de estudos baseados em ML oferecem insights valiosos para a formulação de políticas de saúde pública. Compreender os fatores de risco associados à mortalidade neonatal permite que os formuladores de políticas desenvolvam programas direcionados de saúde pública que possam abordar esses riscos de maneira eficaz, seja através

da educação de gestantes, melhoramento dos cuidados pré-natais ou alocação de recursos para pesquisa e desenvolvimento em cuidados neonatais (GAO et al., 2019).

A personalização do tratamento baseada em modelos preditivos também representa uma mudança significativa na maneira como os cuidados são prestados. Ao identificar neonatos em risco, os profissionais de saúde podem adaptar os cuidados e tratamentos às necessidades individuais, melhorando os desfechos e otimizando o uso de recursos médicos (HE et al., 2020).

Para os formuladores de políticas de saúde pública, a análise detalhada das variáveis que contribuem para o risco de mortalidade neonatal oferece uma base sólida para o desenvolvimento de estratégias de intervenção. Isso inclui não apenas a melhoria dos cuidados de saúde, mas também ações em níveis sociais e econômicos, abordando determinantes sociais da saúde que impactam a mortalidade infantil (AKAZAWA; HASHIMOTO, 2022).

A adoção desses modelos também desafia as práticas médicas existentes, exigindo um compromisso com a educação contínua dos profissionais de saúde sobre as tecnologias emergentes e sua aplicação clínica. O sucesso dessa transformação depende da capacidade de integrar novas ferramentas tecnológicas em sistemas de saúde existentes, garantindo que complementem e enriqueçam o cuidado ao paciente, em vez de substituir o julgamento clínico humano (BEEK et al., 2021).

Do ponto de vista ético e regulatório, a utilização de ML na saúde pública requer uma atenção rigorosa à privacidade dos dados, consentimento informado e equidade no acesso aos benefícios dessas tecnologias. As políticas de saúde pública devem, portanto, contemplar essas considerações, assegurando que os avanços tecnológicos beneficiem todos os segmentos da população de maneira justa e ética (CHANDRIKA; SURENDRAN, 2022).

A colaboração internacional e a partilha de conhecimentos entre países também podem acelerar o progresso na redução da mortalidade infantil globalmente. Através do compartilhamento de modelos preditivos e práticas baseadas em evidências, países com recursos limitados podem beneficiar-se dos avanços em ML, adaptando essas ferramentas às suas necessidades e contextos específicos (RAIHAN et al., 2024).

A aplicação de ML na previsão da mortalidade neonatal tem implicações profundas para a saúde pública e práticas médicas. Ao fornecer ferramentas poderosas para a identificação precoce de riscos e personalização do tratamento, esses modelos têm o potencial de melhorar significativamente os cuidados neonatais e contribuir para a redução da mortalidade infantil. A chave para o sucesso dessas iniciativas reside na colaboração efetiva entre cientistas de dados, profissionais de saúde, formuladores de políticas e comunidades, garantindo que os avanços tecnológicos se traduzam em benefícios tangíveis para a saúde dos neonatos (MONFARED; HASHEMI, 2023).

2.5.2 Limitações e Desafios Futuros:

A implementação de modelos preditivos de Machine Learning (ML) no atendimento clínico, especialmente na previsão do risco de mortalidade em neonatos prematuros, apresenta um campo promissor com potencial para melhorar significativamente os desfechos de saúde. No entanto, o estudo atual enfrenta limitações que destacam áreas importantes para pesquisa futura e desenvolvimento. Uma dessas limitações é a dependência de grandes volumes de dados de alta qualidade, que podem ser difíceis de obter devido a questões de privacidade, consentimento e interoperabilidade entre sistemas de saúde (JASKARI et al., 2020).

Outro desafio é a variabilidade nos protocolos de coleta de dados e nas práticas clínicas entre diferentes hospitais e regiões. Esta variabilidade pode introduzir viés nos modelos de ML, limitando sua aplicabilidade e precisão em diferentes contextos clínicos. A padronização dos procedimentos de coleta de dados e a harmonização dos protocolos clínicos são, portanto, áreas cruciais para futuras investigações (FENG et al., 2021).

A integração dos modelos preditivos no fluxo de trabalho clínico também apresenta desafios significativos, desde a resistência à mudança por parte dos profissionais de saúde até questões técnicas relacionadas à implementação de sistemas de informação em saúde. A aceitação e a adesão dos profissionais de saúde são essenciais para o sucesso desta integração, exigindo esforços contínuos em educação e treinamento (GAO et al., 2019).

Além disso, a interpretabilidade dos modelos de ML é uma preocupação crescente, especialmente em contextos clínicos onde a compreensão das razões por trás das previsões é fundamental. Desenvolver modelos que sejam não apenas precisos, mas também transparentes e explicáveis, é uma área de pesquisa importante para aumentar a confiança e a aceitação dos profissionais de saúde (HE et al., 2020).

A ética no uso de dados de saúde e a proteção da privacidade dos pacientes são questões críticas na aplicação de ML na medicina. O desenvolvimento de diretrizes éticas e regulamentações robustas que acompanhem os avanços tecnológicos é essencial para garantir o uso responsável e seguro dessas tecnologias (AKAZAWA; HASHIMOTO, 2022).

A questão da equidade no acesso às inovações em ML também é uma consideração importante. Garantir que os benefícios dessas tecnologias sejam acessíveis a todas as populações, incluindo aquelas em regiões de baixa renda ou com recursos limitados, é fundamental para evitar o aumento das disparidades em saúde (BEEK et al., 2021).

Além disso, a rápida evolução das técnicas de ML e a emergência de novos modelos exigem uma atualização constante dos conhecimentos e das habilidades dos profissionais de saúde e pesquisadores. O desenvolvimento de programas de formação contínua que abordem os avanços mais recentes em ML e sua aplicação clínica é, portanto, crucial (CHANDRIKA; SURENDRAN, 2022).

Por fim, a necessidade de estudos de validação em larga escala que testem a eficácia e a segurança dos modelos preditivos em diferentes populações e ambientes clínicos é evidente. Tais estudos são fundamentais para assegurar que os modelos sejam generalizáveis e possam ser efetivamente implementados como ferramentas de apoio à decisão clínica para melhorar os cuidados neonatais e reduzir a mortalidade infantil (RAIHAN et al., 2024).

A reflexão sobre essas limitações e a identificação de desafios futuros são passos cruciais para avançar na integração de modelos preditivos no atendimento clínico. Abordar essas questões não só melhorará a precisão e a aplicabilidade dos modelos de ML, mas também facilitará sua adoção em práticas médicas, contribuindo para o objetivo final de melhorar os desfechos de saúde para neonatos prematuros (MONFARED; HASHEMI, 2023).

2.5.3 Avanços Tecnológicos e Ética:

Os avanços tecnológicos na área da saúde, especialmente aqueles impulsionados por técnicas de Machine Learning (ML), prometem transformar radicalmente a maneira como os riscos de saúde são previstos e gerenciados. A capacidade de processar e analisar grandes volumes de dados em velocidades e precisões sem precedentes oferece novas oportunidades para identificar padrões e prever resultados que seriam inacessíveis através de métodos tradicionais (JASKARI et al., 2020).

No entanto, com grandes poderes vêm grandes responsabilidades. As questões éticas relacionadas ao uso de ML na medicina são complexas e multifacetadas, abrangendo desde a privacidade dos dados até o consentimento informado, passando pela equidade no acesso às inovações tecnológicas. A integridade e a confidencialidade dos dados dos pacientes devem ser prioritárias, exigindo sistemas robustos de segurança e protocolos rigorosos de gestão de dados (FENG et al., 2021).

Outra consideração crítica é o potencial viés nos modelos de ML, que pode decorrer tanto dos dados de treinamento quanto dos algoritmos usados. Dados históricos podem refletir práticas discriminatórias ou preconceitos existentes na coleta de dados, resultando em modelos que perpetuam ou exacerbam desigualdades. A atenção cuidadosa à seleção e preparação dos dados, bem como a escolha de algoritmos, é essencial para mitigar esses riscos (GAO et al., 2019).

Além disso, a explicabilidade dos modelos de ML é um aspecto crucial para sua aceitação e aplicabilidade clínica. Os profissionais de saúde devem ser capazes de entender como as previsões são feitas para confiar nos resultados e tomar decisões informadas. Modelos altamente complexos e "caixas-pretas"podem ser um desafio nesse sentido, levantando questões sobre a transparência e a responsabilidade nas decisões clínicas baseadas em ML (HE et al., 2020).

A integração de modelos preditivos de ML no atendimento clínico também apresenta desafios operacionais, desde a necessidade de infraestrutura tecnológica adequada até a formação

e o treinamento dos profissionais de saúde. A adoção de novas tecnologias requer mudanças nos processos de trabalho e na cultura organizacional das instituições de saúde, o que pode ser um obstáculo significativo (AKAZAWA; HASHIMOTO, 2022).

No contexto de saúde pública, a implementação de ML na predição de riscos de saúde abre caminho para políticas mais proativas e baseadas em evidências. No entanto, isso também implica em desafios regulatórios e éticos, especialmente em relação ao equilíbrio entre o benefício público e a autonomia individual. A regulamentação cuidadosa e a governança de dados são fundamentais para navegar nessas questões (BEEK et al., 2021).

A pesquisa futura deve, portanto, focar não apenas no desenvolvimento de modelos de ML mais avançados e precisos, mas também na abordagem das questões éticas, legais e sociais que acompanham essas inovações. A colaboração multidisciplinar entre cientistas de dados, profissionais de saúde, juristas e éticos é crucial para desenvolver diretrizes que orientem a prática ética na aplicação de ML na saúde (CHANDRIKA; SURENDRAN, 2022).

Além disso, é essencial promover o diálogo com o público e os pacientes sobre as implicações dessas tecnologias, garantindo que suas perspectivas e preocupações sejam consideradas no desenvolvimento e implementação de soluções de ML. A participação pública pode ajudar a garantir que as inovações tecnológicas se alinhem com os valores e as necessidades da sociedade (RAIHAN et al., 2024).

Enquanto os avanços tecnológicos em ML oferecem possibilidades promissoras para melhorar a predição de riscos de saúde e o atendimento clínico, eles também trazem consigo uma série de questões éticas e desafios que devem ser cuidadosamente abordados. A pesquisa e o desenvolvimento futuros devem, portanto, avançar de maneira responsável e ética, garantindo que os benefícios dessas tecnologias sejam acessíveis a todos e alinhados com os princípios éticos fundamentais da medicina (MONFARED; HASHEMI, 2023)

3 METODOLOGIA

3.1 Dataset

Um dos pontos críticos do projeto foi o ajuste do dataset (ou conjunto de dados) para utilização das técnicas e algoritmos de aprendizagem de máquina (Machine Learning – ML) voltadas para predição e estratificação. Como as técnicas e algoritmos em ML precisam de um processo de treinamento para geração dos modelos, é necessário que os datasets sejam bem definidos. O projeto propôs inicialmente trabalhar com o dataset da Fiocruz chamado de CIDACS (Centro de Integração de Dados e Conhecimentos para Saúde) (CIDACS,), dataset este que integra as bases do Cadastro Único (CADU) com as do Sistema de Informação sobre Nascidos Vivos (SINASC), do Sistema de Informação sobre Mortalidade (SIM) e do Programa Bolsa Família. Todavia os trâmites burocráticos para acesso ao CIDACS foram finalizados, após um esforço conjunto de vários departamentos da UFRN para acesso a este dataset, apenas após o início do desenvolvimento do projeto.

Sendo assim, como as bases que compõem o CIDACS são abertas (CADU, SINASC, SIM e Bolsa Família), o projeto redirecionou parte do esforço para criar um dataset semelhante ao CIDACS mas voltado apenas para utilização de ferramentas de ML. O novo dataset é um novo produto do projeto e será disponibilizado a comunidade científica ao final. Assim, essas informações tratam-se dos trabalhos que vêm sendo realizados no dataset do Sistema de Informações de Nascidos Vivos (SINASC) e do Sistema de Informações Sobre Mortalidade (SIM). O acesso à essas duas bases de dados é feito pela Plataforma de Ciência de Dados aplicada à Saúde (PCDaS/Icict) que tem como objetivo principal desenvolver e disponibilizar interfaces tecnológicas para armazenamento, gestão e análise de grandes quantidades de dados para pesquisadores, docentes e discentes de instituições de ensino e pesquisa.

Inicialmente foram feitas análises dos dados obtidos da PCDaS, para entender todos os atributos do dataset. Com isso, todos os dados foram expostos graficamente e analisados a fim de distinguir os dados necessários dos desnecessários e, com isso, eliminar as informações que seriam inúteis para este estudo (tais como colunas de itens ignorados que são comumente usados por médicos no preenchimento de registros). Além disso, muitos dos atributos apresentam dados que não condizem com a realidade. Foram utilizados os dados dos anos de 2015, 2016 e 2017 de ambas as bases de dados. Com as analises realizadas percebeu-se a possibilidade de unificar os dois datasets a partir da coluna "NUMERODN", referente ao número da Declaração de Nascido Vivo (DN). Portanto, foram retiradas todas as linhas das quais essa coluna estava vazia em ambos os datasets. Além disso, como este estudo trata-se do desenvolvimento de uma ferramenta para predição do risco de mortalidade em neonatos prematuros, foram retiradas também, no

dataset do SINASC, as linhas dos casos que não apresentavam indícios de prematuridade (coluna "parto_prematuro" com dado igual a 0). Com essas modificações, obteve-se o primeiro dataset desenvolvido neste projeto: o dataset "SIM + SINASC", mantendo 100% dos indivíduos mortos e 50% dos indivíduos vivos. A Figura 1 mostra o fluxograma das alterações realizadas nesses datasets.

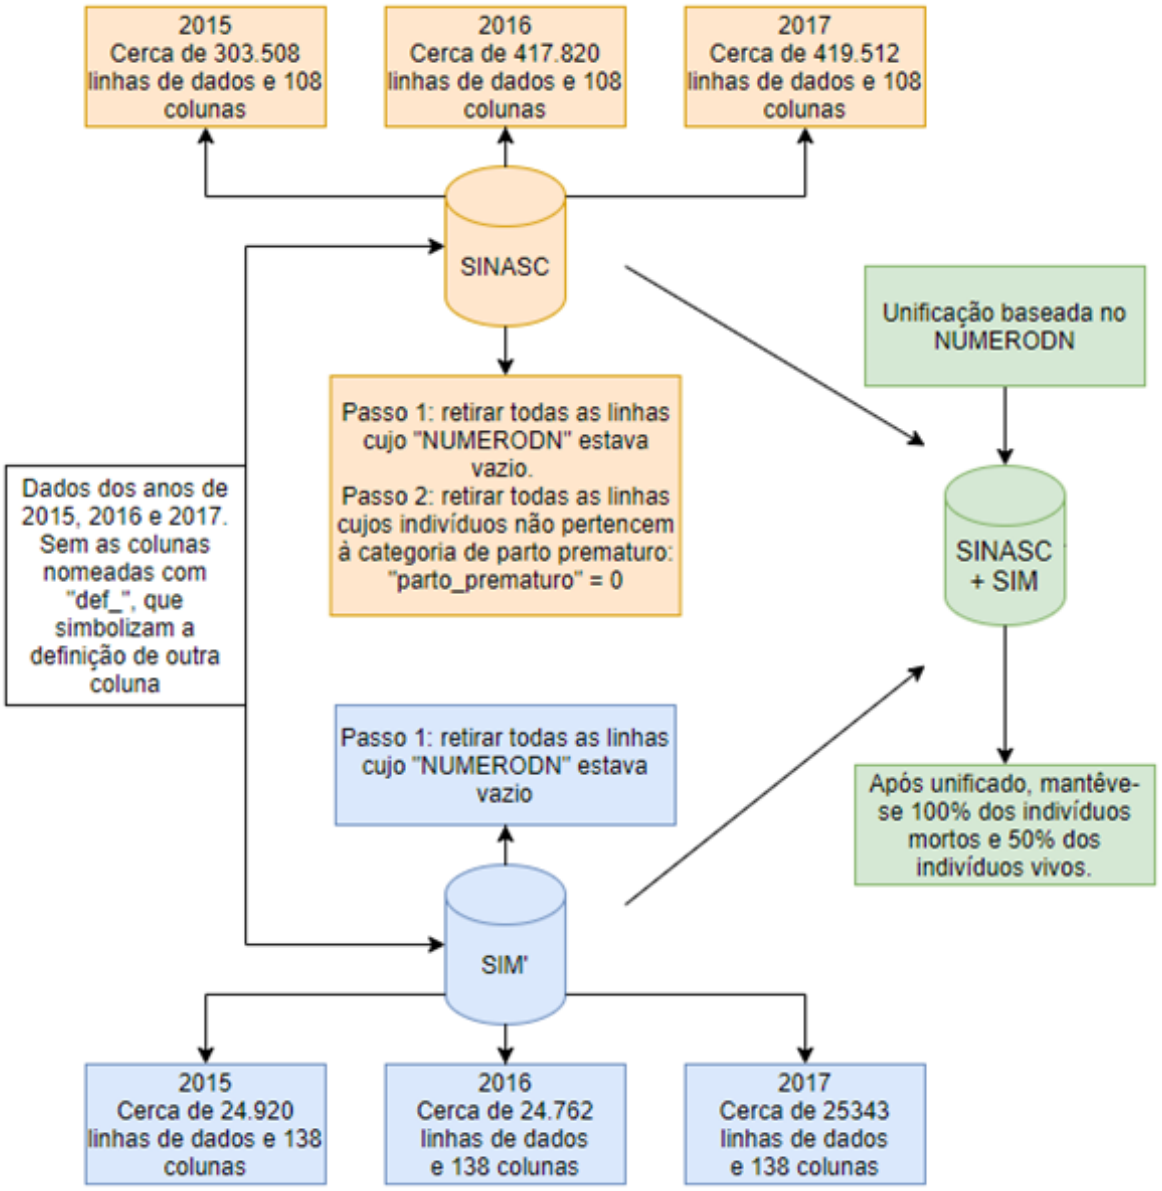

Figura 1 – Fluxograma da unificação dos Datasets SIM e SINASC

Com o dataset "SIM + SINASC" foram realizadas novas análises a respeito da importância de algumas colunas para este estudo. Após definir os dados essenciais, as variáveis julgadas como desnecessárias foram eliminadas, sendo elas: CODPAISRES, OCUP, OBITOGRAV, OBITOPUERP, EXAME, CIRURGIA, ACIDTRAB, FONTE, ESC2010, SERIESCFAL, TPMORTEOCO, COMUNSVOIM, ESCFALAGR1, NUDIASOBCO, DTCADINV, TPOBITO-

COR, DTCONINV, TPRESGINFO, TPNIVELINV. As informações a respeito dessas colunas e de todas as outras estão disponíveis no portal da PCDaS (PCDaS,). Com essas modificações pôde-se criar mais um dataset: "DATASET UNIFICADO", contendo cerca de 91 mil linhas de dados e 226 variáveis, como mostra o fluxograma na Figura 2.

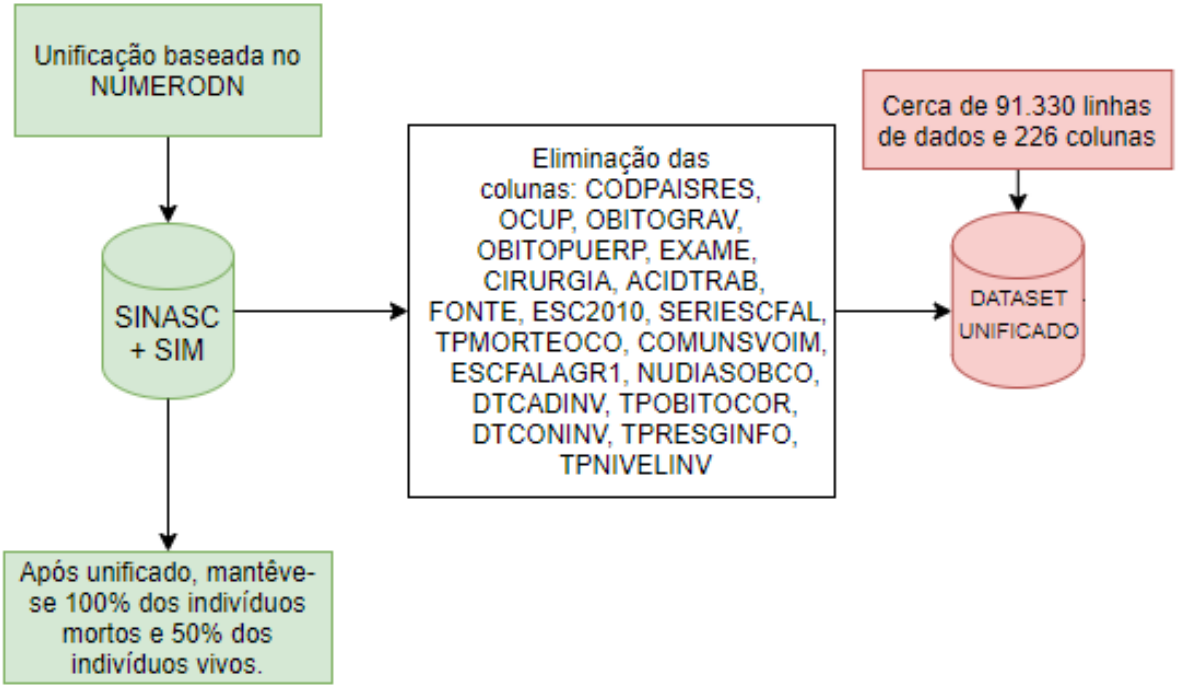

Figura 2 – Fluxograma da limpeza do Dataset recém unificado

Tendo criado o DATASET UNIFICADO percebeu-se a necessidade da criação de algumas variáveis além da limpeza em algumas colunas com dados faltantes. Foram criadas as colunas "vivo", sendo uma variável binária, com valores 0 ou 1 (1 para vivo e 0 para morto), representando se o indivíduo estava vivo ou não, "dias_de_vida", apresentando a quantidade de dias de vida de cada indivíduo, e "mais_de_dois_dias", sendo também uma variável binária, sendo 1 para indivíduos que permaneceram vivos por mais de dois dias e 0 para o caso contrário. Para a criação desta última foi usada a variável "dias_de_vida". Além do mais, foram eliminados os dados faltantes em todas as colunas e os dados ignorados, que consiste no valor "9" ou "99" em todas as colunas. Essa definição de ignorado é estabelecida a partir do Dicionário de Dados do Sistema de Informação de Agravos de Notificação (SINAN) (Ministério da Educação,). Então, com o dataset completamente limpo, chegou-se a uma versão final e sem mais modificações. Portanto, com esses dados, foram feitas análises e estudos a fim de definir as variáveis que seriam usadas como entradas no modelo de Machine Learning (ML) para a predição, onde foi criado o DATASET ENTRADAS, com as seguintes variáveis: IDADEMAE, ESTCIVMAE, ESCMAE, QTDFILVIVO, QTDFILMORT, ESTACAO, GRAVIDEZ, PARTO, CONSULTAS, SEXO, APGAR1, APGAR5, RACACOR, PESO, RACACORMAE,

QTDGESTANT, QTDPARTNOR, QTDPARTCES, DTULTMENST, SEMAGESTAC, TPAPRESENT, STTRABPART, STCESPARTO, ESCMAEAGR1, KOTELCHUCK, parto_prematuro, vivo, dias_de_vida, mais_de_dois_dias. Essas modificações estão apresentadas no fluxograma na Figura 3.

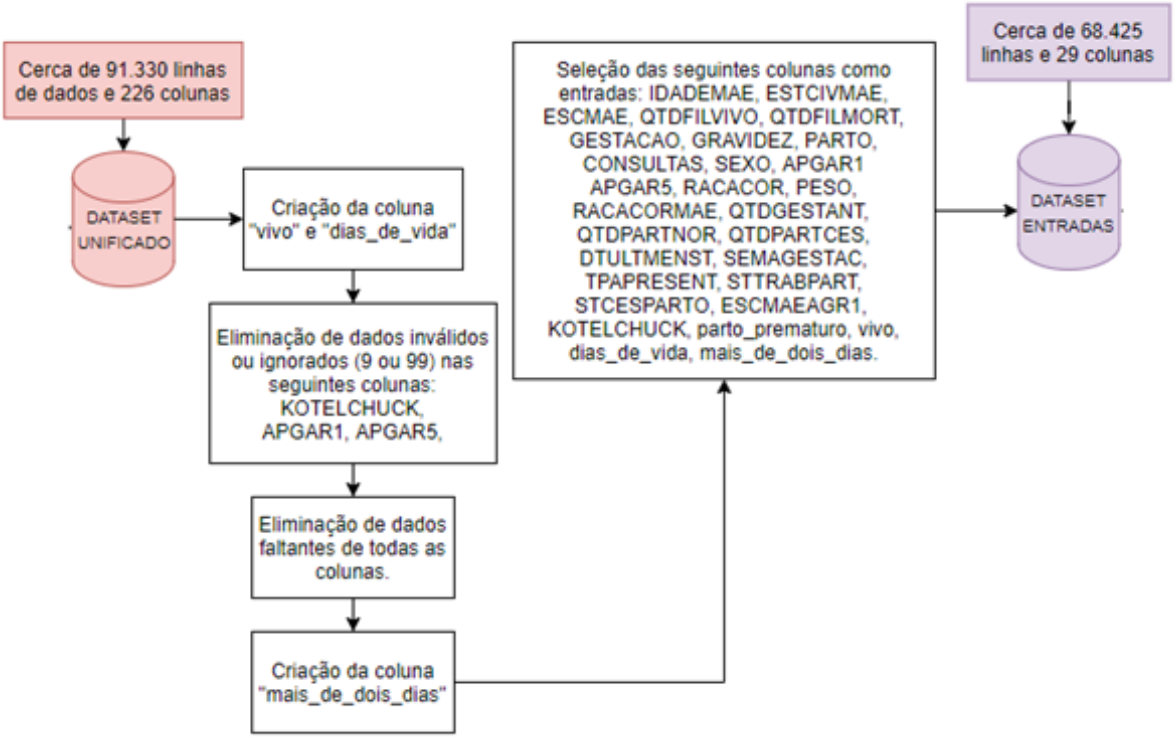

Figura 3 – Fluxograma da limpeza do dataset unificado para formação do dataset de entradas

Inicialmente, o dataset de entradas foi submetido a testes com o MLPClassifier do Python, mas os resultados não foram satisfatórios. O modelo obteve uma acurácia de 68,6%, e a análise da matriz de confusão revelou um desequilíbrio nas previsões: 69,2% de verdadeiros negativos, 67,9% de verdadeiros positivos, 30,8% de falsos negativos e 32,1% de falsos positivos. Esses resultados indicam que o modelo teve dificuldades em classificar corretamente os casos positivos, comprometendo a performance geral. Diante disso, foi necessário realizar uma nova análise e pesquisa na literatura afim de encontrar soluções de melhorias para esses resultados.

Após pesquisas, com base no estudo de (ALVES et al., 2020), decidiu-se realizar modificações no dataset com o objetivo de melhorar a interpretação e o desempenho dos modelos de machine learning. De acordo com a literatura, como sugerido por (KUHN; JOHNSON, 2013), transformações nas variáveis preditoras são frequentemente necessárias para garantir que os modelos possam lidar adequadamente com os dados. Em particular, variáveis contínuas podem precisar ser transformadas em variáveis categóricas para que as técnicas de modelagem, como o Naive Bayes e Redes Neurais, possam interpretar as relações hierárquicas entre as categorias. No estudo de (ALVES et al., 2020), foram realizadas transformações semelhantes, onde variáveis

contínuas, como idade materna, Apgar1 e Apgar5, número de nascimentos vivos, perdas fetais e número de cesarianas, foram convertidas em variáveis categóricas, permitindo que os modelos entendam que valores mais elevados indicam uma maior efetividade. Seguindo essa abordagem, foram criadas novas colunas categóricas com base nos dados originais, o que resultou no DATASET COM AGRUPAMENTOS, a última versão do dataset utilizada neste estudo. O fluxograma na Figura 4 ilustra essas novas colunas, explicando os agrupamentos realizados e os dados usados.

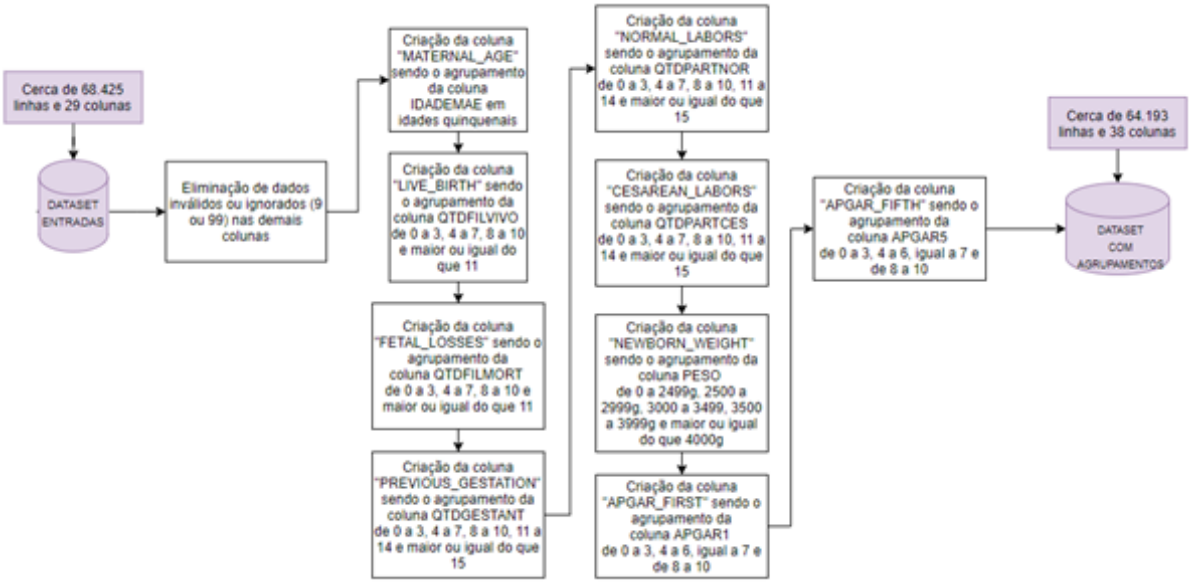

Figura 4 – Fluxograma da categorização e agrupamento dos dados do dataset para se obter melhores resultados nos algorítmos

As colunas selecionadas como entradas para os modelos foram: ESTCIVMAE, ESCMAE, GESTACAO, GRAVIDEZ, PARTO, SEXO, CONSULTAS, KOTELCHUCK, RACACOR, RACACORMAE, MATERNAL_AGE, LIVE_BIRTH, FETAL_LOSSES, PREVIOUS_GESTATION, NORMAL_LABORS, CESARIAN_LABORS, NEWBORN_WEIGHT, APGAR_FIST, APGAR_FIFTH e parto_prematuro, todas definidas como variáveis categóricas, com exceção de KOTELCHUCK, que foi tratada como variável numérica. A variável alvo (target) foi a coluna "vivo".

A Tabela 1 apresenta a distribuição das variáveis após o processo de limpeza e pré-processamento dos dados. A seguir, detalham-se as principais características de cada uma dessas variáveis, abordando aspectos maternos, obstétricos, relacionados ao recém-nascido e aos cuidados prévios, com ênfase na relevância de cada variável para a predição do risco de mortalidade infantil.

Quanto à idade materna, observa-se que a maioria das mães está na faixa etária de 20 a 34 anos, sendo a faixa mais predominante de 20 a 24 anos, representando 23,01% da amostra. Em relação ao nível educacional, a maior parte das mães possui entre 8 e 11 anos de escolaridade

(60,02%). Quanto ao estado civil, 45,96% das mães eram solteiras, seguidas por 30,43% casadas e 22,16% em união consensual. A distribuição racial/cor das mães é majoritariamente parda (56,61%), com 35,81% de brancas e 6,47% de pretas.

A distribuição das variáveis obstétricas revela que a grande maioria das mães teve de 0 a 3 filhos vivos (94,87%), e que as perdas fetais também se concentraram entre 0 a 3 casos (99,42%). A maioria das mães teve entre 0 e 3 gestações anteriores (91,70%) e partos normais (95,56%). Além disso, 99,71% das mães tiveram até 3 partos cesáreos. Quanto ao tipo de gravidez, a maioria das gestantes teve uma gravidez única (88,13%).

Em relação ao recém-nascido, 73,80% dos bebês nasceram com peso inferior a 2500 gramas, indicando uma alta prevalência de baixo peso ao nascer na amostra. A gestação foi predominantemente inferior a 22 semanas (99,71%), com a maioria dos bebês nascendo com Apgar entre 8 e 10 no primeiro (50,59%) e no quinto minuto (70,53%). Quanto ao sexo, 52,28% dos recém-nascidos eram masculinos e 47,28% femininos. Em termos de prematuridade, 38,05% dos recém-nascidos apresentaram prematuridade devido à idade gestacional e peso ao nascer.

Quanto aos cuidados prévios, a maioria das mães realizou de 4 a 6 consultas de pré-natal (38,05%), seguidas por 41,37% que realizaram 7 ou mais consultas. O tipo de parto mais comum foi o cesáreo (52,11%), seguido pelo parto vaginal (47,89%).

Essas informações fornecem uma visão detalhada das características da amostra estudada, destacando a prevalência de fatores que podem impactar as taxas de mortalidade infantil, como a idade materna, o peso ao nascer, o número de gestações e partos, e as condições de saúde materna e neonatal. Essas variáveis são cruciais para a análise dos riscos de mortalidade infantil em neonatos prematuros, sendo utilizadas como base para a aplicação dos modelos de aprendizado de máquina desenvolvidos neste estudo.

Variáveis	**N (64.193)**	**%**
Condições maternas		
MATERNAL_AGE (Idade Materna)		
10-14	941	1.47
15-19	12.310	19.18
20-24	14.768	23.01
25-29	13.347	20.79
30-34	12.306	19.17
35-39	7.900	12.31
40-44	2.410	3.75
45-49	204	0.32
50 ou mais	7	0.01
ESCMAE_x (Educação Materna, em anos de estudo concluídos)		

Variáveis	**N (64.193)**	**%**
0	400	0.62
1-3	1.706	2.66
4-7	12.021	18.73
8-11	38.530	60.02
12 ou mais	11.536	17.97
ESTCIVMAE (Status matrimonial)		
Solteira	29.506	45.96
Casada	19.533	30.43
Viuva	110	0.17
Separado judicialmente/Divorciado	820	1.28
União consensual	14.224	22.16
RACACOR_x (Raça/cor)		
Branca	22.985	35.81
Preta	4.152	6.47
Amarela	227	0.35
Parda	36.339	56.61
Indígena	490	0.76
Informações obstétricas		
LIVE_BIRTH (Quantidade de filhos vivos)		
0-3	60.898	94.87
4-7	3.024	4.71
8-10	235	0.37
11 ou mais	36	0.06
FETAL_LOSSES (Quantidade de perdas fetais)		
0-3	63.822	99.42
4-7	356	0.55
8-10	13	0.02
11 ou mais	2	0.00
PREVIOUS_GESTATION (Quantidade de gestações anteriores)		
0-3	58.862	91.70
4-7	4.809	7.49
8-10	425	0.66
11-14	91	0.14
15 ou mais	6	0.01
NORMAL_LABORS (Quantidade de partos normais)		
0-3	61.341	95.56

Variáveis	**N (64.193)**	**%**
4-7	2.570	4.00
8-10	234	0.36
11-14	43	0.07
15 ou mais	5	0.01
CESAREAN_LABORS (Quantidade de partos cesáreos)		
0-3	64.008	99.71
4-7	181	0.28
8-10	4	0.01
11-14	0	0.00
15 ou mais	0	0.00
GRAVIDEZ_x (Tipo de gravidez)		
Única	56.575	88.13
Dupla	7.225	11.26
Tripla ou mais	396	0.61
Informações relacionadas ao recém-nascido		
NEWBORN_WEIGHT (Peso em gramas)		
< 2500	47.375	73.80
2500-2999	8.845	13.78
3000-3499	5.543	8.63
3500-3999	1.979	3.08
4000 ou mais	451	0.70
GESTACAO_x (Tempo gestacional em semanas)		
< 22	64.008	99.71
22-27	181	0.28
28-31	4	0.01
32-36	0	0.00
37-41	0	0.00
42 ou mais	0	0.00
APGAR_FIRST (Apgar no primeiro minuto)		
0-3: severo	13.355	20.80
4-6: moderado	11.851	18.46
7: aceitável	6.513	10.15
8-10: ótimo	32.474	50.59
APGAR_FIFTH (Apgar no quinto minuto)		
0-3: severo	6.831	10.64
4-6: moderado	6.916	10.77

Variáveis	**N (64.193)**	**%**
7: aceitável	5.170	8.05
8-10: ótimo	45.276	70.53
KOTELCHUCK (Kotelchuck)		
1	1.604	2.50
2	15.541	24.21
3	15.416	24.02
4	7.196	11.21
5	24.436	38.07
SEXO_x (Sexo)		
1: branca	22.985	35.81
2: preta	4.152	6.47
3: amarela	227	0.35
4: parda	36.339	56.61
5: indígina	490	0.76
RACACOR_x (Raça)		
0: não informado	281	0.44
1: masculino	33.559	52.28
2: feminino	30.353	47.28
parto_prematuro (Nível de prematuridade)		
Prematuridade dado a idade gestacional (< 37 semanas)	1.660	2.59
Prematuridade dado o peso ao nascer (< 2500 g)	11.554	18.00
Prematuridade dado a idade gestacional e o peso ao nascer	24.425	38.05
vivo (Vivo após dois dias)		
Não	30.827	48.02
Sim	33.366	51.98
Informações relacionadas aos cuidados prévios		
CONSULTAS (Quantidade de consultas)		
0	1.660	2.59
1-3	11.554	18.00
4-6	24.425	38.05
7 ou mais	26.554	41.37
PARTO_x (Tipo de parto)		
Vaginal	30.740	47.89
Cesáreo	33.453	52.11

Tabela 1 – Distribuição relativa de dados demográficos, socioeconômicos, obstétricos e cuidados prévios relacionados aos recém-nascidos no Brasil, 2015-2017

Esses dados, após o pré-processamento e limpeza, servem como base para a construção e treinamento dos modelos de aprendizado de máquina. A seleção das variáveis foi feita com o objetivo de capturar fatores maternos, obstétricos e neonatais críticos para a predição do risco de mortalidade infantil, considerando as condições de saúde materna e neonatal e as características socioeconômicas. As variáveis selecionadas desempenham um papel central na construção do modelo preditivo, que busca oferecer uma ferramenta útil na identificação de risco de mortalidade infantil, especialmente em neonatos prematuros.

3.2 Algorítmos e suas arquiteturas

A seleção e implementação dos algoritmos de aprendizado de máquina (Machine Learning – ML) foram etapas fundamentais neste estudo, visando à predição do risco de mortalidade infantil em neonatos prematuros. Para essa tarefa, foi necessário considerar a complexidade dos dados disponíveis e a capacidade dos modelos em lidar com desafios como o desbalanceamento das classes e a identificação de padrões complexos.

Inicialmente, diversas técnicas foram avaliadas, incluindo algoritmos baseados em árvores, redes neurais artificiais e modelos probabilísticos. O objetivo foi testar diferentes abordagens para identificar aquelas que melhor se adequassem ao problema e oferecessem um desempenho confiável nas análises. O processo de execução dos learners e das etapas de teste e validação foi realizado utilizando a plataforma **Orange Data Mining**, que facilitou a visualização e a análise dos modelos, além de proporcionar uma interface amigável para a configuração e ajuste dos parâmetros dos algoritmos. Para garantir a validade das predições, cada algoritmo foi configurado com parâmetros ajustados e submetido a processos rigorosos de validação, assegurando a robustez dos resultados.

Selecionamos os 4 melhores algoritmos para serem aprofundados em sua avaliação, com destaque para o Gradient Boosting, Neural Network, Logistic Regression e Naive Bayes. A seguir, cada um deles será descrito em detalhes, junto com as configurações específicas empregadas neste estudo.

3.2.1 Gradient Boosting

O Gradient Boosting é uma técnica amplamente utilizada em aprendizado de máquina devido à sua capacidade de combinar múltiplos modelos fracos, geralmente árvores de decisão, para formar um modelo robusto e altamente preditivo. Neste estudo, o algoritmo foi implementado utilizando a biblioteca *scikit-learn* com as seguintes configurações específicas:

- **Número de árvores:** Foram utilizadas 100 árvores de decisão, permitindo ao modelo iterar sobre múltiplos estágios para corrigir os erros residuais de predições anteriores.

- **Taxa de aprendizado:** O valor foi definido como 0,1 (ou 10%), garantindo que cada nova árvore contribua gradualmente para o modelo, reduzindo o risco de *overfitting*.
- **Replicabilidade do treinamento:** A opção de treinamento replicável foi ativada, assegurando que os experimentos realizados possam ser reproduzidos com os mesmos parâmetros e dados.
- **Profundidade máxima das árvores:** A profundidade de cada árvore foi limitada a 3 níveis, uma escolha que ajuda a evitar o *overfitting* ao restringir a complexidade de cada estimador individual.
- **Mínimo de amostras por divisão:** Foi estipulado que nenhuma divisão seria realizada em nós contendo menos de 2 amostras, impedindo o modelo de criar árvores extremamente específicas e propensas a *overfitting*.
- **Subamostragem:** Todo o conjunto de dados de treinamento foi utilizado em cada iteração (fração de 1,0), garantindo que cada árvore fosse treinada com base em todas as amostras disponíveis.

Essas configurações foram escolhidas de forma a equilibrar o desempenho e a generalização do modelo, considerando a natureza sensível e complexa dos dados médicos analisados neste estudo. A combinação desses parâmetros permitiu ao Gradient Boosting alcançar resultados consistentes e robustos na predição do risco de mortalidade infantil, destacando-se como um dos métodos mais promissores entre os avaliados.

3.2.2 Neural Network

As redes neurais artificiais são modelos amplamente utilizados em problemas de classificação e predição devido à sua capacidade de aprender padrões complexos a partir dos dados. Neste estudo, foi implementada uma rede neural utilizando as seguintes configurações:

- **Número de neurônios na camada oculta:** A rede foi configurada com 5 neurônios em sua única camada oculta, balanceando a complexidade do modelo com a quantidade de dados disponíveis.
- **Função de ativação:** Foi utilizada a função de ativação ReLU (*Rectified Linear Unit*), amplamente empregada por sua eficiência computacional e por ajudar a mitigar o problema de gradientes vanishing.
- **Otimização:** O otimizador Adam foi escolhido por sua capacidade de adaptação dinâmica das taxas de aprendizado, melhorando a convergência durante o treinamento.

- **Regularização:** Um coeficiente de regularização (α) de 0,0001 foi aplicado para evitar *overfitting*, adicionando uma penalidade baseada na complexidade do modelo.
- **Número máximo de iterações:** O treinamento foi limitado a um máximo de 200 iterações, garantindo um tempo de execução controlado enquanto permitia a convergência do modelo.
- **Treinamento replicável:** A opção de replicabilidade foi ativada para assegurar que os resultados possam ser reproduzidos em execuções futuras com os mesmos parâmetros e dados.

Essas configurações foram definidas considerando a necessidade de um modelo eficiente e generalizável para a predição do risco de mortalidade infantil. A simplicidade da arquitetura foi proposital, visando reduzir o risco de *overfitting* em um conjunto de dados de tamanho limitado, ao mesmo tempo em que preserva o desempenho preditivo.

3.2.3 Regressão Logística

A regressão logística é um modelo amplamente utilizado para tarefas de classificação binária devido à sua simplicidade e interpretabilidade. Neste estudo, a configuração do modelo de regressão logística foi definida da seguinte forma:

- **Tipo de regularização:** Foi empregada a regularização do tipo Ridge (L2), que adiciona uma penalidade proporcional ao quadrado dos coeficientes do modelo. Esse tipo de regularização ajuda a evitar *overfitting* e melhora a generalização do modelo.
- **Força da regularização:** O hiperparâmetro C, que controla a força da regularização, foi configurado com valor igual a 1. Valores menores de C aumentam a regularização, enquanto valores maiores reduzem a penalidade.
- **Distribuição de classes:** Não foi utilizada a opção de balanceamento da distribuição de classes, assumindo que os dados de entrada já estavam adequadamente processados para lidar com possíveis desbalanceamentos.

As configurações adotadas foram escolhidas para garantir um equilíbrio entre simplicidade e desempenho do modelo, respeitando a estrutura dos dados disponíveis. A regularização L2 desempenhou um papel crucial para evitar ajustes excessivos aos dados de treinamento, contribuindo para a robustez do modelo.

3.2.4 Naive Bayes

O modelo Naive Bayes foi utilizado como um dos algoritmos para a classificação no estudo, sendo conhecido por sua simplicidade e eficiência. Este método é baseado no teorema de Bayes, que calcula a probabilidade de uma classe com base nas características dos dados.

Apesar de sua suposição de independência condicional entre as variáveis preditoras, o Naive Bayes apresenta bom desempenho em diversos cenários, especialmente quando aplicado a conjuntos de dados estruturados e problemas de classificação.

No contexto do estudo, o modelo foi configurado diretamente através da interface da ferramenta utilizada, que oferece opções otimizadas de aplicação automática. Essa abordagem permite focar nos resultados do modelo sem a necessidade de ajustes manuais detalhados, garantindo praticidade e eficiência no fluxo de trabalho.

3.2.5 Validação e Avaliação dos Modelos

A avaliação do desempenho dos modelos foi realizada utilizando a funcionalidade de *Test and Score* da ferramenta Orange. Este procedimento permite validar os modelos com base em estratégias de divisão dos dados e cálculo de métricas de desempenho. Para este estudo, as seguintes configurações foram aplicadas:

- **Validação cruzada (*Cross-validation*)**: Foi utilizada a técnica de validação cruzada com 5 *folds*, onde o conjunto de dados é dividido em cinco subconjuntos. Em cada iteração, quatro subconjuntos são utilizados para treinamento e um para teste, garantindo que todas as amostras sejam usadas tanto para treinamento quanto para teste ao longo das iterações. Além disso, foi habilitada a opção de estratificação (*Stratified*), assegurando que a proporção das classes seja preservada em cada divisão.

- **Amostragem aleatória (*Random sampling*)**: Foram realizadas 10 repetições do processo de treinamento e teste, com 80% das amostras sendo utilizadas para treinamento e 20% para teste em cada repetição. A opção de estratificação também foi habilitada para essa configuração, garantindo representatividade das classes em ambas as divisões.

- **Mecanismos alternativos de validação**: Outras estratégias, como validação *leave-one-out* e testes diretos nos conjuntos de treinamento e teste, estavam disponíveis, mas não foram selecionadas para este estudo, pois o foco principal foi na validação cruzada e na amostragem aleatória.

Por meio dessas configurações, garantiu-se que o processo de avaliação dos modelos fosse realizado de forma robusta, minimizando possíveis vieses e assegurando que os resultados refletissem adequadamente a capacidade de generalização dos modelos aos dados desconhecidos. Esse cuidado metodológico é fundamental para validar a aplicabilidade do sistema proposto em cenários reais, além de fornecer métricas confiáveis para a análise comparativa do desempenho dos algoritmos utilizados.

Com a metodologia estabelecida e o processo de avaliação estruturado, os resultados obtidos pelos modelos serão apresentados e discutidos na próxima seção, destacando as principais métricas e comparações realizadas.

4 RESULTADOS E ANÁLISES

4.1 Resultados

Cerca de 64 mil neonatos, cujos dados foram coletados entre 2015 e 2017, foram analisados neste estudo. Para comparar o desempenho de diferentes modelos de aprendizado de máquina, foram empregados sete algoritmos distintos, com o objetivo de identificar os mais eficazes na tarefa de predição. A acurácia e o desempenho de cada modelo foram avaliados utilizando Curvas ROC e suas respectivas Áreas Sob a Curva (AUC), métricas fundamentais para mensurar a capacidade de distinção entre as classes. Além disso, as Matrizes de Confusão foram analisadas para detalhar os falsos positivos, falsos negativos, verdadeiros positivos e verdadeiros negativos.

Sete algoritmos de Machine Learning foram testados: Gradient Boosting, Neural Network, Logistic Regression, Naive Bayes, Random Forest, kNN e Stochastic Gradient Descent. Contudo, foram selecionados os quatro modelos que apresentaram os melhores resultados para uma análise mais aprofundada nas subseções abaixo: Gradient Boosting, Neural Network, Logistic Regression e Naive Bayes. A tabela 2 resume a comparação geral dos resultados obtidos por cada um dos modelos.

Modelo	**AUC**	**Acurácia**
Gradient Boosting	0,917	85,2%
Neural Network	0,916	85,1%
Logistic Regression	0,914	84,8%
Naive Bayes	0,906	84,2%
Random Forest	0,898	83,8%
kNN	0,879	82,7%
Stochastic Grandient Descent	0,830	83,2%

Tabela 2 – Comparação dos resultados de todos os mudelos utilizados

4.1.1 Gradient Boosting

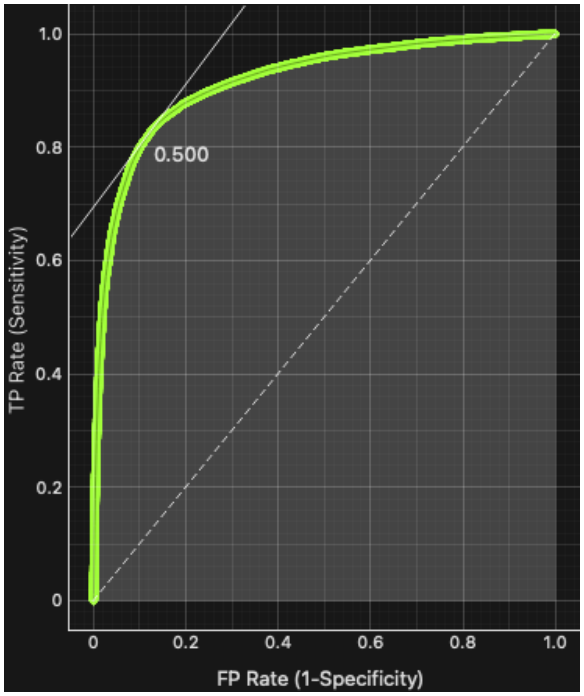

(a) Curva ROC com target em 0

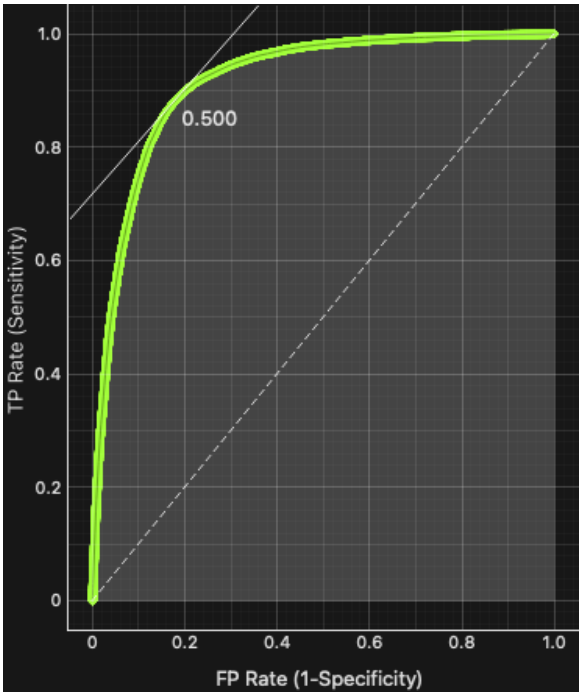

(b) Curva ROC com target em 1

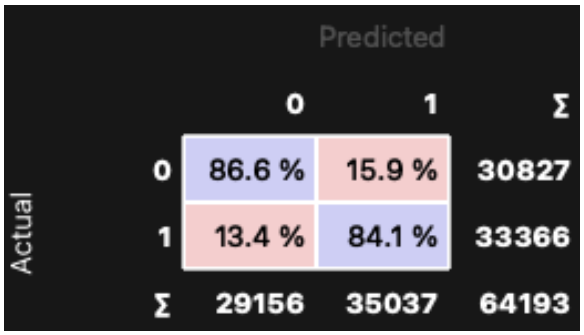

Actual \ Predicted	0	1	Σ
0	86.6 %	15.9 %	30827
1	13.4 %	84.1 %	33366
Σ	29156	35037	64193

(c) Matriz de confusão

Figura 5 – Resultados do modelo Gradient Boosting

O modelo Gradient Boosting foi o que apresentou o melhor desempenho geral neste estudo, alcançando uma Área Sob a Curva (AUC) de 0,917. Esta métrica indica que o modelo possui alta capacidade de distinguir corretamente as classes de risco de mortalidade infantil.

A matriz de confusão do modelo reforça sua robustez no estudo. Observa-se que a taxa de acertos para a classe negativa (0) foi de 86,6%, enquanto para a classe positiva (1) foi de 84,1%, evidenciando uma boa capacidade de predição para ambas as classes. No entanto, há uma taxa de falsos positivos (15,9%) e falsos negativos (13,4%) que, embora relativamente baixa, ainda podem impactar decisões sensíveis no contexto de saúde neonatal. Esses resultados demonstram que o modelo possui um desempenho balanceado, mas que há espaço para ajustes dependendo das prioridades do problema, como reduzir os falsos negativos em cenários críticos.

Além disso, o modelo atingiu uma acurácia (CA) de 85,2%, um F1-score de 0,852 e

uma precisão (Prec) de 0,853, valores que destacam sua eficiência tanto na predição quanto no balanceamento entre os falsos positivos e falsos negativos. O recall (0,852) reforça a habilidade do modelo em identificar corretamente os casos positivos. O coeficiente de Matthews (MCC), que mede a qualidade da classificação em cenários desbalanceados, foi de 0,704, consolidando o Gradient Boosting como o mais robusto entre os algoritmos testados.

4.1.2 Neural Network

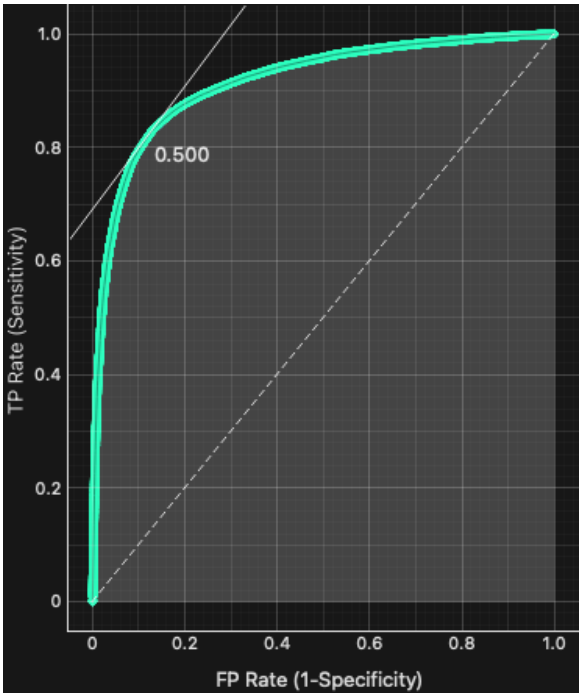

(a) Curva ROC com target em 0

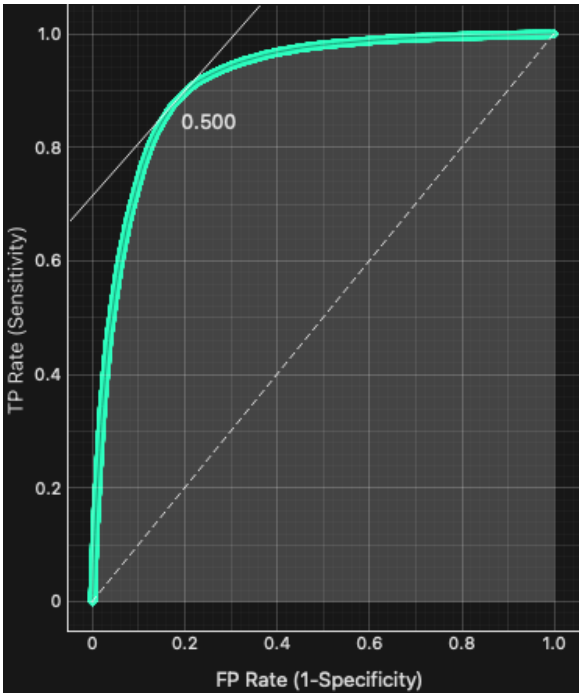

(b) Curva ROC com target em 1

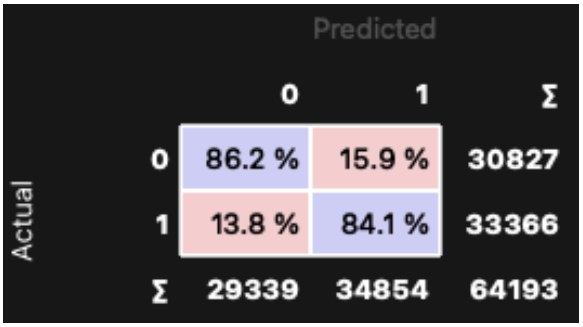

Actual \ Predicted	0	1	Σ
0	86.2 %	15.9 %	30827
1	13.8 %	84.1 %	33366
Σ	29339	34854	64193

(c) Matriz de confusão

Figura 6 – Resultados do modelo Neural Network

As Redes Neurais alcançaram resultados comparáveis ao Gradient Boosting, com uma AUC de 0,916, ligeiramente inferior ao modelo anterior. A acurácia (CA) ficou em 85,1%, acompanhada de um F1-score de 0,851. Esses valores demonstram um desempenho consistente em prever as classes de risco.

A matriz de confusão do modelo reforça os resultados apresentados. O modelo apresentou uma taxa de acertos de 86,2% para a classe negativa (0) e 84,1% para a classe positiva (1), com taxas de falsos positivos e falsos negativos de 15,9% e 13,8%, respectivamente. Esses números indicam que o modelo possui um desempenho balanceado entre as classes, sendo ligeiramente mais inclinado a classificar corretamente os casos negativos. Contudo, a presença de falsos negativos (13,8%) ainda pode ser um ponto de atenção, dependendo das implicações práticas do uso do modelo no contexto de saúde neonatal. A matriz confirma que o modelo é confiável e competitivo em relação ao Gradient Boosting, apresentando um desempenho robusto em ambos os casos.

A precisão (0,851) e o recall (0,851) indicam que o modelo possui um equilíbrio adequado entre os casos identificados como positivos e a cobertura total dos casos positivos reais. O MCC foi calculado em 0,702, destacando a eficácia do modelo em cenários com possíveis desbalanceamentos nas classes.

4.1.3 Logistic Regression

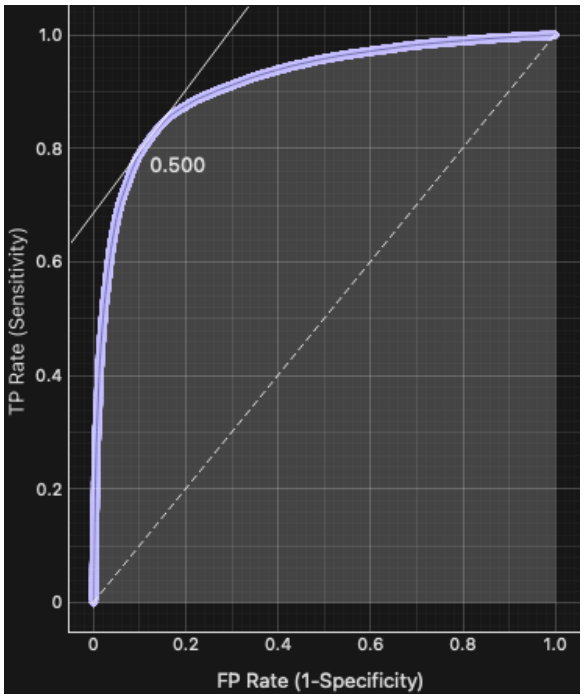

(a) Curva ROC com target em 0

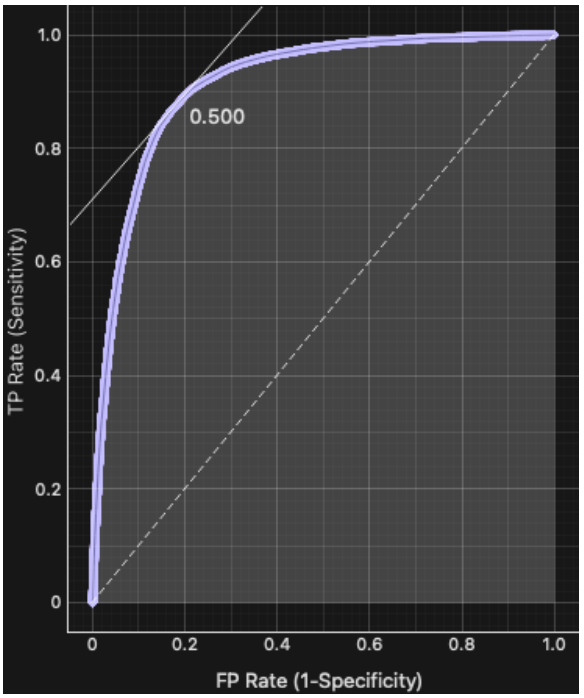

(b) Curva ROC com target em 1

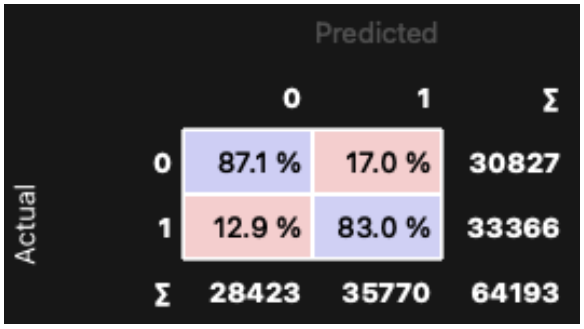

Actual \ Predicted	0	1	Σ
0	87.1 %	17.0 %	30827
1	12.9 %	83.0 %	33366
Σ	28423	35770	64193

(c) Matriz de confusão

Figura 7 – Resultados do modelo Logistic Regression

O modelo de Regressão Logística obteve um desempenho notável, com uma AUC de 0,914, refletindo sua capacidade de discriminar entre as classes de risco de maneira confiável. A acurácia (CA) foi de 84,8%, enquanto o F1-score ficou em 0,848, indicando um desempenho ligeiramente inferior em relação aos dois primeiros modelos.

A matriz de confusão do modelo reforça seus resultados gerais. A taxa de acertos para a classe negativa (0) foi de 87,1%, enquanto para a classe positiva (1) foi de 83,0%, mostrando uma leve predominância na identificação correta dos casos negativos. No entanto, as taxas de falsos positivos (17,0%) e falsos negativos (12,9%) revelam uma margem de erro que pode ser significativa dependendo do contexto de aplicação. Esses resultados mostram que, embora o modelo tenha desempenho ligeiramente inferior ao Gradient Boosting e às Redes Neurais, ele ainda apresenta boa consistência e pode ser utilizado de maneira confiável no cenário de saúde

neonatal, especialmente em situações onde o equilíbrio entre classes seja um fator importante.

A precisão (0,850) e o recall (0,848) mostram que o modelo manteve um bom equilíbrio entre os falsos positivos e os falsos negativos. O MCC foi calculado como 0,698, reforçando sua eficácia em cenários de dados desbalanceados.

4.1.4 Naive Bayes

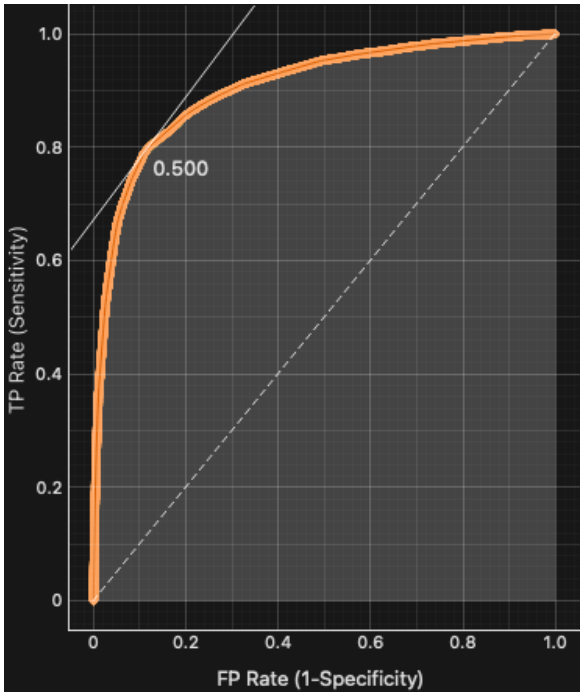

(a) Curva ROC com target em 0

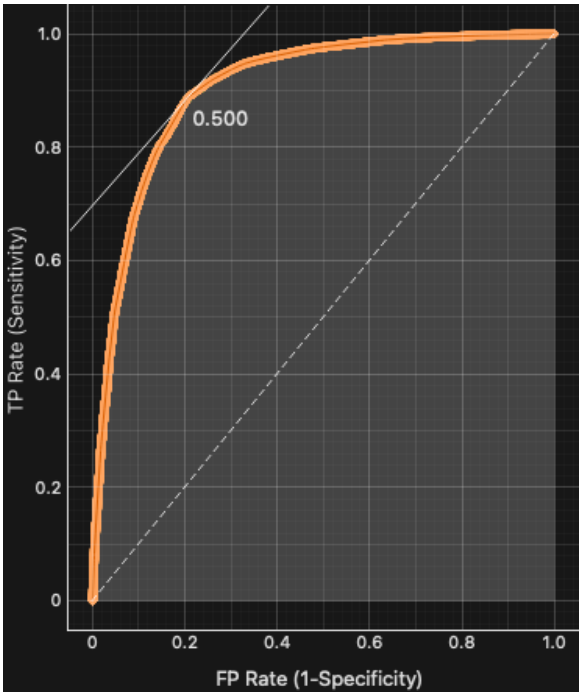

(b) Curva ROC com target em 1

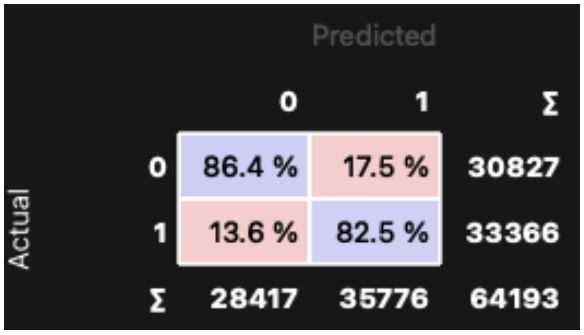

Actual \ Predicted	0	1	Σ
0	86.4 %	17.5 %	30827
1	13.6 %	82.5 %	33366
Σ	28417	35776	64193

(c) Matriz de confusão

Figura 8 – Resultados do modelo Naive Bayes

O Naive Bayes apresentou a menor AUC (0,906) entre os modelos destacados, embora ainda seja considerado bom para o contexto do estudo. A acurácia (CA) foi de 84,2%, e o F1-score alcançou 0,841, demonstrando um desempenho sólido, mas inferior aos modelos de Gradient Boosting e Redes Neurais.

O modelo obteve uma precisão de 0,843 e um recall de 0,842, indicando sua habilidade consistente em prever os casos positivos. No entanto, a análise da matriz de confusão revela uma

distribuição das previsões que reflete a natureza dos erros cometidos. O Naive Bayes apresentou um valor de 17,5% para falsos positivos e 13,6% para falsos negativos. Esses números sugerem que, apesar de ser eficaz em identificar os casos positivos (com um recall de 84,2%), o modelo tende a cometer mais erros de falso positivo do que de falso negativo. Ou seja, ele pode classificar incorretamente alguns casos negativos como positivos, o que pode ser um fator a ser considerado dependendo do custo associado a cada tipo de erro.

Além disso, o modelo obteve 86,4% de verdadeiros negativos e 82,5% de verdadeiros positivos, evidenciando que ele ainda é eficiente em identificar corretamente tanto os casos negativos quanto os positivos, embora, como mencionado, com uma ligeira tendência a ter mais falsos positivos. O MCC foi de 0,684, consolidando o Naive Bayes como um modelo com desempenho adequado, mas com uma margem de melhoria quando comparado a modelos mais robustos, especialmente em cenários que exigem uma menor incidência de erros em qualquer uma das classes.

4.2 Análises

O estudo teve como foco principal a utilização de técnicas avançadas de machine learning para a predição de riscos de mortalidade em neonatos prematuros. A relevância desse objetivo reside na alta taxa de mortalidade neonatal associada à prematuridade, que é uma preocupação global em saúde pública. Os modelos de machine learning têm o potencial de oferecer insights valiosos por meio da análise de grandes volumes de dados clínicos e demográficos, que podem ajudar na identificação precoce de riscos, permitindo intervenções mais eficazes e potencialmente salvadoras de vidas.

Neste estudo, foram analisados sete algoritmos de aprendizado de máquina, dos quais Gradient Boosting, Neural Network, Logistic Regression e Naive Bayes apresentaram os melhores resultados, com base em métricas como AUC, acurácia, F1-score, precisão, recall e MCC. Essas métricas fornecem uma visão abrangente do desempenho dos modelos, permitindo avaliar não apenas a capacidade de discriminação, mas também o equilíbrio entre erros e acertos na predição.

O Gradient Boosting destacou-se como o modelo de melhor desempenho, alcançando uma AUC de 0,917 e acurácia de 85,2%. Além disso, seu F1-score de 0,852 e valores de precisão (0,853) e recall (0,852) demonstram um excelente equilíbrio entre os falsos positivos e falsos negativos. O coeficiente de Matthews (MCC), que é particularmente útil em cenários de classes desbalanceadas, foi de 0,704, reforçando a robustez do modelo. Esses resultados podem ser atribuídos à capacidade do Gradient Boosting de construir árvores de decisão sequenciais, ajustando-se iterativamente aos erros dos modelos anteriores.

Comparando esses resultados com os de estudos da literatura, como o trabalho de

(ALVES et al., 2020), que também usou o XGBoost para classificação de dados de saúde, podemos observar uma boa proximidade no desempenho geral. No estudo mencionado, o modelo XGBoost obteve uma AUC de 93,93%, enquanto os valores de acurácia foram de 89% para o XGBoost, que, embora ligeiramente superior ao nosso modelo (85,2%), ainda indicam uma performance geral muito similar. A diferença na AUC pode ser atribuída a diferenças no conjunto de dados e nas características específicas de cada problema, como a complexidade do contexto e os dados de entrada.

As Redes Neurais também apresentaram resultados expressivos, com AUC de 0,916 e acurácia de 85,1%. O F1-score de 0,851, junto com a precisão (0,851) e o recall (0,851), reflete um desempenho altamente consistente. O MCC de 0,702 confirma a qualidade do modelo em contextos de dados desbalanceados. A força das redes neurais reside na sua habilidade de modelar relações complexas e não lineares entre variáveis, embora sua interpretabilidade seja um desafio. Em contextos clínicos, essa limitação pode impactar sua adoção, pois compreender as razões por trás de uma predição é tão importante quanto a precisão da predição em si.

Comparando os resultados das Redes Neurais neste estudo com os encontrados no estudo de (BATISTA et al., 2021), que obteve uma AUC de 0,9700, podemos observar que, embora o desempenho geral seja semelhante, a AUC no presente estudo foi ligeiramente inferior. A diferença na AUC pode ser atribuída às características dos dados utilizados, que podem influenciar a capacidade de discriminação do modelo. Outro ponto a destacar é que, enquanto o estudo da literatura obteve uma sensibilidade de 0,426, este estudo demonstrou um recall de 0,851, indicando que o modelo utilizado aqui foi significativamente mais eficaz na identificação dos casos positivos, um aspecto crucial em contextos de saúde neonatal. Em termos de F1-score, o modelo deste estudo obteve um desempenho muito superior (0,851) em relação ao 0,530 reportado no estudo da literatura, o que reflete um equilíbrio muito melhor entre a precisão e o recall. A discrepância nos resultados de sensibilidade e F1-score sugere que, embora ambos os modelos apresentem boas capacidades de classificação, o modelo utilizado neste estudo possui uma maior robustez na predição de casos positivos, o que é fundamental em contextos onde a detecção precoce de risco é essencial.

A Regressão Logística, apesar de ser um modelo mais simples, alcançou uma AUC de 0,914 e uma acurácia de 84,8%, com F1-score de 0,848. Esses valores, combinados com uma precisão de 0,850 e recall de 0,848, demonstram que, mesmo sendo menos complexo, o modelo é confiável e eficiente. O MCC de 0,698 reflete um bom desempenho geral, especialmente considerando a simplicidade do modelo. Sua interpretabilidade é um ponto forte, permitindo que os coeficientes sejam traduzidos em odds ratio, oferecendo insights diretos sobre os fatores de risco associados à mortalidade neonatal.

Ao comparar os resultados deste estudo com o trabalho de (LEE et al., 2021), que também utilizou Regressão Logística para predição de mortalidade utilizando apenas variáveis clínicas e demográficas estáticas, como idade gestacional, sexo, raça e peso ao nascer, observa-se que os

valores de AUC e acurácia são superiores no presente estudo. O estudo de (LEE et al., 2021) reportou uma AUC de 0,84 e acurácia de 80%, ambos valores abaixo dos obtidos aqui. A diferença na AUC pode ser atribuída às variáveis utilizadas e à complexidade do modelo, já que no presente estudo, o modelo pode ter se beneficiado de uma combinação mais abrangente de características, o que melhora a discriminação entre as classes de risco. Além disso, o estudo comparativo mencionou uma excelente especificidade com sensibilidade comprometida, enquanto o modelo de Regressão Logística deste estudo mostrou um bom equilíbrio entre precisão e recall, o que pode ser mais vantajoso em cenários como a mortalidade neonatal, onde é fundamental tanto identificar corretamente os casos positivos quanto minimizar os falsos negativos.

O Naive Bayes, com AUC de 0,906 e acurácia de 84,2%, foi o modelo com desempenho mais modesto entre os quatro melhores. Seu F1-score de 0,841, juntamente com a precisão (0,843) e o recall (0,842), indica que ele é eficaz em identificar corretamente os casos positivos, embora apresente maior suscetibilidade a erros comparado aos demais modelos. O MCC de 0,684 reforça que, apesar de suas limitações, o modelo é funcional em contextos de alta dimensionalidade. Suas suposições de independência entre as variáveis podem limitar sua aplicabilidade em cenários mais complexos, mas sua simplicidade computacional é uma vantagem significativa.

Ao comparar os resultados do Naive Bayes deste estudo com os encontrados no trabalho de (RAMOS et al., 2017), que obteve uma AUC de 0,921 e destacou o modelo como eficiente devido à sua capacidade de lidar com informações imprecisas e incompletas, observamos que, embora a AUC do presente estudo seja ligeiramente inferior (0,906), ela ainda está dentro de uma faixa aceitável para tarefas de predição de mortalidade. O estudo citado também reportou uma excelente taxa de acertos (98,25%), com uma distribuição de 1,75% de erros entre falsos positivos e falsos negativos, enquanto o modelo deste estudo apresentou uma taxa de falsos positivos de 17,5% e falsos negativos de 13,6%. Esses valores indicam que, embora o desempenho geral seja bom, o modelo utilizado neste estudo tem uma maior propensão a cometer falsos positivos, o que pode ser um ponto crítico em contextos de saúde, onde a sensibilidade é essencial. Contudo, a escolha do Naive Bayes neste estudo da literatura foi em grande parte devido à sua simplicidade e capacidade de trabalhar bem com dados imprecisos, aspectos que também são vantajosos no contexto deste estudo, apesar das limitações observadas nas taxas de erro.

Esses resultados são consistentes com a literatura existente, que destaca a eficácia de modelos avançados, como Gradient Boosting e Redes Neurais, em tarefas de classificação biomédica. No entanto, os desafios relacionados à interpretabilidade de modelos mais complexos, como Gradient Boosting, continuam a ser uma barreira para sua integração prática em ambientes clínicos. Modelos como a Regressão Logística, embora menos precisos, oferecem maior transparência, tornando-os uma alternativa viável em cenários onde a interpretabilidade é essencial.

As implicações práticas dos resultados são vastas. Modelos de alto desempenho, como Gradient Boosting e Redes Neurais, podem ser integrados em sistemas de alerta precoce para

identificar neonatos prematuros em risco, permitindo intervenções rápidas e eficazes. No entanto, para maximizar seu impacto, é necessário continuar investindo em pesquisas que melhorem a interpretabilidade dos modelos, garantindo sua aceitação por parte de profissionais de saúde e sua adoção em larga escala. A colaboração entre engenheiros, clínicos e pesquisadores será essencial para traduzir o potencial das técnicas de machine learning em melhorias concretas nos cuidados neonatais.

5 CONCLUSÕES

O estudo teve como objetivo desenvolver e validar modelos de machine learning para prever a mortalidade em neonatos prematuros, enfrentando um problema crítico de saúde pública. Por meio da aplicação de técnicas avançadas de aprendizado de máquina, foram analisados e comparados diferentes algoritmos para identificar aqueles com maior eficácia preditiva, utilizando dados clínicos e demográficos. Os modelos avaliados incluíram Gradient Boosting, Neural Network, Logistic Regression e Naive Bayes, selecionados por sua relevância no campo da predição médica.

Os resultados demonstraram que o Gradient Boosting apresentou o melhor desempenho geral, com uma AUC de 0,917, seguido de perto pela Neural Network, com AUC de 0,916. Além das altas AUCs, esses modelos também se destacaram em outras métricas como F1-score (0,852 e 0,851, respectivamente), precisão e recall (ambos em torno de 0,85 para ambos os modelos) e MCC (0,704 e 0,702, respectivamente), evidenciando sua robustez na discriminação entre neonatos em risco e não risco. A Logistic Regression, com AUC de 0,914, e o Naive Bayes, com AUC de 0,906, também demonstraram desempenhos promissores, com métricas consistentes que destacam sua utilidade em cenários clínicos, mesmo sendo metodologias menos complexas.

A análise rigorosa dos modelos incluiu o uso de curvas ROC, Matrizes de Confusão e outras métricas estatísticas, garantindo uma avaliação abrangente e precisa de sua performance. Essa abordagem permitiu identificar tanto os pontos fortes quanto as limitações de cada modelo, contribuindo para uma compreensão mais profunda de sua aplicabilidade prática.

Na prática, os modelos mais eficazes têm o potencial de serem integrados em sistemas clínicos como ferramentas de suporte à decisão, ajudando a monitorar e alertar profissionais de saúde sobre neonatos prematuros em risco. Sistemas desse tipo poderiam ser utilizados para priorizar intervenções precoces e direcionadas, reduzindo significativamente as taxas de mortalidade neonatal, especialmente em unidades de terapia intensiva neonatal (UTINs). A capacidade de identificar de forma confiável os neonatos em risco pode não apenas salvar vidas, mas também otimizar o uso de recursos hospitalares.

Do ponto de vista acadêmico e técnico, o estudo oferece contribuições significativas ao campo da saúde neonatal e da ciência de dados aplicada à saúde. Ao demonstrar o uso eficaz de técnicas de machine learning em dados clínicos, a pesquisa reforça o valor da interdisciplinaridade, combinando conhecimentos de engenharia de dados, estatística e cuidado médico para solucionar problemas reais.

No entanto, algumas limitações foram identificadas. A dependência de bases de dados clínicas, que podem conter viés de coleta ou representatividade limitada, é um ponto crítico

que pode impactar a generalização dos modelos. Além disso, a interpretabilidade de modelos complexos, como o Gradient Boosting e as Redes Neurais, ainda representa um desafio. Em contextos clínicos, é crucial entender os fatores que levam a uma predição para garantir a confiança e a aceitação dos profissionais de saúde. Futuros esforços devem se concentrar em melhorar a transparência dos modelos preditivos, explorando técnicas explicáveis de machine learning (XAI, eXplainable AI).

Futuras pesquisas poderiam incluir a integração de dados adicionais, como biomarcadores ou dados genéticos, que têm o potencial de enriquecer significativamente as predições. Além disso, seria relevante investigar formas de adaptar os modelos a diferentes populações ou cenários clínicos, garantindo maior abrangência de aplicação. A análise longitudinal, com o uso de dados ao longo do tempo, também poderia ser explorada para prever desfechos em longo prazo.

Este estudo reafirma o potencial transformador do machine learning na medicina neonatal. Os modelos desenvolvidos demonstraram alta precisão preditiva e oferecem uma oportunidade real de impactar positivamente os cuidados clínicos. No longo prazo, a integração dessas ferramentas em ambientes clínicos, combinada com a colaboração contínua entre engenheiros, cientistas de dados e profissionais de saúde, pode revolucionar a forma como os riscos em neonatos prematuros são avaliados e tratados.

Por fim, espera-se que as contribuições deste estudo inspirem avanços contínuos, não apenas na área de saúde neonatal, mas também na adoção mais ampla de práticas baseadas em dados para a tomada de decisão clínica. A busca por modelos preditivos que combinem precisão, interpretabilidade e aplicabilidade prática será essencial para garantir que os benefícios dessas tecnologias sejam plenamente realizados na melhoria dos cuidados ao neonato prematuro.

REFERÊNCIAS

AKAZAWA, M.; HASHIMOTO, K. Prediction of preterm birth using artificial intelligence: a systematic review. *Journal of Obstetrics and Gynaecology*, v. 42, p. 1662–1668, 2022.

ALVES, L. C. et al. Assessing the performance of machine learning models to predict neonatal mortality risk in brazil, 2000-2016. *medRxiv*, 2020.

BATISTA, A. et al. Neonatal mortality prediction with routinely collected data: a machine learning approach. *BMC Pediatr*, v. 21, n. 322, 2021.

BEEK, P. E. V. et al. Prognostic models predicting mortality in preterm infants: Systematic review and meta-analysis. *Pediatrics*, v. 147, 2021.

CHANDRIKA, V.; SURENDRAN, S. Incremental machine learning model for fetal health risk prediction. In: *2022 International Conference on Smart Generation Computing, Communication and Networking (SMART GENCON)*. [S.l.: s.n.], 2022. p. 1–6.

CIDACS. *Coorte de 100 Milhões de Brasileiros*. https://cidacs.bahia.fiocruz.br/plataforma/coorte-de-100-milhoes-de-brasileiros/.

FENG, J. et al. Predicting mortality risk for preterm infants using deep learning models with time-series vital sign data. *NPJ Digital Medicine*, v. 4, 2021.

GAO, C. et al. Deep learning predicts extreme preterm birth from electronic health records. *Journal of Biomedical Informatics*, 2019.

GIL, A. C. *Como elaborar projetos de pesquisa*. São Paulo: Atlas, 2017.

HE, L. et al. A multi-task, multi-stage deep transfer learning model for early prediction of neurodevelopment in very preterm infants. *Scientific Reports*, v. 10, 2020.

JASKARI, J. et al. Machine learning methods for neonatal mortality and morbidity classification. *IEEE Access*, v. 8, p. 123347–123358, 2020.

KUHN, M.; JOHNSON, K. *Applied Predictive Modeling*. New York, NY: Springer, 2013.

LEE, J. et al. Predicting mortality risk for preterm infants using random forest. *Scientific Reports*, v. 11, n. 1, p. 7308, 2021.

MATSUSHITA, F. Y.; KREBS, V.; CARVALHO, W. B. Risk prediction model for 24-hour mortality in preterm infants using lactate and blood gas analysis: A machine learning approach and retrospective cohort study. *F1000Research*, v. 11, p. 444, 2022.

Ministério da Educação. *Sistema de Informação de Agravos de Notificação - Dicionário de Dados - SINAN NET - Versão 5.0*. http://portalsinan.saude.gov.br/images/documentos/Agravos/Notificacao_Individual/DIC_DADOS_NET---Notificacao-Individual_rev.pdf.

MONFARED, V.; HASHEMI, A. Prediction analysis of preterm neonates mortality using machine learning algorithms via python programming. *bioRxiv*, 2023.

OLIVEIRA, Y. S. de P. et al. Aprendizagem de máquina aplicada à estratificação de risco de mortalidade de recém-nascidos associados a partos prematuros. In: SIMAS, E.; FERREIRA, D. D.; OLIVEIRA, L. R. (Ed.). *Anais do XVI Congresso Brasileiro de Inteligência Computacional (CBIC'2023)*. Salvador, BA: SBIC, 2023. p. 1–8.

OMS. *OMS: cerca de 30 milhões de bebês nascem prematuros por ano no mundo*. 2018. https://brasil.un.org/pt-br/81878-oms-cerca-de-30-milhoes-de-bebes-nascem-prematuros-por-ano-no-mundo.

PCDaS. *Plataforma de Ciência de Dados aplicada à Saúde*. https://pcdas.icict.fiocruz.br/.

RAIHAN, M. et al. A deep learning and machine learning approach to predict neonatal death in the context of são paulo. *International Journal of Public Health Science (IJPHS)*, 2024.

RAMOS, R. et al. Using predictive classifiers to prevent infant mortality in the brazilian northeast. In: *2017 IEEE 19th International Conference on e-Health Networking, Applications and Services (Healthcom)*. [S.l.: s.n.], 2017. p. 1–6.

UNICEF. *Monitoring the Situation of Children and Women*. [S.l.], 2018.